



6 星学长的学习宝库

统计计算与模拟资料

作者：6 星学长

组织：对外经济贸易大学-统计学院

时间：2026/1/7



注意：本资料当然是为我们统院人而制啦！（doge）爱统计！！爱统院！！

目录

第一章 一维非均匀随机数的产生	2
1.1 常用连续非均匀随机数的产生	2
1.1.1 随机数的定义	2
1.1.2 逆变换抽样法	2
1.1.3 舍选抽样法	5
1.1.4 变换抽样法	14
1.1.5 复合抽样法	19
1.1.6 近似抽样法（中心极限定理）	20
1.1.7 近似抽样法（其他方法，非课程内容）	21
1.2 离散分布随机数的抽样法	23
1.2.1 逆变换法	23
第一章 练习	24
第二章 随机向量随机数的抽样法	30
2.1 连续随机向量随机数的抽样法	30
2.1.1 变换抽样法（非课程内容）	30
2.1.2 条件分布法	31
2.1.3 舍选抽样法（非课程内容）	37
2.2 离散随机向量随机数的抽样法（非课程内容）	38
2.2.1 条件分布法	38
第二章 练习	41
第三章 运用模拟的手段评估参数估计的估计量优劣	43
3.1 点估计数值计算	43
3.1.1 点估计的数值模拟方法	43
3.2 置信区间估计数值计算	47
3.2.1 单总体置信区间估计	48
3.2.2 两总体置信区间估计	52
3.3 拓展阅读：the James-Stein 估计量（书上无）	55
第三章 练习	56
第四章 使用数值计算与模拟评估假设检验方法	57
4.1 参数检验数值计算	57
4.2 单样本的拟合优度检验	60
4.2.1 总体分布的卡方检验	60
4.2.2 单样本 K-S 检验	61
4.2.3 变量值随机性检验	63
4.3 两样本的非参数检验	65
4.3.1 两样本的曼-惠特尼 U 检验	65
4.3.2 两样本的 K-S 检验（非课程内容）	66
4.3.3 两样本的游程检验（非课程内容）	67
4.4 独立性检验（非课程内容）	68

4.4.1 列联分析检验	68
4.4.2 相关系数检验	70
4.5 传统假设检验中可能的问题	71
4.5.1 扩展内容与阅读：多重假设检验问题 (Multiplicity Issue; Multiple Comparison Problem)	73
4.5.2 Bonferroni 校正法	73
4.5.3 Holm-Bonferroni 方法	73
4.6 归总：思维模式/思考步骤 (老师认为的)	74
第四章 练习	74
第五章 简单的数值求根与极值问题	75
5.1 数值求解问题：单根	75
5.1.1 简单示例	75
5.1.2 多根情况示例	75
5.2 通用 (且简单) 的优化方法：梯度下降	75
5.3 步长 (学习率) 以及最优化实现	75
5.3.1 案例：以下代码为部分简单的求根或优化问题，以及一个最优化问题中数值估计的实例，即最小“一乘”估计	77
第六章 降低方差的统计方法	79
6.1 估计定积分的例子	79
6.1.1 随机投点法	79
6.1.2 平均值估计法	81
6.2 对偶变量的应用 (非课程内容)	81
6.3 控制变量法的应用 (非课程内容)	82
6.4 条件期望法 (非课程内容)	83
6.5 重要抽样法	83
6.6 分层抽样法 (非课程内容)	86
6.7 随机数重复使用法	87
第六章 练习	87
第七章 重抽样方法	93
7.1 Bootstrap 方法	93
7.1.1 偏差的自助估计	94
7.1.2 估计量标准差的 Bootstrap 估计	96
7.1.3 基于 Bootstrap 法的置信区间估计	97
7.2 Jackknife 法的估计	98
第七章 练习	100
第八章 多元分布抽样问题以及 MCMC 方法	101
8.1 Gibbs 抽样与贝叶斯层次模型：激励示例	101
8.1.1 贝叶斯层次模型应用背景	101
8.1.2 数据来源与问题定义	101
8.1.3 贝叶斯层次模型构建	101
8.1.4 后验分布与满条件分布	101
8.1.5 MCMC 结果与变点解释	102
8.2 满条件分布	102

8.2.1 满条件分布计算示例	103
8.2.2 Gibbs 抽样的直觉解释	104
8.2.3 Gibbs 抽样的详细解释	106
8.3 扩展：数据增强的 Gibbs 抽样	109
8.4 Metropolis 算法与 Metropolis-Hastings 算法	111
8.4.1 Metropolis 算法	111
8.4.2 课堂练习与思考	114
8.5 结论	114
第八章 练习	114

序言

本书是专门为统计学《统计计算与模拟》这门课程所写，旨在助力各位学弟学妹的理解这门课，希望能帮到你们，嘻嘻！

本书相对于老师的讲义的优势在于：

- √ 对讲义内容进行重新排版，整体更美观、重点更突出；
- √ 补充了大量习题，避免了大家缺少习题训练，有利于提升熟练度；
- √ 将中英文混杂的讲义全部翻译成中文，便于理解课程内容
- √ 将教材中的一些非课程内容补充其中，有利于拓展大家的见识（当然你们大概率不会看，我已经标注“非课程内容”，略过就行！）；
- √ 增加了一些学习心得和期末重点，可以多多注重复习；
- √ 在本书最后，6星学长补充了一些期末考试回忆题/相似题（这是你们最喜欢的吧 o(*￣￣*)ブ），方便大家期末突击。
- √ 总之，该书有利于大家日常学习和练习、拓展见识、重点复习和期末突击！

有优势，定然有缺点，目前本人在编制该书过程中的认为有以下缺点：

- 本书内容的顺序与课程顺序略有不同，例如，老师的讲义“第三章”在本书中为“第六章”
- 老师讲义中部分图片暂未补充到本书内容中，主要集中在第八章
- 补充了大量数学证明（非课程重点），主要集中在前四章

当然，作为一个初入门的统计学人，本人难免出错，若读者发现有误或者想与6星学长交流，欢迎大家联系：

1. VX: wxid_sb2obaa6m4622;
2. QQ: 1550138429;
3. xhs: 5669549260.

祝大家该课程取得好成绩！

第一章 一维非均匀随机数的产生

内容提要

- 随机数定义 1.1
- 逆变换抽样法定理 1.1
- 舍选抽样法定理 1.2
- 变换抽样法定理 1.3
- 复合抽样法定理 1.6
- 中心极限定理（近似抽样） 1.7
- 离散逆变换抽样法定理 1.8

1.1 常用连续非均匀随机数的产生

本章主要介绍一维情况下非均匀随机数的产生方法。首先给出随机数的定义，随后详细阐述连续非均匀随机数的各类产生方法，包括逆变换抽样法、舍选抽样法、变换抽样法、复合抽样法和近似抽样法。

1.1.1 随机数的定义

定义 1.1 (随机数)

设随机变量 X 的分布函数为 $F(x)$ ，从分布函数 $F(x)$ 中随机抽样得到的序列 $\{x_i, i = 1, 2, \dots\}$ 称为该分布的随机数序列， x_i 称为该分布的随机数。

我们目前所讲的随机数，都是假设服从一个参数分布的（狭义下）的随机数。例如，投掷一个硬币投掷到正面记为 1 是一个随机数；投掷一枚筛子投掷到 5，那么 5 也是一个随机数。如果我们连续不断的投掷，会得到一系列的随机数；这些随机数假设服从某一个分布，分布函数为 $F(x)$ 。随机数可以分为连续与离散型。

1.1.2 逆变换抽样法

定理 1.1 (逆变换抽样法)

设连续型随机变量 η 的分布函数 $F(x)$ 是连续且严格单调上升的分布函数，其反函数存在且记为 $F^{-1}(x)$ ，则有：

1. 随机变量 $F(\eta)$ 服从 $(0, 1)$ 上的均匀分布，即 $F(\eta) \sim U(0, 1)$ ；
2. 对于随机变量 $U \sim U(0, 1)$ ， $F^{-1}(U)$ 的分布函数为 $F(x)$ 。

证明 设随机变量 $F(\eta)$ 的分布函数为 $G(u) = P(F(\eta) \leq u)$ 。

根据分布函数的性质 $F(x) \in [0, 1]$ ，可得：

1. 当 $u \in [0, 1]$ 时， $G(u) = P(\eta \leq F^{-1}(u)) = F(F^{-1}(u)) = u$ ；
2. 当 $u \in (-\infty, 0)$ 时， $G(u) = P(F(\eta) \leq u) = 0$ ；
3. 当 $u \in (1, \infty)$ 时， $G(u) = P(F(\eta) \leq u) = 1$ 。

因此，随机变量 $F(\eta)$ 服从 $U(0, 1)$ 。

设随机变量 $F^{-1}(U)$ 的分布函数为 $H(x)$ ，则：

$$H(x) = P(F^{-1}(U) \leq x) = P(U \leq F(x))$$

因为 $U \sim U(0, 1)$ ，对任意 $F(x) \in [0, 1]$ ，有 $P(U \leq F(x)) = F(x)$ ，因此 $F^{-1}(U)$ 的分布函数为 $F(x)$ ，定理得证。

推论 1.1

已知连续型随机变量 $\xi \sim G(x)$, 如果 η 的分布函数 $F(x)$ 的反函数存在, 则随机变量 $F^{-1}(G(\xi)) \sim F(x)$ 。

证明 根据定理 1.1 结论 1, 若 $\xi \sim G(x)$, 则 $G(\xi) \sim U(0, 1)$ 。再根据定理 1.1 结论 2, 可得 $F^{-1}(G(\xi)) \sim F(x)$ 。

由 1.1 可知, 当随机变量 X 的分布函数 $F(x)$ 的反函数存在, 且容易计算时, 可通过产生均匀分布的随机数来产生 X 的随机数序列 $\{x_i, i = 1, 2, \dots\}$ 。这种产生非均匀分布随机数的方法称为逆变换法或反函数法。

命题 1.1 (PIT 的具体步骤)

逆变换法产生随机数 η 的步骤如下:

1. 产生 $U(0, 1)$ 的随机数序列 $\{u_i, i = 1, 2, \dots\}$;
2. η 的随机数序列为:

$$\eta_i = F^{-1}(u_i), \quad i = 1, 2, \dots$$

式中, $\eta_i = F^{-1}(u_i)$ 称为逆变换法的抽样公式。

逆变换抽样法, 英文为 probability inverse transform, 简称为 PIT, or Inverse transform sampling, 是运用最广, 也是最基础的单一变量抽样方法。

练习 1.1 产生概率密度函数为 $f(x)$ 的随机数, 其中:

$$f(x) = \begin{cases} \frac{x}{\sigma^2} e^{-\frac{x^2}{2\sigma^2}}, & x > 0 \\ 0, & x \leq 0 \end{cases} \quad (1.1)$$

要求通过逆变换法推导抽样公式, 并编写 R 代码实现。

解 设随机变量 η 具有概率密度函数 $f(x)$, 其概率分布函数为:

$$F(x) = \begin{cases} 1 - e^{-\frac{x^2}{2\sigma^2}}, & x > 0 \\ 0, & x \leq 0 \end{cases}$$

令 $U = F(x)$, 解得反函数为:

$$F^{-1}(u) = \sqrt{-2\sigma^2 \log(1-u)}, \quad 0 < u < 1$$

根据定理 1.1, 随机变量 η 的随机数产生公式为:

$$\eta_i = \sqrt{-2\sigma^2 \log(1-u_i)}, \quad i = 1, 2, \dots$$

设置 $\sigma = 1$, R 代码实现如下:

```
1 set.seed(1)
2 n <- 10000 # 确定产生随机数的个数
3 sigma <- 1 # 确定sigma
4 r <- matrix(runif(n), n, 1) # 产生[0,1]上的均匀分布随机数
5 x <- sqrt(-2 * sigma^2 * log(1 - r)) # 代入抽样公式
6 x0 <- seq(0, 4, 0.01)
7 fx <- x0 / (sigma^2) * exp(-x0^2 / (2 * sigma^2)) # 概率密度函数
8 hist(x, 20, freq = F) # 查看随机数分布情况
9 lines(x0, fx, 'l') # 查看频率直方图和概率密度函数是否吻合
```

练习 1.2 产生分布函数为 $F(x) = \frac{x^2+x}{2}$ ($0 \leq x \leq 1$) 的随机数 η , 要求通过逆变换法推导抽样公式, 并编写 R 代码验证。

解 根据 $F(x)$ 的定义, 令 $U = F(x) = \frac{x^2+x}{2}$, 整理得二次方程 $x^2 + x - 2U = 0$, 解得反函数为:

$$F^{-1}(u) = \frac{-1 + \sqrt{1+8u}}{2}, \quad 0 < u < 1$$

随机数的抽样公式为:

$$\eta_i = \frac{-1 + \sqrt{1+8u_i}}{2}, \quad i = 1, 2, \dots$$

R 代码验证如下:

```
1 set.seed(1)
2 n <- 10000 # 确定产生随机数的个数
3 r <- matrix(runif(n), n, 1) # 产生[0,1]上的均匀分布随机数
4 x <- (-1 + sqrt((1 + 8 * r)))/2 # 代入抽样公式
5 x0 <- seq(0, 1, 0.001)
6 fx <- x0 + 0.5 # 概率密度函数
7 hist(x, 20, freq = F) # 随机数分布情况
8 lines(x0, fx, 'l') # 频率直方图和概率密度函数是否吻合
9 index <- (matrix(1, length(x0), 1) %*% t(x)) <= x0 %*% matrix(1, 1, n)
10 Fx <- rowMeans(index) # 计算累积频率
11 Fx0 <- (x0^2 + x0)/2 # 理论分布函数
12 plot(x0, Fx, 'l')
13 lines(x0, Fx0, 'l', col = 'red') # 累积频率和理论分布函数是否吻合
```



笔记 在上述的抽样过程中, 我们事实上依赖于分布函数的反函数存在, 能够计算与表达, 并且事实上服从均匀分布。而分布函数的反函数事实上与分位数函数密切相关。PIT 的精髓在于利用分位数是均匀的 (可以想象这个假设是合理的, 因为分位数就是这么定义的)

定义 1.2 (分位数函数)

设 X 是一个随机变量, 其分布函数为 $F(x)$, 则它的分位数函数是一个从 $(0, 1)$ 到 $\mathbb{R}$ 的函数 Q , 定义为:

$$Q(t) = \inf\{x \in \mathbb{R} : F(x) \geq t\}, \quad t \in (0, 1).$$

这一概念表明: 当分位数函数对应的随机变量在 $(0, 1)$ 上服从均匀分布时, 其关联的随机变量 X 的分布函数恰好为 $F(x)$ 。

上述分位数函数也说明了, 如果对离散变量使用逆变换抽样, 则由于 $F()$ 不是一对一的函数, 因此需严格按照分位数函数定义运算 (具体运算略)。

练习 1.3 考虑逻辑斯谛 (Logistic) 分布的概率密度函数:

$$f(x) = \frac{\lambda e^{-\lambda x}}{(1 + e^{-\lambda x})^2}, \quad x \in \mathbb{R}$$

请陈述如何使用逆变换法 (PIT) 从该分布中模拟抽取随机数。

解 步骤如下:

1. 求分布函数 $F(x)$: 对密度函数积分:

$$F(x) = \int_{-\infty}^x \frac{\lambda e^{-\lambda t}}{(1 + e^{-\lambda t})^2} dt = \frac{1}{1 + e^{-\lambda x}}$$

2. 求分布函数的反函数 $F^{-1}(u)$: 令 $u = F(x) = \frac{1}{1+e^{-\lambda x}}$, 解得:

$$F^{-1}(u) = -\frac{1}{\lambda} \ln\left(\frac{1}{u} - 1\right), \quad u \in (0, 1)$$

3. 逆变换抽样：产生 $U(0, 1)$ 随机数 u ，代入反函数得

$$x = -\frac{1}{\lambda} \ln \left(\frac{1}{u} - 1 \right)$$

此 x 即为逻辑斯谛分布的随机数。

 **练习 1.4** 设 $X_1, \dots, X_n$ 是独立同分布 (i.i.d.) 的随机变量，分布函数为 $F(x)$ ，记 $M = \min\{X_1, X_2, \dots, X_n\}$ ， $N = \max\{X_1, X_2, \dots, X_n\}$ 。请说明如何模拟生成 M 和 N 的随机数。

解 模拟 $M = \min\{X_1, \dots, X_n\}$ ：

1. 先求 M 的分布函数：

$$F_M(x) = P(M \leq x) = 1 - P(M > x) = 1 - [1 - F(x)]^n$$

2. 用逆变换法：产生 $U(0, 1)$ 随机数 u ，令 $u = 1 - [1 - F(x)]^n$ ，解得：

$$F^{-1} \left(1 - (1 - u)^{1/n} \right)$$

代入 X 的反函数即可得 M 的随机数。

模拟 $N = \max\{X_1, \dots, X_n\}$ ：

(a). 先求 N 的分布函数：

$$F_N(x) = P(N \leq x) = [F(x)]^n$$

(b). 用逆变换法：产生 $U(0, 1)$ 随机数 u ，令 $u = [F(x)]^n$ ，解得：

$$F^{-1} \left(u^{1/n} \right)$$

代入 X 的反函数即可得 N 的随机数。



笔记 [逆变换抽样法的局限性]

逆变换法是一个常用的方法，但对连续随机变量应用时，首先必须求得分布函数的反函数 $F^{-1}(x)$ 。然而，当分布函数的反函数无法用初等函数表示时（例如正态分布、Gamma 分布等），随机数的抽样公式不能精确写出，此时逆变换法无法直接使用。

1.1.3 舍选抽样法

注意：请忽略下列的 1.2 的陈述与证明，该部分来自教材，其顺序不够人性化（直接看不太好理解），也可以忽略其中的一些符号。此部分韩老师建议先看他的笔记，因此 6 星学长将其补充在定理证明的后面，A-R 方法参照后续内容理解。如果想看教材，请从本笔记的推论开始看。

定理 1.2 (舍选抽样法)

设 $f(\cdot)$ 、 $g(\cdot)$ 分别为概率密度函数， $h(\cdot)$ 为给定函数（不要求是密度函数）。如果按下列步骤生成随机数 η ：

1. 独立生成 $X \sim f(x)$ 和 $Y \sim g(y)$ ；

2. 若 $Y \leq h(X)$ ，令 $\eta = X$ 并输出 η ，否则返回上一步。

令 $G(y)$ 为随机变量 Y 的分布函数，则 η 的概率密度函数为：

$$p(z) = \frac{f(z)G(h(z))}{\int_{-\infty}^{+\infty} f(y)G(h(y))dy}$$



证明 由抽样步骤，随机变量 η 的分布函数为：

$$\begin{aligned} P(\eta \leq z) &= P\{X \leq z | Y \leq h(X)\} = \frac{P\{X \leq z, Y \leq h(X)\}}{P\{Y \leq h(X)\}} \\ &= \frac{\int_{-\infty}^z \int_{-\infty}^{h(x)} f(x)g(y)dydx}{\int_{-\infty}^{\infty} \int_{-\infty}^{h(x)} f(x)g(y)dydx} = \frac{\int_{-\infty}^z f(x)G(h(x))dx}{\int_{-\infty}^{\infty} f(x)G(h(x))dx} \end{aligned}$$

因此 η 的密度函数为:

$$p(z) = \frac{f(z)G(h(z))}{\int_{-\infty}^{\infty} f(x)G(h(x))dx}$$

定理得证。



笔记 由定理 1.2 可知, $p(z)$ 的分母与 z, x 无关, 可以将其视为常数 $1/C$. 因此, 按照上述方法产生的随机数, 具有形式为 $Cf(z)G(h(z))$ 的密度函数, 这种生成随机数的方法称为舍选抽样法。

由定理 1.2, 当随机变量 η 的概率密度函数 $p(z)$ 具有复杂的形式且反函数也很难有显式表达式时, 可以借助形式较简单的 $f(x)$ 和 $g(y)$ 产生 X 和 Y 的随机数, 当它们满足定理中 $Y \leq h(X)$ 条件时, 可以得到随机变量 η 的随机数. 下面的推论给出了 $f(x), g(y)$ 和 $h(z)$ 具体形式下的结论。

推论 1.2

设随机变量 η 的概率密度函数 $p(z) \leq M(z)$, 且 $\int_{-\infty}^{\infty} M(z)dz = C < \infty$. 令概率密度函数 $f(x) = M(x)/C$, 且 $g(y)$ 是 $U(0, 1)$ 的概率密度函数, 按以下方法生成随机变量 η :

1. 独立生成 $X \sim f(x)$ 和 $Y \sim U(0, 1)$;
 2. 直到 $Y \leq p(X)/M(X)$ 时, 令 $\eta = X$ 并输出 η 。
- 则 η 的概率密度函数为 $p(z)$ 。



证明 由定理 1.2 可知, 按照上述抽样过程产生的随机数具有概率密度函数

$$p(z) = \frac{f(z)G(h(z))}{\int_{-\infty}^{\infty} f(y)G(h(y))dy} = \frac{\frac{M(z)}{C} \cdot \frac{p(z)}{M(z)}}{\int_{-\infty}^{\infty} \frac{M(x)}{C} \cdot \frac{p(x)}{M(x)}dx}$$

推论 1.2 得证。



笔记 推论 1.2 中的抽样过程循环产生随机数对 (X, Y) , 直到数对 (X, Y) 满足 $Y \leq p(X)/M(X)$ 时停止, 此时令 $\eta = X$. 根据推论 1.2, 函数 $M(\cdot)$ 需要满足 $p(x) \leq M(x)$ (对一切 x), 且概率密度函数 $f(x) = M(x)/C$ 的随机数容易生成。

下面的推论说明, 当 η 是有限区间 (a, b) 上的随机变量, 密度函数具有最大值 M , 此时 M 只需满足 $\int_a^b Mdx < \infty$, 可以将 $f(x)$ 取为 (a, b) 上均匀分布的密度函数。

推论 1.3

设随机变量 η 在有限区间 (a, b) 上取值, 概率密度函数 $p(z)$ 满足 $\sup_{z \in (a, b)} p(z) = M < \infty$, 按下列方法生成 η :

1. 独立生成 $X \sim U(a, b)$ 和 $Y \sim U(0, 1)$;
2. 直到 $Y \leq p(X)/M$ 时, 令 $\eta = X$ 并输出 η 。

则 η 的概率密度函数为 $p(z)$ 。



证明 令 $I(\cdot)$ 为示性函数, 取

$$M(x) = M \cdot I(x \in (a, b)),$$

即

$$\int_{-\infty}^{\infty} M(x)dx = (b-a)M.$$

根据推论 1.2, 有

$$f(x) = (b-a)^{-1}I(x \in (a, b))$$

即 $U(a, b)$ 的概率密度函数。



笔记 当 $X \sim U(a, b)$ 时, $p(X)/M(X) = p(X)/M$. 因此, 当随机变量在有限空间上取值, 且密度函数的最大值是有限值, 按照上述舍选抽样法抽得的随机数具有概率密度函数 $p(z)$ 。

Beta(α, β) 是常见的有限区间上的分布之一. 后面将以 Beta(α, β) (练习 1.10) 为例, 介绍有限区间上

非均匀随机数的舍选抽样法。



笔记 按照推论 1.3 抽样方法，随机变量 η 只能在有限空间上取值，且概率密度函数 $p(z)$ 有界。但很多情况下随机变量可能在无穷区间上取值，例如指数分布、Gamma 分布、正态分布等。此时，很难取到常数 M 使得 $\int_{-\infty}^{\infty} M(x)dx < \infty$ 。因此，当随机变量 η 在无穷区间上取值时，有界函数 $M(x)$ 和概率密度函数 $f(x)$ 的确定比较困难。下面的推论 1.4 给出可以用于无穷区间的舍选抽样法。

推论 1.4

设随机变量 η 的概率密度函数 $p(z) = Lh(z)f(z)$ ，其中 $L > 1$ 、 $0 \leq h(z) \leq 1$ 、 $f(z)$ 为概率密度函数，按下列方法生成 η ：

1. 独立生成 $X \sim f(x)$ 和 $Y \sim U(0, 1)$ ；
2. 直到 $Y \leq h(X)$ 时，令 $\eta = X$ 并输出 η 。

则 η 的概率密度函数为 $p(z)$ ，其中 $L = \left(\int_{-\infty}^{\infty} f(x)h(x)dx \right)^{-1}$ 。



证明 根据定理 1.2，步骤 1 和 2 产生的 η 的概率密度函数为

$$p(z) = \frac{f(z)h(z)}{\int_{-\infty}^{\infty} f(x)h(x)dx} = Lf(z)h(z)$$

其中，

$$L = \left(\int_{-\infty}^{\infty} f(x)h(x)dx \right)^{-1}.$$

注意：请忽略上面的定理 1.2 的陈述与证明，该部分来自教材，其顺序不够人性化（直接看不太好理解），也可以忽略其中的一些符号。A-R 方法参照后续内容理解。如果想看教材，请从本笔记的推论开始看。

问题描述：

1. $f(x)$ 为目标函数的概率密度函数， $F(x)$ 为对应的分布函数。假设我们很难从 $F(x)$ 反推出其反函数，因此无法用逆变换法直接采样。
2. $g(x)$ 为另一个非目标分布的概率密度函数，我们比较容易抽取符合 $g(x)$ 分布的样本（例如使用逆变换法等简单方法）。
3. 现在的问题是：为了从目标分布中抽样，我们能否先从 $g(x)$ 中抽样，再仅保留一部分样本，使得保留的样本可以看作是从 $f(x)$ 中抽取的？

答案是“可以”，但这需要满足一些条件。

一个直观的例子是：如果我们能从均匀分布 $(0, 1)$ 中抽样，之后对中间区域（例如 0.25 到 0.75 之间）的样本保留较多，对两端区域的样本仅保留一半，那么剩余的模拟样本会服从什么分布呢？（此处无答案）



笔记 A-R 方法的条件：

假设 $\frac{f(x)}{g(x)}$ 有上界 $c > 0$ ，即对所有 x 满足 $\frac{f(x)}{g(x)} \leq c$ 。

上述条件可以理解为：

- 经过有限倍的放大后，容易抽样的密度函数 $g(x)$ 需要能够“覆盖”住原始目标密度函数 $f(x)$ 。
- 换句话说，要求 $g(x)$ 比 $f(x)$ 更“厚尾”。（思考回顾：何为“厚尾”？）

定义 1.3 (舍选抽样算法 (Acceptance-Rejection Algorithm))

我们的目标是从分布 F 中抽样，算法步骤如下：

1. 从分布 G 中生成随机变量 Y ；
2. 生成服从均匀分布 $U \sim \text{unif}(0, 1)$ 的随机数；
3. 若 $U \leq \frac{f(Y)}{cg(Y)}$ ，则令 $X = Y$ （“接受”）；否则返回步骤 1（“拒绝”）。

其中， $c = \max \left(\frac{f(x)}{g(x)} \right)$ 。最终得到的 X 服从 Y 在条件 $U \leq \frac{f(Y)}{cg(Y)}$ 下的条件分布，且可以证明该条件分布即为目标分布 F 。



 **练习 1.5 接受概率的计算** 舍选抽样法中的接受概率是什么?

解 接受概率是“生成的随机数对满足接受条件 $U \leq \frac{f(Y)}{cg(Y)}$ ”的概率, 推导过程如下:

$$\begin{aligned} P\left(U \leq \frac{f(Y)}{cg(Y)}\right) &= \mathbb{E}\left[1\left\{U \leq \frac{f(Y)}{cg(Y)}\right\}\right] \\ &= \mathbb{E}\left[\mathbb{E}\left[1\left\{U \leq \frac{f(Y)}{cg(Y)}\right\} \mid Y\right]\right] \\ &= \int \mathbb{E}\left[1\left\{U \leq \frac{f(y)}{cg(y)}\right\} \mid Y=y\right] g(y) dy \\ &= \int \mathbb{P}\left(U \leq \frac{f(y)}{cg(y)}\right) g(y) dy \\ &= \int \frac{f(y)}{cg(y)} \cdot g(y) dy \\ &= \frac{1}{c} \end{aligned}$$

其中, $1(\cdot)$ 是示性函数 (满足条件时取 1, 否则取 0);

推导中用到了全期望公式: $\mathbb{E}[\mathbb{E}(X \mid Y)] = \mathbb{E}(X)$, 以及均匀分布的性质 (若 $U \sim \text{unif}(0, 1)$, 则 $\mathbb{P}(U \leq a) = a$, 其中 $0 \leq a \leq 1$)。

 **练习 1.6 条件分布的验证** 为何 $Y \mid U \leq \frac{f(Y)}{cg(Y)}$ 的条件分布是目标分布 F ?

证明 要证明该条件分布为 F , 只需验证其分布函数等于 $F(y)$ 。根据条件概率公式:

$$\begin{aligned} P\left(Y \leq y \mid U \leq \frac{f(Y)}{cg(Y)}\right) &= \frac{P\left(Y \leq y, U \leq \frac{f(Y)}{cg(Y)}\right)}{P\left(U \leq \frac{f(Y)}{cg(Y)}\right)} \\ &= \frac{P\left(U \leq \frac{f(Y)}{cg(Y)} \mid Y \leq y\right) \cdot P(Y \leq y)}{\frac{1}{c}} \quad (\text{贝叶斯公式, 且已知 } P\left(U \leq \frac{f(Y)}{cg(Y)}\right) = \frac{1}{c}) \\ &= G(y) \cdot c \cdot P\left(U \leq \frac{f(Y)}{cg(Y)} \mid Y \leq y\right) \end{aligned}$$

进一步展开条件概率项 (利用全期望公式):

$$P\left(U \leq \frac{f(Y)}{cg(Y)} \mid Y \leq y\right) = \frac{\int_{-\infty}^y P\left(U \leq \frac{f(w)}{cg(w)} \mid Y=w\right) g(w) dw}{G(y)}$$

由于 $U \sim \text{unif}(0, 1)$, 有 $P\left(U \leq \frac{f(w)}{cg(w)}\right) = \frac{f(w)}{cg(w)}$, 代入后化简:

$$\begin{aligned} P\left(Y \leq y \mid U \leq \frac{f(Y)}{cg(Y)}\right) &= G(y) \cdot c \cdot \frac{\int_{-\infty}^y \frac{f(w)}{cg(w)} \cdot g(w) dw}{G(y)} \\ &= \int_{-\infty}^y f(w) dw \\ &= F(y) \end{aligned}$$

因此, $Y \mid U \leq \frac{f(Y)}{cg(Y)}$ 的条件分布函数恰好是 $F(y)$, 即其条件分布为目标分布 F 。

 **笔记** 直觉上而言, 不严谨的说, $g(y)$ 与 $f(x)$ 越“相似”, 似乎接受率就越高。

例题 1.1 舍选抽样法生成标准正态分布随机数 目标: 生成 $Z \sim N(0, 1)$ 的随机数, 其密度函数为 $f(x) = \frac{1}{\sqrt{2\pi}} e^{-x^2/2}$ 。

前置分析:

1. 能否直接用逆变换法 (PIT)? 理论上可以 (若标准正态分布的分布函数 $\Phi(x)$ 可直接调用), 但 $\Phi(x)$ 或其反函数 $\Phi^{-1}(x)$ 需依赖软件/近似计算, 实际操作受限。
2. 舍选抽样法的核心: 选择满足 $\max \frac{f(x)}{g(x)} < \infty$ 的提议分布 $g(x)$, 且 $g(x)$ 易抽样。
提议分布的选择:

1. 选择双指数分布作为提议分布，其密度为：

$$g(x) = \frac{1}{2}e^{-|x|}, \quad x \in \mathbb{R}$$

2. 该分布满足：

(a). 易抽样（可通过逆变换法生成）；

(b). 尾部比标准正态更“厚”（验证 $\lim_{x \rightarrow \infty} \frac{f(x)}{g(x)} < \infty$ ）。

计算常数 c ：

1. 定义 $h(x) = \frac{f(x)}{g(x)} = \sqrt{\frac{2}{\pi}}e^{-\frac{x^2}{2}+|x|}$ ，需找到 $h(x)$ 的最大值（即 c ）；

2. 令 $d(x) = -\frac{x^2}{2} + |x|$ ，求导得极值点：

(a). 当 $x > 0$ 时， $d'(x) = 1 - x$ ，极值点 $x^* = 1$ ；

(b). 当 $x < 0$ 时， $d'(x) = -1 - x$ ，极值点 $x^* = -1$ 。

3. 代入得 $c = \sqrt{\frac{2}{\pi}}e^{1/2} \approx 1.32$ 。

舍选抽样算法：

1. 从双指数分布 $g(x) = \frac{1}{2}e^{-|x|}$ 中生成随机数 Y （例如用逆变换法）；
2. 生成均匀随机数 $U \sim \text{unif}(0, 1)$ ；
3. 若 $U \leq e^{-\frac{Y^2}{2}+|Y|-1/2}$ ，则令 $X = Y$ （接受）；否则返回步骤 1（拒绝）；
4. 重复上述步骤，直到得到足够多的样本。

练习 1.7

- a) 上述方法中，理论上的接受率是多少？大体而言，该接受率是否越大越好？
- b) 增大接受率是否可行？（从“感性”的画图，到大致的推导）
- c) 增大接受率，但仍然采取类似于 double exponential 分布的提议是否可行？

解

- a) 理论接受率与合理性：舍选抽样的理论接受率为 $\frac{1}{c}$ ($c = \max \frac{f(x)}{g(x)}$)。在标准正态分布的舍选抽样示例中， $c \approx 1.32$ ，故接受率约为 $\frac{1}{1.32} \approx 0.76$ (76%)。接受率“越大越好”：接受率越高，每次抽样被“接受”的概率越高，算法重复抽样的次数越少，效率越高。
- b) 增大接受率的可行性：可行。接受率由 $c = \max \frac{f(x)}{g(x)}$ 决定，若选择与目标分布 $f(x)$ 形状更接近的提议分布 $g(x)$ ，可减小 c 从而增大接受率。从“画图”角度：若 $g(x)$ 的曲线与 $f(x)$ 越贴合， $\frac{f(x)}{g(x)}$ 的最大值越接近 1，接受率越接近 100%；从推导角度： c 越小， $\frac{1}{c}$ 越大，接受率越高。
- c) 采用类双指数分布增大接受率的可行性：可行。双指数分布的核心优势是“厚尾 + 易抽样”，可通过调整双指数分布的参数（如缩放系数），使其形状更接近目标分布 $f(x)$ ，从而减小 c 、增大接受率；也可选择“尾部特性与双指数类似，但主体更贴合正态分布”的分布（如广义双指数分布），既保持易抽样性，又能提升接受率。

推论 1.5 (含参数双指数分布的最优选择)

我们考虑一类带参数 α 的分布作为提议分布，双指数分布的形式为：

$$g_\alpha(x) = \frac{\alpha}{2}e^{-\alpha|x|}, \quad x \in \mathbb{R}, \alpha > 0$$

定义 $h_\alpha(x) = \frac{f(x)}{g_\alpha(x)} = \frac{1}{\alpha}\sqrt{\frac{2}{\pi}}e^{-\frac{x^2}{2}+\alpha|x|}$ ，其最大值由 $d_\alpha(x) = -\frac{x^2}{2} + \alpha|x|$ 的最大值决定，求导得极值点 $x^* = |\alpha|$ ，因此：

$$h_\alpha(x) \leq \frac{1}{\alpha}\sqrt{\frac{2}{\pi}}e^{\frac{\alpha^2}{2}} = c(\alpha)$$

为使算法效率最高，需最小化 $c(\alpha)$ 。对 $\log c(\alpha) = \frac{\alpha^2}{2} - \log(\alpha) + \frac{1}{2}\log(2/\pi)$ 求导，得极值点满足 $\alpha - \frac{1}{\alpha} = 0$ ，即 $\alpha = 1$ 。因此，在双指数分布族中， $\alpha = 1$ 是最优选择。



笔记 上述问题本质是 **min-max** 问题：

$$\min_{\alpha \in \mathbb{R}^+} \left\{ \max_{x \in \mathbb{R}} \frac{f(x)}{g_{\alpha}(x)} \right\}$$

其目的是在易抽样的参数分布族中，选择最“接近”目标分布的提议分布，以实现最高效的舍选抽样。

练习 1.8 非严格密度函数的舍选抽样 如果目标函数 $f(x)$ 不是严格的密度函数（即不满足 $\int f(x)dx = 1$ ），是否依然可以采取 A-R 方法？

解 可以。理由如下：

1. 核心概念（核函数）：统计中，密度函数去掉标准化常数后的部分称为“核（kernel）”，即 $f(x) = c \cdot \text{kernel}(x)$ （ c 为标准化常数）；
2. 舍选抽样的兼容性：舍选抽样的接受条件是 $U \leq \frac{f(Y)}{cg(Y)}$ ，其中 $c = \max \frac{f(x)}{g(x)}$ 。若 $f(x)$ 是核函数（未标准化），则 $\frac{f(Y)}{cg(Y)}$ 中的标准化常数会被抵消，因此无需计算标准化常数即可完成抽样。

核函数的产生原因包括：

1. 简化计算：“偷懒”省略标准化常数（实际计算中常无需显式写出）；
2. 贝叶斯统计：后验分布的核函数更常出现（似然与先验的乘积）。

生成标准正态分布样本的 R 代码如下：

```
1 simulate_normal_ar <- function(n) {
2   # 生成n个样本
3   samples <- numeric(n)
4   count <- 0
5   c <- sqrt(2 * exp(1) / pi) # 常数c
6   while (count < n) {
7     # 从双指数分布生成Y
8     U1 <- runif(1)
9     Y <- -log(U1) * sign(runif(1) - 0.5)
10    # 生成均匀随机数U
11    U2 <- runif(1)
12    # 接受-拒绝条件
13    if (U2 <= exp(-0.5 * Y^2 + abs(Y) - 0.5)) {
14      count <- count + 1
15      samples[count] <- Y
16    }
17  }
18  return(samples)
19 }
20
21 # 生成10000个样本并绘图
22 n_samples <- 10000
23 normal_samples <- simulate_normal_ar(n_samples)
24 hist(normal_samples, probability = TRUE, breaks = 50,
25 main = "Simulated N(0,1)", xlab = "Value")
26 curve(dnorm(x), col = "red", lwd = 2, add = TRUE)
```

代码通过舍选抽样生成标准正态分布样本，并绘制直方图与理论密度曲线对比。

练习 1.9 随堂练习 生成 $\text{Gamma}(\alpha, 1)$ 分布的随机数，其概率密度函数为：

$$f(x) = \frac{1}{\Gamma(\alpha)} x^{\alpha-1} e^{-x}, \quad x > 0 (\alpha > 1)$$

考虑提议分布 $g(x) = \frac{1}{\theta} e^{-x/\theta}$ ，回答：

1. 为何 $g(x)$ 可行?
2. 对 θ 有什么要求?

取 $\theta = 2$ 完成 R 代码, 并思考: θ 取何值时抽样效率最高 (接受率最高)?

解

1. $g(x)$ 可行的原因:

(a). $g(x)$ 是指数分布的密度函数, 易通过逆变换法抽样;

(b). 指数分布的尾部满足“厚尾”条件 ($\lim_{x \rightarrow \infty} \frac{f(x)}{g(x)} < \infty$), 保证 $\max \frac{f(x)}{g(x)} < \infty$ 。

2. 对 θ 的要求: 需满足 $\max \frac{f(x)}{g(x)} < \infty$, 即 $\frac{x^{\alpha-1}e^{-x}/\Gamma(\alpha)}{e^{-x}/\theta} = \frac{\theta}{\Gamma(\alpha)}x^{\alpha-1}e^{-x(1-1/\theta)}$ 有界, 因此需 $1 - 1/\theta > 0$ (即 $\theta > 1$), 否则当 $x \rightarrow \infty$ 时该式无界。

当 $\theta = \frac{\alpha}{\alpha-1}$ 时, 抽样效率最高 (通过最小化 $\max \frac{f(x)}{g(x)}$ 推导可得)。

取 $\theta = 2$ 时的 R 代码:

```

1 simulate_gamma_ar <- function(n, alpha) {
2   # 生成n个Gamma(alpha, 1)样本
3   samples <- numeric(n)
4   count <- 0
5   theta <- 2 # 指定theta=2
6   while (count < n) {
7     # 从指数分布g(x)生成Y (rate=1/theta)
8     Y <- rexp(1, rate = 1/theta)
9     # 计算f(Y)/g(Y)的核函数比值 (省略Gamma(alpha)常数)
10    ratio <- Y^(alpha-1) * exp(-Y) * theta * exp(Y/theta)
11    # 计算c (f/g的最大值, 简化版)
12    c_val <- (theta^alpha) * exp(-alpha + theta) / gamma(alpha)
13    # 生成均匀随机数U
14    U <- runif(1)
15    # 接受-拒绝条件
16    if (U <= ratio / c_val) {
17      count <- count + 1
18      samples[count] <- Y
19    }
20  }
21  return(samples)
22 }
23
24 # 测试: 生成10000个Gamma(2,1)样本
25 alpha <- 2
26 n_samples <- 10000
27 gamma_samples <- simulate_gamma_ar(n_samples, alpha)
28 # 绘图验证
29 hist(gamma_samples, probability = TRUE, breaks = 50,
30      main = "Simulated Gamma(2,1)", xlab = "Value")
31 curve(dgamma(x, shape = alpha, rate = 1), col = "red", lwd = 2, add = TRUE)

```

 **练习 1.10** 产生分布为 $Beta(\alpha, \beta)$ 的随机数, 其概率密度函数为:

$$p(z) = \frac{\Gamma(\alpha + \beta)}{\Gamma(\alpha)\Gamma(\beta)} z^{\alpha-1} (1-z)^{\beta-1}, \quad 0 < z < 1 \quad (1.2)$$

要求通过舍选抽样法设计抽样步骤, 并编写 R 代码实现 (设置 $\alpha = 3$ 、 $\beta = 2$)。

解 Beta 分布的众数为 $(\alpha - 1)/(\alpha + \beta - 2)$, 概率密度函数在该点取得最大值 M 。舍选抽样法步骤如下:

1. 独立生成 $X \sim U(0, 1)$ 和 $Y \sim U(0, 1)$;
2. 计算舍选条件 $Y \leq p(X)/M$, 满足时输出 $\eta = X$, 否则重复步骤 1。

R 代码实现如下:

```

1  set.seed(1)
2  func.h <- function(x, alpha, beta) {
3    if (alpha == 1 || beta == 1) {
4      print("ERROR PARAMETER") # 当alpha=1或beta=1时该抽样不适用
5    } else {
6      ((alpha + beta - 2) * (alpha + beta - 2) * (x/(alpha - 1))^(alpha - 1) * ((1 - x)/(beta -
7        1))^(beta - 1))
8    }
9  }
10 n <- 1000 # 确定产生随机数的个数
11 m <- 0 # 记录产生的舍选随机数个数
12 i <- 0
13 alpha <- 3
14 beta <- 2 # 确定参数数值
15 z <- c()
16 repeat {
17   m <- m + 1
18   x <- runif(1)
19   y <- runif(1) # 生成[0,1]上的均匀分布随机数
20   ay <- func.h(x, alpha, beta) # 计算舍选条件
21   if (y <= ay) { # 进行舍选检验
22     z <- c(z, x)
23     i <- i + 1
24   }
25   if (i == n) break
26 }
27 x0 <- seq(0, 1, 0.001)
28 fx <- dbeta(x0, alpha, beta) # 概率密度函数
29 hist(z, 30, freq = F) # 查看随机数分布
30 lines(x0, fx, 'l', col = 'red') # 频率直方图和概率密度函数

```

 **练习 1.11** 产生均值为 0、方差为 1 的半正态分布随机数, 其概率密度函数为:

$$p(z) = \begin{cases} \sqrt{2/\pi} e^{-\frac{z^2}{2}}, & z \geq 0 \\ 0, & z < 0 \end{cases} \quad (1.3)$$

要求通过舍选抽样法设计抽样步骤, 并编写 R 代码实现。

解 对 $p(z)$ 进行恒等变换:

$$p(z) = \sqrt{\frac{2e}{\pi}} e^{-\frac{(z-1)^2}{2}} e^{-z}$$

令 $L = \sqrt{2e/\pi}$ 、 $h(x) = e^{-\frac{(x-1)^2}{2}}$, 取 $f(x) = e^{-x}$ ($x > 0$) (参数为 1 的指数分布)。舍选抽样步骤如下:

1. 独立生成 $X \sim \text{Exp}(1)$ 和 $Y \sim U(0, 1)$;
2. 直到 $Y \leq e^{-(X-1)^2/2}$ 时, 令 $\eta = X$ 并输出 η 。

R 代码实现如下:

```

1  set.seed(1)
2  n <- 10000 # 确定产生随机数的个数

```

```

3      m <- 0    # 记录产生的舍选随机数个数
4      i <- 0
5      z <- c()
6      repeat {
7          m <- m + 1
8          x <- rexp(1, 1)
9          y <- runif(1) # 生成[0,1]上的均匀分布随机数
10         ay <- exp(-(x - 1)^2 / 2) # 计算舍选条件
11         if (y <= ay) { # 进行舍选检验
12             z <- c(z, x)
13             i <- i + 1
14         }
15         if (i == n) break
16     }
17     x0 <- seq(0, max(z), 0.01)
18     fx <- sqrt(2/pi) * exp(-x0^2 / 2) # 概率密度函数
19     hist(z, 20, freq = F) # 随机数分布
20     lines(x0, fx, 'l', col = 'red') # 概率密度函数

```

 **练习 1.12** 产生分布为 $\text{Gamma}(\alpha, 1)$ 的随机数 ($\alpha > 1$)，其概率密度函数为：

$$p(z) = \frac{1}{\Gamma(\alpha)} z^{\alpha-1} e^{-z}, \quad z > 0 \quad (1.4)$$

要求通过舍选抽样法设计抽样步骤，并编写 R 代码实现（设置 $\alpha = 3$ ）。

解 对 $p(z)$ 进行恒等变换：

$$p(z) = \frac{\alpha^\alpha}{\Gamma(\alpha)e^{\alpha-1}} \cdot \frac{e^{\alpha-1}}{\alpha^\alpha} z^{\alpha-1} e^{-\frac{\alpha-1}{\alpha}z} e^{-\frac{1}{\alpha}z}$$

令 $L = \alpha^\alpha / (\Gamma(\alpha)e^{\alpha-1})$ 、 $h(x) = e^{\alpha-1}(x/\alpha)^{\alpha-1}e^{-\frac{\alpha-1}{\alpha}x}$ ，取 $f(x) = e^{-\frac{x}{\alpha}}/\alpha$ （参数为 $1/\alpha$ 的指数分布）。舍选抽样步骤如下：

1. 独立生成 $X \sim \text{Exp}(1/\alpha)$ 和 $Y \sim U(0, 1)$ ；
2. 直到 $Y \leq h(X)$ 时，令 $\eta = X$ 并输出 η 。

R 代码实现如下：

```

1      set.seed(1)
2      func.h <- function(x, alpha) {
3          if (alpha < 1) {
4              print("ERROR PARAMETER") # 当alpha<1时该抽样不适用
5          } else {
6              exp(alpha - 1)/(alpha^(alpha - 1)) * x^(alpha - 1) * exp(-(alpha - 1)/alpha * x)
7          }
8      }
9      n <- 1000 # 确定产生随机数的个数
10     m <- 0    # 记录产生的舍选随机数个数
11     i <- 0
12     alpha <- 3 # 确定参数数值
13     z <- c()
14     repeat {
15         m <- m + 1
16         x <- rexp(1, 1/alpha)
17         y <- runif(1) # 生成[0,1]上的均匀分布随机数

```

```

18     ay <- func.h(x, alpha) # 计算舍选条件
19     if (y <= ay) { # 进行舍选检验
20         z <- c(z, x)
21         i <- i + 1
22     }
23     if (i == n) break
24 }
25 x0 <- seq(0, max(z), 0.01)
26 fx <- dgamma(x0, alpha, 1) # 概率密度函数
27 hist(z, 30, freq = F) # 随机数分布
28 lines(x0, fx, 'l', col = 'red') # 概率密度函数

```

1.1.4 变换抽样法

定义 1.4 (变换抽样法)

若随机变量 η 不易直接抽样，但存在容易抽样的随机变量 ξ 与 η 满足一一对应关系（即 $\eta = h(\xi)$ 或 $\xi = h^{-1}(\eta)$ ，其中 $h(\cdot)$ 是可逆变换），则可通过以下步骤生成 η 的样本：

1. 生成易抽样随机变量 ξ 的样本；
2. 利用变换关系 $h(\cdot)$ ，将 ξ 的样本转换为 η 的样本。

这种通过“先抽样易处理的随机变量，再经可逆变换得到目标变量”的抽样方法，称为变换抽样法。

定理 1.3 (一维随机变量函数的分布)

设随机变量 ξ 具有概率密度函数 $f(x)$ ，另有一函数 $h(z)$ 严格单调，其反函数记为 $h^{-1}(z)$ 且导函数存在，则 $\eta = h(\xi)$ 的概率密度函数为：

$$p(z) = f\left(h^{-1}(z)\right) \cdot \left|h^{-1}(z)\right|'$$

证明 首先求随机变量 η 的分布函数：

$$\begin{aligned}
 P(\eta \leq z) &= P(h(\xi) \leq z) = P\left(\xi \leq h^{-1}(z)\right) \\
 &= \int_{-\infty}^{h^{-1}(z)} f(x) dx = \int_{-\infty}^z f\left(h^{-1}(y)\right) \cdot \left|h^{-1}(y)\right|' dy
 \end{aligned}$$

求导得随机变量 η 的概率密度函数，定理得证。

 **笔记** 定理 1.3 给出了一维随机变量函数的分布。设随机向量 $(\xi_1, \xi_2, \dots, \xi_n)$ 的概率密度函数为 $f(x_1, x_2, \dots, x_n)$ ，则其函数 $\eta = g(\xi_1, \xi_2, \dots, \xi_n)$ 的分布函数为：

$$P(\eta \leq y) = \int \dots \int_{g(x_1, x_2, \dots, x_n) \leq y} f(x_1, x_2, \dots, x_n) dx_1 dx_2 \dots dx_n$$

 **笔记** [常见的 n 维随机向量变换] 多维随机向量的典型函数变换包括：

1. 求和变换： $\eta_1 = \xi_1 + \xi_2 + \dots + \xi_n$ （如独立随机变量和的分布）；
2. 平方和变换： $\eta_2 = \xi_1^2 + \xi_2^2 + \dots + \xi_n^2$ （如卡方分布的构造）；
3. 最大值变换： $\eta_3 = \max(\xi_1, \xi_2, \dots, \xi_n)$ （如极值分布）；
4. 最小值变换： $\eta_4 = \min(\xi_1, \xi_2, \dots, \xi_n)$ （如系统可靠性分析中的寿命分布）。

 **笔记** [常用分布的经典变换关系] 变换抽样法的核心是通过已知分布的样本经变换得到目标分布样本，以下是统计学中核心的分布变换：

原始分布/变量	变换形式	结果分布
n 个独立 $Bernoulli(p)$ 变量	求和: $\xi = \xi_1 + \xi_2 + \cdots + \xi_n$	二项分布 $B(n, p)$
$Z \sim N(0, 1)$	线性变换: $X = \mu + \sigma Z$	正态分布 $N(\mu, \sigma^2)$
$Z \sim exp(1)$	尺度变换: $X = \lambda Z$	指数分布 $exp(\lambda)$
$Z_1, \dots, Z_n \sim N(0, 1)$ (独立)	平方和: $X = Z_1^2 + Z_2^2 + \cdots + Z_n^2$	卡方分布 $\chi^2(n)$
$Y \sim N(0, 1), Z \sim \chi^2(n)$ (独立)	$X = Y / \sqrt{Z/n}$	t 分布 $t(n)$
$Y \sim \chi^2(n_1), Z \sim \chi^2(n_2)$ (独立)	$X = \frac{Y/n_1}{Z/n_2}$	F 分布 $F(n_1, n_2)$

(不需要死记硬背; 如考试需要运用, 则会在卷面上提供)

 **练习 1.13** 用变换抽样法产生分布为 $N(\mu, \sigma^2)$ 的随机数, 要求推导变换关系并编写 R 代码实现 (设置 $\mu = 0.6$ 、 $\sigma = 1.5$)。

解 由正态分布性质, 若 $\xi \sim N(0, 1)$, 则 $\eta = \mu + \sigma \cdot \xi \sim N(\mu, \sigma^2)$, 函数关系为:

$$\eta = h(\xi) = \mu + \sigma \cdot \xi$$

只需产生标准正态分布随机数, 代入上式即可。

R 代码实现如下:

```

1 set.seed(1)
2 n <- 10000 # 确定产生随机数的个数
3 mu <- 0.6
4 sigma <- 1.5
5 xi <- rnorm(n, 0, 1)
6 eta <- mu + sigma * xi
7 hist(eta, 30, freq = F) # 频率直方图和概率密度函数
8 x0 <- seq(min(eta), max(eta), 0.01)
9 lines(x0, dnorm(x0, mu, sigma), 'l', col = 'red')

```

 **练习 1.14** 用变换抽样法产生分布为 $Gamma(1/2, 3)$ 的随机数, 要求推导变换关系并编写 R 代码实现。

解 由 Gamma 分布性质, 若 $\xi \sim Gamma(\alpha, \gamma)$, 则 $\eta = \xi/a \sim Gamma(\alpha, a\gamma)$ 。取 $\alpha = 1/2$ 、 $\gamma = 1/2$ 、 $a = 6$, 函数关系为:

$$\eta = h_1(\xi) = \xi/6$$

其中 $\xi \sim Gamma(1/2, 1/2)$ (即自由度为 1 的卡方分布), 而 $\xi = \zeta^2$ ($\zeta \sim N(0, 1)$)。

R 代码实现如下:

```

1 set.seed(1)
2 n <- 100000 # 确定产生随机数的个数
3 alpha <- 1/2
4 gamma <- 3
5 a <- gamma / 0.5
6 zeta <- rnorm(n, 0, 1)
7 xi <- zeta^2
8 eta <- xi / a
9 hist(eta, 30, freq = F) # 随机数分布
10 x0 <- seq(min(eta), max(eta), 0.01)
11 lines(x0, dgamma(x0, alpha, gamma), 'l', col = 'red') # 概率密度函数

```

 **练习 1.15** 证明: n 个独立同分布于标准正态分布的随机变量, 其平方和服从自由度为 n 的卡方分布 $\chi^2(n)$, 并编写 R 代码产生该分布的随机数 (设置 $n = 4$)。

解 设 $\xi_1 \sim N(0, 1)$, 则 ξ_1^2 的分布函数为:

$$\begin{aligned} P(\xi_1^2 \leq y) &= P(-\sqrt{y} \leq \xi_1 \leq \sqrt{y}) \\ &= \int_{-\sqrt{y}}^{\sqrt{y}} \frac{1}{\sqrt{2\pi}} e^{-x^2/2} dx = \frac{1}{\sqrt{2\pi}} \int_0^y e^{-u/2} u^{-1/2} du, \quad y > 0 \end{aligned}$$

求导得概率密度函数, 即为 $\text{Gamma}(1/2, 1/2)$ 分布。由 Gamma 分布可加性, $\eta = \sum_{i=1}^n \xi_i^2 \sim \chi^2(n)$ 。

取 $n = 4$ 的 R 代码实现如下:

```
1 set.seed(1)
2 n <- 10000 # 确定产生随机数的个数
3 m <- 4     # 确定卡方分布的自由度
4 eta <- NULL
5 for (i in 1:n) {
6   x <- rnorm(m, 0, 1)
7   eta[i] <- sum(x^2) # 平方和为自由度为m的卡方分布的随机数
8 }
9 hist(eta, 30, freq = F) # 随机分布
10 x0 <- seq(min(eta), max(eta), 0.01)
11 lines(x0, dchisq(x0, m), 'l', col = 'red') # 概率密度函数
```



笔记 代码简化课堂练习: 事实上, 上述代码 (教材中提供) 有很大的优化空间。试着采用“向量/矩阵化”编程思维, 使用 `apply()` 类似函数改进上述代码。

在实际的运用中, 变换抽样法大多用于解决较为经典的问题, 使用经典变换以及分布之间的关系。



笔记 `apply()` 这个函数 22、23 级期末都考了一道 20 分的大题, 这个函数一定要熟悉!!!

以下内容为非课程内容, 仅供拓展

定理 1.4 (二维随机向量函数的密度公式)

设随机向量 (ξ_1, ξ_2) 的联合概率密度函数为 $f(x_1, x_2)$, 令 $\eta = g(\xi_1, \xi_2)$, 且存在唯一的反变换 $h(\cdot, \cdot)$ (其一阶偏导数存在), 则随机变量 η 的概率密度函数为:

$$p(y) = \left| \frac{\partial h}{\partial y} \right| \int_{-\infty}^{\infty} f(h(y, z), z) dz$$



证明 构造辅助变量 $\zeta = \xi_2$, 则变换关系为:

$$\begin{cases} \eta = g(\xi_1, \xi_2) \\ \zeta = \xi_2 \end{cases}$$

其反变换为:

$$\begin{cases} \xi_1 = h(\eta, \zeta) \\ \xi_2 = \zeta \end{cases}$$

计算该变换的雅可比行列式:

$$J = \begin{vmatrix} \frac{\partial h}{\partial \eta} & \frac{\partial h}{\partial \zeta} \\ 0 & 1 \end{vmatrix} = \frac{\partial h}{\partial \eta}$$

因此, 随机向量 (η, ζ) 的联合密度函数为:

$$p(y, z) = f(h(y, z), z) \cdot |J| = f(h(y, z), z) \cdot \left| \frac{\partial h}{\partial y} \right|$$

对联合密度关于 z 积分, 即得 η 的边缘密度函数:

$$p(y) = \left| \frac{\partial h}{\partial y} \right| \int_{-\infty}^{\infty} f(h(y, z), z) dz$$

定理得证。

定义 1.5 (次序统计量)

设 $X_1, X_2, \dots, X_n$ 是来自分布 $F(x)$ 的样本，将其按从小到大排列为：

$$X_{(1)} \leq X_{(2)} \leq \dots \leq X_{(n)}$$

则称 $X_{(k)}$ 为该样本的第 k 个次序统计量；其中 $X_{(1)}$ （最小值）和 $X_{(n)}$ （最大值）分别称为样本的极值次序统计量。

次序统计量是 n 维样本的函数，常用于极值分析、可靠性评估等场景。

定理 1.5 (独立同分布样本的次序统计量分布)

设 $X_1, X_2, \dots, X_n$ 独立同分布，概率密度函数为 $f(x)$ ，分布函数为 $F(x)$ ，则：

1. 第 k 个次序统计量 $X_{(k)}$ 的密度函数：

$$g(y_k) = \frac{n!}{(k-1)!(n-k)!} [F(y_k)]^{k-1} [1-F(y_k)]^{n-k} f(y_k)$$

2. 第 k, j 个次序统计量 $X_{(k)}, X_{(j)}$ ($1 \leq k \leq j \leq n$) 的联合密度函数（当 $y_k \leq y_j$ 时）：

$$g(y_k, y_j) = \frac{n!}{(k-1)!(j-1-k)!(n-j)!} [F(y_k)]^{k-1} \times [F(y_j) - F(y_k)]^{j-k-1} [1-F(y_j)]^{n-j} f(y_k) f(y_j)$$

3. 前 r 个次序统计量 $X_{(1)}, X_{(2)}, \dots, X_{(r)}$ 的联合密度函数（当 $y_1 \leq y_2 \leq \dots \leq y_r$ 时）：

$$g(y_1, y_2, \dots, y_r) = \frac{n!}{(n-r)!} [1-F(y_r)]^{n-r} f(y_1) f(y_2) \cdots f(y_r)$$

证明

1. 第 k 个次序统计量的密度函数证明

将实数轴划分为三个区间： $(-\infty, y_k]$ 、 $(y_k, y_k + dy_k]$ 、 $(y_k + dy_k, \infty)$ 。要使 $X_{(k)} \in (y_k, y_k + dy_k]$ ，需满足：

- (a). $k-1$ 个样本落入 $(-\infty, y_k]$ ；
- (b). 1 个样本落入 $(y_k, y_k + dy_k]$ ；
- (c). $n-k$ 个样本落入 $(y_k + dy_k, \infty)$ 。

根据多项分布，该事件的概率元为：

$$g(y_k) dy_k = \frac{n!}{(k-1)!1!(n-k)!} [F(y_k)]^{k-1} [1-F(y_k + dy_k)]^{n-k} f(y_k) dy_k + o(dy_k)$$

当 $dy_k \rightarrow 0$ 时， $1-F(y_k + dy_k) \approx 1-F(y_k)$ ，约去 dy_k 后即得 $X_{(k)}$ 的密度函数。

2. 第 k, j 个次序统计量的联合密度函数证明

将实数轴划分为五个区间： $(-\infty, y_k]$ 、 $(y_k, y_k + dy_k]$ 、 $(y_k + dy_k, y_j]$ 、 $(y_j, y_j + dy_j]$ 、 $(y_j + dy_j, \infty)$ 。

要使 $X_{(k)} \in (y_k, y_k + dy_k]$ 且 $X_{(j)} \in (y_j, y_j + dy_j]$ ，需满足：

- (a). $k-1$ 个样本落入 $(-\infty, y_k]$ ；
- (b). $j-k-1$ 个样本落入 $(y_k + dy_k, y_j]$ ；
- (c). $n-j$ 个样本落入 $(y_j + dy_j, \infty)$ ；
- (d). 各 1 个样本落入 $(y_k, y_k + dy_k]$ 和 $(y_j, y_j + dy_j]$ 。

同理，由多项分布的概率元，约去 dy_k, dy_j 并令 $dy_k, dy_j \rightarrow 0$ ，即得联合密度函数。

3. 前 r 个次序统计量的联合密度函数证明

类似地，将实数轴划分为 $r+1$ 个区间，要求前 r 个次序统计量分别落入 $(y_i, y_i + dy_i]$ ($i = 1, \dots, r$)，剩余 $n-r$ 个样本落入 $(y_r + dy_r, \infty)$ ，通过多项分布的概率元推导可得。



笔记 [次序统计量分布的意义]

1. 第 k 个次序统计量的密度：本质是二项分布的连续形式（“成功”为样本 $\leq y_k$ ，概率 $F(y_k)$ ），结合

排列数体现样本的排序组合。

- 联合密度：通过划分区间、分配样本数量的方式，体现多个次序统计量的“位置约束”（如 $X_{(k)} \leq X_{(j)}$ ）。
- 应用场景：极值分析（如 $X_{(1)}, X_{(n)}$ ）、可靠性评估（如寿命数据的分位数）等。

笔记 [逆变换/变换抽样法 vs 舍选抽样法]

1. 方法分类与核心逻辑

- 直接抽样法（逆变换 + 变换抽样法）：已知目标分布的密度/分布函数 $f(x)/F(x)$ ，通过变换关系（如逆变换 $X = F^{-1}(U)$ 、分布间的函数变换），将易抽样的已知分布（如均匀分布）样本转换为目标分布样本。
- 舍选抽样法（非直接法）：
独立生成两个已知分布的随机数对，通过检验条件决定是否保留第一个随机数作为目标分布样本（满足条件则接受，否则拒绝）。

2. 方法对比

对比维度	直接抽样法（逆变换/变换）	舍选抽样法
核心依赖	需已知目标分布的逆分布/变换关系	需选取合适的“上界函数 + 已知分布”
操作复杂度	需推导逆变换/变换关系	无需逆变换，只需检验条件
效率	无拒绝过程，效率高	存在拒绝过程，效率依赖上界函数选取
适用场景	目标分布的逆变换/变换关系易获取	目标分布复杂、逆变换难推导时
缺点	逆变换/变换关系可能不存在/难推导	上界函数选取困难，选不好时效率低

练习 1.16 用变换抽样法产生 $Beta(a, b)$ 的随机数，要求基于次序统计量设计抽样步骤，并编写 R 代码实现（设置 $a = 5$ 、 $b = 10$ ）。

解 对于 $U(0, 1)$ 的 $n = a + b - 1$ 个独立样本，其第 a 个次序统计量 $X_{(a)} \sim Beta(a, b)$ 。抽样步骤如下：

- 产生 $n = a + b - 1$ 个 $U(0, 1)$ 随机数；
- 排序后取第 a 个值即为所求随机数。

R 代码实现如下：

```

1  set.seed(1)
2  n <- 10000 # 确定产生随机数的个数
3  a <- 5     # 确定参数a
4  b <- 10    # 确定参数b
5  m <- a + b - 1 # 确定均匀随机数个数
6  eta <- NULL
7  for (i in 1:n) {
8    x <- runif(m, 0, 1)
9    sx <- sort(x) # 将x排序
10   eta[i] <- sx[a] # 第a个次序统计量为Beta(a,b)的随机数
11 }
12 hist(eta, 30, freq = F) # 随机数分布
13 x0 <- seq(min(eta), max(eta), 0.01)
14 lines(x0, dbeta(x0, a, b), 'l', col = 'red') # 概率密度函数

```

以上内容非课程内容，仅供拓展！！

1.1.5 复合抽样法

定理 1.6 (复合抽样法)

设随机变量 η 的分布函数和概率密度函数分别为 $F(x)$ 和 $f(x)$, 且可表示为:

$$F(x) = \sum_{j=1}^k p_j F_j(x), \quad f(x) = \sum_{j=1}^k p_j f_j(x)$$

其中 $p_j \geq 0$, $\sum_{j=1}^k p_j = 1$, $F_j(x)$ 、 $f_j(x)$ 分别为随机变量 ξ_j 的分布函数和概率密度函数。产生随机数的步骤如下:

1. 产生 $U \sim U(0, 1)$, 若 $U \in \left[\sum_{j=1}^{l-1} p_j, \sum_{j=1}^l p_j \right)$, 令 $J = l$;
2. 产生分布为 $F_J(x)$ (或密度为 $f_J(x)$) 的随机数, 记为 η 。

则 η 具有上述分布函数和概率密度函数。



证明 根据全概率公式, η 的分布函数为:

$$P(\eta \leq x) = \sum_{j=1}^k P(J = j)P(\eta \leq x | J = j) = \sum_{j=1}^k p_j F_j(x)$$

求得密度函数 $f(x) = \sum_{j=1}^k p_j f_j(x)$, 定理得证。



笔记 复合抽样法步骤如下:

1. 产生 $U \sim U(0, 1)$, 根据 U 的取值区间确定抽样分布;
2. 产生对应分布的随机数作为输出。



练习 1.17 产生双指数分布的随机数, 其概率密度函数为 $f(x) = \frac{1}{2}e^{-|x|}$, 要求通过复合抽样法设计抽样步骤, 并编写 R 代码实现。

解 将密度函数分解为:

$$f(x) = \frac{1}{2}e^{-x}I(x > 0) + \frac{1}{2}e^xI(x < 0)$$

其中 $p_1 = p_2 = 1/2$, $f_1(x) = e^{-x}I(x > 0)$ (指数分布), $f_2(x) = e^xI(x < 0)$ (逆变换法产生)。抽样步骤如下:

1. 产生均匀随机数 $U \sim U(0, 1)$;
2. 如果 $U \leq 1/2$, 令 $\eta = \xi_1$ ($\xi_1 \sim \text{Exp}(1)$); 如果 $U > 1/2$, 令 $\eta = \log(R)$ ($R \sim U(0, 1)$)。

R 代码实现如下:

```

1  set.seed(1)
2  n <- 10000 # 确定产生随机数的个数
3  eta <- NULL
4  for (i in 1:n) {
5    u <- runif(1, 0, 1)
6    if (u <= 0.5) {
7      eta[i] <- rexp(1, 1)
8    } else {
9      R <- runif(1, 0, 1)
10     eta[i] <- log(R)
11   }
12 }
13 hist(eta, 30, freq = F) # 随机数分布
14 x0 <- seq(min(eta), max(eta), 0.01)
15 lines(x0, 0.5 * exp(-abs(x0)), 'l', col = 'red') # 概率密度函数

```



练习 1.18 课堂代码练习 将上述代码重新写, 从而尽量避免使用循环。

 **练习 1.19** 产生混合正态分布的随机数，其概率密度函数为：

$$f(x) = p_1 f_1(x) + p_2 f_2(x) + p_3 f_3(x)$$

其中， $f_1(x)$, $f_2(x)$ 和 $f_3(x)$ 分别是 $N(\mu_1, \sigma_1)$ 、 $N(\mu_2, \sigma_2)$ 和 $N(\mu_3, \sigma_3)$ 的概率密度函数，要求编写 R 代码实现。

解

1. 产生 $U \sim U(0, 1)$ ，如果 $U \in \left(\sum_{j=1}^{l-1} p_j, \sum_{j=1}^l p_j\right)$ ，令 $J = l$ ；
2. 产生 $N(\mu_J, \sigma_J)$ 的随机数，记为 η 。

产生随机数 η 的 R 代码如下（以 $p_1 = p_2 = p_3 = 1/3$ ， $f_1(x)$, $f_2(x)$ 和 $f_3(x)$ 分别是 $N(0, 1)$ 、 $N(1, 1.5)$ 和 $N(-2, 2)$ 为例）

```

1      set.seed(1)
2      n <- 10000 # 确定产生随机数的个数
3      eta <- NULL
4      mu1 <- 0; mu2 <- 1; mu3 <- -2
5      sigma1 <- 1; sigma2 <- 1.5; sigma3 <- 2
6      for (i in 1:n) {
7          u <- runif(1, 0, 1)
8          if (u <= 1/3) {
9              eta[i] <- rnorm(1, mu1, sigma1)
10             } else if (u > 1/3 & u <= 2/3) {
11                 eta[i] <- rnorm(1, mu2, sigma2)
12             } else {
13                 eta[i] <- rnorm(1, mu3, sigma3)
14             }
15         }
16         hist(eta, 30, freq = F) # 随机数分布
17         x0 <- seq(min(eta), max(eta), 0.01)
18         lines(x0, 1/3*(dnorm(x0, mu1, sigma1) + dnorm(x0, mu2, sigma2) + dnorm(x0, mu3, sigma3)), 'l', col
              = 'red')

```

1.1.6 近似抽样法（中心极限定理）

近似抽样法适用于分布复杂、直接抽样困难的场景，基于中心极限定理的近似抽样是最常用的方法之一。

定理 1.7 (中心极限定理)

设 $\{\xi_1, \xi_2, \dots, \xi_m\}$ 为独立同分布的随机变量序列，数学期望为 μ 、方差为 σ^2 ，令：

$$\eta_m = \frac{1}{\sqrt{m}\sigma} \left(\sum_{i=1}^m \xi_i - m\mu \right)$$

则 $\lim_{m \rightarrow \infty} F_m(x) = \Phi(x)$ ，其中 $\Phi(\cdot)$ 为标准正态分布的分布函数，即 $\eta_m \xrightarrow{d} N(0, 1)$ 。



 **练习 1.20** 利用中心极限定理产生 $N(0, 1)$ 随机数，要求推导抽样公式并编写 R 代码实现（设置 $m = 12$ ）。

解 利用 $U(0, 1)$ 随机变量（期望 $1/2$ 、方差 $1/12$ ），抽样公式为：

$$\eta = \sqrt{\frac{12}{m}} \sum_{i=1}^m \left(\xi_i - \frac{1}{2} \right)$$

R 代码实现如下：

```

1  set.seed(1)
2  n <- 10000 # 确定产生随机数的个数
3  eta <- NULL
4  m <- 12
5  for (i in 1:n) {
6    u <- runif(m, 0, 1)
7    eta[i] <- sqrt(12/m) * sum(u - 1/2)
8  }
9  hist(eta, 30, freq = F) # 随机数分布
10 x0 <- seq(min(eta), max(eta), 0.01)
11 lines(x0, dnorm(x0, 0, 1), 'l', col = 'red') # 概率密度函数

```

1.1.7 近似抽样法（其他方法，非课程内容）

除中心极限定理外，近似抽样还包括密度函数近似（Butler）、分布函数近似、经验分布抽样法，以下是核心实现：

1. 密度函数近似抽样（Butler 抽样法） 将密度函数分解为多个简单函数的线性组合，再通过复合抽样法产生随机数。

 **练习 1.21** 用 Butler 抽样法产生 $N(0, 1)$ 随机数（取 $a = -6$ 、 $b = 6$ 、 $m = 40$ ），R 代码实现如下：
解

```

1  set.seed(1)
2  n <- 100000 # 确定产生随机数的个数
3  eta <- NULL
4  m <- 40 # 确定小区间个数
5  fx <- function(x) {
6    resu <- sqrt(1/(2*pi)) * exp(-x^2/2) # 理论概率密度函数
7    return(resu)
8  }
9  Fx <- function(x) {
10   resu <- integrate(fx, lower = -6, upper = x)$value # 理论分布函数
11   return(resu)
12 }
13 x <- seq(-6, 6, 0.0001)
14 Npdf <- fx(x)
15 Ncdf <- sapply(x, Fx)
16 xd <- NULL
17 for (i in 1:m) { # 确定m个小区间的分割点
18   index <- min(which(abs(Ncdf - i/m) < 0.0001))
19   xd[i] <- x[index]
20 }
21 xd <- c(x[1], xd)
22 for (i in 1:n) {
23   r <- runif(1, 0, 1)
24   k <- floor(m * r + 1)
25   u1 <- runif(1, 0, 1)
26   u2 <- runif(1, 0, 1)

```

```

27     dk <- abs(fx(xd[k+1]) - fx(xd[k])) / (fx(xd[k+1]) + fx(xd[k]))
28     if (u2 <= dk) {
29         if (fx(xd[k+1]) > fx(xd[k])) {
30             eta[i] <- xd[k] + (xd[k+1] - xd[k]) * sqrt(u1)
31         } else {
32             eta[i] <- xd[k+1] - (xd[k+1] - xd[k]) * sqrt(1 - u1)
33         }
34     } else {
35         eta[i] <- xd[k] + (xd[k+1] - xd[k]) * u1
36     }
37 }
38 hist(eta, 40, xlim = c(-6, 6), freq = F)
39 lines(x, dnorm(x, 0, 1), 'l', col = 'red') # 概率密度函数

```

2. 分布函数近似抽样 将分布函数分解为区间上的分段近似，核心 R 代码实现如下：

 **练习 1.22** 用分布函数近似抽样法产生 $N(0, 1)$ 随机数（取 $a = -6$ 、 $b = 6$ 、 $m = 40$ ）：
解

```

1     set.seed(1)
2     n <- 100000 # 确定产生随机数的个数
3     eta <- NULL
4     m <- 40 # 确定小区间个数
5     fx <- function(x) {
6         resu <- sqrt(1/(2*pi)) * exp(-x^2/2)
7         return(resu)
8     }
9     Fx <- function(x) {
10        resu <- integrate(fx, lower = -6, upper = x)$value # 理论分布函数
11        return(resu)
12    }
13    x <- seq(-6, 6, 0.0001)
14    xd <- x[1] + seq(0, m) * 12/m # 平均分割取值区间
15    p <- sapply(1:(length(xd)-1), function(i) Fx(xd[i+1]) - Fx(xd[i])) # 计算权系数
16    cump <- cumsum(p)
17    for (i in 1:n) {
18        r <- runif(1, 0, 1)
19        k <- min(which(cump >= r)) # 确定抽样区间为第k个区间
20        u <- runif(1, 0, 1)
21        eta[i] <- xd[k] + (xd[k+1] - xd[k]) * u
22    }
23    hist(eta, 40, xlim = c(-6, 6), freq = F)
24    lines(x, dnorm(x, 0, 1), 'l', col = 'red') # 概率密度函数

```

3. 经验分布抽样法 基于观测数据的经验分布函数抽样，核心规则：

1. 已知原始数据：产生 $U_1 \sim U(0, 1)$ 确定序号 k ，再产生 $U_2 \sim U(0, 1)$ 生成 $\eta = x_{(k)} + U_2(x_{(k+1)} - x_{(k)})$ ；
2. 已知分组频数：产生 $U \sim U(0, 1)$ 确定区间 k ，生成 $\eta = a_{k-1} + \frac{U - F_n(a_{k-1})}{F_n(a_k) - F_n(a_{k-1})}(a_k - a_{k-1})$ 。

1.2 离散分布随机数的抽样法

离散型随机变量的随机数产生常用逆变换法，以下详细介绍。

1.2.1 逆变换法

定理 1.8 (离散逆变换抽样法)

设 $\{x_i\}$ 为离散型随机变量 ξ 的所有可能取值, $p_i = P(\xi = x_i)$, 分布函数为 $F(x) = \sum_{x_i \leq x} p_i$ 。产生随机数的步骤如下:

1. 产生 $R \sim U(0, 1)$;
2. 如果 $R \leq F(x_1)$, 则令 $\xi = x_1$; 如果 $F(x_{i-1}) < R \leq F(x_i) (i = 2, 3, \dots)$, 则令 $\xi = x_i$ 。
则 ξ 是分布 $F(x)$ 的随机数。

证明 根据随机数 ξ 的产生方法, 有:

$$P(\xi = x_1) = P(R \leq F(x_1)) = F(x_1) = p_1$$

$$P(\xi = x_i) = P(F(x_{i-1}) < R \leq F(x_i)) = F(x_i) - F(x_{i-1}) = p_i, i = 2, 3, \dots$$

所以 $\xi \sim F(x)$, 定理得证。

 **练习 1.23** 已知离散型随机变量的概率分布列如下表, 试用逆变换法产生服从该分布的随机数, 并编写 R 代码验证。

解 抽样步骤如下:

1. 产生 $R \sim U(0, 1)$;
2. 按以下规则确定随机数:

$$\xi = \begin{cases} 1, & R \leq 0.1 \\ 2.5, & 0.1 < R \leq 0.3 \\ 3.5, & 0.3 < R \leq 0.6 \\ 5, & 0.6 < R \leq 0.8 \\ 6, & 0.8 < R \leq 1 \end{cases}$$

R 代码验证如下:

```

1  set.seed(1)
2  X <- c(1, 2.5, 3.5, 5, 6)
3  prob <- c(0.1, 0.2, 0.3, 0.2, 0.2) # 离散分布列
4  Fx <- cumsum(prob) # 分布函数
5  n <- 10000 # 产生随机数的个数
6  xi <- NULL
7  for (i in 1:n) {
8    r <- runif(1, 0, 1)
9    if (r <= prob[1]) {
10     xi[i] <- X[1]
11   } else {
12     xi[i] <- X[min(which(Fx >= r))]
13   }
14 }
15 # 逆变换法产生的随机数分布
16 cat("逆变换法随机数分布: \n")

```

```

17 print(table(xi)/n)
18 # 直接抽样产生的随机数分布 (对比验证)
19 x_direct <- sample(X, size = n, replace = TRUE, prob = prob)
20 cat("直接抽样随机数分布: \n")
21 print(table(x_direct)/n)

```

结论 本章节共介绍了几种连续非均匀随机数的产生方法 (逆变换, 舍选, 变换, 复合, 近似等)。事实上, 在 R 语言中, 已经给出了常用的连续型随机数的产生函数, 例如, 均匀分布 (runif)、正态分布 (rnorm)、对数正态分布 (rlnorm)、指数分布 (rexp)、Gamma 分布 (rgamma)、Beta 分布 (rbeta)、t 分布 (rt)、 χ^2 分布 (rchisq)、F 分布 (rf) 等。

在实际运用的过程中, 可以直接使用已有的函数进行运算 (除非作业或考试说明要用 PIT, A-R 等等)。对于不常用的分布, 需要思考具体方法并自己写函数。

第一章 练习

1. 补充例题练习

- (a). (使用逆变换法) 对于 $0 < m < 1$, 三角形分布 $Tri(0, 1, m)$ 的密度函数为 $p(x) = 2x/m$ (若 $0 < x \leq m$), $2(1-x)/(1-m)$ (若 $m < x < 1$)。求如何从其分布中抽样, 并写出代码。
- (b). (舍选法) 生成服从 $p(x) = \frac{1}{\Gamma(3/2)} x^{1/2} e^{-x}, x > 0$ 的随机数 Z , 其中已知 $\Gamma(3/2) = \sqrt{\pi}/2$ (已知 $E(Z) = 3/2$)。

2. 作业 1

原则: 纸笔推导 (每个人都要交) + 分组完成代码

- (a). 编写 R 函数: 输入向量 x 后, 输出 $\phi = \frac{n}{(n-1)(n-2)} \sum_{i=1}^n \left(\frac{x_i - \bar{x}}{s} \right)^3$, 其中 n 为向量长度, $\bar{x}, s$ 分别表示样本均值与样本标准差。
- (b). 生成密度为 $p(x) = \frac{2}{\pi\sqrt{1-x^2}}, x \in [0, 1]$ 的随机数。
- (c). 生成密度为 $p(x) = \cos(x), x \in [0, \pi/2]$ 的随机数。
- (d). 课本 (人大) P24: 1.1 (用逆变换抽样与舍选抽样)
Pareto(a,b) 分布具有累积分布函数 $F(x) = 1 - \left(\frac{b}{x}\right)^a$ ($x \geq b > 0, a > 0$), 利用逆变换法产生 $a = 2, b = 2$ 时 Pareto 分布的随机样本, 同时绘制样本密度直方图和分布密度曲线图来比较随机数的产生效果。
- (e). 课本 (人大) P24: 1.2 (用逆变换抽样与舍选抽样)
生成样本量为 1000、服从正态混合分布 $p_1 N(0, 1) + (1 - p_1) N(3, 1)$ 的随机样本 ($p_1 = 0.5$), 同时绘制样本密度直方图和分布密度曲线图比较随机数的产生效果。
- (f). 课本 (人大) P24: 1.3 (用逆变换抽样与舍选抽样)
Rayleigh 分布具有密度函数 $f(x) = \frac{x}{\sigma^2} e^{-\frac{x^2}{2\sigma^2}}$ ($x > 0, \sigma > 0$), 给定 $\sigma = 1$, 设计多种方法生成该分布的随机数。

解法一: 逆变换法

```

1 import numpy as np
2 import matplotlib.pyplot as plt
3 np.random.seed(1)
4 n = 10000 # 样本量
5 sigma = 1 # 参数
6 r = np.random.rand(n) # 生成U(0,1)随机数
7 x = np.sqrt(-2 * sigma**2 * np.log(1 - r)) # 逆变换抽样公式
8
9 # 绘制图形

```

```

10 x0 = np.arange(0, 4, 0.01)
11 fx = x0 / (sigma**2) * np.exp(-x0**2 / (2 * sigma**2)) # 理论密度函数
12 plt.figure(figsize=(8, 4))
13 plt.hist(x, 20, density=True, label='样本密度直方图')
14 plt.plot(x0, fx, 'r-', label='理论密度曲线')
15 plt.xlabel('x')
16 plt.ylabel('密度')
17 plt.legend()
18 plt.title('逆变换法生成Rayleigh分布随机数')
19 plt.show()

```

法二：变换抽样法，利用 $Y \sim \text{Exp}(2\sigma^2)$, $X = \sqrt{Y}$:

```

1 import numpy as np
2 import matplotlib.pyplot as plt
3 np.random.seed(1)
4 n = 10000 # 样本量
5 sigma = 1 # 参数
6 # 生成Exp(2^2)随机数 (scale为指数分布均值, 即2^2)
7 y = np.random.exponential(scale=2 * sigma**2, size=n)
8 x = np.sqrt(y) # 变换得到Rayleigh分布
9
10 # 绘制图形
11 x0 = np.arange(0, max(x), 0.01)
12 fx = x0 / (sigma**2) * np.exp(-x0**2 / (2 * sigma**2)) # 理论密度函数
13 plt.figure(figsize=(8, 4))
14 plt.hist(x, 20, density=True, label='样本密度直方图')
15 plt.plot(x0, fx, 'r-', label='理论密度曲线')
16 plt.xlabel('x')
17 plt.ylabel('密度')
18 plt.legend()
19 plt.title('变换抽样法生成Rayleigh分布随机数')
20 plt.show()

```

法三：舍选抽样法，取 $L = \sqrt{2e/\pi}$, $h(x) = e^{-(x-1)^2/2}$, $f(x) = e^{-x}$:

```

1 import numpy as np
2 import matplotlib.pyplot as plt
3 np.random.seed(1)
4 n = 10000 # 样本量
5 sigma = 1 # 参数
6 z = []
7 i = 0
8 m = 0 # 记录总生成次数
9
10 while i < n:
11     m += 1
12     x = np.random.exponential(1, 1) # 生成Exp(1)随机数
13     y = np.random.rand(1) # 生成U(0,1)随机数
14     ay = np.exp(-(x - 1)**2 / 2) # 舍选条件h(x)
15     if y <= ay:

```

```

16         z.append(x[0])
17         i += 1
18
19         # 绘制图形
20         x0 = np.arange(0, max(z), 0.01)
21         fx = x0 / (sigma**2) * np.exp(-x0**2 / (2 * sigma**2)) # 理论密度函数
22         plt.figure(figsize=(8, 4))
23         plt.hist(z, 20, density=True, label='样本密度直方图')
24         plt.plot(x0, fx, 'r-', label='理论密度曲线')
25         plt.xlabel('x')
26         plt.ylabel('密度')
27         plt.legend()
28         plt.title('舍选抽样法生成Rayleigh分布随机数')
29         plt.show()

```

(g). 讨论能够生成密度函数 $p(x) = \frac{1}{0.000336}x(1-x)^3, 0.8 < x < 1$ 的随机数的有效算法。

3. 判断题（共 2 题）

1. 复合抽样法和近似抽样法都是用于生成连续非均匀随机数的方法。

（正确答案：错误；解析：复合抽样法不仅适用于连续分布，也可用于离散分布（如混合分布），近似抽样法虽主要用于连续分布，但题干“都是”表述绝对，故错误）

2. 在一维非均匀随机数的产生中，舍选抽样法是其中一种常用的方法。

（正确答案：正确；解析：舍选抽样法通过“生成-检验-舍弃”机制，适用于分布函数反函数难求解的连续非均匀随机数生成，是核心方法之一）

4. 多选题（共 2 题）

1. 关于一维非均匀随机数的产生方法，下列哪些选项是正确的？

- A、逆变换抽样法是利用分布函数的逆函数来生成随机数的一种方法。
- B、舍选抽样法是一种通过舍弃不满足特定条件的样本来生成随机数的方法。
- C、变换抽样法是将一种已知分布的随机数通过变换得到所需分布的随机数的方法。
- D、复合抽样法适用于离散分布随机数的生成。（错误，复合抽样法也适用于连续混合分布）
- E、近似抽样法是通过近似的方法来生成非均匀分布的随机数。

（正确答案：ABCE）

（解析：复合抽样法适用于“分布可表示为多个已知分布线性组合”的场景，既包含离散也包含连续，故 D 错误；其余选项均符合各方法核心定义）

2. 在一维非均匀随机数的产生中，下列哪些抽样方法可以用于生成连续型随机数？

- A、逆变换抽样法
- B、舍选抽样法
- C、变换抽样法
- D、复合抽样法

（正确答案：ABCD）（解析：逆变换法通过分布函数逆函数生成，舍选法通过检验条件筛选，变换法通过函数变换已知分布，复合法通过组合多个连续分布生成，均适用于连续型随机数）

5. 离散型随机变量 X 的分布列为：设计算法生成样本量为 1000 的随机数，并比较观测频率与理论概

X	0	1	2	3	4
$P(X)$	0.1	0.2	0.2	0.2	0.3

率：

```

1 import numpy as np
2 import pandas as pd
3 np.random.seed(1)
4 X = [0, 1, 2, 3, 4]
5 prob = [0.1, 0.2, 0.2, 0.2, 0.3]
6 Fx = np.cumsum(prob) # 累积分布函数
7 n = 1000 # 样本量
8 xi = []
9
10 # 逆变换法生成随机数
11 for _ in range(n):
12     r = np.random.rand(1)
13     if r <= prob[0]:
14         xi.append(X[0])
15     else:
16         # 找到首个满足累积分布 r 的索引
17         xi.append(X[np.min(np.where(Fx >= r))])
18
19 # 直接抽样法（对比验证）
20 x_direct = np.random.choice(X, size=n, replace=True, p=prob)
21
22 # 计算观测频率
23 freq_inverse = pd.DataFrame(xi)[0].value_counts(normalize=True).sort_index()
24 freq_direct = pd.DataFrame(x_direct)[0].value_counts(normalize=True).sort_index()
25 theory = pd.Series(prob, index=X, name='理论概率')
26
27 # 输出对比结果
28 print("逆变换法观测频率：")
29 print(freq_inverse)
30 print("\n直接抽样法观测频率：")
31 print(freq_direct)
32 print("\n理论概率：")
33 print(theory)

```

6. Cauchy 分布的概率密度函数为 $f(x) = \frac{1}{\pi(1+x^2)}$ ，分布函数为 $F(x) = \frac{1}{2} + \frac{1}{\pi} \arctan(x)$ 。利用逆变换法产生样本量为 1000 的随机样本，绘制样本密度直方图与理论曲线：

```

1 import numpy as np
2 import matplotlib.pyplot as plt
3 np.random.seed(1)
4 n = 1000 # 样本量
5 r = np.random.rand(n) # 生成U(0,1)随机数
6 x = np.tan(np.pi * (r - 0.5)) # 逆变换抽样公式 ( $F^{-1}(u) = \tan(\pi(u-0.5))$ )
7
8 # 绘制图形（限制x范围为[-10,10]以聚焦主要分布区域）
9 x0 = np.arange(-10, 10, 0.01)
10 fx = 1 / (np.pi * (1 + x0**2)) # 理论密度函数
11 plt.figure(figsize=(8, 4))
12 plt.hist(x, 20, range=(-10, 10), density=True, label='样本密度直方图')
13 plt.plot(x0, fx, 'r-', label='理论密度曲线')

```

```

14     plt.xlabel('x')
15     plt.ylabel('密度')
16     plt.legend()
17     plt.title('逆变换法生成Cauchy分布随机数')
18     plt.show()

```

7. 编写程序生成 n 个如下离散分布的随机数: $P(X=1)=1/3$, $P(X=2)=2/3$, 完成以下任务:
 - (a). 生成 $n=100, 1000, 10000$ 个随机数, 分别计算 $X=1$ 的百分比;
 - (b). 用中心极限定理推导 n 个随机数中 $X=1$ 的百分比 f_n 的渐近分布, 并检验上述三组样本是否与 $P(X=1)=1/3$ 相符。
8. 设随机变量 X 服从离散分布 $P(X=k)=p_k$ ($k=1, 2, \dots, m$), 编写 R 程序, 输入 $\{p_k\}$, 输出 n 个该离散分布的随机数。
9. 洗好一副编号为 $1, 2, \dots, 54$ 的纸牌, 依次抽取, 若第 i 次抽取到编号 i 的纸牌则称为“成功抽取”。编写程序估计成功抽取个数 T 的期望和方差, 推导理论公式并与模拟结果比较。
10. 做投掷两枚骰子的试验, 连续试验直到点数之和的所有可能值 $2, 3, \dots, 12$ 都出现一次, 所需试验次数记为 T 。用随机模拟方法估计 T 的期望和方差。
11. 设 X 服从负二项分布 (第 r 次成功所需试验次数), 完成以下任务:
 - (a). 利用负二项分布与几何分布的关系 ($X=X_1+X_2+\dots+X_r$, $X_i \sim \text{Geom}(p)$ 独立) 构造 X 的随机数;
 - (b). 直接利用负二项分布的概率递推式构造 X 的随机数。
12. 用变换法生成如下分布的随机数:
 - (a). Beta($1/n, 1$), 密度 $p(x) = \frac{1}{n}x^{1/n-1}$ ($x \in [0, 1]$);
 - (b). Beta($n, 1$), 密度 $p(x) = nx^{n-1}$ ($x \in [0, 1]$);
 - (c). 密度 $p(x) = \frac{2}{\pi\sqrt{1-x^2}}$ ($x \in [0, 1]$);
 - (d). 柯西分布, 密度 $p(x) = \frac{1}{\pi(1+x^2)}$ ($x \in (-\infty, \infty)$);
 - (e). 密度 $p(x) = \cos(x)$ ($x \in [0, \pi/2]$);
 - (f). 威布尔分布, 密度 $p(x) = \frac{\alpha}{\eta}x^{\alpha-1}e^{-x^\alpha/\eta}$ ($x > 0, \alpha > 0, \eta > 0$)。
13. 设 $X \sim \text{Exp}(1)$, 模拟 $X < 0.05$ 条件下 X 的分布 (密度 $p(x) = \frac{e^{-x}}{1-e^{-0.05}}$, $0 < x < 0.05$):
 - (a). 生成 1000 个该条件分布的随机数;
 - (b). 用模拟结果估计 $E(X|X < 0.05)$, 推导理论值并比较。
14. 设 X 的分布为 $P(X=k) = \frac{e^{-\lambda}\lambda^k/k!}{\sum_{i=0}^m e^{-\lambda}\lambda^i/i!}$ ($k=0, 1, \dots, m$), 给出两种模拟该分布的方法。
15. 设 $X \sim B(n, p)$, k 为给定整数 ($0 \leq k \leq n$), Y 的分布为 $P(Y \leq y) = P(X \leq y|X \geq k)$, 记 $\alpha = P(X \geq k)$:
 - (a). 分别用逆变换法和舍选法生成 Y 的随机数;
 - (b). 分析 α 取大值或小值时, 舍选法是否可取。
16. 给出生成密度 $p(x) = xe^{-x}$ ($x > 0$) 的随机数的两种方法, 并比较其效率 (提示: 方法一: 利用 Gamma 分布性质; 方法二: 舍选法)。
17. 设 X 分别以概率 $0.06, 0.06, 0.06, 0.06, 0.06, 0.15, 0.13, 0.14, 0.15, 0.13$ 取值 $1, 2, \dots, 10$, 用复合法给出该分布随机数的生成算法。
18. 设 X 的分布为 $P(X=k) = \frac{1}{2^{k+1}} + \frac{2^{k-1}}{3^k}$ ($k=1, 2, \dots$), 给出模拟该随机变量的算法。
19. 设 $X \sim \text{Laplace}$ 分布 (双指数分布), 密度 $p(x) = \frac{1}{2}e^{-|x|}$ ($x \in (-\infty, \infty)$), 分别用逆变换法和复合法生成 X 的随机数。
20. 给出生成密度 $p(x) = \frac{1}{0.000336}x(1-x)^3$ ($0.8 < x < 1$) 的随机数的有效算法 (提示: 考虑条件分布或舍选法, 选择合适的试投密度)。
21. 设 $X \sim RT(a, b)$ (右三角形分布, 密度 $p_R(x) = \frac{2(x-a)}{(b-a)^2}$, $x \in (a, b)$), $Y \sim LT(a, b)$ (左三角形分布, 密度 $p_L(x) = \frac{2(b-x)}{(b-a)^2}$, $x \in (a, b)$), 证明:
 - (a). 若 $X \sim RT(0, 1)$, 则 $Y = a+(b-a)X \sim RT(a, b)$; 若 $X \sim LT(0, 1)$, 则 $Y = a+(b-a)X \sim LT(a, b)$;

- (b). $X \sim RT(0, 1)$ 当且仅当 $1 - X \sim LT(0, 1)$;
- (c). 若 $U_1, U_2 \sim U(0, 1)$ 独立, 则 $X = \max(U_1, U_2) \sim RT(0, 1)$, $Y = \min(U_1, U_2) \sim LT(0, 1)$ 。
22. 设 $\alpha \sim U(0, 2\pi)$, $R \sim \text{Exp}(1/2)$ 与 α 独立, 令 $\begin{cases} X = \sqrt{R} \cos \alpha \\ Y = \sqrt{R} \sin \alpha \end{cases}$, 证明 X, Y 独立且均服从 $N(0, 1)$ 。
23. 设 $U_1, U_2, \dots, U_k, V_1, V_2, \dots, V_{k-1}$ 独立同 $U(0, 1)$, 令 $T = -\ln(U_1 U_2 \cdots U_k)$, $V_{(1)} \leq V_{(2)} \leq \cdots \leq V_{(k-1)}$ 为 $V_1, \dots, V_{k-1}$ 的次序统计量 (记 $V_{(0)} = 0, V_{(k)} = 1$), 令 $X_i = T(V_{(i)} - V_{(i-1)})$ ($i = 1, 2, \dots, k$), 证明 $X_1, \dots, X_k$ 独立同 $\text{Exp}(1)$ 。
24. 设随机向量 (X, Y) 服从单位圆 $C = \{(x, y) : x^2 + y^2 \leq 1\}$ 上的均匀分布, $R^2 = X^2 + Y^2$, θ 为 (X, Y) 的极角, 证明 R^2 与 θ 独立, 且 $R^2 \sim U(0, 1)$, $\theta \sim U(0, 2\pi)$ 。
25. 设随机变量 X 的分布函数为 $G(x)$, 密度为 $g(x)$, 对 $a < b$, 令 $F(x) = \frac{G(x) - G(a)}{G(b) - G(a)}$ ($a \leq x \leq b$):
- (a). 说明 $F(x)$ 对应的分布是 X 的什么条件分布;
- (b). 证明: 反复生成 $X \sim G(x)$ 直到 $X \in [a, b]$, 输出 X 即为 $F(x)$ 的随机数。
26. 设 X 的概率分布为 $p_k = P(X = k)$ ($\sum p_k = 1$), 记 $\lambda_n = P(X = n | X > n-1) = \frac{p_n}{1 - \sum_{i=1}^{n-1} p_i}$ ($n = 1, 2, \dots$):
- (a). 证明 $p_1 = \lambda_1$, $p_n = (1 - \lambda_1)(1 - \lambda_2) \cdots (1 - \lambda_{n-1})\lambda_n$ ($n \geq 2$);
- (b). 证明 “离散机会比方法” (生成 $U \sim U(0, 1)$ 直到 $U < \lambda_k$, 输出 $X = k$) 产生的随机数符合 X 的分布;
- (c). 若 $X \sim \text{Geom}(p)$, 求 λ_n , 说明该算法的有效性。

第二章 随机向量随机数的抽样法

内容提要

□ 二维随机向量变换定理 2.1

□ 随机向量舍选定理 2.3

□ 条件分布抽样原理 2.1

2.1 连续随机向量随机数的抽样法

连续随机向量的抽样需基于联合密度函数，结合变换、条件分布或舍选机制实现，以下是三类核心方法的详细介绍。

2.1.1 变换抽样法（非课程内容）

多维随机向量的变换抽样法与一维原理一致，通过已知分布随机向量的可逆变换，得到目标分布的随机向量。

定理 2.1 (二维随机向量变换定理)

设随机向量 (ξ_1, ξ_2) 具有二维联合密度函数 $f(x_1, x_2)$ ，定义变换关系：

$$\begin{cases} y_1 = g_1(x_1, x_2) \\ y_2 = g_2(x_1, x_2) \end{cases}$$

若存在唯一反变换 $\begin{cases} x_1 = h_1(y_1, y_2) \\ x_2 = h_2(y_1, y_2) \end{cases}$ ，且反变换的雅可比行列式：

$$J = \begin{vmatrix} \frac{\partial x_1}{\partial y_1} & \frac{\partial x_1}{\partial y_2} \\ \frac{\partial x_2}{\partial y_1} & \frac{\partial x_2}{\partial y_2} \end{vmatrix} \neq 0$$

则随机向量 $(\eta_1, \eta_2) = (g_1(\xi_1, \xi_2), g_2(\xi_1, \xi_2))$ 的联合密度函数为：

$$p(y_1, y_2) = f(h_1(y_1, y_2), h_2(y_1, y_2)) \cdot |J|$$

证明 随机向量 (η_1, η_2) 的分布函数为：

$$P(\eta_1 \leq y_1, \eta_2 \leq y_2) = \iint_{\substack{g_1(x_1, x_2) \leq y_1 \\ g_2(x_1, x_2) \leq y_2}} f(x_1, x_2) dx_1 dx_2$$

通过反变换替换积分变量，利用雅可比行列式的变量替换公式，积分转化为：

$$\int_{-\infty}^{y_1} \int_{-\infty}^{y_2} f(h_1(u_1, u_2), h_2(u_1, u_2)) \cdot |J| du_1 du_2$$

对分布函数求导，即得联合密度函数表达式，定理得证。

例题 2.1 二维指数变换向量 用变换抽样法产生二维随机向量 (η_1, η_2) ，其联合密度函数为：

$$f(x_1, x_2) = \lambda^2 e^{-\lambda(x_1 + 2x_2)}, \quad x_1 + x_2 > 0; x_2 > 0$$

抽样步骤如下：

1. 独立产生参数为 λ 的指数分布随机数 $\xi_1 \sim \text{Exp}(\lambda)$ 和 $\xi_2 \sim \text{Exp}(\lambda)$ ；
2. 令变换关系 $\begin{cases} \eta_1 = \xi_1 - \xi_2 \\ \eta_2 = \xi_2 \end{cases}$ ，其雅可比行列式 $J = 1$ ；
3. 代入得到目标向量 (η_1, η_2) 。

```

1  set.seed(1)
2  n <- 1000
3  lambda <- 1
4  eta <- matrix(0, n, 2)
5  xi1 <- rexp(n, lambda)
6  xi2 <- rexp(n, lambda)
7  eta1 <- xi1 - xi2
8  eta2 <- xi2
9  eta <- cbind(eta1, eta2)
10 # 查看结果 (可选)
11 head(eta)
12 plot(eta, xlab = "eta1", ylab = "eta2", main = "二维变换抽样结果")

```

例题 2.2 二维正态向量 生成二维正态随机向量 $(\eta_1, \eta_2) \sim N_2(\mu, \Sigma)$, 其中 $\mu = \begin{pmatrix} \mu_1 \\ \mu_2 \end{pmatrix}$, $\Sigma = \begin{pmatrix} \sigma_1^2 & \rho\sigma_1\sigma_2 \\ \rho\sigma_1\sigma_2 & \sigma_2^2 \end{pmatrix}$ 。

```

1  set.seed(1)
2  n <- 1000
3  mu1 <- 0
4  mu2 <- 0
5  sigma1 <- 2
6  sigma2 <- 2
7  rho <- 0.8
8  xi1 <- rnorm(n, 0, 1)
9  xi2 <- rnorm(n, 0, 1)
10 eta1 <- sigma1 * xi1 + mu1
11 eta2 <- (sqrt(1 - rho^2) * xi2 + rho * xi1) * sigma2 + mu2
12 # 验证结果
13 cat("均值: ", mean(eta1), mean(eta2), "\n")
14 cov_matrix <- matrix(c(var(eta1), cor(eta1, eta2)*sd(eta1)*sd(eta2),
15   cor(eta1, eta2)*sd(eta1)*sd(eta2), var(eta2)), 2, 2)
16 print("协方差矩阵: ")
17 print(cov_matrix)

```

2.1.2 条件分布法

第一章介绍了产生一维非均匀随机数的方法。在实际应用中,常常需要产生 p 维随机向量 $(\xi_1, \xi_2, \dots, \xi_p)$ 的随机数。

若各分量独立, 则可对分量 $\xi_1, \xi_2, \dots, \xi_p$ 独立进行抽样。但很多情况下分量之间是相关的。

变换抽样法与 A-R 法是一维情况的推广, 不是全新的方法, 暂时不讲。之后在后续的章节中, 我们会继续介绍利用贝叶斯统计中的 Gibbs 抽样法 8.3 以及 Metropolis-Hastings 抽样法 8.2 进行采样。

下面将介绍最直接的抽样方法, 即利用条件分布进行抽样。

条件分布法通过将联合密度分解为边际密度与条件密度的乘积, 逐步抽样得到随机向量。

定义 2.1 (条件分布抽样原理)

设 p 维随机向量 $(\xi_1, \xi_2, \dots, \xi_p)$ 的联合密度函数可分解为:

$$f(x_1, x_2, \dots, x_p) = f_1(x_1) \cdot f_2(x_2|x_1) \cdots f_p(x_p|x_1, \dots, x_{p-1})$$

其中 $f_j(x_j|x_1, \dots, x_{j-1})$ 为条件密度函数, 抽样步骤为:

1. 生成 $x_1 \sim f_1(x_1)$;
2. 给定 x_1 , 生成 $x_2 \sim f_2(x_2|x_1)$;
3. 依次类推, 给定 $x_1, \dots, x_{p-1}$, 生成 $x_p \sim f_p(x_p|x_1, \dots, x_{p-1})$ 。

推论 2.1 (条件分布法抽样步骤)

设随机向量 $(\xi_1, \dots, \xi_p)$ 的联合密度为 $f(x_1, \dots, x_p)$, 其随机数可通过以下步骤生成:

1. 产生随机数 $x_1 \sim f_1(x_1)$;
2. 给定 $\xi_1 = x_1$, 产生随机数 $x_2 \sim f_2(x_2 | \xi_1 = x_1)$;
3. ...
4. 给定 $(\xi_1, \xi_2, \dots, \xi_{p-1}) = (x_1, x_2, \dots, x_{p-1})$, 产生随机数

$$x_p \sim f_p(x_p | (\xi_1, \xi_2, \dots, \xi_{p-1}) = (x_1, x_2, \dots, x_{p-1}))$$

由此得到的随机向量 $(x_1, x_2, \dots, x_p)$ 服从联合密度 $f(x_1, \dots, x_p)$, 该方法称为条件分布法。

 **练习 2.1** 上述分解方法是否是唯一的? 为什么? 会影响我们最终的结果吗?

解 1. 分解方法不唯一

原因: 联合密度的条件分布分解顺序可任意调整, 核心是“边际密度 + 条件密度”的组合不唯一。

例如对二维随机向量 (ξ_1, ξ_2) , 联合密度有两种等价分解:

$$\begin{cases} f(x_1, x_2) = f_1(x_1) \cdot f_2(x_2|x_1) & (\text{先抽 } \xi_1, \text{再抽 } \xi_2|\xi_1) \\ f(x_1, x_2) = f_2(x_2) \cdot f_1(x_1|x_2) & (\text{先抽 } \xi_2, \text{再抽 } \xi_1|\xi_2) \end{cases}$$

对 p 维向量, 分量的抽样顺序 (如先抽 ξ_3 、再抽 $\xi_1|\xi_3$ 、最后抽 $\xi_2|\xi_1, \xi_3$) 可任意排列, 每种顺序对应一种分解方式, 因此分解方法不唯一。

2. 分解方法不影响最终抽样结果

原因: 无论采用哪种分解顺序, 最终生成的随机向量都服从同一联合密度 $f(x_1, x_2, \dots, x_p)$ 。从概率理论上, 联合密度的分解本质是利用乘法公式:

$$P(A_1 A_2 \cdots A_p) = P(A_1)P(A_2|A_1) \cdots P(A_p|A_1 \cdots A_{p-1}) = P(A_p)P(A_{p-1}|A_p) \cdots P(A_1|A_2 \cdots A_p)$$

不同分解顺序仅改变“分步抽样的路径”, 但最终的联合概率 (密度) 保持不变, 因此抽样得到的随机向量服从的分布与分解顺序无关, 不会影响结果的正确性。

 **笔记** 分解顺序可能影响抽样的计算效率 (如某些条件分布更易抽样、某些顺序的条件密度计算更简单), 但不会影响抽样结果的分布特性。

例题 2.3 p 维联合密度的条件分布法抽样 试用条件分布法产生联合密度函数为:

$$f(x_1, \dots, x_p) = x_1^{p-1} + x_2^{p-1} + \cdots + x_p^{p-1}, \quad (x_i \in [0, 1], i = 1, 2, \dots, p)$$

的随机数。

我们不妨先尝试最容易的情况, 即 $p = 2$ 。

简化情形 $p = 2$ 试用条件分布法产生联合密度函数为:

$$f(x_1, x_2) = x_1 + x_2, \quad (x_1, x_2 \in [0, 1])$$

的随机数。

(1) 边际分布

对 x_2 积分可得:

$$f_1(x_1) = \int_0^1 (x_1 + x_2) dx_2 = x_1 + \frac{1}{2}, \quad 0 \leq x_1 \leq 1.$$

生成该边际分布的方法：通过 PIT（概率积分变换）求积分即可。

(2) 条件分布

给定 x_1 时，条件密度为：

$$f(x_2|x_1) = \frac{x_1 + x_2}{x_1 + \frac{1}{2}} = \frac{2x_2}{2x_1 + 1} + \frac{2x_1}{2x_1 + 1} = \frac{1}{2x_1 + 1} \cdot (2x_2) + \frac{2x_1}{2x_1 + 1} \cdot 1.$$

该条件分布为复合分布：

1. 以概率 $\frac{1}{2x_1+1}$ ，变量 x_2 服从密度为 $2x$ 的分布（取值为 0 到 1）；
2. 以概率 $\frac{2x_1}{2x_1+1}$ ， x_2 服从均匀分布 $U(0, 1)$ 。

生成密度函数为 $2x$ 的随机数的方法：通过 PIT 可证明其为均匀分布开根号（即若 $U \sim U(0, 1)$ ，则 $U^{1/2}$ 服从密度为 $2x$ 的分布）。

(3) 生成算法

1. 从 $U(0, 1)$ 中独立产生 R_1, U_1 ，若 $R_1 \leq 1/2$ ，取 $x_1 = U_1^{1/2}$ ；否则取 $x_1 = U_1$ 。
2. 给定 x_1 ，从 $U(0, 1)$ 中独立产生 R_2, U_2 ，若 $R_2 \leq 1/(2x_1 + 1)$ ，取 $x_2 = U_2^{1/2}$ ；否则取 $x_2 = U_2$ 。

R 代码实现（ $p = 2$ 情形）

```

1  set.seed(123)
2  generateVector_p2 <- function(){
3    # Step 1: generate x1
4    R1 <- runif(1); U1 <- runif(1)
5    if (R1 <= 1/2) {
6      x1 <- U1^(1/2)
7    } else {
8      x1 <- U1
9    }
10
11   # Step 2: generate x2 | x1
12   R2 <- runif(1); U2 <- runif(1)
13   if (R2 <= 1/(2*x1+1)) {
14     x2 <- U2^(1/2)
15   } else {
16     x2 <- U2
17   }
18
19   return(c(x1, x2))
20 }
21
22 xi = generateVector_p2()
23 print("生成的二维随机向量 (x1, x2): ")
24 print(xi)

```

推广： p 维联合密度的条件分布法抽样 设随机向量 $(\xi_1, \xi_2, \dots, \xi_p)$ 具有上述联合密度函数，且可分解为：

$$f(x_1, x_2, \dots, x_p) = f_1(x_1)f_2(x_2|x_1) \cdots f_p(x_p|x_1, \dots, x_{p-1}).$$

通过计算可得 $(\xi_1, \dots, \xi_j)$ ($j = 1, \dots, p-1$) 的联合密度函数为:

$$\begin{aligned} f(x_1, \dots, x_j) &= \int_0^1 \cdots \int_0^1 (x_1^{p-1} + x_2^{p-1} + \cdots + x_p^{p-1}) dx_{j+1} \cdots dx_p \\ &= \sum_{i=1}^j x_i^{p-1} + \frac{p-j}{p}. \end{aligned}$$

进而可得各条件分布的密度函数为:

$$\begin{aligned} f_j(x_j|x_1, \dots, x_{j-1}) &= \frac{f(x_1, \dots, x_j)}{f(x_1, \dots, x_{j-1})} \\ &= \frac{\sum_{i=1}^j x_i^{p-1} + (p-j)/p}{\sum_{i=1}^{j-1} x_i^{p-1} + (p-j+1)/p} \\ &= \frac{x_j^{p-1} + \sum_{i=1}^{j-1} x_i^{p-1} + (p-j)/p}{\sum_{i=1}^{j-1} x_i^{p-1} + (p-j+1)/p} \\ &= \frac{px_j^{p-1}}{p \sum_{i=1}^{j-1} x_i^{p-1} + (p-j+1)} + \frac{p \sum_{i=1}^{j-1} x_i^{p-1} + (p-j)}{p \sum_{i=1}^{j-1} x_i^{p-1} + (p-j+1)}. \end{aligned}$$

令 $f_j(x_j|x_1, \dots, x_{j-1}) = p_{j1}px_j^{p-1} + p_{j2}$, 其中:

$$p_{j1} = \frac{1}{p \sum_{i=1}^{j-1} x_i^{p-1} + (p-j+1)}, \quad p_{j2} = \frac{p \sum_{i=1}^{j-1} x_i^{p-1} + (p-j)}{p \sum_{i=1}^{j-1} x_i^{p-1} + (p-j+1)},$$

且 $p_{j1} + p_{j2} = 1$ 。特别地, 当 $j = 1$ 时, $p_{11} = 1/p$ 和 $p_{12} = (p-1)/p$ 。

条件密度 $f_j(x_j|x_1, \dots, x_{j-1})$ 的随机数可通过复合抽样法产生, 因此密度函数为 $f(x_1, \dots, x_p) = x_1^{p-1} + x_2^{p-1} + \cdots + x_p^{p-1}$ ($x_i \in [0, 1], i = 1, 2, \dots, p$) 的随机数 $(x_1, \dots, x_p)$ 可通过条件分布法产生:

1. 从均匀分布 $U(0, 1)$ 中独立产生随机数 R_1 和 U_1 , 如果 $R_1 \leq 1/p$, 取 $x_1 = U_1^{1/p}$; 否则, 取 $x_1 = U_1$;
2. 给定 x_1 , 从 $U(0, 1)$ 中独立产生随机数 R_2 和 U_2 , 如果 $R_2 \leq 1/(px_1^{p-1} + p - 1)$, 取 $x_2 = U_2^{1/p}$; 否则, 取 $x_2 = U_2$;
3. ...
4. 给定 $(x_1, x_2, \dots, x_{p-1})$, 从 $U(0, 1)$ 中独立产生随机数 R_p 和 U_p , 如果 $R_p \leq 1/(p \sum_{i=1}^{p-1} x_i^{p-1} + 1)$, 取 $\xi_p = U_p^{1/p}$; 否则, 取 $\xi_p = U_p$ 。得到密度函数为 $f(x_1, \dots, x_p)$ 的随机数 $x_1, \dots, x_p$ 。

R 代码实现 (以 $p = 5$ 为例)

```

1  set.seed(1)
2  p=5
3  generateVector = function(p){
4    vec = c()
5    for (i in 1:p){
6      # 计算复合抽样的阈值 point
7      point = 1 / (sum(p*(vec^(p-1))) + p-i+1)
8      threshold = runif(1)
9      if (threshold < point){
10         # 从密度为 p x^(p-1) 的分布抽样 (PIT: U^(1/p))
11         vec = c(vec, (runif(1))^(1/p))
12       } else {
13         # 从均匀分布 U(0,1) 抽样
14         vec = c(vec, runif(1))
15       }
16     }
17     return(vec)

```

```

18     }
19
20     xi=generateVector(p)
21     print(paste("生成的", p, "维随机向量: "))
22     print(xi)

```

例题 2.4 p 维正态分布向量的条件分布法抽样 试用条件分布法产生 p 维正态分布向量 $X = (X_1, X_2) \sim N_p(\mu, \Sigma)$ 的随机数, 其中:

$$\mu = \begin{pmatrix} \mu_1 \\ \mu_2 \end{pmatrix}, \quad \Sigma = \begin{pmatrix} \Sigma_{11} & \Sigma_{12} \\ \Sigma_{21} & \Sigma_{22} \end{pmatrix}.$$

且 X_1 和 X_2 分别为 k 和 $p-k$ 维向量。

定理 2.2 (正态分布的条件分布定理)

给定 $X_2 = x_2$, X_1 的条件分布是 $N_k(\mu_1 + \Sigma_{12}\Sigma_{22}^{-1}(x_2 - \mu_2), \Sigma_{11} - \Sigma_{12}\Sigma_{22}^{-1}\Sigma_{12}^T)$ 。

证明 对 X_1 和 X_2 作线性变换, 令:

$$\begin{cases} Y_1 = X_1 - \Sigma_{12}\Sigma_{22}^{-1}X_2, \\ Y_2 = X_2, \end{cases}$$

则 (Y_1, Y_2) 仍然服从正态分布。下证 Y_1 与 Y_2 独立 (即 $\text{Cov}(Y_1, Y_2) = 0$):

令 $A = -\Sigma_{12}\Sigma_{22}^{-1}$, 则:

$$\begin{aligned} \text{Cov}(Y_1, Y_2) &= \mathbb{E}(Y_1 Y_2^T) - \mathbb{E}(Y_1)\mathbb{E}(Y_2)^T \\ &= \mathbb{E}\left((X_1 + AX_2)X_2^T\right) - (\mu_1 + A\mu_2)\mu_2^T \\ &= \mathbb{E}(X_1 X_2^T) + A\mathbb{E}(X_2 X_2^T) - \mu_1 \mu_2^T - A\mu_2 \mu_2^T \\ &= \{\mathbb{E}(X_1 X_2^T) - \mu_1 \mu_2^T\} + A\{\mathbb{E}(X_2 X_2^T) - \mu_2 \mu_2^T\} \\ &= \Sigma_{12} + A\Sigma_{22} = \Sigma_{12} - \Sigma_{12}\Sigma_{22}^{-1}\Sigma_{22} = 0. \end{aligned}$$

正态分布 Y_1 的均值和方差分别为:

$$\begin{aligned} \mathbb{E}(X_1 - \Sigma_{12}\Sigma_{22}^{-1}X_2) &= \mathbb{E}(X_1) - \Sigma_{12}\Sigma_{22}^{-1}\mathbb{E}(X_2) = \mu_1 - \Sigma_{12}\Sigma_{22}^{-1}\mu_2, \\ \text{Var}(X_1 - \Sigma_{12}\Sigma_{22}^{-1}X_2) &= \text{Var}(X_1) + \Sigma_{12}\Sigma_{22}^{-1}\text{Var}(X_2)\left(\Sigma_{12}\Sigma_{22}^{-1}\right)^T - 2\Sigma_{12}\Sigma_{22}^{-1}\text{Cov}(X_1, X_2) \\ &= \Sigma_{11} + \Sigma_{12}\Sigma_{22}^{-1}\Sigma_{22}\Sigma_{22}^{-1}\Sigma_{12}^T - 2\Sigma_{12}\Sigma_{22}^{-1}\Sigma_{12}^T \\ &= \Sigma_{11} - \Sigma_{12}\Sigma_{22}^{-1}\Sigma_{12}^T. \end{aligned}$$

结合 $X_2 = Y_2$ 与 Y_1 独立、 $X_1 = Y_1 + \Sigma_{12}\Sigma_{22}^{-1}X_2$, 可得:

$$\begin{aligned} \mathbb{E}(X_1|X_2 = x_2) &= \mu_1 + \Sigma_{12}\Sigma_{22}^{-1}(x_2 - \mu_2), \\ \text{Var}(X_1|X_2 = x_2) &= \Sigma_{11} - \Sigma_{12}\Sigma_{22}^{-1}\Sigma_{12}^T. \end{aligned}$$

即 $X_1|X_2 = x_2 \sim N_k(\mu_1 + \Sigma_{12}\Sigma_{22}^{-1}(x_2 - \mu_2), \Sigma_{11} - \Sigma_{12}\Sigma_{22}^{-1}\Sigma_{12}^T)$ 。

因此, 在给定 $X_2 = x_2$ 时, $X_1 = Y_1 + \Sigma_{12}\Sigma_{22}^{-1}X_2$ 的条件分布是 $N_k(\mu_1 + \Sigma_{12}\Sigma_{22}^{-1}(x_2 - \mu_2), \Sigma_{11} - \Sigma_{12}\Sigma_{22}^{-1}\Sigma_{12}^T)$ 。可通过条件分布法产生 p 维正态分布向量 $(X_1, X_2) \sim N_p(\mu, \Sigma)$ 的随机数。



笔记 这个定理在概率论第五章和多元统计分析第一章会出现, 比较难记忆, 且该方法太复杂了, 可以用打洞原理 (命题 2.1) 去记忆, 把 A, B, C, D 分别当成 $\Sigma_{11}, \Sigma_{12}, \Sigma_{21}, \Sigma_{22}$ 去记忆就行, 23 级多元统计分析考了多元正态分布的条件分布!!!

命题 2.1 (打洞原理)

已知 A, D 分别是 n 级、 m 级方阵，则：

1. 当 A 可逆时，有 $\begin{vmatrix} A & B \\ C & D \end{vmatrix} = |A| |D - CA^{-1}B|$;
2. 当 D 可逆时，有 $\begin{vmatrix} A & B \\ C & D \end{vmatrix} = |D| |A - BD^{-1}C|$ 。

证明 (1) 当 A 可逆时，容易验证如下矩阵乘法等式：

$$\begin{pmatrix} E & O \\ -CA^{-1} & E \end{pmatrix} \begin{pmatrix} A & B \\ C & D \end{pmatrix} = \begin{pmatrix} A & B \\ O & D - CA^{-1}B \end{pmatrix}.$$

对上式两边同时取行列式可得：

$$\begin{vmatrix} A & B \\ C & D \end{vmatrix} = |A| |D - CA^{-1}B|.$$

(2) 当 D 可逆时，容易验证如下矩阵乘法等式：

$$\begin{pmatrix} E & -BD^{-1} \\ O & E \end{pmatrix} \begin{pmatrix} A & B \\ C & D \end{pmatrix} = \begin{pmatrix} A - BD^{-1}C & O \\ C & D \end{pmatrix}.$$

对上式两边同时取行列式可得：

$$\begin{vmatrix} A & B \\ C & D \end{vmatrix} = |D| |A - BD^{-1}C|.$$

R 代码实现（以 $p = 2, k = 1$ 为例）设置参数： $\mu = (0, 0)^T$ ， $\text{Var}(X_1) = 1$ ， $\text{Var}(X_2) = 2$ ， X_1 与 X_2 的相关系数为 0.8，产生 1000 组正态分布随机数：

```

1  set.seed(1)
2  rep=1000
3  xi=matrix(0,rep,2)
4
5  # 定义参数
6  mu1=0; mu2=0
7  sigma11=1
8  sigma22=2 # 注：原文sigma22=0.2为笔误，修正为2以匹配Var(X2)=2
9  rho=0.8
10 sigma12=sigma21=rho*sqrt(sigma11*sigma22)
11 sigma_c=sigma11-sigma12*sigma22^(-1)*sigma21
12
13 # 循环生成随机数
14 for (i in 1:rep){
15   # 步骤1：从X2的边缘分布N(mu2, sigma22)抽样
16   x2=rnorm(1,mu2,sigma22^0.5)
17   # 步骤2：计算X1的条件分布均值
18   mu_c=mu1+sigma12*sigma22^(-1)*(x2-mu2)
19   # 步骤3：从X1的条件分布N(mu_c, sigma_c)抽样
20   x1=rnorm(1,mu_c, sigma_c^0.5)
21   # 存储结果
22   xi[i,]=c(x1,x2)
23 }
24

```

```

25 # 验证结果 (可选)
26 cat("样本均值: ", round(colMeans(xi), 3), "\n")
27 cat("样本协方差矩阵: \n")
28 print(round(cov(xi), 3))

```

注意事项

采用条件分步的前提是必须能够计算出边际分布，以及相关的条件分布。其中边际分布的计算通常需要使用积分等手段。在后续的课程中，我们会给出使用 Gibbs 抽样法规避积分运算的更简洁的方法。

2.1.3 舍选抽样法 (非课程内容)

随机向量的舍选抽样法是一维舍选法的推广，通过生成候选向量并检验接受条件得到目标向量。

定理 2.3 (随机向量舍选定理)

设 p 维随机向量 $(\xi_1, \dots, \xi_p)$ 在平行多面体 $a_i \leq x_i \leq b_i$ ($i = 1, \dots, p$) 上取值，联合密度函数 $f(x_1, \dots, x_p)$ 的上界为 $f_0 = \sup f(x_1, \dots, x_p) < \infty$ ，抽样步骤为：

1. 独立生成 $U_0, U_1, \dots, U_p \sim U(0, 1)$;
2. 计算候选向量 $X_i = a_i + (b_i - a_i)U_i$ ($i = 1, \dots, p$);
3. 若 $U_0 f_0 \leq f(X_1, \dots, X_p)$ ，则接受 $X = (X_1, \dots, X_p)$ ；否则重复步骤 1-3。

最终得到的向量 X 服从密度函数 f 。



例题 2.5 二维单位圆内均匀向量 产生联合密度函数为 $f(x_1, x_2) = \frac{1}{\pi}$ ($x_1^2 + x_2^2 < 1$) 的随机向量。

```

1  set.seed(1)
2  n <- 1000
3  XY <- matrix(0, n, 2)
4  count <- 1
5  while (count <= n) {
6    u1 <- runif(1)
7    u2 <- runif(1)
8    X1 <- 2 * u1 - 1
9    Y1 <- 2 * u2 - 1
10   r <- X1^2 + Y1^2
11   if (r < 1) {
12     XY[count, ] <- c(X1, Y1)
13     count <- count + 1
14   }
15 }
16 # 绘图验证
17 plot(XY, xlab = "X1", ylab = "X2", main = "二维单位圆内均匀抽样", asp = 1)
18 points(0, 0, pch = 3, col = "red")
19 lines(cos(seq(0, 2*pi, 0.01)), sin(seq(0, 2*pi, 0.01)), col = "red")

```

例题 2.6 p 维密度向量舍选抽样 产生联合密度函数为 $f(x_1, \dots, x_p) = x_1^{p-1} + \dots + x_p^{p-1}$ ($x_i \in [0, 1]$) 的随机向量。

```

1  set.seed(1)
2  p <- 5
3  f0 <- p
4  point <- 0

```

```

5 while (point == 0) {
6   r0 <- runif(1)
7   r <- runif(p)
8   f <- sum(r^(p-1))
9   if (f0 * r0 < f) {
10    point <- 1
11    x <- r
12  }
13 }
14 print("生成的随机向量: ")
15 print(x)

```

2.2 离散随机向量随机数的抽样法 (非课程内容)

离散随机向量的抽样以条件分布法为主，通过边际分布与条件分布的结合实现抽样。

2.2.1 条件分布法

定义 2.2 (条件分布法)

设二维离散随机向量 (X, Y) 的联合分布列为 $P(X = x_i, Y = y_j) = p_{ij}$ ，则：

1. 边际分布列 $P(X = x_i) = \sum_j p_{ij} = p_i$;
2. 条件分布列 $P(Y = y_j | X = x_i) = \frac{p_{ij}}{p_i}$ ($p_i > 0$)。抽样时先抽 X ，再基于 X 的取值抽 Y 。



笔记 抽样步骤：

1. 从 X 的边际分布 $P(X = x_i) = p_i$ 抽样，得到 $X = x_k$;
2. 从给定 $X = x_k$ 时 Y 的条件分布 $P(Y = y_j | X = x_k) = \frac{p_{kj}}{p_k}$ 抽样，得到 $Y = y_l$;
3. 最终 (x_k, y_l) 为 (X, Y) 的随机数。

该方法可推广至 p 维离散随机向量：将联合分布列分解为 p 个边际-条件分布的乘积，依次抽样各分量。

例题 2.7 球盒模型随机向量 将 3 个球等可能放入 3 个篮子 A、B、C，记 X 为落入 A 篮的球数， Y 为落入 B 篮的球数，产生 (X, Y) 的随机数。

步骤推导：

1. 确定边际分布： X 服从二项分布 $B(3, \frac{1}{3})$ ，即 $P(X = i) = \binom{3}{i} \left(\frac{1}{3}\right)^i \left(\frac{2}{3}\right)^{3-i}$ ($i = 0, 1, 2, 3$);
2. 确定条件分布：给定 $X = i$ ，剩余 $3 - i$ 个球落入 B 或 C 篮（等可能），故 $Y | X = i \sim B(3 - i, \frac{1}{2})$ ，即 $P(Y = j | X = i) = \binom{3-i}{j} \left(\frac{1}{2}\right)^{3-i}$ ($j = 0, 1, \dots, 3 - i$);
3. 分步抽样：先抽 X ，再抽 $Y | X$ 。

产生 1000 组随机数的 R 程序如下：

```

1 set.seed(1)
2 n <- 1000 # 生成样本个数
3 data <- matrix(0, n, 2) # 存储(X,Y)
4 colnames(data) <- c("X (A篮球数)", "Y (B篮球数)")
5
6 # 步骤1: 定义X的边际分布 (二项分布B(3, 1/3))
7 X_vals <- 0:3 # X的可能取值
8 p_X <- dbinom(X_vals, size = 3, prob = 1/3) # X的边际概率

```

```

9   Fx <- cumsum(p_X) # 累积分布函数（用于逆变换抽样）
10
11   for (i in 1:n) {
12     # 步骤2：抽样X（逆变换法）
13     r1 <- runif(1)
14     if (r1 <= Fx[1]) {
15       x <- X_vals[1]
16     } else {
17       x <- X_vals[min(which(Fx >= r1))]
18     }
19
20     # 步骤3：抽样Y | X=x（逆变换法，二项分布B(3-x, 1/2)）
21     Y_vals <- 0:(3 - x) # Y的可能取值
22     p_Y_given_X <- dbinom(Y_vals, size = 3 - x, prob = 1/2) # 条件概率
23     Fy <- cumsum(p_Y_given_X) # 累积分布函数
24
25     r2 <- runif(1)
26     if (r2 <= Fy[1]) {
27       y <- Y_vals[1]
28     } else {
29       y <- Y_vals[min(which(Fy >= r2))]
30     }
31
32     data[i, ] <- c(x, y)
33   }
34
35   # 验证：计算样本分布列与理论分布列
36   sample_dist <- table(data[, 1], data[, 2]) / n
37   cat("样本分布列（行=X，列=Y）：\n")
38   print(round(sample_dist, 3))
39
40   # 计算理论分布列
41   theo_dist <- matrix(0, 4, 4)
42   rownames(theo_dist) <- X_vals; colnames(theo_dist) <- 0:3
43   for (i in X_vals) {
44     for (j in 0:(3 - i)) {
45       theo_dist[as.character(i), as.character(j)] <- dbinom(i, 3, 1/3) * dbinom(j, 3 - i, 1/2)
46     }
47   }
48   cat("理论分布列（行=X，列=Y）：\n")
49   print(round(theo_dist, 3))
50
51   # 绘制X的边际分布直方图
52   hist(data[, 1], breaks = seq(-0.5, 3.5, 1), freq = FALSE,
53        xlab = "X（A篮球数）", main = "X的边际分布")
54   lines(X_vals, p_X, col = "red", type = "h", lwd = 3)

```

例题 2.8 多项分布随机向量 现有装有 r 种颜色球的盒子，第 i 种颜色球的比例为 p_i ($\sum_{i=1}^r p_i = 1$)。有放回抽取 n 次，记 X_i 为抽出第 i 种颜色球的次数，产生 $(X_1, X_2, \dots, X_r)$ 的随机数（服从多项分布

$Mult(n; p_1, \dots, p_r)$ 。

抽样原理：

1. 边际分布: $X_1 \sim B(n, p_1)$ (第 1 种颜色球的抽取次数);
2. 条件分布: 给定 $X_1 = x_1$, 剩余 $n - x_1$ 次抽取中第 2 种颜色的概率为 $\frac{p_2}{1 - p_1}$, 故 $X_2 | X_1 = x_1 \sim B(n - x_1, \frac{p_2}{1 - p_1})$;
3. 依次类推: 给定 $X_1 = x_1, \dots, X_{r-1} = x_{r-1}$, $X_r = n - \sum_{i=1}^{r-1} x_i$ (确定值, 无需抽样)。

设置 $r = 4$ 、 $p = (0.1, 0.2, 0.3, 0.4)$ 、 $n = 50$, 产生 1000 组随机数的 R 程序如下:

```

1  set.seed(1)
2  n <- 50 # 抽取次数
3  r <- 4 # 颜色种类
4  p <- c(0.1, 0.2, 0.3, 0.4) # 颜色比例
5  rep <- 1000 # 生成样本个数
6  x_matrix <- matrix(0, rep, r) # 存储结果
7  colnames(x_matrix) <- paste("X", 1:r, sep = "")
8
9  for (t in 1:rep) {
10     x <- numeric(r) # 存储当前样本
11     remaining <- n # 剩余抽取次数
12
13     for (i in 1:(r-1)) {
14         # 步骤1: 抽样  $X_i | X_1, \dots, X_{i-1}$  (二项分布)
15         prob <- p[i] / sum(p[i:r]) # 条件概率
16         x[i] <- rbinom(1, size = remaining, prob = prob)
17         remaining <- remaining - x[i] # 更新剩余次数
18     }
19
20     # 步骤2:  $X_r =$  剩余次数 (确定值)
21     x[r] <- remaining
22     x_matrix[t, ] <- x
23 }
24
25 # 验证: 计算样本均值与理论均值
26 sample_mean <- colMeans(x_matrix)
27 theo_mean <- n * p # 多项分布均值  $E(X_i) = n p_i$ 
28 cat("样本均值: ", round(sample_mean, 3), "\n")
29 cat("理论均值: ", round(theo_mean, 3), "\n")
30
31 # 验证: 计算样本协方差矩阵与理论协方差矩阵
32 sample_cov <- cov(x_matrix)
33 # 理论协方差:  $Cov(X_i, X_j) = -n p_i p_j (i \neq j)$ ,  $Var(X_i) = n p_i (1 - p_i)$ 
34 theo_cov <- matrix(0, r, r)
35 for (i in 1:r) {
36     for (j in 1:r) {
37         if (i == j) {
38             theo_cov[i, j] <- n * p[i] * (1 - p[i])
39         } else {
40             theo_cov[i, j] <- -n * p[i] * p[j]
41         }
42     }
43 }
```

```

43 }
44 cat("样本协方差矩阵: \n")
45 print(round(sample_cov, 3))
46 cat("理论协方差矩阵: \n")
47 print(round(theo_cov, 3))
48
49 # 绘制第1种颜色球次数的直方图
50 hist(x_matrix[, 1], 20, freq = FALSE, xlab = "X (第1种颜色次数)", main = "X 的边际分布")
51 x0 <- 0:n
52 fx <- dbinom(x0, n, p[1]) # 理论边际密度 (二项分布)
53 lines(x0, fx, col = "red", lwd = 2)

```

例题 2.9 球盒模型随机向量 将 3 个球等可能放入 3 个篮子 A、B、C，记 X 为 A 篮球数， Y 为 B 篮球数，产生 (X, Y) 的随机数。

```

1  set.seed(1)
2  n <- 1000
3  XY <- matrix(0, n, 2)
4  for (i in 1:n) {
5    # 生成3个球的放置位置 (1=A,2=B,3=C)
6    balls <- sample(1:3, 3, replace = TRUE)
7    X <- sum(balls == 1)
8    Y <- sum(balls == 2)
9    XY[i, ] <- c(X, Y)
10 }
11 # 统计分布列验证
12 table(XY[,1], XY[,2]) / n

```

结论 本章系统介绍了连续与离散随机向量的核心抽样方法，包括变换抽样法、条件分布法和舍选抽样法。变换抽样法依赖可逆变换与雅可比行列式，适用于联合密度可解析变换的场景；条件分布法通过分步抽样降低多维难度，是离散向量的主要抽样方式；舍选抽样法无需复杂变换，适用于密度有界的多维场景。三类方法均基于一维抽样原理推广，通过 R 代码实现了具体案例，可直接应用于实际数据分析与建模。

第二章 练习

1. 设 $\alpha \sim U(0, 2\pi)$, $R \sim \text{Exp}(0.5)$ 且独立于 α 。令 $X = \sqrt{R} \cos \alpha$, $Y = \sqrt{R} \sin \alpha$ ，证明 X, Y 相互独立且均服从 $N(0, 1)$ ，并设计算法生成二维标准正态分布的随机数。
2. 生成样本量 $n = 1000$ 、服从二维分布函数 $F(x, y) = 1 - e^{-2x} - e^{-2y} + e^{-2(x+y)}$ ($x, y > 0$) 的随机数，编程实现并验证分布。
3. 分别使用条件分布法和变换抽样法生成 1000 个服从分布 $N(\mu, \Sigma)$ 的随机向量 $X = (X_1, X_2)^T$ ，其中：

$$\mu = \begin{pmatrix} 1 \\ 1 \end{pmatrix}, \quad \Sigma = \begin{pmatrix} 1 & -0.5 \\ -0.5 & 1 \end{pmatrix}.$$

4. 生成密度函数为 $f(x_1, x_2, x_3) = \frac{4}{3\pi} (x_1^2 + x_2^2 + x_3^2 < 1)$ 的三维随机向量，计算抽样效率并绘制散点图。
5. 设坛子中有 n 个球（共 r 种颜色，第 i 种颜色有 n_i 个， $\sum_{i=1}^r n_i = n$ ），无放回抽取 m 个球，记 X_i 为取出第 i 种颜色球的个数，设计算法生成随机向量 $(X_1, \dots, X_r)^T$ 的随机数。
6. 设二维离散随机向量 (X, Y) 的联合分布列为：

$X \setminus Y$	1	2	3
0	0.1	0.2	0.1
1	0.2	0.3	0.1

用条件分布法生成 1000 组随机数，验证样本分布与理论分布的一致性。

第三章 运用模拟的手段评估参数估计的估计量优劣

内容提要

- 点估计的评价标准 3.1
- 正态总体均值区间估计定理 (第 3 章) ??
- 正态总体方差区间估计定理 (第 3 章) ??
- 两总体均值差区间估计定理 (第 3 章) ??
- 两总体方差比区间估计定理 (第 3 章) ??

3.1 点估计数值计算

参数估计的核心是构造合适的估计量并评价其性能。设总体分布含未知参数 θ , 样本 $X_1, X_2, \dots, X_n$ 来自该总体, $\hat{\theta}(X_1, X_2, \dots, X_n)$ 为 θ 的估计量, 需通过数值计算验证其期望、方差、均方误差 (MSE) 等性质。

3.1.1 点估计的数值模拟方法

命题 3.1 (点估计的评价标准)

点估计的优劣通过以下标准衡量:

- 无偏性: 若 $E(\hat{\theta}) = \theta$, 则 $\hat{\theta}$ 为 θ 的无偏估计量, 即估计量抽样分布的均值等于参数真值。
- 有效性: 对同一参数的两个无偏估计量 $\hat{\theta}_1$ 和 $\hat{\theta}_2$, 若 $Var(\hat{\theta}_1) \leq Var(\hat{\theta}_2)$, 则 $\hat{\theta}_1$ 更有效。
- 一致性: 当样本量 $n \rightarrow \infty$ 时, $\hat{\theta} \xrightarrow{P} \theta$ (依概率收敛), 即估计量随样本量增大趋近于参数真值。

定义 3.1 (点估计的数值模拟方法)

当估计量的期望、方差等理论值难以推导时, 采用数值模拟方法近似计算, 步骤如下:

- 从总体 X 中随机生成 K 组独立样本, 每组样本量为 n , 记第 k 组样本为 $X_1^{(k)}, X_2^{(k)}, \dots, X_n^{(k)}$ ($k = 1, 2, \dots, K$)。
- 对每组样本计算估计量 $\hat{\theta}^{(k)} = \hat{\theta}(X_1^{(k)}, X_2^{(k)}, \dots, X_n^{(k)})$, 得到估计量序列 $\hat{\theta}^{(1)}, \hat{\theta}^{(2)}, \dots, \hat{\theta}^{(K)}$ 。
- 基于该序列计算:
 - 估计量期望的近似值: $\hat{E}(\hat{\theta}) = \frac{1}{K} \sum_{k=1}^K \hat{\theta}^{(k)}$
 - 估计量方差的近似值: $\hat{Var}(\hat{\theta}) = \frac{1}{K-1} \sum_{k=1}^K (\hat{\theta}^{(k)} - \hat{E}(\hat{\theta}))^2$
 - 均方误差 (MSE) 的近似值: $\hat{MSE}(\hat{\theta}) = \frac{1}{K} \sum_{k=1}^K (\hat{\theta}^{(k)} - \theta)^2$ (需已知 θ 真值)

例题 3.1 正态分布均值估计的数值验证 设 $X_1, X_2, \dots, X_n$ 来自 $N(\mu, \sigma^2)$, 均值 μ 的估计量为 $\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$, 理论上 $E(\bar{X}) = \mu$, $Var(\bar{X}) = \frac{\sigma^2}{n}$ 。通过数值模拟验证该性质

解 方法: 在正态分布 $N(\mu, \sigma^2)$ 中独立产生 K 个容量为 n 的样本 $X_1^{(k)}, X_2^{(k)}, \dots, X_n^{(k)}$, $k = 1, 2, \dots, K$, 对于第 k 个样本, 均值估计量记为 $\bar{X}^{(k)}$ 。可得 $\bar{X}$ 期望和方差的估计为

$$\hat{E}(\bar{X}) = \frac{1}{K} \sum_{k=1}^K \bar{X}^{(k)},$$
$$\hat{Var}(\bar{X}) = \frac{1}{K} \sum_{k=1}^K \{\bar{X}^{(k)} - \hat{E}(\bar{X})\}^2.$$

理论上, 估计量 $\hat{E}(\bar{X})$ 的方差为 $(nK)^{-1}\sigma^2$ 。因此, 可以调整重复产生样本的数量 K 来提高估计的有效性。

R 程序实现如下:

```

1  set.seed(1)
2  K <- 1000 # 模拟次数
3  n <- 500 # 样本量
4  mu <- 0 # 总体均值真值
5  sigma <- 1 # 总体标准差
6  resu <- matrix(0, K, 1) # 存储每组样本的均值估计
7
8  for (i in 1:K) {
9    data <- rnorm(n, mu, sigma) # 生成正态分布样本
10   resu[i] <- mean(data) # 计算样本均值
11 }
12
13 # 输出结果: 估计的期望、理论期望; 估计的方差、理论方差
14 cat("估计的均值期望: ", round(mean(resu), 4), ", 理论期望: ", mu, "\n")
15 cat("估计的均值方差: ", round(var(resu), 4), ", 理论方差: ", sigma^2/n, "\n")

```

模拟结果中, 估计的期望接近 μ , 估计的方差接近 $\frac{\sigma^2}{n}$, 验证了 $\bar{X}$ 的无偏性和方差性质。

例题 3.2 设 $(X_1, X_2) \sim N(0, I_2)$, 其中 I_2 为 2 维单位阵。我们需要估计 $\theta_1 = E(|X_1 - X_2|)$ 和 $\theta_2 = \text{Var}(|X_1 - X_2|)$ 。

方法: 基于样本 (X_{1i}, X_{2i}) , $i = 1, 2, \dots, n$, 可得 θ_1, θ_2 的估计:

$$\hat{\theta}_1 = \frac{1}{n} \sum_{i=1}^n |X_{1i}^{(1)} - X_{2i}^{(1)}|, \quad \hat{\theta}_2 = \frac{1}{n-1} \sum_{i=1}^n \left(|X_{1i}^{(1)} - X_{2i}^{(1)}| - \hat{\theta}_1 \right)^2.$$

如何验证估计是否无偏?

通过计算 (非模拟, 详细计算过程可以看“笔记”) 可得

$$E(\hat{\theta}_1) = \theta_1 = 2/\sqrt{\pi}, \quad E(\hat{\theta}_2) = \theta_2 = 2 - 4/\pi.$$

这说明我们可以通过数学运算来验证无偏性。

如果没有容易计算的方式, 如何通过模拟验证? 算法流程如下:

1. 从总体 $N(0, I_2)$ 中产生样本 $(X_{1i}^{(1)}, X_{2i}^{(1)})$, $i = 1, 2, \dots, n$, 基于此样本得到 θ_1 和 θ_2 的估计;
2. 重复上述步骤 K 次, 相应得到估计 $\hat{\theta}_1^{(k)}$ 和 $\hat{\theta}_2^{(k)}$;
3. 计算 $E(\hat{\theta}_1)$ 和 $E(\hat{\theta}_2)$ 的估计为

$$\hat{E}(\hat{\theta}_1) = \frac{1}{K} \sum_{k=1}^K \hat{\theta}_1^{(k)}, \quad \hat{E}(\hat{\theta}_2) = \frac{1}{K} \sum_{k=1}^K \hat{\theta}_2^{(k)}.$$

```

1  # 选择 $n=50$, $K=1000$, R程序计算如下:
2  set.seed(1)
3  library(MASS)
4  K=1000
5  n=50
6  theta1=matrix(0,K,1)
7  theta2=matrix(0,K,1)
8  for (i in 1:K){
9    data=mvrnorm(n,c(0,0),diag(2))
10   theta1[i]=mean(abs(data[,1]-data[,2]))
11   theta2[i]=var(abs(data[,1]-data[,2]))
12 }
13 c(mean(theta1),2/(sqrt(pi))) # 估计的|X1-X2|的均值和参数真值
14 c(mean(theta2),2-4/pi) # 估计的|X1-X2|的方差和参数真值

```



笔记 这题的计算过程其实是（茆诗松《概率论与数理统计》2.5.31 的拓展）参考下面这道题的过程。

由 I_2 是单位阵可知 $X_1, X_2 \sim N(0, 1)$ ，且相互独立，则 $X_1 - X_2 \sim N(0, 2)$ ，令下面这道题的 $\sigma^2 = 2$ 即得到计算结果。



练习 3.1

1. 设随机变量 $X \sim N(\mu, \sigma^2)$ ，求 $E(|X - \mu|)$ ；
2. 设随机变量 $X \sim N(0, \sigma^2)$ ，求 $E(|X|)$ 和 $\text{Var}|X|$ 。

解

1. 利用变换 $t = (x - \mu)/\sigma$ 及偶函数性质可得

$$\begin{aligned} E(|X - \mu|) &= \frac{1}{\sqrt{2\pi}\sigma} \int_{-\infty}^{+\infty} |x - \mu| \exp\left\{-\frac{(x - \mu)^2}{2\sigma^2}\right\} dx \\ &= \sigma \sqrt{\frac{2}{\pi}} \int_0^{+\infty} \exp\left\{-\frac{t^2}{2}\right\} d\left(\frac{t^2}{2}\right) \\ &= \sigma \sqrt{\frac{2}{\pi}}. \end{aligned}$$

2. 在上题中令 $\mu = 0$ 即可得 $E(|X|) = \sigma \sqrt{\frac{2}{\pi}}$ ；

$$\text{Var}|X| = E|X|^2 - (E|X|)^2 = EX^2 - (E|X|)^2 = \left(1 - \frac{2}{\pi}\right) \sigma^2.$$



笔记 均方误差：简单而言，估计值 $\hat{\theta}$ 的均方误差（Mean squared error; MSE）为

$$\text{MSE} = E(\hat{\theta} - \theta)^2 = \text{bias}^2 + \text{variance}.$$

例题 3.3 设 $X_1, X_2, \dots, X_n$ 是来自标准正态分布在区间 $[0, 1]$ 截尾后的样本，记该截尾分布为 $X_{[0,1]}$ 。

分布 $X_{[0,1]}$ 的均值 θ 的估计为 $\hat{\theta} = \sum_{i=1}^n X_i/n$ 。

计算期望估计 $\hat{\theta}$ 的 MSE，即 $E(\hat{\theta} - \theta)^2$ 。

方法：首先计算截尾正态分布的期望 $\theta = E(X_{[0,1]})$ 。

设 X 服从正态分布 $N(\mu, \sigma^2)$ ，概率密度函数为

$$f(x) = \frac{1}{\sqrt{2\pi}\sigma} \exp\left\{-\frac{(x - \mu)^2}{2\sigma^2}\right\},$$

其导数为

$$f'(x) = \frac{1}{\sqrt{2\pi}\sigma} \cdot \left(-\frac{x - \mu}{\sigma^2}\right) \exp\left\{-\frac{(x - \mu)^2}{2\sigma^2}\right\} = -\frac{x - \mu}{\sigma^2} \cdot f(x).$$

相应的分布函数记为 $F(x)$ 。如果限制 X 在 (a, b) 区间取值，则密度函数为

$$f_1(x; \mu, \sigma, a, b) = \frac{f(x)}{F(b) - F(a)}.$$

正态分布 $N(\mu, \sigma^2)$ 在 $[a, b]$ 上截尾分布 $X_{[\mu, \sigma, a, b]}$ 的数学期望为

$$\begin{aligned} E(X_{[\mu, \sigma, a, b]}) &= \int_a^b x \cdot \frac{f(x)}{F(b) - F(a)} dx \\ &= \int_a^b (x - \mu + \mu) \cdot \frac{f(x)}{F(b) - F(a)} dx \\ &= \mu + \frac{-\sigma^2}{F(b) - F(a)} \int_a^b \frac{x - \mu}{\sigma^2} \cdot f(x) dx \\ &= \mu + \frac{-\sigma^2}{F(b) - F(a)} \int_a^b f'(x) dx = \mu - \sigma^2 \frac{f(b) - f(a)}{F(b) - F(a)}. \end{aligned}$$

本例中， $\mu = 0$ ， $\sigma = 1$ ， $a = 0$ ， $b = 1$ ，则

$$\theta = E(X_{[0,1]}) = \frac{\phi(0) - \phi(1)}{\Phi(1) - 0.5}.$$

算法流程：

1. 从截尾正态分布中产生 K 组样本 $\{X_1^{(k)}, \dots, X_n^{(k)}\}$, 并计算每组样本下的均值:

$$\hat{\theta}^{(k)} = \frac{1}{n} \sum_{i=1}^n X_i^{(k)}, \quad k = 1, 2, \dots, K.$$

2. MSE 的估计为

$$\hat{E}(\hat{\theta} - \theta)^2 = \frac{1}{K} \sum_{k=1}^K \left(\hat{\theta}^{(k)} - \theta \right)^2.$$

例题 3.4 截尾正态分布均值估计的 MSE 计算 (教材上) 设 X 为标准正态分布在 $[0, 1]$ 上的截尾分布, 密度函数为:

$$f(x) = \frac{\phi(x)}{\Phi(1) - 0.5}, \quad 0 < x < 1 \quad (3.1)$$

其中 $\phi(x)$ 为标准正态密度, $\Phi(x)$ 为标准正态分布函数。均值 $\theta = E(X)$ 的估计量为 $\hat{\theta} = \frac{1}{n} \sum_{i=1}^n X_i$, 需计算 $\hat{\theta}$ 的 MSE。

理论均值计算截尾正态分布的均值为:

$$\theta = \frac{\phi(0) - \phi(1)}{\Phi(1) - 0.5} \quad (3.2)$$

其中 $\phi(0) = \frac{1}{\sqrt{2\pi}} \approx 0.3989$, $\phi(1) = \frac{1}{\sqrt{2\pi}} e^{-0.5} \approx 0.2420$, $\Phi(1) \approx 0.8413$, 代入得 $\theta \approx \frac{0.3989 - 0.2420}{0.8413 - 0.5} \approx 0.460$ 。

数值模拟计算 MSE R 程序实现如下 (需加载 'truncnorm' 包生成截尾正态样本):

```

1  set.seed(1)
2  library(truncnorm)
3  K <- 1000 # 模拟次数
4  n <- 50 # 样本量
5  mu <- 0 # 原正态分布均值
6  sigma <- 1 # 原正态分布标准差
7  a <- 0 # 截尾下限
8  b <- 1 # 截尾上限
9
10 # 计算理论均值theta
11 phi0 <- dnorm(0, mu, sigma)
12 phi1 <- dnorm(1, mu, sigma)
13 Phi1 <- pnorm(1, mu, sigma)
14 theta <- (phi0 - phi1) / (Phi1 - 0.5)
15
16 thetahat <- matrix(0, K, 1) # 存储每组样本的均值估计
17 for (i in 1:K) {
18   data <- rtruncnorm(n, a, b, mu, sigma) # 生成截尾正态样本
19   thetahat[i] <- mean(data) # 计算样本均值
20 }
21
22 MSE <- mean((thetahat - theta)^2) # 计算MSE
23 cat("理论均值theta: ", round(theta, 4), "\n")
24 cat("估计量的MSE: ", round(MSE, 4), "\n")

```

模拟结果中, MSE 反映了估计量 $\hat{\theta}$ 与真值 θ 的平均平方误差, 可用于评价估计精度。

3.2 置信区间估计数值计算

区间估计通过样本构造随机区间 $[\hat{\theta}_L, \hat{\theta}_U]$, 使得 $P(\hat{\theta}_L \leq \theta \leq \hat{\theta}_U) \geq 1 - \alpha$ ($1 - \alpha$ 为置信水平)。需通过数值计算验证置信区间的覆盖率 (实际包含 θ 的概率) 和平均长度 (精度)。

定义 3.2 (置信区间的基本定义)

设 θ 为总体参数, $X_1, X_2, \dots, X_n$ 为样本, $\hat{\theta}_L = \hat{\theta}_L(X_1, \dots, X_n)$ 和 $\hat{\theta}_U = \hat{\theta}_U(X_1, \dots, X_n)$ 为两个统计量, 满足:

$$P_{\theta}(\hat{\theta}_L \leq \theta \leq \hat{\theta}_U) \geq 1 - \alpha$$

则 $[\hat{\theta}_L, \hat{\theta}_U]$ 称为 θ 的 $1 - \alpha$ 置信区间。

关键评价指标:

1. 覆盖率: $Prob = P_{\theta}(\hat{\theta}_L \leq \theta \leq \hat{\theta}_U)$, 理想值为 $1 - \alpha$ 。
2. 平均长度: $E(\hat{\theta}_U - \hat{\theta}_L)$, 长度越短, 区间精度越高。
3. 基于该序列计算:

定义 3.3 (置信区间的数值模拟方法)

当覆盖率和置信区间理论值难以计算时, 采用数值模拟近似, 步骤如下:

1. 从总体 X 中生成 K 组独立样本, 每组样本量为 n , 记第 k 组样本为 $X_1^{(k)}, \dots, X_n^{(k)}$ 。
2. 对每组样本计算置信区间 $[\hat{\theta}_L^{(k)}, \hat{\theta}_U^{(k)}]$ 。
3. 基于该序列计算:
 - (a). 覆盖率估计: $\widehat{Prob} = \frac{1}{K} \sum_{k=1}^K I(\hat{\theta}_L^{(k)} \leq \theta \leq \hat{\theta}_U^{(k)})$, 其中 $I(\cdot)$ 为示性函数。
 - (b). 平均置信区间: $\widehat{Inter} = \left[\frac{1}{K} \sum_{k=1}^K \hat{\theta}_L^{(k)}, \frac{1}{K} \sum_{k=1}^K \hat{\theta}_U^{(k)} \right]$ 。
 - (c). 平均长度: $\widehat{Length} = \frac{1}{K} \sum_{k=1}^K (\hat{\theta}_U^{(k)} - \hat{\theta}_L^{(k)})$ 。

基于某种方法, 我们总能根据一组数据算出某个参数的置信区间。如何评估该置信区间计算方法的好坏?

顾名思义, 我们可以进行多组模拟, 用同样的方法计算多组模拟产生的置信区间, 然后统计有多少组置信区间能够覆盖参数, 最后将理论覆盖率与实际覆盖率进行比较。

如果覆盖率接近理论值, 则该置信区间的计算方法表现良好。

如果采用 A 方法与 B 方法计算的置信区间覆盖率相近, 则置信区间长度越短越好。

推论 3.1 (置信区间算法流程)

1. 从总体 X 中抽取随机样本 $X_1^{(1)}, \dots, X_n^{(1)}$, 基于此样本计算置信区间的上下界:

$$\hat{\theta}_L^{(1)} = \hat{\theta}_L(X_1^{(1)}, \dots, X_n^{(1)}), \quad \hat{\theta}_U^{(1)} = \hat{\theta}_U(X_1^{(1)}, \dots, X_n^{(1)})$$

2. 重复上述步骤 K 次, 得到 K 组样本对应的置信区间上下界 $\hat{\theta}_L^{(k)}, \hat{\theta}_U^{(k)}$;
3. 覆盖率 Prob 和置信区间长度 Inter 的估计分别为:

$$\widehat{Prob} = \frac{1}{K} \sum_{k=1}^K I(\hat{\theta}_L^{(k)} \leq \theta \leq \hat{\theta}_U^{(k)}),$$

$$\widehat{Inter} = \left[\frac{1}{K} \sum_{k=1}^K \hat{\theta}_L^{(k)}, \frac{1}{K} \sum_{k=1}^K \hat{\theta}_U^{(k)} \right]$$

其中 $I(\cdot)$ 为指示函数, 当条件满足时取 1, 否则取 0。

3.2.1 单总体置信区间估计

单总体参数（均值、方差、比例）的置信区间构造需结合总体分布、方差已知性及样本量大小，以下分情况讨论。

1. 总体均值 μ 的置信区间

设总体 $X \sim N(\mu, \sigma^2)$ ，样本均值 $\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$ ，分 σ^2 已知和未知两种情形：

(a). 情形 1: σ^2 已知

此时 $\bar{X} \sim N(\mu, \frac{\sigma^2}{n})$ ，取枢轴量 $U = \frac{\sqrt{n}(\bar{X} - \mu)}{\sigma} \sim N(0, 1)$ 。对置信水平 $1 - \alpha$ ，标准正态分布的 $1 - \alpha/2$ 分位数为 $u_{1-\alpha/2}$ ，可得

$$P\left(u_{\alpha/2} \leq \frac{\sqrt{n}(\bar{X} - \mu)}{\sigma} \leq u_{1-\alpha/2}\right) = 1 - \alpha. \quad (3.3)$$

$$P\left(\bar{X} - u_{1-\alpha/2} \frac{\sigma}{\sqrt{n}} \leq \mu \leq \bar{X} + u_{1-\alpha/2} \frac{\sigma}{\sqrt{n}}\right) = 1 - \alpha. \quad (3.4)$$

则 μ 的 $1 - \alpha$ 置信区间为：

$$\left[\bar{X} - u_{1-\alpha/2} \frac{\sigma}{\sqrt{n}}, \bar{X} + u_{1-\alpha/2} \frac{\sigma}{\sqrt{n}}\right] \quad (3.5)$$

参数 μ 的置信区间 $\left[\bar{X} - u_{1-\alpha/2} \frac{\sigma}{\sqrt{n}}, \bar{X} + u_{1-\alpha/2} \frac{\sigma}{\sqrt{n}}\right]$ 的覆盖率和置信区间长度分别为

$$\text{Prob} = P_{\theta}(\hat{\theta}_L \leq \theta \leq \hat{\theta}_U) = 1 - \alpha,$$

$$\text{Inter} = \left[\mu - u_{1-\alpha/2} \frac{\sigma}{\sqrt{n}}, \mu + u_{1-\alpha/2} \frac{\sigma}{\sqrt{n}}\right].$$

例题 3.5 方差已知时正态均值的置信区间模拟 设 $X \sim N(0, 1)$ ($\mu = 0, \sigma = 1$)，样本量 $n = 50$ ，置信水平 $\alpha = 0.05$ ($u_{0.975} = 1.96$)，通过数值模拟计算覆盖率和平均长度。

解

I. 从总体 X 中抽取随机样本 $X_1^{(1)}, \dots, X_n^{(1)}$ ，基于此样本计算置信区间的上下界：

$$\hat{\theta}_L^{(1)} = \bar{X}^{(1)} - u_{1-\alpha/2} \sigma / \sqrt{n}, \quad \hat{\theta}_U^{(1)} = \bar{X}^{(1)} + u_{1-\alpha/2} \sigma / \sqrt{n}$$

II. 重复上述步骤 K 次，得到 K 组置信区间的上下界 $\hat{\theta}_L^{(k)}, \hat{\theta}_U^{(k)}$ ；

III. 覆盖率 Prob 和置信区间长度 Inter 的估计分别为：

$$\widehat{\text{Prob}} = \frac{1}{K} \sum_{k=1}^K I(\hat{\theta}_L^{(k)} \leq \theta \leq \hat{\theta}_U^{(k)}), \quad (3.6)$$

$$\widehat{\text{Inter}} = \left[\frac{1}{K} \sum_{k=1}^K \hat{\theta}_L^{(k)}, \frac{1}{K} \sum_{k=1}^K \hat{\theta}_U^{(k)}\right]. \quad (3.7)$$

其中 $I(\cdot)$ 为指示函数，当条件满足时取 1，否则取 0。

R 程序如下：

```
1 set.seed(1)
2 K <- 1000 # 模拟次数
3 n <- 50 # 样本量
4 alpha <- 0.05 # 显著性水平
5 mu <- 0 # 总体均值真值
6 sigma <- 1 # 总体标准差
7 u <- qnorm(1 - alpha/2, 0, 1) # 标准正态分位数
8
9 inter <- matrix(0, K, 2) # 存储每组样本的置信区间
10 prob <- matrix(0, K, 1) # 存储每组样本是否覆盖真值
11
```

```

12   for (i in 1:K) {
13     data <- rnorm(n, mu, sigma) # 生成正态样本
14     barX <- mean(data)         # 计算样本均值
15     # 计算置信区间上下限
16     inter[i, 1] <- barX - u * sigma / sqrt(n)
17     inter[i, 2] <- barX + u * sigma / sqrt(n)
18     # 判断是否覆盖真值
19     prob[i] <- (mu >= inter[i, 1]) & (mu <= inter[i, 2])
20   }
21
22   # 输出结果
23   cat("平均置信区间下限: ", round(mean(inter[,1]), 4), "\n")
24   cat("平均置信区间上限: ", round(mean(inter[,2]), 4), "\n")
25   cat("平均区间长度: ", round(mean(inter[,2]-inter[,1]), 4), "\n")
26   cat("覆盖率: ", round(mean(prob), 4), "\n")

```

模拟结果中，覆盖率接近 0.95，平均长度接近 $2u_{0.975}\frac{\sigma}{\sqrt{n}} \approx 0.549$ ，验证了置信区间的有效性。

(b). 情形 2: σ^2 未知

此时用样本方差 $S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$ 估计 σ^2 ，枢轴量 $T = \frac{\sqrt{n}(\bar{X} - \mu)}{S} \sim t(n-1)$ (t 分布，自由度 $n-1$)。 t 分布的 $1-\alpha/2$ 分位数为 $t_{1-\alpha/2}(n-1)$ ，则 μ 的 $1-\alpha$ 置信区间为：

$$\left[\bar{X} - t_{1-\alpha/2}(n-1) \frac{S}{\sqrt{n}}, \bar{X} + t_{1-\alpha/2}(n-1) \frac{S}{\sqrt{n}} \right] \quad (3.8)$$

例题 3.6 方差未知时正态均值的置信区间模拟 设 $X \sim N(0, 1)$ ，样本量 $n = 50$ ，置信水平 $\alpha = 0.05$ ($t_{0.975}(49) \approx 2.0096$)。

解

- I. 从总体 X 中抽取随机样本 $X_1^{(1)}, \dots, X_n^{(1)}$ ，基于此样本计算均值 $\bar{X}^{(1)}$ 和标准差 $S^{(1)}$ ，得到置信区间的上下界：

$$\hat{\theta}_L^{(1)} = \bar{X}^{(1)} - t_{1-\alpha/2} S^{(1)} / \sqrt{n}, \quad \hat{\theta}_U^{(1)} = \bar{X}^{(1)} + t_{1-\alpha/2} S^{(1)} / \sqrt{n}$$

- II. 重复上述步骤 K 次，得到 K 组置信区间的上下界 $\hat{\theta}_L^{(k)}, \hat{\theta}_U^{(k)}$ ；

- III. 基于 K 组 $\hat{\theta}_L^{(k)}, \hat{\theta}_U^{(k)}$ ，计算覆盖率 Prob 和置信区间长度 Inter 的估计：

$$\widehat{\text{Prob}} = \frac{1}{K} \sum_{k=1}^K I(\hat{\theta}_L^{(k)} \leq \theta \leq \hat{\theta}_U^{(k)}), \quad (3.9)$$

$$\widehat{\text{Inter}} = \frac{1}{K} \sum_{k=1}^K (\hat{\theta}_U^{(k)} - \hat{\theta}_L^{(k)}). \quad (3.10)$$

其中 $I(\cdot)$ 为指示函数，当条件满足时取 1，否则取 0。

R 程序如下：

```

1   set.seed(1)
2   K <- 1000 # 模拟次数
3   n <- 50   # 样本量
4   alpha <- 0.05 # 显著性水平
5   mu <- 0    # 总体均值真值
6   sigma <- 1 # 总体标准差
7
8   inter <- matrix(0, K, 2) # 存储置信区间
9   prob <- matrix(0, K, 1) # 存储覆盖情况

```

```

10
11   for (i in 1:K) {
12     data <- rnorm(n, mu, sigma) # 生成正态样本
13     barX <- mean(data)         # 样本均值
14     S <- sd(data)              # 样本标准差
15     t_val <- qt(1 - alpha/2, n-1) # t分布分位数
16     # 计算置信区间
17     inter[i, 1] <- barX - t_val * S / sqrt(n)
18     inter[i, 2] <- barX + t_val * S / sqrt(n)
19     # 判断覆盖真值
20     prob[i] <- (mu >= inter[i, 1]) & (mu <= inter[i, 2])
21   }
22
23   # 输出结果
24   cat("平均置信区间下限: ", round(mean(inter[,1]), 4), "\n")
25   cat("平均置信区间上限: ", round(mean(inter[,2]), 4), "\n")
26   cat("平均区间长度: ", round(mean(inter[,2]-inter[,1]), 4), "\n")
27   cat("覆盖率: ", round(mean(prob), 4), "\n")

```

模拟结果中，覆盖率接近 0.95，平均长度略大于方差已知情形（因 t 分布分位数大于标准正态分位数）。

2. 总体方差的置信区间

设总体 $X \sim N(\mu, \sigma^2)$ ，样本方差 $S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$ ，枢轴量 $\chi^2 = \frac{(n-1)S^2}{\sigma^2} \sim \chi^2(n-1)$ （卡方分布，自由度 $n-1$ ）。 χ^2 分布的 $\alpha/2$ 分位数为 $\chi_{\alpha/2}^2(n-1)$ ， $1-\alpha/2$ 分位数为 $\chi_{1-\alpha/2}^2(n-1)$ ，则 σ^2 的 $1-\alpha$ 置信区间为：

$$\left[\frac{(n-1)S^2}{\chi_{1-\alpha/2}^2(n-1)}, \frac{(n-1)S^2}{\chi_{\alpha/2}^2(n-1)} \right] \quad (3.11)$$

例题 3.7 正态总体方差的置信区间模拟 设 $X \sim N(0, 1)$ ($\sigma^2 = 1$)，样本量 $n = 50$ ，置信水平 $\alpha = 0.05$ ($\chi_{0.025}^2(49) \approx 31.555$, $\chi_{0.975}^2(49) \approx 66.339$)。

R 程序如下：

```

1   set.seed(1)
2   K <- 1000 # 模拟次数
3   n <- 50   # 样本量
4   alpha <- 0.05 # 显著性水平
5   sigma_true <- 1 # 总体方差真值
6   sigma2_true <- sigma_true^2
7
8   inter <- matrix(0, K, 2) # 存储置信区间
9   prob <- matrix(0, K, 1) # 存储覆盖情况
10
11  for (i in 1:K) {
12    data <- rnorm(n, 0, sigma_true) # 生成正态样本
13    S2 <- var(data)                 # 样本方差
14    Q <- S2 * (n-1)                  # (n-1)S^2
15    # 卡方分布分位数
16    chi1 <- qchisq(1 - alpha/2, n-1)
17    chi2 <- qchisq(alpha/2, n-1)
18    # 计算置信区间

```

```

19     inter[i, 1] <- Q / chi1
20     inter[i, 2] <- Q / chi2
21     # 判断覆盖真值
22     prob[i] <- (sigma2_true >= inter[i, 1]) & (sigma2_true <= inter[i, 2])
23 }
24
25 # 输出结果
26 cat("平均置信区间下限: ", round(mean(inter[,1]), 4), "\n")
27 cat("平均置信区间上限: ", round(mean(inter[,2]), 4), "\n")
28 cat("平均区间长度: ", round(mean(inter[,2]-inter[,1]), 4), "\n")
29 cat("覆盖率: ", round(mean(prob), 4), "\n")

```

模拟结果中，覆盖率接近 0.95，验证了置信区间的有效性。

3. 总体比例的置信区间

设总体 $X \sim B(1, p)$ (两点分布)，样本比例 $\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$ ($X_i = 1$ 表示“成功”，0 表示“失败”)。大样本下 ($n \geq 30$)，由中心极限定理， $\bar{X} \xrightarrow{d} N(p, \frac{p(1-p)}{n})$ ，用 $\bar{X}$ 估计 p ，则 p 的 $1 - \alpha$ 近似置信区间为：

$$\left[\bar{X} - u_{1-\alpha/2} \sqrt{\frac{\bar{X}(1-\bar{X})}{n}}, \bar{X} + u_{1-\alpha/2} \sqrt{\frac{\bar{X}(1-\bar{X})}{n}} \right] \quad (3.12)$$

例题 3.8 总体比例的置信区间模拟 设 $X \sim B(1, 0.2)$ ($p = 0.2$)，样本量 $n = 50$ ，置信水平 $\alpha = 0.05$ ($u_{0.975} = 1.96$)。

R 程序如下：

```

1     set.seed(1)
2     K <- 1000 # 模拟次数
3     n <- 50 # 样本量
4     alpha <- 0.05 # 显著性水平
5     p_true <- 0.2 # 总体比例真值
6
7     inter <- matrix(0, K, 2) # 存储置信区间
8     prob <- matrix(0, K, 1) # 存储覆盖情况
9
10    for (i in 1:K) {
11        data <- rbinom(n, 1, p_true) # 生成两点分布样本
12        barX <- mean(data) # 样本比例
13        S <- sqrt(barX * (1 - barX) / n) # 标准误估计
14        u <- qnorm(1 - alpha/2, 0, 1) # 标准正态分位数
15        # 计算置信区间
16        inter[i, 1] <- barX - u * S
17        inter[i, 2] <- barX + u * S
18        # 判断覆盖真值
19        prob[i] <- (p_true >= inter[i, 1]) & (p_true <= inter[i, 2])
20    }
21
22    # 输出结果
23    cat("平均置信区间下限: ", round(mean(inter[,1]), 4), "\n")
24    cat("平均置信区间上限: ", round(mean(inter[,2]), 4), "\n")
25    cat("平均区间长度: ", round(mean(inter[,2]-inter[,1]), 4), "\n")

```

```
cat("覆盖率: ", round(mean(prob), 4), "\n")
```

大样本下, 覆盖率接近 0.95, 区间精度随样本量增大而提高。

3.2.2 两总体置信区间估计

设两独立总体 $X \sim N(\mu_1, \sigma_1^2)$ 和 $Y \sim N(\mu_2, \sigma_2^2)$, 样本分别为 $X_1, \dots, X_n$ 和 $Y_1, \dots, Y_m$, 重点估计 $\mu_1 - \mu_2$ (均值差) 和 σ_1^2/σ_2^2 (方差比)。

1. 两总体均值差的置信区间

分 σ_1^2, σ_2^2 已知和未知 (但相等) 两种情形:

(a). 情形 1: σ_1^2, σ_2^2 已知

此时 $\bar{X} - \bar{Y} \sim N(\mu_1 - \mu_2, \frac{\sigma_1^2}{n} + \frac{\sigma_2^2}{m})$, 枢轴量 $U = \frac{(\bar{X} - \bar{Y}) - (\mu_1 - \mu_2)}{\sqrt{\frac{\sigma_1^2}{n} + \frac{\sigma_2^2}{m}}} \sim N(0, 1)$, 则 $\mu_1 - \mu_2$ 的 $1 - \alpha$ 置信区间为:

$$\left[(\bar{X} - \bar{Y}) - u_{1-\alpha/2} \sqrt{\frac{\sigma_1^2}{n} + \frac{\sigma_2^2}{m}}, (\bar{X} - \bar{Y}) + u_{1-\alpha/2} \sqrt{\frac{\sigma_1^2}{n} + \frac{\sigma_2^2}{m}} \right] \quad (3.13)$$

(b). 情形 2: $\sigma_1^2 = \sigma_2^2 = \sigma^2$ (未知) 用合并方差 $S_w^2 = \frac{(n-1)S_X^2 + (m-1)S_Y^2}{n+m-2}$ 估计 σ^2 , 枢轴量 $T = \frac{(\bar{X} - \bar{Y}) - (\mu_1 - \mu_2)}{\sqrt{S_w^2(\frac{1}{n} + \frac{1}{m})}} \sim t(n+m-2)$, 则 $\mu_1 - \mu_2$ 的 $1 - \alpha$ 置信区间为:

$$\left[(\bar{X} - \bar{Y}) - t_{1-\alpha/2}(n+m-2) \sqrt{S_w^2 \left(\frac{1}{n} + \frac{1}{m} \right)}, (\bar{X} - \bar{Y}) + t_{1-\alpha/2}(n+m-2) \sqrt{S_w^2 \left(\frac{1}{n} + \frac{1}{m} \right)} \right] \quad (3.14)$$

例题 3.9 方差相等时两总体均值差的置信区间模拟 设 $X \sim N(0, 1)$ ($\mu_1 = 0, \sigma_1 = 1$), $Y \sim N(0.2, 1)$ ($\mu_2 = 0.2, \sigma_2 = 1$), 样本量 $n = m = 50$, 置信水平 $\alpha = 0.05$ ($t_{0.975}(98) \approx 1.984$)。

解

- I. 从总体 $N(\mu_1, \sigma_1^2)$ 中产生样本 $\{X_1^{(1)}, X_2^{(1)}, \dots, X_n^{(1)}\}$, 从总体 $N(\mu_2, \sigma_2^2)$ 中产生样本 $\{Y_1^{(1)}, Y_2^{(1)}, \dots, Y_m^{(1)}\}$; 基于此样本分别计算均值 $\bar{X}^{(1)}$ 和 $\bar{Y}^{(1)}$, 得到置信区间的上下界:

$$\begin{aligned} \hat{\theta}_L^{(1)} &= \bar{X}^{(1)} - \bar{Y}^{(1)} - u_{1-\alpha/2} \sqrt{\frac{\sigma_1^2}{n} + \frac{\sigma_2^2}{m}}, \\ \hat{\theta}_U^{(1)} &= \bar{X}^{(1)} - \bar{Y}^{(1)} + u_{1-\alpha/2} \sqrt{\frac{\sigma_1^2}{n} + \frac{\sigma_2^2}{m}} \end{aligned}$$

- II. 重复上述步骤 K 次, 得到 K 组置信区间的上下界 $\hat{\theta}_L^{(k)}, \hat{\theta}_U^{(k)}, k = 1, 2, \dots, K$;

- III. 基于 K 组 $\hat{\theta}_L^{(k)}, \hat{\theta}_U^{(k)}$, 计算覆盖率 Prob 和置信区间长度 Inter 的估计:

$$\widehat{\text{Prob}} = \frac{1}{K} \sum_{k=1}^K I(\hat{\theta}_L^{(k)} \leq \mu_1 - \mu_2 \leq \hat{\theta}_U^{(k)}), \quad (3.15)$$

$$\widehat{\text{Inter}} = \frac{1}{K} \sum_{k=1}^K (\hat{\theta}_U^{(k)} - \hat{\theta}_L^{(k)}). \quad (3.16)$$

其中 $I(\cdot)$ 为指示函数, 当条件满足时取 1, 否则取 0。

R 程序如下:

```
1 set.seed(1)
2 K <- 1000 # 模拟次数
3 n <- 50 # X样本量
4 m <- 50 # Y样本量
5 alpha <- 0.05 # 显著性水平
6 mu1 <- 0 # X总体均值
```

```

7      mu2 <- 0.2 # Y总体均值
8      sigma <- 1 # 共同标准差
9      delta_true <- mu1 - mu2 # 均值差真值
10
11     inter <- matrix(0, K, 2) # 存储置信区间
12     prob <- matrix(0, K, 1) # 存储覆盖情况
13
14     for (i in 1:K) {
15         # 生成两总体样本
16         data1 <- rnorm(n, mu1, sigma)
17         data2 <- rnorm(m, mu2, sigma)
18         # 计算样本均值和方差
19         barX <- mean(data1)
20         barY <- mean(data2)
21         Sx2 <- var(data1)
22         Sy2 <- var(data2)
23         # 合并方差
24         Sw2 <- ((n-1)*Sx2 + (m-1)*Sy2) / (n + m - 2)
25         # t分布分位数
26         t_val <- qt(1 - alpha/2, n + m - 2)
27         # 标准误
28         se <- sqrt(Sw2 * (1/n + 1/m))
29         # 均值差估计
30         delta_hat <- barX - barY
31         # 置信区间
32         inter[i, 1] <- delta_hat - t_val * se
33         inter[i, 2] <- delta_hat + t_val * se
34         # 判断覆盖真值
35         prob[i] <- (delta_true >= inter[i, 1]) & (delta_true <= inter[i, 2])
36     }
37
38     # 输出结果
39     cat("平均置信区间下限: ", round(mean(inter[,1]), 4), "\n")
40     cat("平均置信区间上限: ", round(mean(inter[,2]), 4), "\n")
41     cat("平均区间长度: ", round(mean(inter[,2]-inter[,1]), 4), "\n")
42     cat("覆盖率: ", round(mean(prob), 4), "\n")

```

模拟结果中，覆盖率接近 0.95，验证了置信区间的有效性。

2. 两总体方差比的置信区间 (非课程内容)

设两独立正态总体，样本方差 $S_X^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$, $S_Y^2 = \frac{1}{m-1} \sum_{i=1}^m (Y_i - \bar{Y})^2$, 枢轴量 $F = \frac{S_X^2/\sigma_1^2}{S_Y^2/\sigma_2^2} \sim F(n-1, m-1)$ (F分布)。F分布的 $\alpha/2$ 分位数为 $F_{\alpha/2}(n-1, m-1)$, $1-\alpha/2$ 分位数为 $F_{1-\alpha/2}(n-1, m-1)$, 则 σ_1^2/σ_2^2 的 $1-\alpha$ 置信区间为:

$$\left[\frac{S_X^2}{S_Y^2 \cdot F_{1-\alpha/2}(n-1, m-1)}, \frac{S_X^2}{S_Y^2 \cdot F_{\alpha/2}(n-1, m-1)} \right] \quad (3.17)$$

例题 3.10 两总体方差比的置信区间模拟 设 $X \sim N(0, 1)$ ($\sigma_1^2 = 1$), $Y \sim N(0.2, 4)$ ($\sigma_2^2 = 4$), 样本量 $n = m = 50$, 置信水平 $\alpha = 0.05$ ($F_{0.025}(49, 49) \approx 0.538$, $F_{0.975}(49, 49) \approx 1.859$), 方差比真值 $\sigma_1^2/\sigma_2^2 = 0.25$.

R 程序如下:

```

1      set.seed(1)
2      K <- 1000 # 模拟次数
3      n <- 50   # X样本量
4      m <- 50   # Y样本量
5      alpha <- 0.05 # 显著性水平
6      sigma1 <- 1 # X标准差
7      sigma2 <- 2 # Y标准差
8      ratio_true <- (sigma1^2) / (sigma2^2) # 方差比真值
9
10     inter <- matrix(0, K, 2) # 存储置信区间
11     prob <- matrix(0, K, 1) # 存储覆盖情况
12
13     for (i in 1:K) {
14         # 生成两总体样本
15         data1 <- rnorm(n, 0, sigma1)
16         data2 <- rnorm(m, 0.2, sigma2)
17         # 计算样本方差
18         Sx2 <- var(data1)
19         Sy2 <- var(data2)
20         # 方差比估计
21         ratio_hat <- Sx2 / Sy2
22         # F分布分位数
23         F1 <- qf(1 - alpha/2, n-1, m-1)
24         F2 <- qf(alpha/2, n-1, m-1)
25         # 置信区间
26         inter[i, 1] <- ratio_hat / F1
27         inter[i, 2] <- ratio_hat / F2
28         # 判断覆盖真值
29         prob[i] <- (ratio_true >= inter[i, 1]) & (ratio_true <= inter[i, 2])
30     }
31
32     # 输出结果
33     cat("平均置信区间下限: ", round(mean(inter[,1]), 4), "\n")
34     cat("平均置信区间上限: ", round(mean(inter[,2]), 4), "\n")
35     cat("平均区间长度: ", round(mean(inter[,2]-inter[,1]), 4), "\n")
36     cat("覆盖率: ", round(mean(prob), 4), "\n")

```

模拟结果中, 覆盖率接近 0.95, 验证了置信区间的有效性。

3. 两总体比例差的置信区间 (非课程内容)

设两独立两点分布总体 $X \sim B(1, p_1)$ 和 $Y \sim B(1, p_2)$, 样本比例 $\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$, $\bar{Y} = \frac{1}{m} \sum_{i=1}^m Y_i$ 。大样本下, $\bar{X} - \bar{Y} \xrightarrow{d} N(p_1 - p_2, \frac{p_1(1-p_1)}{n} + \frac{p_2(1-p_2)}{m})$, 则 $p_1 - p_2$ 的 $1 - \alpha$ 近似置信区间为:

$$\left[(\bar{X} - \bar{Y}) - u_{1-\alpha/2} \sqrt{\frac{\bar{X}(1-\bar{X})}{n} + \frac{\bar{Y}(1-\bar{Y})}{m}}, (\bar{X} - \bar{Y}) + u_{1-\alpha/2} \sqrt{\frac{\bar{X}(1-\bar{X})}{n} + \frac{\bar{Y}(1-\bar{Y})}{m}} \right] \quad (3.18)$$

例题 3.11 两总体比例差的置信区间模拟 设 $X \sim B(1, 0.2)$ ($p_1 = 0.2$), $Y \sim B(1, 0.5)$ ($p_2 = 0.5$), 样本量 $n = m = 500$, 置信水平 $\alpha = 0.05$ ($u_{0.975} = 1.96$), 比例差真值 $p_1 - p_2 = -0.3$ 。

R 程序如下:

```

1  set.seed(1)
2  K <- 1000 # 模拟次数
3  n <- 500 # X样本量
4  m <- 500 # Y样本量
5  alpha <- 0.05 # 显著性水平
6  p1 <- 0.2 # X总体比例
7  p2 <- 0.5 # Y总体比例
8  delta_true <- p1 - p2 # 比例差真值
9
10 inter <- matrix(0, K, 2) # 存储置信区间
11 prob <- matrix(0, K, 1) # 存储覆盖情况
12
13 for (i in 1:K) {
14   # 生成两总体样本
15   data1 <- rbinom(n, 1, p1)
16   data2 <- rbinom(m, 1, p2)
17   # 计算样本比例
18   barX <- mean(data1)
19   barY <- mean(data2)
20   # 标准误
21   se <- sqrt(barX*(1-barX)/n + barY*(1-barY)/m)
22   # 比例差估计
23   delta_hat <- barX - barY
24   # 标准正态分位数
25   u <- qnorm(1 - alpha/2, 0, 1)
26   # 置信区间
27   inter[i, 1] <- delta_hat - u * se
28   inter[i, 2] <- delta_hat + u * se
29   # 判断覆盖真值
30   prob[i] <- (delta_true >= inter[i, 1]) & (delta_true <= inter[i, 2])
31 }
32
33 # 输出结果
34 cat("平均置信区间下限：", round(mean(inter[,1]), 4), "\n")
35 cat("平均置信区间上限：", round(mean(inter[,2]), 4), "\n")
36 cat("平均区间长度：", round(mean(inter[,2]-inter[,1]), 4), "\n")
37 cat("覆盖率：", round(mean(prob), 4), "\n")

```

大样本下，覆盖率接近 0.95，区间精度较高。

3.3 拓展阅读：the James-Stein 估计量（书上无）

James-Stein 估计量说明，当 $k \geq 3$ 时， k 维高斯分布 $N(\theta, \sigma^2 I_k)$ 关于均值的最大似然估计 $\hat{\theta} = y$ 是不可容许的（一个估计量是可容许的，若不存在其他估计量能一致地优于它），而以下给出的估计量比最大似然估计具有更小的期望均方误差（ $E(MSE)$ ）。

在独立的高斯分布中估计每个分量的均值时，该估计量也利用了其他分量的信息。在方差已知的情

况下, James-Stein 估计量为:

$$\hat{\theta}_{JS} = \left(1 - \frac{(k-2)\sigma^2}{\sum_{j=1}^k Y_j^2}\right) Y_i. \quad (3.19)$$

感兴趣的同学可以查阅 **shrinkage estimator** (压缩估计) 相关知识。如何通过模拟判别 JS 估计比 MLE 更好?

以下代码给出了一个简单的模拟:

```

1  p = 10
2  mu_true = 1:p
3  sigma = 1
4  M = 1000
5  mle_mse = c()
6  js_mse = c()
7  for(i in 1:M){
8    mle = rnorm(p, mean = mu_true, sd = sigma)
9    js = mle * (1 - (p-2)*sigma^2/sum(mle^2))
10   mle_mse[i] = sum((mle - mu_true)^2)
11   js_mse[i] = sum((js - mu_true)^2)
12 }
13 avg_mle_mse = mean(mle_mse)
14 avg_js_mse = mean(js_mse)

```

 **练习 3.2 代码练习** 评估四类方差估计量的性质(无偏性, MSE), 其中包括四种不同的分母: $(n-1)$, n , $(n+1)$ 与 $(n+2)$ 。

第三章 练习

1. 设 $X_1, X_2, \dots, X_n$ 是来自参数为 1 的泊松分布总体的样本, $n = 500$, 试给出总体期望 ($\lambda = 1$) 和方差 ($\lambda = 1$) 的点估计形式, 编写 R 程序重复 1000 次模拟, 验证估计量的无偏性和方差。
2. 设 $X_1, X_2, \dots, X_n$ 独立同分布, 密度函数为 $f(x) = (\alpha+1)x^\alpha$ ($0 < x < 1$), $n = 500$, $\alpha = 0.7$ 。编写 R 程序计算 α 的矩估计 (提示: $E(X) = \frac{\alpha+1}{\alpha+2}$) 和最大似然估计 (提示: 似然函数 $L(\alpha) = (\alpha+1)^n \prod_{i=1}^n X_i^\alpha$), 并比较两种估计的 MSE。
3. 设线性模型 $y = \alpha + \beta x + \epsilon$, 其中 $x \sim N(0, 1)$, $\epsilon \sim N(0, 1)$, $\alpha = 1$, $\beta = 1$ 。编写 R 程序生成 300 组样本 (x_i, y_i) , 基于最小二乘法估计 α 和 β (提示: $\hat{\beta} = \frac{\sum (x_i - \bar{x})(y_i - \bar{y})}{\sum (x_i - \bar{x})^2}$, $\hat{\alpha} = \bar{y} - \hat{\beta}\bar{x}$), 并验证估计量的无偏性。
4. 考虑二项分布 $B(n, p)$, 分别在大样本 ($n = 1000$, $p = 0.5$) 和小样本 ($n = 20$, $p = 0.5$) 下, 编写 R 程序给出 p 的点估计 (样本比例) 和区间估计 (大样本用正态近似, 小样本用 Wilson 区间), 并比较两种样本量下区间的覆盖率和长度。
5. 考虑泊松分布 $Poisson(\lambda)$, 分别在大样本 ($n = 1000$, $\lambda = 5$) 和小样本 ($n = 20$, $\lambda = 5$) 下, 编写 R 程序给出 λ 的点估计 (样本均值) 和区间估计 (大样本用正态近似, 小样本用精确区间), 并验证区间的覆盖率。

第四章 使用数值计算与模拟评估假设检验方法

假设检验是统计推断的主要内容之一。假设检验就是当我们对所关心的参数做出一个假设之后，利用样本信息构造检验统计量来判断该假设是否正确。对于一个假设检验问题，通常使用检验的功效衡量检验统计量的优劣，统计功效指的是，在备择假设成立的情况下，检验统计量落入拒绝域的概率。

假设检验过程中可能发生两类错误：弃真错误，即原假设正确的情况下，拒绝原假设，也称一类错误；取伪错误，即原假设错误的情况下，接受原假设，也称二类错误。通常把犯一类错误和二类错误的概率分别记为 α 和 β 。由此可知，统计功效等于 $1 - \beta$ 。 α 和 β 是此消彼长的关系，通常要求在控制犯一类错误概率 α 的前提下，统计功效越大越好。

定义 4.1 (统计功效与两类错误)

统计功效指的是，在备择假设成立的情况下，检验统计量落入拒绝域的概率。

假设检验过程中可能发生两类错误：

1. 弃真错误（第一类错误）：原假设正确的情况下，拒绝原假设，概率记为 α ；
2. 取伪错误（第二类错误）：原假设错误的情况下，接受原假设，概率记为 β 。

由此可知，统计功效等于 $1 - \beta$ 。

对于同类检验（标称显著水平为 α ），也会评估其在实际问题中，是否能够有效地将第一类错误控制在 α 或更低的水平。

本章主要讨论假设检验数值计算，用数值方法估计假设检验问题的一类错误概率 α 和统计功效 $1 - \beta$ 。

与上一章类似的是，对于不同检验的检验统计量以及推导并不是本课程重点，我们主要掌握如何使用模拟的手段进行评估。

4.1 参数检验数值计算

首先通过一个简单的例子说明参数检验的数值计算。

例题 4.1 设 $X_1, X_2, \dots, X_n$ 是来自总体 $N(\mu, 1)$ 的相互独立的样本，检验原假设和备择假设分别为： $H_0 : \mu = 0$ 和 $H_1 : \mu \neq 0$ 。

解 对于上述假设检验问题，设样本均值 $\bar{X} = \sum_{i=1}^n X_i/n$ ，统计量为 $T = \sqrt{n}\bar{X}$ 。在原假设成立的情况下， T 服从 $N(0, 1)$ 分布；在备择假设成立的情况下， T 服从 $N(\sqrt{n}\mu, 1)$ 分布。

记 $u_{1-\frac{\alpha}{2}}$ 为标准正态分布的 $1 - \alpha/2$ 分位数，当 $|T| > u_{1-\frac{\alpha}{2}}$ 时，拒绝 H_0 。如果 $\mu = n^r C$ ，当 $r = -1/2$ 时， T 服从 $N(C, 1)$ 分布；当 $r > -1/2$ 时， T 的分布趋于无穷；当 $r < -1/2$ 时， T 的分布趋于 $N(0, 1)$ 。说明检验统计量 T 能够检测以速度 $n^r (r \geq -1/2)$ 偏离原假设的备择假设。

检验的功效为： $p = P(\text{拒绝 } H_0 | H_1 \text{ 成立})$ 。对于上述假设检验，注意到：

$$\begin{aligned} & P\left(|\sqrt{n}\bar{X}| \leq u_{1-\frac{\alpha}{2}} | H_1 \text{ 成立} \right) \\ &= P\left(-u_{1-\frac{\alpha}{2}} \leq \sqrt{n}(\bar{X} - \mu) + \sqrt{n}\mu \leq u_{1-\frac{\alpha}{2}} | H_1 \text{ 成立} \right) \\ &= P\left(-u_{1-\frac{\alpha}{2}} - \sqrt{n}\mu \leq \sqrt{n}(\bar{X} - \mu) \leq u_{1-\frac{\alpha}{2}} - \sqrt{n}\mu | H_1 \text{ 成立} \right) \\ &= \Phi\left(u_{1-\frac{\alpha}{2}} - \sqrt{n}\mu\right) - \Phi\left(-u_{1-\frac{\alpha}{2}} - \sqrt{n}\mu\right) \\ &= \Phi\left(u_{1-\frac{\alpha}{2}} - \sqrt{n}\mu\right) + \Phi\left(u_{1-\frac{\alpha}{2}} + \sqrt{n}\mu\right) - 1 \end{aligned}$$

这里, $\Phi(\cdot)$ 为标准正态分布的分布函数, 因此, 检验统计量功效为:

$$\begin{aligned} p &= P\left(|\sqrt{n}\bar{X}| > u_{1-\frac{\alpha}{2}} | H_1 \text{ 成立} \right) \\ &= 1 - P\left(|\sqrt{n}\bar{X}| \leq u_{1-\frac{\alpha}{2}} | H_1 \text{ 成立} \right) \\ &= 2 - \Phi\left(u_{1-\frac{\alpha}{2}} - \sqrt{n}\mu\right) - \Phi\left(u_{1-\frac{\alpha}{2}} + \sqrt{n}\mu\right) \end{aligned}$$



笔记 在实际问题中, 很多检验统计量的功效没有显示表达式。此时, 可采用数值模拟方法估计统计量的功效 $\hat{p} = \hat{P}$ (拒绝 $H_0 | H_1$ 成立)。对于本例, 如果 p 没有显示表达式, 可以用备择假设成立时, 拒绝原假设的发生频率来估计功效 p , 具体步骤:

1. 从备择假设 $N(\mu, 1) (\mu \neq 0)$ 随机产生数据 $X_{11}, X_{12}, \dots, X_{1n}$, 样本均值为 $\bar{X}^{(1)} = \sum_{i=1}^n X_{1i}/n$, 相应得到统计量 $\sqrt{n}\bar{X}^{(1)}$;
2. 重复上述步骤 K 次, 相应得到 $\sqrt{n}\bar{X}^{(1)}, \sqrt{n}\bar{X}^{(2)}, \dots, \sqrt{n}\bar{X}^{(K)}$;
3. 功效 p 的估计为:

$$\hat{p} = \frac{1}{K} \sum_{k=1}^K I\left(|\sqrt{n}\bar{X}^{(k)}| > u_{1-\frac{\alpha}{2}}\right)$$

这里 $I(\cdot)$ 表示示性函数。

接下来考虑估计 $\hat{p}$ 的均值和方差。

由于 $K\hat{p}$ 服从二项分布 $\text{Bino}(K, p)$, 可得:

$$\begin{aligned} E(K\hat{p}) &= Kp, \quad \text{Var}(K\hat{p}) = Kp(1-p) \\ E(\hat{p}) &= p, \quad \text{Var}(\hat{p}) = \frac{p(1-p)}{K} \end{aligned}$$

如果 K 越大, 功效的估计越稳定。若 $K = 1000$, $\alpha = 0.05$, 则:

$$p = 2 - \Phi(1.96 - \sqrt{n}\mu) - \Phi(1.96 + \sqrt{n}\mu), \quad \text{Var}(\hat{p}) = \frac{p(1-p)}{1000}$$

在本例中, 取样本量 $n = 100$, $\mu = 0.3$, 重复次数 $K = 1000$, 估计功效的 R 程序如下:

```
1  set.seed(1)
2  n=100
3  res=c()
4  mu=0.3
5  for (i in 1:1000){
6    data=rnorm(n)
7    E.data=mean(data)+mu
8    stat=sqrt(n)*E.data
9    res[i]=as.numeric(abs(stat)>qnorm(0.975,0,1))
10 }
11 result=mean(res)#数值模拟估计的统计功效
12 power=2-pnorm(qnorm(0.975,0,1)-sqrt(n)*mu,0,1)-pnorm(qnorm(0.975,0,1)+sqrt(n)*mu,0,1)#统计功效真值
13 c(result, power)
```

例题 4.2 设 $X_1, X_2, \dots, X_n$ 和 $Y_1, Y_2, \dots, Y_m$ 分别是来自总体 $N(0, \sigma_1^2)$ 和 $N(0, \sigma_2^2)$ 的两个独立样本, 检验原假设和备择假设分别为: $H_0: \sigma_1 = \sigma_2$ 和 $H_1: \sigma_1 \neq \sigma_2$ 。

解 对于上述假设检验问题, 记样本方差为 $S_x^2 = \sum_{i=1}^n (X_i - \bar{X})^2 / (n-1)$ 和 $S_y^2 = \sum_{i=1}^m (Y_i - \bar{Y})^2 / (m-1)$, 统计量为 $T_s = S_x^2 / S_y^2$ 。在原假设成立的情况下, T_s 服从 $F(n-1, m-1)$ 分布; 备择假设下 $\sigma_2^2 T_s / \sigma_1^2$ 服从 $F(n-1, m-1)$ 分布。

设 $F_{1-\frac{\alpha}{2}}(n-1, m-1)$ 和 $F_{\frac{\alpha}{2}}(n-1, m-1)$ 分别是自由度为 $n-1$ 和 $m-1$ 的 F 分布的 $1-\alpha/2$ 和 $\alpha/2$

分位数, 则该假设检验的拒绝域为 $T_s > F_{1-\frac{\alpha}{2}}(n-1, m-1)$ 或 $T_s < F_{\frac{\alpha}{2}}(n-1, m-1)$ 。由于:

$$\begin{aligned} & P(\text{接受 } H_0 | H_1 \text{ 成立}) \\ &= P\left(F_{\frac{\alpha}{2}}(n-1, m-1) \leq T_s \leq F_{1-\frac{\alpha}{2}}(n-1, m-1) | H_1 \text{ 成立}\right) \\ &= P\left(\sigma_2^2 F_{\frac{\alpha}{2}}(n-1, m-1) / \sigma_1^2 \leq \sigma_2^2 T_s / \sigma_1^2 \leq \sigma_2^2 F_{1-\frac{\alpha}{2}}(n-1, m-1) / \sigma_1^2 | H_1 \text{ 成立}\right) \\ &= F_{n-1, m-1}\left(\sigma_2^2 F_{1-\frac{\alpha}{2}}(n-1, m-1) / \sigma_1^2\right) - F_{n-1, m-1}\left(\sigma_2^2 F_{\frac{\alpha}{2}}(n-1, m-1) / \sigma_1^2\right) \end{aligned}$$

这里, $F_{(n-1, m-1)}(\cdot)$ 表示自由度为 $n-1$ 和 $m-1$ 的 F 分布的分布函数, 因此, 检验统计量 T_s 的功效为:

$$p = 1 - F_{n-1, m-1}\left(\sigma_2^2 F_{1-\frac{\alpha}{2}}(n-1, m-1) / \sigma_1^2\right) + F_{n-1, m-1}\left(\sigma_2^2 F_{\frac{\alpha}{2}}(n-1, m-1) / \sigma_1^2\right)$$



笔记 也可以采用数值计算方法对其进行估计, 具体步骤如下:

1. 从 X 和 Y 的总体 $N(0, \sigma_1^2)$ 和 $N(0, \sigma_2^2)$ ($\sigma_1 \neq \sigma_2$) 中产生数据 $X_1^{(1)}, X_2^{(1)}, \dots, X_n^{(1)}, Y_1^{(1)}, Y_2^{(1)}, \dots, Y_m^{(1)}$, 计算样本均值:

$$\bar{X}^{(1)} = \sum_{i=1}^n X_i^{(1)}, \quad \bar{Y}^{(1)} = \sum_{i=1}^m Y_i^{(1)}$$

样本方差为:

$$S_{x(1)}^2 = \sum_{i=1}^n \left(X_i^{(1)} - \bar{X}^{(1)}\right)^2 / (n-1) \quad \text{和} \quad S_{y(1)}^2 = \sum_{i=1}^m \left(Y_i^{(1)} - \bar{Y}^{(1)}\right)^2 / (m-1)$$

以及统计量的值 $T_s^{(1)} = S_{x(1)}^2 / S_{y(1)}^2$;

2. 重复上述步骤 K 次, 相应得到 $T_s^{(1)}, T_s^{(2)}, \dots, T_s^{(K)}$;
3. 功效 p 的估计为:

$$\hat{p} = \frac{1}{K} \sum_{k=1}^K I\left(T_s^{(k)} > F_{1-\frac{\alpha}{2}}(n-1, m-1) \text{ 或 } T_s^{(k)} < F_{\frac{\alpha}{2}}(n-1, m-1)\right)$$

设置 $n = 100$ 和 $m = 50$, 总体方差分别为 $\sigma_1^2 = 1$ 和 $\sigma_2^2 = 4$, 重复次数 $K = 1000$, 估计功效的 R 程序如下:

```
1  set.seed(1)
2  n=100;m=50
3  res=c()
4  sigma=2
5  for (i in 1:1000){
6    X.data=rnorm(n)
7    Y.data=sigma*rnorm(m)
8    S.x=sum((X.data-mean(X.data))^2)/(n-1)
9    S.y=sum((Y.data-mean(Y.data))^2)/(m-1)
10   stat=S.x/S.y
11   criti.1=qf(0.975,n-1,m-1)
12   criti.2=qf(0.025,n-1,m-1)
13   res[i]=as.numeric(stat>=criti.1)+as.numeric(stat<=criti.2)
14 }
15 result=mean(res)#数值模拟估计的统计功效
16 power=1-pf(sigma^2*criti.1,n-1,m-1)+pf(sigma^2*criti.2,n-1,m-1)#统计功效真值
17 c(result, power)
```

4.2 单样本的拟合优度检验



笔记 该小节的推导过程将在大三下学期《非参数统计》中讲解！不是统计计算的重点！只需会如何进行数值模拟即可！

4.2.1 总体分布的卡方检验

首先介绍连续总体的卡方检验。（注：卡方检验的推导过程不在本课程要求范围之内，上课会简单梳理，有兴趣的同学可以仔细看一看）

定义 4.2 (连续总体的卡方检验)

设 $r_1, r_2, \dots, r_n$ 是待检验的一组随机数，原假设为 $H_0: r_1, r_2, \dots, r_n$ 来自区间 $[0, 1]$ 上的均匀总体。将 $[0, 1]$ 区间根据分割点 $0, 1/m, 2/m, \dots, 1$ 分成 m 个小区间，第 i 个小区间为：

$$\left[\frac{i-1}{m}, \frac{i}{m} \right), \quad i = 1, 2, \dots, m$$

设 $\{r_j, j = 1, 2, \dots, n\}$ 落入第 i 个小区间的数目为 $n_i = \sum_{j=1}^n I(r_j \in [\frac{i-1}{m}, \frac{i}{m}))$ 。原假设 H_0 成立时， r_j 落入每个区间的概率为 $p_i = 1/m$ ， $r_j (j = 1, 2, \dots, m)$ 落入第 i 个小区间的理论频数 $\mu_i = n/m$ 。卡方检验的思想是基于观测样本落入 m 个区间的实际频数和理论频数的差异构造检验统计量。差异越大说明样本的总体分布与原假设下的分布差异越大，检验统计量为：

$$T = \sum_{i=1}^m \frac{(n_i - \mu_i)^2}{\mu_i} = \frac{m}{n} \sum_{i=1}^m \left(n_i - \frac{n}{m} \right)^2$$

在原假设下渐近服从 $\chi^2(m-1)$ 。

接下来证明 T 在原假设下渐近服从 $\chi^2(m-1)$ 。

证明 首先证明 n_i 在原假设下渐近服从正态分布，注意到 $n_i \sim \text{Bino}(n, p_i) (i = 1, 2, \dots, m)$ ，由二项分布的性质可知：

$$E(n_i) = np_i, \quad \text{Var}(n_i) = np_i(1 - p_i) = np_i q_i$$

根据中心极限定理，可知 $(n_i - np_i)/\sqrt{n} \xrightarrow{L} N(0, p_i q_i)$ 。

由于 $(n_1, n_2, \dots, n_m) \sim M(n, p_1, p_2, \dots, p_m)$ （这里 $M(n, p_1, p_2, \dots, p_m)$ 表示多项分布），根据多项分布的性质，可得：

$$E(n_i \cdot n_j) = n(n-1)p_i p_j, \quad \text{Cov}(n_i, n_j) = -np_i p_j$$

记随机向量 $N = (n_1, n_2, \dots, n_m)^T$ ，则有 $E(N) = (np_1, np_2, \dots, np_m)^T$ ，且协方差矩阵为 $n\Sigma$ ，其中：

$$\Sigma = \begin{pmatrix} p_1 q_1 & -p_1 p_2 & \cdots & -p_1 p_m \\ -p_1 p_2 & p_2 q_2 & \cdots & -p_2 p_m \\ \vdots & \vdots & \ddots & \vdots \\ -p_1 p_m & -p_2 p_m & \cdots & p_m q_m \end{pmatrix}$$

由中心极限定理，当 $n \rightarrow \infty$ 时：

$$(N - E(N))/\sqrt{n} \xrightarrow{L} N_m(0, \Sigma)$$

取 $D = \text{diag}(1/\sqrt{p_1}, 1/\sqrt{p_2}, \dots, 1/\sqrt{p_m})$ ，由上式可得：

$$D\{N - E(N)\}/\sqrt{n} \xrightarrow{L} N_m(0, D\Sigma D^T)$$

由于 $\sum_{i=1}^m p_i = 1$ ，因此可以验证 $D\Sigma D^T$ 为幂等矩阵。根据幂等矩阵的性质， $D\Sigma D^T$ 的特征值为 0 或 1，即存在正交矩阵 Q 使得 $Q^T D\Sigma D^T Q = \Lambda = \text{diag}(1, 1, \dots, 1, 0)$ 。因此，有：

$$Q^T D(N - E(N))/\sqrt{n} \xrightarrow{L} N_m(0, \Lambda)$$

记 $Q^T D(N - E(N))/\sqrt{n} = (w_1, w_2, \dots, w_m)^T$, 根据上式有 $\{w_i, i = 1, 2, \dots, m-1\}$ 相互独立且渐近服从 $N(0, 1)$, 同时 $w_m = 0$ 。因此, 有:

$$(N - E(N))^T D^T Q Q^T D(N - E(N))/n = \sum_{i=1}^m w_i^2 \xrightarrow{L} \chi^2(m-1)$$

根据正交矩阵的性质 $Q Q^T = I$, 不难验证:

$$(N - E(N))^T D^T D(N - E(N))/n = \sum_{i=1}^m w_i^2 = \sum_{i=1}^m \frac{(n_i - np_i)^2}{np_i}$$

因此, 根据统计量的定义, 有:

$$T = \sum_{i=1}^m \frac{(n_i - np_i)^2}{np_i} \xrightarrow{L} \chi^2(m-1)$$

结论得证。给定显著性水平 α , 由 χ^2 分布得到临界值, 即可做显著性检验。

对于原假设是随机数为均匀分布的假设, 采用如下的模拟来估计统计量的功效, 设置样本量 $n = 500$, 区间个数 $m = 10$, 重复 1000 次。R 程序模拟如下:

```
1      ###均匀性检验——卡方检验
2      set.seed(1)
3      m=10
4      inter=seq(0,1,by=1/m)
5      n=500
6      res1=NULL
7      for (i in 1:1000){
8          data=sqrt(runif(n,min=0,max=1))#备择假设成立
9          #data=runif(n,min=0,max=1)#原假设成立
10         left_inter=rep(1,n)%*%t(inter[1:m])
11         right_inter=rep(1,n)%*%t(inter[2:(m+1)])
12         Data=matrix(data,nrow=n,ncol=m,byrow=FALSE)
13         A=left_inter<=Data&Data<right_inter
14         frequ=apply(A,2,sum)
15         stat1=m/n*sum((frequ-n/m)^2)
16         res1[i]=stat1>qchisq(0.95,m-1)
17     }
18     result=mean(res1)
19     result
```

4.2.2 单样本 K-S 检验

单样本情形下, K-S (柯尔莫哥洛夫-斯米尔诺夫) 检验用于检验观测样本的经验分布函数与假设理论分布函数是否一致。

定义 4.3 (单样本 K-S 检验)

设 $X_1, X_2, \dots, X_n$ 是 n 个独立观测样本, 该检验问题的原假设为 H_0 : 该样本来自分布函数为 $F(\cdot)$ 的总体。

设 $X_{(1)} \leq X_{(2)} \leq \dots \leq X_{(n)}$ 为次序样本, 经验分布函数为 $F_n(X_{(i)}) = i/n (i = 1, 2, \dots, n)$ 。经验分布函数与原假设下的分布函数之间的最大偏差记为 KS 统计量, 即:

$$K_n = \max_{1 \leq i \leq n} \left[\max \left(\left| F(X_{(i)}) - \frac{i}{n} \right|, \left| F(X_{(i)}) - \frac{i-1}{n} \right| \right) \right]$$

H_0 成立时, K-S 统计量依分布收敛于 Kolmogorov 分布, 其分布函数为:

$$P(K_n \leq x) = 1 - 2 \sum_{j=1}^{\infty} (-1)^j \exp(-2nj^2x^2), \quad 0 < x < +\infty$$

为了方便 KS 检验在实际数据分析中的使用, 文献中也给出了单样本 K-S 检验统计量 K_n 的临界值表。对于给定的显著性水平 α , 当 K_n 大于临界值时拒绝 H_0 。

显然 K-S 检验的功效表达不容易给出, 因此, 对于固定的备择假设, 采用蒙特卡罗方法来模拟检验统计量 K_n 的功效。这里选取样本量 $n = 35$, $X_1, X_2, \dots, X_n$ 从自由度为 3 的 t 分布中产生, 检验 H_0 : 该样本来自标准正态分布。对于此例, 当显著性水平 $\alpha = 0.05$ 时, 查表得临界值为 0.23, 当 $K_n > 0.23$ 时, 拒绝 H_0 。根据上述分布函数, 可以计算检验统计量的 p 值, 当 p 值小于 0.05 时, 拒绝 H_0 。R 程序模拟如下:

```
1  ### 正态性检验——K-S检验(柯氏检验)
2  set.seed(1)
3  n=35
4  stat1=NULL
5  res1=NULL
6  res2=NULL
7  for (i in 1:1000){
8    #data=rnorm(n,0,1)#数据来自原假设
9    data=rt(n,3)#数据来自备择假设
10   data=sort(data)
11   D_plus=max(abs(c(1:n)/n-pnorm(data)))
12   D_minus=max(abs(pnorm(data)-(c(1:n)-1)/n))
13   stat1=max(D_plus,D_minus)
14   res1[i]=as.numeric(stat1>0.23)
15   index=seq(1,10000,1)
16   p_val=2*sum((-1)^(index-1)*exp(-2*n*index^2*stat1^2))
17   res2[i]=as.numeric(p_val<0.05)
18 }
19 c(mean(res1),mean(res2))
```

 **练习 4.1 课堂思考与练习 1** 能否使用“向量化”编程, 使得代码更简单?

事实上, 在 R 中也有 KS 检验的函数, 可以直接使用。

 **练习 4.2 课堂练习 2 之拓展练习** 一类统计学中的研究问题为: 在进行同一类检验时, 采用哪种检验得到的功效是最大的, 与此同时又能够控制第一类错误。

例如, 在检验某个样本是否服从均匀分布时, 我们既可以采用卡方检验 (将分布中取值的范围分成 m 个格子间, 然后计算如果服从该分布情况下的预期格子间的样本个数从而构建统计量。事实上, 上述检验又叫做 Goodness-of-fit test (适配性检验))。

当然, 我们也可以直接采取单样本 KS 检验。

我们的练习内容为: 分析与讨论二者的优劣。

例如, 在检验不同的备选假设时的功效是否有差别。可以考虑的备选假设, 例如, 开根号的均匀分布, 贝塔分布, 均匀分布混合其他分布, 均匀分布混合异常值 (outlier) 等等。(注: 使用已有的函数即可)

 **练习 4.3 课堂练习 3 之拓展 2** 当备选假设为 $\text{Beta}(1, x)$, 其中 $x \in (0.05, 4)$ 时, 试图绘制两类检验的功效与 x 之间的关系图 (x 不应取 1, 因为取 1 时所计算的结果为第一类错误, 但可以把 1 也包含进去)

注: “ties are not appropriate for KS test warning”。详见: <https://www.sciencedirect.com/science/article/abs/pii/S0378375894900957>

 **练习 4.4 比较功效：正态分布的假设性检验 - 开放性问题** 在进行线性回归时，如果需要计算回归参数的区间估计，或判定回归参数是否显著，则需要对残差进行正态分布的假设。（问：如果仅仅计算最小二乘点估计，是否需要残差为正态分布的假设？）

在现实中，大多数软件通常会进行拟合，然后计算残差，并给出对残差进行检验的结果（包括严格的统计检验以及图形判定）。

例如，在 SAS 中，默认进行四类检验：Shapiro-Wilk、Kolmogorov-Smirnov、Cramér-von Mises、Anderson-Darling。

比较以上检验在实际问题中的功效以及第一类错误的概率。比较功效时，考虑：不同自由度的 t 分布、双指数分布（double exponential）、Cauchy 分布、正态分布混合部分异常值、Gumbel 分布，以及混合分布。

在比较问题时，可以考虑使用几种不同的样本量，例如，20, 30, 50, 100, 200，或连续的样本，如 30-150，每隔 10 个样本计算一次，方便画图。

如果有兴趣，也可以查找其他能够进行的检验，试图评估其功效。

提醒：可以使用现成的 R 函数来得到 p-value，上述问题中使用 $\alpha = 0.05$ 。后两个检验的函数可以由安装 ‘nortest’ 包得到。

将所得结果制成表或以图的形式展现。

定义 4.4 (Shapiro-Wilk 检验)

Shapiro-Wilk 检验的原假设为：样本 $x_1, \dots, x_n$ 来自一个正态分布总体。检验统计量为：

$$W = \frac{(\sum_{i=1}^n a_i x_{(i)})^2}{\sum_{i=1}^n (x_i - \bar{x})^2},$$

其中 $x_{(i)}$ 是第 i 个顺序统计量， $\bar{x}$ 是样本均值。

系数 a_i 的定义为： $(a_1, \dots, a_n) = \frac{m^T V^{-1}}{C}$ ，其中 C 是向量范数： $C = \|V^{-1}m\| = (m^T V^{-1} V^{-1} m)^{1/2}$ ；向量 $m = (m_1, \dots, m_n)^T$ 由独立同分布标准正态随机变量的顺序统计量的期望值构成； V 是这些正态顺序统计量的协方差矩阵。

统计量 W 的分布没有解析表达式，其临界值通过蒙特卡洛模拟得到。



 **笔记** 该定义 4.4 在茆诗松《概率论与数理统计》中有详细介绍！

定义 4.5 (Cramér-von Mises 检验与 Anderson-Darling 检验)

Anderson-Darling 检验与 Cramér-von Mises 检验属于二次 EDF 统计量（基于经验分布函数的检验）。若原假设的分布为 F ，经验（样本）累积分布函数为 F_n ，则二次 EDF 统计量通过 $n \int_{-\infty}^{\infty} (F_n(x) - F(x))^2 w(x) dF(x)$ 度量 F 与 F_n 的距离，其中 n 为样本量， $w(x)$ 为权重函数。

当权重函数为 $w(x) = 1$ 时，该统计量即为 Cramér-von Mises 统计量。

Anderson-Darling 检验基于距离 $A^2 = n \int_{-\infty}^{\infty} \frac{(F_n(x) - F(x))^2}{F(x)(1 - F(x))} dF(x)$ ，对应的权重函数为 $w(x) = [F(x)(1 - F(x))]^{-1}$ 。

因此，与 Cramér-von Mises 距离相比，Anderson-Darling 距离对分布尾部的观测值赋予了更大的权重。



4.2.3 变量值随机性检验

在实际应用中，如果关心某个数据序列是不是随机出现，那么游程检验是直接检验数据序列是否随机的一种非参数方法。对于一个按照某种顺序排列（例如按从小到大的顺序排列）的数据，将其分成若干子序列，使得每一个子序列内部的值都是上升的，每一个子序列称为一个上升游程，每一个子序列包含的元素个数称为游程长度，数据序列分得的子序列个数称为游程个数。

例如以下 10 个随机数: 0.243, 0.363, 0.941, |0.698, |0.472, |0.458, 0.788, |0.133, 0.342, 0.504, 可分为 5 个上升的游程, 游程长度分别为 3,1,1,2,3。

游程检验的基本思想是: 如果数据序列在 $[0, 1]$ 随机出现的, 则每个上升游程的长度不应过大或过小, 序列中的游程个数也不应太多或太少。记游程长度为 1, 2, 3, 4, 5 和 ≥ 6 的游程数目为 $G_i (i = 1, 2, \dots, 6)$ 。令向量 $G = (G_1, G_2, G_3, G_4, G_5, G_6)^T$, 当数据序列完全随机时, 可证明随机向量 G 的期望为:

$$E(G) = n(b_1, b_2, b_3, b_4, b_5, b_6)^T = n\left(\frac{1}{6}, \frac{5}{24}, \frac{11}{120}, \frac{19}{720}, \frac{29}{5040}, \frac{1}{840}\right)^T$$

协方差矩阵的逆为:

$$\Sigma_G^{-1} = \frac{1}{n} \begin{pmatrix} 4529.4 & 9044.9 & 13568 & 18091 & 22615 & 27892 \\ 9044.9 & 18097 & 27139 & 36187 & 45234 & 55789 \\ 13568 & 27139 & 40771 & 54281 & 67852 & 83685 \\ 18091 & 36187 & 54281 & 72414 & 90470 & 111580 \\ 22615 & 45234 & 67852 & 90470 & 113262 & 139476 \\ 27892 & 55789 & 83685 & 111580 & 139476 & 172860 \end{pmatrix}$$

构造的检验统计量为:

$$Q_n = (G - E(G))^T \Sigma_G^{-1} (G - E(G)) = \frac{1}{n} \sum_{i=1}^6 \sum_{j=1}^6 a_{ij} (g_i - nb_i) (g_j - nb_j)$$

在样本量 n 趋于无穷时, 可证明 Q_n 渐近服从 $\chi^2(6)$ 。在原假设是 $[0, 1]$ 上均匀随机数的情况下, 样本量 $n = 200$, R 程序计算如下:

```

1      ##变量值随机性检验——游程检验
2      set.seed(1)
3      n=200
4      B=c(1/6,5/24,11/120,19/720,29/5040,1/840)
5      A=matrix(data=c(4529.4,9044.9,13568,18091,22615,27892,
6      0,18097,27139,36187,45234,55789,
7      0,0,40721,54281,67852,83685,
8      0,0,0,72414,90470,111580,
9      0,0,0,0,113262,139476,
10     0,0,0,0,0,172860),byrow=TRUE,nrow=6,ncol=6)
11     A=A+t(A)-diag(diag(A),nrow=6,ncol=6)
12     G=matrix(0,nrow=1000,ncol=6)
13     res=NULL
14     for (i in 1:1000){
15         data=runif(n,min=0,max=1)
16         beg_stop=1
17         for (j in 1:(n-1)){
18             if (data[j+1]<data[j]){
19                 beg_stop=c(beg_stop,j+1)
20             }
21         }
22         beg_stop=c(beg_stop,n+1)
23         end=length(beg_stop)
24         runs=beg_stop[2:end]-beg_stop[1:(end-1)]#确定游程长度
25         G[i,]=c(sum(runs==1),sum(runs==2),sum(runs==3),
26         sum(runs==4),sum(runs==5),sum(runs>=6))
27         stat=t(G[i,]-n*B)%*%(A/n)%*%(G[i,]-n*B)

```

```

28     res[i]=stat>=qchisq(0.95,6)
29 }
30 mean(res)

```

以上按上升游程进行游程检验，同样也可以按下降游程进行检验，检验统计量的形式不变。

4.3 两样本的非参数检验



笔记 该小节的推导过程将在大三下学期《非参数统计》中讲解！不是统计计算的重点！只需会如何进行数值模拟即可！

本节首先回顾两样本情形下常用的三种非参数检验方法，并估计或验证这些方法的功效。对于来自两个独立总体的两个样本 $X_1, X_2, \dots, X_n$ 和 $Y_1, Y_2, \dots, Y_m$ ，我们通常关心两个样本统计特征的差异，一般将这一类问题称为两样本问题。

4.3.1 两样本的曼-惠特尼 U 检验

本小节考虑两样本的差异仅存在于位置参数，例如总体均值、中位数等。这里设总体 X 和 Y 分别具有连续分布函数 $F(x)$ 和 $F(x - \mu)$ ，这一问题的原假设和备择假设分别是 $H_0: \mu = 0$ 和 $H_1: \mu \neq 0$ 。

对于上述两样本问题中的位置检验问题，曼-惠特尼 U 检验（Wilcoxon 秩和检验）是应用较广泛的非参数检验方法。

定义 4.6 (曼-惠特尼 U 检验 (Wilcoxon 秩和检验))

Wilcoxon 秩和检验的基本原理是：当 H_0 成立时，将样本 $X_1, X_2, \dots, X_n$ 和 $Y_1, Y_2, \dots, Y_m$ 混合并排序，两个样本计算得到的秩和不应太大或太小。

具体地，将各样本观测值的秩记为 $\{R_1, R_2, \dots, R_n\}$ 和 $\{R_{n+1}, R_{n+2}, \dots, R_{n+m}\}$ ，Wilcoxon 秩和检验统计量定义为：

$$W_x = \sum_{i=1}^n R_i \quad \text{和} \quad W_y = \sum_{i=n+1}^{m+n} R_i$$

注意到 $W_x + W_y = (m+n)(m+n+1)/2$ ，因此，Wilcoxon 秩和检验统计量 W_x 和 W_y 是一一对应的。在原假设下，我们有：

$$E(W_x) = \frac{n(m+n+1)}{2}, \quad \text{Var}(W_x) = \frac{mn(m+n+1)}{12}$$

$$E(W_y) = \frac{m(m+n+1)}{2}, \quad \text{Var}(W_y) = \frac{mn(m+n+1)}{12}$$

当 m, n 趋于无穷时，可证明标准化的 W_x 和 W_y 渐近服从正态分布。

对 Wilcoxon 秩和检验统计量 W_x 进行变形，有：

$$W_x = \sum_{i=1}^n \sum_{k=1}^m I(Y_k \leq X_i) + \sum_{i=1}^n \sum_{j=1}^n I(X_j \leq X_i)$$

$$= \sum_{i=1}^n \sum_{k=1}^m I(Y_k \leq X_i) + \frac{n(n+1)}{2}$$

令 $W_{yx} = (mn)^{-1} \sum_{i=1}^n \sum_{k=1}^m I(Y_k \leq X_i)$ ，可见 W_x 和 W_{yx} 之间具有线性变换关系。统计量 W_{yx} 具有 U 统计量的形式，因此也称为曼-惠特尼 U 统计量。根据 U 统计量的性质，可以证明原假设下 W_{yx} 的渐近正态性，即：

$$\frac{W_{yx} - 1/2}{\sqrt{(m+n+1)/(12mn)}} \xrightarrow{L} N(0, 1)$$

设置 $m = 50$, $n = 80$, 分别从两个总体 $N(0, 1)$ 和 $N(0.3, 1)$ 产生样本 $X_1, X_2, \dots, X_n$ 和 $Y_1, Y_2, \dots, Y_m$ 。由于统计量 W_x , W_y 和 W_{yx} 是一一对应的, 因此这里只给出 W_x , W_y 的计算方法, 计算基于 W_{yx} 的曼-惠特尼 U 检验的功效。R 程序如下:

```

1  ##Wilcoxon秩和检验
2  set.seed(1)
3  m=50
4  n=80
5  resu=NULL
6  for (i in 1:1000){
7    X.data=rnorm(n,0,1)
8    Y.data=rnorm(m,0.3,1)
9    Data=c(X.data,Y.data)
10   Rank=rank(Data)
11   W_x=sum(Rank[1:n])
12   W_y=sum(Rank[(n+1):(n+m)])
13   Wxy=(W_x-n*(n+1)/2)/(m*n)
14   stat=(Wxy-1/2)/sqrt((m+n-1)/(12*m*n))
15   resu[i]=as.numeric(abs(stat)>1.96)
16 }
17 mean(resu)

```

4.3.2 两样本的 K-S 检验（非课程内容）

在两样本问题中, 除位置差异外, 两个样本的差异还可能存在于尺度、峰度、偏度等方面。另外一类检验考虑比较两个总体分布函数间的差异, 称为同分布检验。由于经验分布函数是总体分布函数的相合估计, 所以基于经验分布函数构造的 K-S 检验是两样本问题中重要的非参数方法之一。

这里设总体 X 和 Y 具有连续分布函数 $F(x)$ 和 $G(x)$, 同分布检验的原假设和备择假设为: $H_0: F(x) = G(x)$, $H_1: F(x) \neq G(x)$ 。用 $F_n(x) = \sum_{i=1}^n I(X_i \leq x)/n$ 和 $G_m(x) = \sum_{i=1}^m I(Y_i \leq x)/m$ 分别表示两个样本的经验分布函数, 两样本的 K-S 检验统计量为:

$$D_N = \max \left[\max_{1 \leq i \leq n} (|F_n(X_i) - G_m(X_i)|), \max_{1 \leq j \leq m} (|F_n(Y_j) - G_m(Y_j)|) \right]$$

记 $N = m + n$, 与单样本 K-S 检验的检验统计量 K_n 类似, H_0 成立时, 统计量 D_N 依分布收敛于 Kolmogorov 分布, 其分布函数为:

$$P(D_N \leq x) = 1 - 2 \sum_{j=1}^{\infty} (-1)^j \exp \{ -2j^2 mnx^2 / N \}, \quad 0 < x < \infty$$

对于给定的显著性水平 $\alpha = 0.05$, 两样本 K-S 检验统计量 D_N 的临界值为 $1.36\sqrt{N/(mn)}$ 。因此, 当 $D_N > 1.36\sqrt{N/(mn)}$ 时拒绝 H_0 。

对于固定的备择假设, 可以用两种方法来估计检验统计量 D_N 的功效。选取样本量 $m = 50$, $n = 30$, $X_1, X_2, \dots, X_n$ 从自由度为 3 的 t 分布中产生, $Y_1, Y_2, \dots, Y_m$ 产生自分布 $\chi^2(1) - 1$, 检验两样本是否来自同一分布。当 $D_N > 1.36\sqrt{N/(mn)}$ 时, 拒绝 H_0 。根据上述分布函数, 可以计算检验统计量观测值的 p 值, 当 p 值小于 0.05 时, 拒绝 H_0 。R 程序计算如下:

```

1  ###同分布检验——K-S检验(柯氏检验)
2  set.seed(1)
3  m=50
4  n=30
5  N=m+n

```

```

6 stat1=NULL
7 res1=NULL
8 res2=NULL
9 for (i in 1:1000){
10   X.data=rt(n,3)
11   Y.data=rchisq(m,1)-1
12   F_nx=rowMeans((matrix(1,n,1)%*%X.data)<=(X.data%*%matrix(1,1,n)))
13   F_ny=rowMeans((matrix(1,m,1)%*%X.data)<=(Y.data%*%matrix(1,1,n)))
14   G_mx=rowMeans((matrix(1,n,1)%*%Y.data)<=(X.data%*%matrix(1,1,m)))
15   G_my=rowMeans((matrix(1,m,1)%*%Y.data)<=(Y.data%*%matrix(1,1,m)))
16   D_x=max(abs(F_nx-G_mx))
17   D_y=max(abs(F_ny-G_my))
18   stat1=max(D_x,D_y)
19   res1[i]=as.numeric(stat1>=1.36*sqrt(N/(m*n)))#确定临界值
20   index=seq(1,10000,1)
21   p.val=2*sum((-1)^(index-1)*exp(-2*m*n*index^2*stat1^2/N))
22   res2[i]=as.numeric(p.val<0.05)#判断p值是否小于犯一类错误的概率
23 }
24 c(mean(res1),mean(res2))

```

4.3.3 两样本的游程检验（非课程内容）

Wald-Wolfowitz 游程检验是把两个样本混合之后排序，将来自同一样本的观测值序列称为一个游程，利用数据中的游程个数来检验两样本服从的分布是否一样。例如，把数据来自第一个样本和第二个样本分别标记为 0 和 1，如果样本序列被表示为 110100111，则这个过程总游程数为 $W = 5$ ，由 0 组成游程的个数为 $U = 2$ ，由 1 组成游程个数为 $V = 3$ ，有 $W = U + V$ 成立。

注意到，如果两组样本来自具有相同分布的总体，那么两组样本在混合样本中排序是完全随机的，则总游程个数不应太小；如果两组样本来自具有不同分布的总体，则游程个数较少，且总游程数最少为 2。Wald-Wolfowitz 游程检验的统计量基于 W 构造。

当 H_0 成立时，根据两样本排序的随机性，可得 W 的精确分布，即：

$$P(W = 2k) = 2 \frac{\binom{m-1}{k-1} \binom{n-1}{k-1}}{\binom{m+n}{m}}, \quad k = 1, 2, \dots, \min(m, n)$$

$$P(W = 2k - 1) = \frac{\binom{m-1}{k-1} \binom{n-1}{k-2} + \binom{m-1}{k-2} \binom{n-1}{k-1}}{\binom{m+n}{m}}, \quad k = 2, 3, \dots, \min(m, n) + 1$$

进而有 $E(W) = 2mn/N + 1$, $Var(W) = 2mn(2mn - N)/[N^2(N - 1)]$ ，这里 $N = m + n$ 。当 m, n 趋于无穷时，可以证明 W 渐近服从正态分布。设 $\lim_{m, n \rightarrow \infty} n/(m + n) = \tau$ ，有：

$$\frac{W - 2N\tau(1 - \tau)}{\sqrt{4N\tau^2(1 - \tau)^2}} \xrightarrow{L} N(0, 1)$$

设置样本量 $m = 50$, $n = 30$, $X_1, X_2, \dots, X_n$ 从自由度为 3 的 t 分布总体中产生, $Y_1, Y_2, \dots, Y_m$ 产生自服从 $\chi^2(1) - 1$ 分布的总体，计算统计量 W 在同分布检验中的功效。R 程序计算如下：

```

1 ### 同分布检验——Wald-Wolfowitz游程检验
2 set.seed(1)
3 m=50
4 n=30
5 N=m+n
6 res1=NULL

```

```

7   for (i in 1:1000){
8     X.data=rt(n,3)
9     Y.data=rchisq(m,1)-1#Y.data=rt(m,3)原假设成立
10    Data=c(X.data,Y.data)
11    Runs=as.numeric(order(Data)<=n)
12    W=1
13    for (j in 1:(length(Runs)-1)){
14      if (Runs[j]!=Runs[j+1]){
15        W=W+1
16      }
17    }
18    E=2*m*n/N+1
19    V=2*m*n*(2*m*n-N)/(N^2*(N-1))
20    res1[i]=as.numeric(abs((W-E)/sqrt(V))>=1.96)
21  }
22  mean(res1)

```

4.4 独立性检验（非课程内容）

在实际应用中，除了研究数据的异质性，还关心两个变量之间的相依关系。例如，消费者对不同商品的选择是否和所处的年龄段有关，某种疾病的处理结果是否和处理方法有关。对于这类分类变量之间的相依关系，用列联分析构造独立性检验；连续性变量之间的相依关系用相关系数来度量。

Pearson 相关系数 r 常用于度量两变量间的线性关系；另外，Spearman r_s 相关系数和 Kendall τ 相关系数是度量变量间单调（不一定为线性）关系的非参数方法。

4.4.1 列联分析检验

本节介绍两个分类变量间的独立性检验方法。二维列联表是指对观测个体的两个特征进行分类计算得到的频数分布表。设 n 个样本可按照两个特征 A (r 个水平) 和 B (c 个水平) 进行分类，二维列联表为：

	B_1	B_2	$\cdots$	B_c	合计
A_1	n_{11}	n_{12}	$\cdots$	n_{1c}	$n_{1\cdot}$
A_2	n_{21}	n_{22}	$\cdots$	n_{2c}	$n_{2\cdot}$
$\vdots$	$\vdots$	$\vdots$	$\ddots$	$\vdots$	$\vdots$
A_r	n_{r1}	n_{r2}	$\cdots$	n_{rc}	$n_{r\cdot}$
合计	$n_{\cdot 1}$	$n_{\cdot 2}$	$\cdots$	$n_{\cdot c}$	n

其中， n_{ij} 表示同时具有 A_i 和 B_j 特征的实际频数，用 p_{ij} 表示第 i 行、第 j 列格子的理论频数，相应第 i 行和第 j 列的理论频率为 $p_{i\cdot} = \sum_{j=1}^c p_{ij}$ 和 $p_{\cdot j} = \sum_{i=1}^r p_{ij}$ ，且 n_{ij}/n 是 p_{ij} 的极大似然估计。

当行变量和列变量独立时，有 $p_{ij} = p_{i\cdot} p_{\cdot j}$ 。因此，分类变量间的独立性检验就可以转换为 $p_{ij} = p_{i\cdot} p_{\cdot j}$ 的拟合优度检验。在原假设成立时，应该有 $n_{ij} \approx \frac{n_{i\cdot} n_{\cdot j}}{n}$ ，其统计量称为 Pearson χ^2 统计量，即：

$$Q = \sum_{i=1}^r \sum_{j=1}^c \frac{(n_{ij} - n_{i\cdot} n_{\cdot j} / n)^2}{n_{i\cdot} n_{\cdot j} / n}$$

且在原假设下，可以证明 $Q \xrightarrow{L} \chi^2((r-1)(c-1))$ 。

观测值落入 (i, j) 格的概率为 p_{ij} ，因此，观测频数服从多项分布，其概率密度为：

$$\frac{n!}{\prod_{i=1}^r \prod_{j=1}^c n_{ij}!} \prod_{i=1}^r \prod_{j=1}^c p_{ij}^{n_{ij}}$$

由于 $\sum_{i=1}^r \sum_{j=1}^c p_{ij} = 1$ ，所以 $p_{ij} (i = 1, 2, \dots, r, j = 1, 2, \dots, c)$ 中的独立参数有 $rc - 1$ 个，且 p_{ij} 的最大似然估计为 $\hat{p}_{ij} = n_{ij}/n$ 。当原假设 $p_{ij} = p_{i \cdot} \cdot p_{\cdot j}$ 成立时，有 $\sum_{i=1}^r p_{i \cdot} = \sum_{j=1}^c p_{\cdot j} = 1$ ，因此 $p_{i \cdot} (i = 1, 2, \dots, r)$ 和 $p_{\cdot j} (j = 1, 2, \dots, c)$ 中共有 $r + c - 2$ 个独立参数。此时， p_{ij} 的极大似然估计为 $\hat{p}_{i \cdot} \cdot \hat{p}_{\cdot j} = (n_{i \cdot}/n)(n_{\cdot j}/n)$ 。因此，该检验问题的似然比统计量为：

$$\Lambda = \frac{\prod_{i=1}^r \prod_{j=1}^c \left(\frac{n_{ij}}{n}\right)^{n_{ij}}}{\prod_{i=1}^r \prod_{j=1}^c \left(\frac{n_{i \cdot}}{n} \frac{n_{\cdot j}}{n}\right)^{n_{ij}}}$$

由于 $(rc - 1) - (r + c - 2) = (r - 1)(c - 1)$ ，故在原假设成立时， $2 \ln \Lambda$ 的极限分布为 $\chi^2((r - 1)(c - 1))$ 。在原假设下可证明上述 Q 和 Λ 具有如下关系：

$$2 \ln \Lambda = Q + o_p(1)$$

根据 Pearson χ^2 统计量的思想，统计量 Q 通过累积每个小格子中联合频数和边际频数之积的差异来检验分类变量间的独立性。当数据来自连续型分布时，通过将连续型变量的取值范围划分为不同区间使其离散化，从而将问题转化为分类变量的独立性检验问题。

接下来，通过一个例子来详细阐述这一做法。取样本量 $n = 100$ ，假设数据 $(X_1, Y_1), (X_2, Y_2), \dots, (X_n, Y_n)$ 服从二元正态分布， X 和 Y 的均值均为 0，方差都为 1，相关系数为 0.6。我们将 $\{X_1, X_2, \dots, X_n\}$ 和 $\{Y_1, Y_2, \dots, Y_n\}$ 分别划分 $k = 8$ 个区间，然后计算 Pearson χ^2 统计量 Q 对该检验问题的功效。

```

1  ###独立检验——列联表检验
2  set.seed(1)
3  library(MASS)
4  k=8
5  n=100
6  Sigma=matrix(c(1,0.6,0.6,1),2,2)
7  res1=NULL
8  for (i in 1:1000){
9      data=mvnrm(n,rep(0,2),Sigma)
10     X.data=data[,1]
11     Y.data=data[,2]
12     Sx=sort(X.data)
13     Sy=sort(Y.data)
14     inter_x=seq(min(X.data),max(X.data),by=(max(X.data)-min(X.data))/k)
15     inter_y=seq(min(Y.data),max(Y.data),by=(max(Y.data)-min(Y.data))/k)
16     left_inter_x=rep(1,n)%>%t(inter_x[1:k])
17     right_inter_x=rep(1,n)%>%t(inter_x[2:(k+1)])
18     left_inter_y=rep(1,n)%>%t(inter_y[1:k])
19     right_inter_y=rep(1,n)%>%t(inter_y[2:(k+1)])
20     Data1=X.data%>%matrix(1,1,k)
21     Data2=Y.data%>%matrix(1,1,k)
22     frequx=(left_inter_x<=Data1)& (Data1<right_inter_x)
23     frequy=(left_inter_y<=Data2)& (Data2<right_inter_y)
24     frequxy=t(frequx)%>%frequy
25     pi=apply(t(frequxy),2,sum)/n
26     pj=apply(frequxy,2,sum)/n
27     pij=pi%>%t(pj)

```

```

28     A=(frequxy-n*pij)^2/(n*pij)
29     A[is.nan(A)]=0
30     stat1=sum(A)
31     res1[i]=stat1>qchisq(0.95,(k-1)^2)
32 }
33 mean(res1)

```

4.4.2 相关系数检验

对于两个连续型变量而言，常用相关系数来衡量二者间的相关程度。本小节主要介绍三种相关系数的定义及其性质，并给出具体的模拟计算三种相关系数的检验功效。

首先考虑两个变量间的线性相关关系。变量 X 和 Y 间的相关系数定义为 ρ ，即：

$$\rho = \frac{E(XY) - E(X)E(Y)}{\sqrt{\text{Var}(X)\text{Var}(Y)}}$$

显然， ρ 取值在 -1 到 1 之间。 $|\rho| = 1$ 说明 X 和 Y 之间存在完全线性关系；如果 X 和 Y 相互独立，则有 $\rho = 0$ 。关心两个变量间是否存在简单线性关系，即检验： $H_0: \rho = 0$ ， $H_1: \rho \neq 0$ 。

样本 $(X_1, Y_1), (X_2, Y_2), \dots, (X_n, Y_n)$ 的相关程度用 Pearson 相关系数 r 度量，即：

$$r = \frac{\sum_{i=1}^n (X_i - \bar{X})(Y_i - \bar{Y})}{\sqrt{\sum_{i=1}^n (X_i - \bar{X})^2 \sum_{i=1}^n (Y_i - \bar{Y})^2}}$$

当 (X, Y) 服从二元正态分布时，在原假设下，可以证明：

$$t = r \sqrt{\frac{n-2}{1-r^2}} \sim t(n-2)$$

注意到，当数据来自正态分布时，独立和不相关等价。因此，在正态性假设下，可以用上述统计量检验数据间的独立性。但在实际分析中，很多数据难以满足正态性假定，同时用简单相关系数也不能反映出变量 X 和 Y 间的相依关系。因此，对于检验问题： $H_0: X$ 和 Y 是不相关的， $H_1: X$ 和 Y 是相关的，Pearson 相关系数 r 不再适用。Spearman r_s 秩相关系数和 Kendall τ 相关系数是常用的度量数据间单调关系的非参数方法。

首先介绍 Spearman r_s 秩相关系数。记 (X_i, Y_i) 在各自样本中的秩为 (R_i, S_i) ，如果 X 和 Y 具有一定的单调关系，那么 X 和 Y 的秩应该具有一定的线性相关关系。因此，Spearman r_s 秩相关系数通过研究两组数据秩的线性相关系数检验原始数据的单调性，定义为：

$$r_s = \frac{\sum_{i=1}^n (R_i - \bar{R})(S_i - \bar{S})}{\sqrt{\sum_{i=1}^n (R_i - \bar{R})^2 \sum_{i=1}^n (S_i - \bar{S})^2}}$$

其中， $\bar{R} = \sum_{i=1}^n R_i/n$ 和 $\bar{S} = \sum_{i=1}^n S_i/n$ 是样本的平均秩，且 $\bar{R} = \bar{S} = (n+1)/2$ 。用 $d_i^2 = (R_i - S_i)^2$ 表示个体 X_i 和 Y_i 在各自样本中的秩差平方。如果 $d_i^2 (i = 1, 2, \dots, n)$ 一致大，说明两组数据间存在负相关关系；如果 $d_i^2 (i = 1, 2, \dots, n)$ 一致小，说明两组数据间存在正相关关系。因此，也可以用 $\sum_{i=1}^n d_i^2$ 度量两组数据间的相关关系。简单的计算表明，上式也可以简化为：

$$r_s = 1 - \frac{6 \sum_{i=1}^n d_i^2}{n(n^2 - 1)}$$

和 Pearson 相关系数 r 一样， $-1 \leq r_s \leq 1$ 。当样本量 n 充分大时，在原假设下，可以证明统计量 r_s 的渐近正态性，即：

$$r_s \sqrt{n-1} \xrightarrow{L} N(0, 1)$$

Kendall τ 相关系数的思想是用所有 X 和 Y 的数对中方向一致和方向相反的数对比例差异来检验 X

和 Y 的单调关系。具体地, n 个观测数据 $(X_1, Y_1), (X_2, Y_2), \dots, (X_n, Y_n)$ 中可以产生 $\binom{n}{2}$ 组数对, 即 $\{X_i, X_j\}$ 和 $\{Y_i, Y_j\}$, $1 \leq i < j \leq n$ 。如果 $(X_i - X_j)(Y_i - Y_j) > 0$, 则称该数对方向一致; 如果 $(X_i - X_j)(Y_i - Y_j) < 0$, 则称该数对方向相反。当数据正相关时, 方向一致的数对倾向较多; 当数据负相关时, 方向相反的数对倾向较多。因此, 两种数对的数目之差可以用来衡量两变量间的相关程度。记 $\text{sign}(\cdot)$ 为符号函数, Kendall τ 相关系数定义为:

$$\tau = \binom{n}{2}^{-1} \sum_{1 \leq i < j \leq n} \text{sign}((X_i - X_j)(Y_i - Y_j))$$

当所有数对的方向均一致时, $\tau = 1$; 当所有数对的方向均相反时, $\tau = -1$ 。因此, 和前两种相关系数一样, Kendall τ 相关系数也满足 $-1 \leq \tau \leq 1$ 。当样本量 n 充分大时, 在原假设下, 可以证明统计量 τ 的渐近正态性, 即:

$$\tau \sqrt{\frac{9n(n-1)}{2(2n+5)}} \xrightarrow{L} N(0, 1)$$

接下来通过数值计算来计算 Spearman r_s 秩相关系数和 Kendall τ 相关系数的检验功效。取样本量 $n = 100$, 按照以下设置产生数据: $X_i \sim N(0, 1)$, $Y_i = \beta_1 X_i + \beta_2 X_i^2 + \epsilon_i$, $i = 1, 2, \dots, n$, 其中 $\beta_1 = 0.5$, $\beta_2 = -1$, $\epsilon_i \sim N(0, 1/\sqrt{n})$ 。R 程序如下:

```

1  ###独立检验——相关系数检验
2  set.seed(1)
3  n=100
4  beta1=0.5
5  beta2=-1
6  res1=NULL
7  res2=NULL
8  for (i in 1:1000){
9    X.data=rnorm(n,0,1)
10   epsilon=rnorm(n,0,1/sqrt(n))
11   Y.data=beta1*X.data+beta2*X.data^2+epsilon
12   R=rank(X.data)
13   S=rank(Y.data)
14   r_s=1-6*mean((R-S)^2)/(n^2-1)
15   XX=X.data%*%t(rep(1,n))-rep(1,n)%*%t(X.data)
16   YY=Y.data%*%t(rep(1,n))-rep(1,n)%*%t(Y.data)
17   tau=sum(sign(XX*YY))/(n*(n-1))
18   res1[i]=abs(r_s*sqrt(n-1))>1.96
19   res2[i]=abs(tau*sqrt(9*n*(n-1)/(4*n+10)))>1.96
20 }
21 c(mean(res1),mean(res2))

```

4.5 传统假设检验中可能的问题

图 4.1 中的结论有哪些地方不对劲吗? 类似的结论是否经常在相关科学、社会、经济等报道中出现呢? 思考一下上述结论有哪些问题?

类似的问题还会在哪些领域出现呢? (例如, 体检中的血象问题, 检的越多, 错的越多; 例如临床试验中的“终点”问题, 终点越多就越不容易都满足) 抽象而言, 如果将规范约束增多的话, 每个人都会被发现“黑历史”。



图 4.1: 多重检验问题的实际示例

4.5.1 扩展内容与阅读：多重假设检验问题（Multiplicity Issue; Multiple Comparison Problem）

（如有兴趣，可以查找并进行一定研究/代码练习）

设 $H_1, \dots, H_m$ 为一族原假设， $p_1, \dots, p_m$ 为对应的 p 值。记 m 为原假设的总数， m_0 为真原假设的数量（对研究者而言通常未知）。

族系错误率（FWER） 是指拒绝至少一个真原假设 H_i 的概率，即犯至少一类错误的概率。

以图 4.1 为例，如果假设糖果与青春痘之间无显著关联（颜色只是假象），那么只要有一个假设被拒绝，我们就会得到错误的新闻信息（此时 m_0 为检验总数）。

这时，FWER 定义为：拒绝至少一个无显著关联的原假设 H_0 的概率。

$$\text{FWER} = P \left\{ \bigcup_{i=1}^{m_0} \left(p_i \leq \frac{\alpha}{m} \right) \right\}.$$

4.5.2 Bonferroni 校正法

Bonferroni 校正在每个 $p_i \leq \frac{\alpha}{m}$ 时拒绝原假设，从而将 FWER 控制在 $\leq \alpha$ 。

该控制的证明基于布尔不等式，推导如下：

$$\text{FWER} = P \left\{ \bigcup_{i=1}^{m_0} \left(p_i \leq \frac{\alpha}{m} \right) \right\} \leq \sum_{i=1}^{m_0} \left\{ P \left(p_i \leq \frac{\alpha}{m} \right) \right\} \leq m_0 \frac{\alpha}{m} \leq \alpha.$$

这种控制不需要对 p 值之间的相关性，或真原假设的数量做任何假设。

4.5.3 Holm-Bonferroni 方法

在统计学中，Holm-Bonferroni 方法（也称为 Holm 方法或 Bonferroni-Holm 方法）用于解决多重比较问题。

它旨在控制族系错误率（FWER），并提供一种比简单 Bonferroni 校正更具检验功效的统一检验。

该方法以提出者 Sture Holm 和 Carlo Emilio Bonferroni 命名。

算法步骤如下：

1. 设有 m 个 p 值，按从小到大排序为 $P_{(1)}, \dots, P_{(m)}$ ，对应原假设为 $H_{(1)}, \dots, H_{(m)}$ ；
2. 目标是将 FWER 控制在预先设定的显著性水平 α 以下：
 - (a). 若 $P_{(1)} \leq \alpha/m$ ，拒绝 $H_{(1)}$ 并继续下一步；否则停止；
 - (b). 若 $P_{(2)} \leq \alpha/(m-1)$ ，拒绝 $H_{(2)}$ 并继续下一步；否则停止。
 - (c). 以此类推：对每个 p 值，检验是否 $P_{(k)} \leq \frac{\alpha}{m+1-k}$ ；
 - (d). 若满足条件，拒绝 $H_{(k)}$ 并继续检验更大的 p 值；否则停止。

该方法确保 FWER 在强意义下不超过 α （证明可在互联网上找到，此处省略）。

简单 Bonferroni 校正仅拒绝 p 值小于等于 $\frac{\alpha}{m}$ 的原假设，以确保 FWER（即拒绝一个或多个真原假设的风险，或犯一类错误的风险）不超过 α 。

这种对一类错误的保护代价是，增加了未能拒绝一个或多个假原假设的风险（即犯二类错误的风险）。因此，简单 Bonferroni 校正被认为“过于保守”。

Holm-Bonferroni 方法同样将 FWER 控制在 α ，但比经典 Bonferroni 方法的二类错误风险增加更小。

Holm-Bonferroni 方法将 p 值从小到大排序，并与名义显著性水平 $\frac{\alpha}{m}$ 到 α （即

$$\frac{\alpha}{m}, \frac{\alpha}{m-1}, \dots, \frac{\alpha}{2}, \frac{\alpha}{1}$$

）进行比较。

索引 k 标识第一个不足以拒绝原假设的 p 值。因此，原假设 $H_{(1)}, \dots, H_{(k-1)}$ 被拒绝，而 $H_{(k)}, \dots, H_{(m)}$ 不被拒绝。若 $k = 1$ ，则没有 p 值小到可以拒绝原假设，因此不拒绝任何原假设。

若未找到这样的索引 k ，则所有 p 值都小到可以拒绝原假设，因此拒绝所有原假设（不接受任何原假设）。

Holm-Bonferroni 方法比 Bonferroni 校正更“尖锐”（检验功效更高）。当然，在研究中可以构建更紧的边界（此处省略，因为不是本课重点）。

另一个研究方向是根据每个假设的重要性分配“显著性水平 α ”，这被称为“ α -分配（alpha-spending）”问题，常见于临床试验。

现代研究领域之一是考虑检验大量假设（如 $m = 1000$ ）的问题。FWER 要求我们不犯任何错误，这在实际中可能过于严格。因此，我们要求错误（假阳性发现）的平均比例不超过 α 水平，这被称为“假发现率（FDR）”。可以应用如 Benjamini-Hochberg 方法等流程来控制 FDR。

推荐阅读：> *Controlling the False Discovery Rate: A Practical and Powerful Approach to Multiple Testing*
> by Yoav Benjamini and Yosef Hochberg,

> *Journal of the Royal Statistical Society. Series B (Methodological)*, Vol. 57, No. 1 (1995).

4.6 归总：思维模式/思考步骤（老师认为的）

1. 发现问题（例如：残差的正态性检验）
2. 搜集方法（例如：已有的检验方法）
3. 运用模拟，考虑不同设定，比较方法（例如：检验问题中的功效、一类错误；估计问题中的 MSE、置信区间）
4. 系统性总结比较的结果，得出结论
5. 思考 4 中结果产生的深层次原因与机制
6. 思考新的方法，能够带来均衡或在特定情况更好
7. 新的方法的实际应用、理论性质等等

第四章 练习

1. 设 $X_1, X_2, \dots, X_n$ 和 $Y_1, Y_2, \dots, Y_m$ 分别是来自总体 $N(\mu_1, \sigma^2)$ 和 $N(\mu_2, \sigma^2)$ （ σ 未知）的两个独立样本，检验原假设和备择假设分别为： $H_0: \mu_1 = \mu_2$, $H_1: \mu_1 \neq \mu_2$ 。取 $n = 100$, $m = 50$, $\mu_1 = 0$, $\mu_2 = 2$, $\sigma = 1$ ，用数值计算方法估计上述检验问题的功效。
2. 35 位健康男性在未进食前的血糖浓度如下，分别用卡方检验和单样本 K-S 检验方法来检验这组数据是否来自均值 $\mu = 80$ 、标准差 $\sigma = 6$ 的正态分布总体，用数值计算方法进行分析。

87	77	92	68	80	78	84	77	81	80	80	77
76	80	81	75	77	72	81	90	84	86	80	68
76	77	78	92	75	80	78					

注：使用卡方检验时应选择合理的区间分割，要求各组观测值个数不低于 5 个。

3. 设 $X_1, X_2, \dots, X_n$ 和 $Y_1, Y_2, \dots, Y_m$ 分别是来自总体 $U(\theta_1, \theta_1 + 1)$ 和 $U(\theta_2, \theta_2 + 1)$ 的两个独立样本，检验原假设和备择假设分别为： $H_0: \theta_1 = \theta_2$, $H_1: \theta_1 \neq \theta_2$ 。取 $n = 30$, $m = 50$, $\theta_1 = 0$, $\theta_2 = 0.5$ ，分别用曼-惠特尼 U 检验和两样本游程检验方法分析上述假设检验问题，并采用数值计算方法估计功效。
4. 设 $X_1, X_2, \dots, X_n$ 和 $Y_1, Y_2, \dots, Y_m$ 分别是来自总体 X 和 Y 的两个独立样本， X 与 Y 的分布函数分别为 $F(x)$ 和 $G(y)$ ，检验的原假设和备择假设分别为： $H_0: F(x) = G(y)$, $H_1: F(x) \neq G(y)$ 。取 $m = 50$, $n = 30$, $X \sim N(0, 1)$, $Y \sim N(0, 2)$ ，用两样本 K-S 检验构造检验统计量，并采用数值计算方法估计检验统计量的功效。
5. 分类变量 X 和 Y 分别有 r 和 c 种可能性，分别记为 $X = i (i = 1, 2, \dots, r)$ 以及 $Y = j (j = 1, 2, \dots, c)$ 。将同时满足 $X = i (i = 1, 2, \dots, r)$ 和 $Y = j (j = 1, 2, \dots, c)$ 的样本观测频数记为 n_{ij} 。固定 r, c, n_{ij} ，利用列联分析方法检验 X 和 Y 是否独立，并用数值分析方法计算检验的功效。

第五章 简单的数值求根与极值问题

之前内容都是用随机数（随机生成样本）的方法解决部分实际问题。这一章我们非常简单地介绍采用循环的手段用数值计算的方法解决一类实际问题，即求极值问题。该类问题也包含求根问题。由于数值计算本身并不属于本统计模拟课程的重点，因此只从应用与实现的角度，做简单介绍。我们将非常简单地介绍 R 中如何简单的解决此类问题，以及介绍梯度下降算法的最简单思想。

5.1 数值求解问题：单根

1. 最传统的方法：二分法（Bisection Search），迭代直到满足停止准则（速度较慢但保证收敛）
2. 停止准则：
 - (a). 绝对准则： $|x^{(t+1)} - x^{(t)}| < \epsilon$ （已收敛）
 - (b). 相对准则： $|x^{(t+1)} - x^{(t)}|/|x^{(t)}| < \epsilon$ （已收敛）
 - (c). 梯度准则： $|g'(x^{(t)})| < \epsilon$ （已收敛）
 - (d). 迭代次数： $t > T$ （未收敛）

5.1.1 简单示例

考虑求解 $f(x) = 0$ 的根，例如：

$$x^5 + 10x^3 + 20x - 4 = 0.$$

在 R 中，直接使用 `uniroot()` 函数即可。

5.1.2 多根情况示例

考虑求解 $f(x) = 0$ 的根，例如：

$$f(x) = \cos(x)^4 - 4\cos(x)^3 + 8\cos(x)^2 - 5\cos(x) + 1/2.$$

在 R 中，可使用 `rootSolve::uniroot.all`。

我们还可以解决以下问题：多方程、多参数（可查看 `rootSolve` 包）。

5.2 通用（且简单）的优化方法：梯度下降

梯度下降（Gradient Descent）适用于凸函数（convex function）。

在数学中，若函数图像上任意两点间的线段都位于这两点间函数图像的上方，则该实值函数称为凸函数。

5.3 步长（学习率）以及最优化实现

- 步子该迈多大？Newton-Raphson 法（利用二阶导数）
- R 函数： `optim()`
- 常用的其他算法：L-BFGS-B




图 5.1: 凸函数示例




图 5.2: 梯度下降方法示意图

5.3.1 案例：以下代码为部分简单的求根或优化问题，以及一个最优化问题中数值估计的实例，即最小“一乘”估计

```

1 ##### Root-finding: for univariate case
2
3 ##### Optimization Task 1: Find root of  $\cos(x) = x$ 
4 x = seq(-5, 5, by = 0.01)
5 cosx = cos(x)
6 plot(x, x, type = 'l')
7 lines(x, cosx)
8
9 uniroot(function(x) cos(x) - x, lower = 0,
10 upper = pi, tol = 1e-9)$root
11
12 ##### Optimization Task 2: Find multiple roots, for univariate function
13 ##### Now you need to use external package called 'rootSolve'
14 f = function(x) cos(x)^4 - 4*cos(x)^3 + 8*cos(x)^2 - 5*cos(x) + 1/2
15 uniroot(f, c(0,2))
16 c(uniroot(f, c(0,1))$root, uniroot(f, c(1,2))$root)
17 rootSolve::uniroot.all(f, c(0,2))
18
19 ##### Optimization Task 3: The n-variable, n-equations problem
20 model <- function(x) c(F1 = x[1] + x[2] + x[3]^2 - 12,
21 F2 = x[1]^2 - x[2] + x[3] - 2,
22 F3 = 2 * x[1] - x[2]^2 + x[3] - 1 )
23
24 # first solution
25 ss <- multiroot(f = model, start = c(1, 1, 1))
26
27 # second solution; use different start values
28 ss <- multiroot(model, c(0, 0, 0))
29 model(ss$root)
30
31 ##### Optimization Task 4: The use of the function optim()
32
33 objective_fun = function(beta){
34   residual = data_all[, 6] - (beta[1] + beta[2]*data_all[, 1] + beta[3]*data_all[, 2] +
35   beta[4]*data_all[, 3] + beta[5]*data_all[, 4] + beta[6]*data_all[, 5])
36   out = sum(residual^2)
37   return(out)
38 }
39
40 objective_fun_LAR = function(beta){
41   residual = data_all[, 6] - (beta[1] + beta[2]*data_all[, 1] + beta[3]*data_all[, 2] +
42   beta[4]*data_all[, 3] + beta[5]*data_all[, 4] + beta[6]*data_all[, 5])
43   out = sum(abs(residual))
44   return(out)
45 }
46

```

```
47 objective_fun_Ridge = function(beta){
48   residual = data_all[, 6] - (beta[1] + beta[2]*data_all[, 1] + beta[3]*data_all[, 2] +
49     beta[4]*data_all[, 3] + beta[5]*data_all[, 4] + beta[6]*data_all[, 5])
50   out = sum(residual^2) + sum(beta[2:6]^2)
51   return(out)
52 }
53
54 optim(par = rep(0, 6), fn = objective_fun, method = "L-BFGS-B", lower = -Inf,
55   upper = Inf)
56 optim(par = rep(1, 6), fn = objective_fun_LAR, method = "L-BFGS-B", lower = -Inf,
57   upper = Inf)
58 optim(par = rep(0, 6), fn = objective_fun_Ridge, method = "L-BFGS-B", lower = -Inf,
59   upper = Inf)
```

第六章 降低方差的统计方法

内容提要



6.1 估计定积分的例子

本节介绍两种直观的估计定积分的基础方法，为后续方差降低技术提供铺垫。

定义 6.1 (蒙特卡洛方法)

蒙特卡洛方法（英语：Monte Carlo method），也称统计模拟方法，是 1940 年代中期由于科学技术的发展和电子计算机的发明，而提出的一种以概率统计理论为指导的数值计算方法。是指使用随机数（或更常见的伪随机数）来解决很多计算问题的方法。

20 世纪 40 年代，在科学家冯·诺伊曼、斯塔尼斯拉夫·乌拉姆和尼古拉斯·梅特罗波利斯于洛斯阿拉莫斯国家实验室为核武器计划工作时，发明了蒙特卡罗方法。因为乌拉姆的叔叔经常在摩纳哥的蒙特卡洛赌场输钱得名，而蒙特卡罗方法正是以概率为基础的方法。

与它对应的是确定性算法。

蒙特卡罗方法在金融工程学、宏观经济学、生物医学、计算物理学（如粒子输运计算、量子热力学计算、空气动力学计算）、机器学习等领域应用广泛。

通常蒙特卡洛方法可以粗略地分成两类：

1. 一类是所求解的问题本身具有内在的随机性，借助计算机的运算能力可以直接模拟这种随机的过程。例如在核物理研究中，分析中子在反应堆中的传输过程。中子与原子核作用受到量子力学规律的制约，人们只能知道它们相互作用发生的概率，却无法准确获得中子与原子核作用时的位置以及裂变产生的新中子的行进速率和方向。科学家依据其概率进行随机抽样得到裂变位置、速度和方向，这样模拟大量中子的行为后，经过统计就能获得中子传输的范围，作为反应堆设计的依据。
2. 另一种类型是所求解问题可以转化为某种随机分布的特征数，比如随机事件出现的概率，或者随机变量的期望。通过随机抽样的方法，以随机事件出现的频率估计其概率，或者以抽样的数字特征估算随机变量的数字特征，并将其作为问题的解。这种方法多用于求解复杂的多维积分问题。

假设我们要计算一个不规则图形的面积，那么图形的不规则程度和分析性计算（比如，积分）的复杂程度是成正比的。蒙特卡洛方法基于这样的想法：假设你有一袋豆子，把豆子均匀地朝这个图形上撒，然后数这个图形之中有多少颗豆子，这个豆子的数目就是图形的面积。当你的豆子越小，撒的越多的时候，结果就越精确。借助计算机程序可以生成大量均匀分布坐标点，然后统计出图形内的点数，透过它们占总点数的比例和坐标点生成范围的面积就可以求出图形面积。



6.1.1 随机投点法

定义 6.2 (随机投点法)

对于积分 $I = \int_0^1 f(x)dx$ ($0 \leq f(x) \leq 1$)，其几何意义是函数 $f(x)$ 在区间 $[0, 1]$ 上形成的曲边梯形面积。向正方形 $\{0 \leq x \leq 1, 0 \leq y \leq 1\}$ 内随机投点 (ξ_i, η_i) ($\xi_i \sim U(0, 1)$ 、 $\eta_i \sim U(0, 1)$ 且相互独

立), 通过落入曲边梯形内点的比例估计积分值:

$$\hat{I}_1 = \frac{1}{n} \sum_{i=1}^n I_{\eta_i \leq f(\xi_i)} \quad (6.1)$$

其中 $I(\cdot)$ 为示性函数。

性质 随机投点法的统计性质

1. 无偏性: $E(\hat{I}_1) = I$, 即估计量的数学期望等于真实积分值。
2. 方差: $Var(\hat{I}_1) = \frac{1}{n} I(1-I)$, 方差随样本量 n 增大而减小。

证明 首先证明无偏性:

$$E(\hat{I}_1) = E(I_{\eta \leq f(\xi)}) = \int_0^1 \int_0^{f(x)} dy dx = \int_0^1 f(x) dx = I,$$

故 $\hat{I}_1$ 是 I 的无偏估计。

接下来计算方差:

$$\begin{aligned} Var(\hat{I}_1) &= \frac{1}{n} Var(I_{\eta \leq f(\xi)}) = \frac{1}{n} E(I_{\eta \leq f(\xi)} - I)^2 \\ &= \frac{1}{n} E(I_{\eta \leq f(\xi)}^2 - 2II_{\eta \leq f(\xi)} + I^2) \\ &= \frac{1}{n} (E(I_{\eta \leq f(\xi)}) - 2I^2 + I^2) \\ &= \frac{1}{n} (I - I^2) = \frac{1}{n} I(1-I). \end{aligned}$$

事实上, $I_{(\xi_i, \eta_i) \in S} \sim \text{Bino}(1, I)$ ($i = 1, 2, \dots, n$), 根据二项分布的性质, 也可直接得到 $\hat{I}_1$ 的均值与方差。



笔记 若 $f(x)$ 定义在一般区间 $[a, b]$ 且有界 $c \leq f(x) \leq d$, 可通过变量变换转换为 $[0, 1]$ 区间的积分, 且被积函数取值在 $[0, 1]$ 之间, 上述结论仍成立。

对于定义在区间 $[a, b]$ 上的函数 $f(x)$ (满足 $c \leq f(x) \leq d$), 更简便的方法是直接向长方形区域 $\{a \leq x \leq b, c \leq y \leq d\}$ 内随机投点 (ξ_i, η_i) , 其中:

1. ξ_i 服从 $[a, b]$ 区间上的均匀分布,
2. η_i 服从 $[c, d]$ 区间上的均匀分布,
3. 且 ξ_i 与 η_i 相互独立。

基于此随机投点, 积分 $I = \int_a^b f(x) dx$ 的估计量为:

$$\hat{I} = \frac{(b-a)(d-c)}{n} \sum_{i=1}^n I_{\eta_i \leq f(\xi_i)}$$

其中 $I(\cdot)$ 为示性函数 (当条件满足时取 1, 否则取 0), n 为投点总数。

例题 6.1 用随机投点法估计 $I = \int_0^1 \frac{\sin x}{x} dx$, R 程序如下:

```
1 n=1000
2 x=runif(n)
3 y=runif(n)
4 g=function(x) sin(x)/x
5 I=length(which(y<=g(x)))/n # 或sum(y<=g(x))/n
6 plot(x,y,pch=16,col=c((y<=g(x))+1))
7 lines(sort(x),g(sort(x)),col="blue",lwd=2)
```

6.1.2 平均值估计法

定义 6.3 (平均值估计法)

对于积分 $I = \int_0^1 f(x)dx$, 利用积分与期望的关系 $I = E(f(R))$ ($R \sim U(0,1)$), 产生均匀随机数 $r_1, r_2, \dots, r_n$, 积分估计为:

$$\hat{I}_2 = \frac{1}{n} \sum_{i=1}^n f(r_i) \quad (6.2)$$

性质 平均值估计法的统计性质

1. 无偏性: $E(\hat{I}_2) = I$, 与随机投点法一致。
2. 方差: $Var(\hat{I}_2) = \frac{1}{n}(Ef^2(R) - I^2)$, 且 $Var(\hat{I}_2) \leq Var(\hat{I}_1)$ (因 $0 \leq f(x) \leq 1$)。



笔记 对于积分的两种不同估计方法 (随机投点法 $\hat{I}_1$ 与平均值估计法 $\hat{I}_2$), 二者均为无偏估计, 但平均值估计法的方差更小。

例题 6.2 如何通过模拟验证, 后者的估计方差比前者小?

(注: 为了用模拟验证“方差”或“波动性”, 我们必须让所得目标“动起来”, 因此需要循环)

例题 6.3 用平均值估计法估计 $I = \int_0^1 \frac{\sin x}{x} dx$, R 程序如下:

```
1 set.seed(1)
2 n=1000
3 x=runif(n)
4 I=sum(sin(x)/x)/n
```



笔记 初步结论: 似乎对于所有定积分问题 (即 $\int_a^b h(x)dx$), 都可以转化为以下思路求解:

1. 改写为期望形式:

$$\int_a^b h(x)dx = \int_a^b \frac{1}{b-a}(b-a)h(x)dx = E_X[(b-a)h(x)]$$

其中 $X \sim \text{Unif}(a, b)$ 。

2. 生成样本: 产生 $x_1, x_2, \dots, x_M \sim \text{Unif}(a, b)$ 。
3. 计算估计量:

$$\frac{1}{M} \sum_{i=1}^M (b-a)h(x_i)$$

更广泛的是, 为计算 $\int h(x)dx$, 我们可以试图找到某个密度函数 $f(x)$ (目前多为均匀分布), 并从 $f(x)$ 中进行抽样。对于非均匀的 $f(x)$, 如何化解为平均值问题从而将蒙特卡洛样本平均以求解呢? (见下节)

6.2 对偶变量的应用 (非课程内容)

定义 6.4 (对偶变量法)

设需估计 $\mu = E(X)$, 若存在对偶变量 $Y = g(X)$ 满足: X 与 Y 同分布且负相关, 则构造估计量:

$$\hat{\mu}_2 = \frac{1}{2n} \sum_{i=1}^n (X_i + Y_i) = \frac{1}{2n} \sum_{i=1}^n (X_i + g(X_i)) \quad (6.3)$$

其方差小于直接平均值估计 $\hat{\mu}_1 = n^{-1} \sum_{i=1}^n X_i$ 。

定理 6.1 (均匀分布对偶变量)

若 $X \sim U(0,1)$, 则 $Y = 1 - X$ 与 X 同分布且满足 $Cov(X, Y) < 0$, 是理想的对偶变量。

证明 由变换法可得 $Y = 1 - X$ 的密度函数为 $U(0, 1)$, 直接计算协方差:

$$\text{Cov}(X, 1 - X) = E(X(1 - X)) - E(X)E(1 - X) = \int_0^1 x(1 - x)dx - \frac{1}{4} = \frac{1}{2} - \frac{1}{3} - \frac{1}{4} < 0$$

故定理得证。

定理 6.2 (单调函数对偶变量)

设 f 为单调函数, $U \sim U(0, 1)$, 则 $\text{Cov}(f(U), f(1 - U)) \leq 0$, 即 $f(1 - U)$ 是 $f(U)$ 的有效对偶变量。♥

例题 6.4 利用对偶变量法估计 $E(\sqrt{1 - U^2})$ ($U \sim U(0, 1)$), R 程序如下:

```
1 set.seed(1)
2 I=vector()
3 for(i in 1:1000){
4   x=runif(100)
5   I[i] = mean((sqrt(1-x^2)+sqrt(1-(1-x)^2))/2)
6 }
7 cat("E(I)",mean(I),"Var(I)",var(I))
```

6.3 控制变量法的应用 (非课程内容)

定义 6.5 (控制变量法)

设需估计 $\mu_x = E(X)$, 令 Y 为任意随机变量 ($E(Y) = \mu_y$), β 为常数, 构造控制变量 $X + \beta(Y - \mu_y)$, 其估计量为:

$$\hat{\mu}_\beta = n^{-1} \sum_{i=1}^n [X_i + \beta(Y_i - \mu_y)] \quad (6.4)$$

当 $\beta_0 = -\text{Cov}(X, Y)/\text{Var}(Y)$ 时, 方差最小:

$$\text{Var}(\hat{\mu}_{\beta_0}) = \frac{1}{n} \left(\text{Var}(X) - \frac{\text{Cov}^2(X, Y)}{\text{Var}(Y)} \right) \leq \text{Var}(\hat{\mu}_1)$$

例题 6.5 用控制变量法估计 $I = \int_0^1 e^t dt = Ee^U$ ($U \sim U(0, 1)$), 选择控制变量 $Y = U - \frac{1}{2}$ ($E(Y) = 0$), R 程序如下:

```
1 set.seed(1)
2 n=100
3 hat_mu1=NULL
4 hat_mu2=NULL
5 for(i in 1:1000){
6   U=runif(n,0,1)
7   X=exp(U)
8   hat_mu1[i]=mean(X)
9   Y=1.690*(U-0.5) # beta=-1.690
10  hat_mu2[i]=mean(X-Y)
11 }
12 c(mean(hat_mu1),mean(hat_mu2),var(hat_mu1),var(hat_mu2))
```

6.4 条件期望法 (非课程内容)

定义 6.6 (条件期望法 (Rao-Blackwell 方法))

设需估计 $\mu = E(X)$, 若存在随机变量 Y 使得 $E(X) = E(E(X|Y))$, 构造估计量:

$$\hat{\mu}_2 = n^{-1} \sum_{i=1}^n E(X_i|Y_i) \quad (6.5)$$

由 Rao-Blackwell 不等式 $Var(E(X|Y)) \leq Var(X)$, 可知 $Var(\hat{\mu}_2) \leq Var(\hat{\mu}_1)$ 。

例题 6.6 设 X, Y 独立同分布于 $U(-1, 1)$, 估计 $E(I(X^2 + Y^2 \leq 1))$, R 程序如下 (对比平均值估计与条件期望估计):

```
1      set.seed(1)
2      I1=vector()
3      I2=vector()
4      for(i in 1:1000){
5          x=2*runif(100)-1
6          y=2*runif(100)-1
7          theta=(x^2+y^2<=1)
8          I1[i]=mean(theta)
9          I2[i]=mean(sqrt(1-x^2))
10     }
11     cat('Var(I1)',var(I1),'Var(I2)',var(I2))
12     cat("E(I1)",mean(I1),"E(I2)",mean(I2))
```

6.5 重要抽样法

重要抽样法 (Importance Sampling; IS) 的想法是: 产生其他独立同分布样本 $Y_1, Y_2, \dots, Y_n$, 基于此样本估计 $E(X)$ 。通过抽取样本 $Y_1, Y_2, \dots, Y_n$, 提高对积分计算重要区域的抽样, 减少估计的方差。

定义 6.7 (重要抽样法)

假设 X 的密度函数是 $f(x)$, 则 $\mu = E(X)$ 可写为:

$$\mu = \int x f(x) dx = \int g(x) \cdot \frac{x f(x)}{g(x)} dx = E \left\{ Y \frac{f(Y)}{g(Y)} \right\},$$

这里随机变量 Y 的密度函数为 $g(x)$ 。

根据上式, 如果 Y 的随机数 $y_1, y_2, \dots, y_n$ 很容易产生, 则 $\mu = EX$ 可以通过下式估计:

$$\hat{\mu}_2 = \frac{1}{n} \sum_{i=1}^n \frac{y_i f(y_i)}{g(y_i)}. \quad (6.6)$$

设 X 的密度函数为 $f(x)$, 需估计 $\mu = E(X) = \int x f(x) dx$, 选择易抽样的密度函数 $g(x)$ (重要抽样密度), 构造估计量:

$$\hat{\mu}_2 = \frac{1}{n} \sum_{i=1}^n \frac{Y_i f(Y_i)}{g(Y_i)} \quad (6.7)$$

其中 $Y_i \sim g(x)$, $\omega(Y_i) = 1/g(Y_i)$ 为权因子, 通过提高积分重要区域的抽样概率降低方差。

性质 重要抽样法估计的方差为：

$$\begin{aligned} \text{Var}(\hat{\mu}_2) &= \frac{1}{n} \text{Var} \left(\frac{Yf(Y)}{g(Y)} \right) \\ &= \frac{1}{n} \int \left(\frac{yf(y)}{g(y)} - \mu \right)^2 g(y) dy \\ &= \frac{1}{n} \left\{ \int \frac{y^2 f^2(y)}{g(y)} dy - \mu^2 \right\}. \end{aligned} \quad (6.8)$$

(最后一步由上一步将完全平方式拆开即可得到) 如果 $x^2 f^2(x)/g(x) = \mu^2$, 可得 $\text{Var}(\hat{\mu}_2) = 0$, 也就是方差达到最小。(本课程不要求掌握方差计算的细节)

若 $f(x)$ 的非零取值部分对应 $x > 0$, 则 $xf(x)/g(x) = \mu$, 也就是 $g(x) = xf(x)/\mu$ 。

因此, 密度函数 $g(x)$ 的最佳选择就是和被积函数 $xf(x)$ 具有相同的形状。对积分值贡献越大的区域, 希望以较大的概率抽取到随机数。

在实际中, μ 是未知量, 因此无法选取 $g(x)$, 使得 $\text{Var}(\hat{\mu}_2) = 0$ 。通常情况下, 我们会选取一个形状接近 $xf(x)$ 的函数作为 $g(x)$ (但原则是 $g(x)$ 能够轻易抽样得到)。

例题 6.7 用重要抽样法估计 $\mu = \int_0^1 xf(x)dx = \int_0^1 e^x dx$ 的估计值。

解 根据重要抽样法的想法, 从和被积函数 e^x 形状类似的密度函数中产生随机数。

根据 Taylor 展开, $e^x = \sum_{i=0}^{\infty} x^i/i!$ 。由于 $x \in [0, 1]$, e^x 的 Taylor 展开前两项 $1+x$ 标准化之后得到 $g(x) = 2(1+x)/3$, 作为和 e^x 形状近似的密度函数。此时:

$$\mu = \int_0^1 \frac{e^x}{g(x)} g(x) dx = E \left\{ \frac{e^Y}{g(Y)} \right\},$$

这里随机变量 Y 的密度函数为 $g(y) = 2(1+y)/3$ 。

关于密度函数 $g(x)$ 的随机数, 注意到 $R = (2Y + Y^2)/3$, 可得 $Y = \sqrt{3R+1} - 1$ 。产生 $[0, 1]$ 上的均匀随机数 $R_1, \dots, R_n$, 计算 $Y_i = \sqrt{3R_i+1} - 1$, 则 μ 的重要抽样法估计为:

$$\hat{\mu}_2 = \frac{3}{2n} \sum_{i=1}^n \frac{e^{Y_i}}{1+Y_i}.$$

根据式 (11), 估计的方差为:

$$\begin{aligned} \frac{1}{n} \left\{ \int \frac{y^2 f^2(y)}{g(y)} dy - \mu^2 \right\} &= \frac{1}{n} \left(\frac{3}{2} \int_0^1 \frac{e^{2y}}{1+y} dy - \mu^2 \right) \\ &= \frac{1}{n} \left(\frac{3}{2e^2} \int_0^1 \frac{e^{2(y+1)}}{1+y} dy - \mu^2 \right) = \frac{1}{n} \left(\frac{3}{2e^2} \int_2^4 \frac{e^t}{t} dt - \mu^2 \right). \end{aligned}$$

(书上有印刷错误, 本课程不要求掌握方差计算)

R 程序如下:

```

1      set.seed(1)
2      n=100
3      I1=NULL
4      I2=NULL
5      Ginv = function(r) sqrt(1 + 3*r)-1 # g(x)的逆变换
6      for (i in 1:1000){
7          R=runif(n)
8          Y=Ginv(runif(n))
9          I1[i]=mean(exp(R)) # 平均值估计
10         I2[i]=mean(3*exp(Y)/(2*(1+Y))) # 重要抽样估计
11     }
12     cat('平均值估计',mean(I1),'重要抽样估计',mean(I2))
13     cat('平均值估计方差',var(I1),'重要抽样估计方差',var(I2))

```

 **练习 6.1** 用蒙特卡洛方法，估计积分：

$$\int_0^1 \frac{e^{-x}}{1+x^2} dx$$

 **练习 6.2** 用蒙特卡洛方法，估计级数和：

$$S = \sum_{j=0}^{\infty} \frac{\sin(\sqrt{j})}{\log(j+2)} e^{-6\sqrt{j}} \frac{1}{j!}$$



笔记 取决于看问题的视角（以及被积函数如何变形），事实上“平均值估计法”与重要性采样估计，本质上是一回事儿。



笔记 重要抽样算法核心原理：在部分场景下，大量模拟点对应的函数值趋近于 0，对近似结果的贡献微乎其微。此时选择与待近似积分拟合度更高的分布作为抽样分布，能够显著提升估计精度——这也是选择重要性密度的核心原则。

根据积分恒等变换：

$$\int h(x) dx = \int h(x) \cdot \frac{1}{g(x)} \cdot g(x) dx$$

其中 $g(x)$ 需满足：

1. $g(x)$ 的支撑集与 $h(x)$ 完全一致；
2. $g(x)$ 易于抽样生成随机数；
3. $g(x)$ 被称为重要性密度函数（Importance Density Function）。

 **练习 6.3** 用蒙特卡洛方法计算积分 $\int_0^{10} \exp(-2|x-5|) dx$ （理论真值约为 1），完成以下要求：

1. 采用均匀抽样实现蒙特卡洛估计，编写 R 代码并分析结果；

$$\hat{I}_{\text{unif}} = \frac{1}{n} \sum_{i=1}^n 10 \cdot \exp(-2|X_i - 5|), \quad X_i \sim U(0, 10) \quad (6.9)$$

2. 选取 $N(5, 1)$ 作为重要性密度，采用重要抽样实现蒙特卡洛估计，编写 R 代码并对比方差；

$$\hat{I}_{\text{IS}} = \frac{1}{n} \sum_{i=1}^n \exp\left(\frac{(X_i - 5)^2}{2} - 2|X_i - 5|\right) \cdot \sqrt{2\pi}, \quad X_i \sim N(5, 1) \quad (6.10)$$

解

1. 均匀抽样的 R 代码实现：

```

1      # 均匀抽样实现
2      X <- runif(100000, 0, 10)
3      Y <- 10 * exp(-2 * abs(X - 5))
4      # 输出估计值与方差
5      c(mean(Y), var(Y))

```

运行结果：[1] 0.9919611 3.9529963

结果分析：均匀抽样的蒙特卡洛估计方差较大，核心原因是被积函数在 $x = 5$ 处形成峰值，其他区域快速衰减，多数样本点贡献极小。

2. 重要抽样的 R 代码实现：

```

1      # 重要抽样实现 (N(5,1)作为重要性密度)
2      n <- 1e5
3      x <- rnorm(n, mean = 5, sd = 1)
4      y <- (exp(((x-5)^2)/2 - 2*abs(x-5))) * sqrt(2*pi)
5      # 输出估计值与方差
6      c(mean(y), var(y))

```

运行结果: [1] 0.9999271 0.3577506

结果分析: 重要抽样的积分估计值保持准确, 方差仅为均匀抽样的 1/10 左右, 估计效率显著提升。

 **练习 6.4** 对于 $a \geq 0$, 计算积分:

$$I(a) = \int_a^{\infty} (1+x^2)^{1/2} \cdot \frac{\sin(x)}{x} \cdot \exp(-|x|^{3/2}) dx \quad (6.11)$$

实验要求:

1. 取 $a = 0, 2, 4$, 分别采用以下三种抽样方法 (样本量 $n = 100000$) 计算 $I(a)$:
 - (a). 方法 1: 抽样分布为标准正态分布 $N(0, 1)$;
 - (b). 方法 2: 抽样分布为正态分布 $N(a, 1)$;
 - (c). 方法 3: 抽样分布为密度函数 $g(x) = \exp(-(x-a)) \cdot I_{[a, \infty)}(x)$ ($I(\cdot)$ 为示性函数)。
2. 手动推导每种方法对应的重要抽样估计公式;
3. 重复估计 $I(a)$ 共 500 次, 计算各方法估计值的方差;
4. 对比三种方法的估计精度与方差, 说明最优方法及原因。

性质 重要抽样的核心优势:

1. 无偏性: 重要抽样估计量的数学期望等于积分真值;
2. 方差优化: 当重要性密度 $g(x)$ 与被积函数形状越接近, 估计方差越小;
3. 适用性: 尤其适用于被积函数在局部区域有显著峰值的积分问题。

6.6 分层抽样法 (非课程内容)

定义 6.8 (分层抽样法)

对于积分 $I = \int_0^1 f(x) dx$, 将区间 $[0, 1]$ 分为 m 个互不相交的子区间 $[a_{i-1}, a_i]$ ($a_0 = 0, a_m = 1$), 则:

$$I = \sum_{i=1}^m \int_{a_{i-1}}^{a_i} f(x) dx = \sum_{i=1}^m (a_i - a_{i-1}) E(f(X_i))$$

其中 $X_i \sim U(a_{i-1}, a_i)$, 在各子区间抽取 n_i 个样本, 构造估计量:

$$\hat{I} = \sum_{i=1}^m \frac{a_i - a_{i-1}}{n_i} \sum_{j=1}^{n_i} f(r_{i,j}) \quad (6.12)$$

总样本量 $n = \sum_{i=1}^m n_i$, 子区间样本数按方差最优原则分配。

性质 最优样本分配: 对于 $m = 2$ 个子区间, $n_1/n_2 = \frac{(a_1-a_0)SD(f(r_1))}{(a_2-a_1)SD(f(r_2))}$, 其中 $SD(\cdot)$ 为标准差。

例题 6.8 用分层抽样法估计 $I = \int_0^1 e^x dx$, 将区间分为 $[0, 0.5]$ 和 $[0.5, 1]$, R 程序如下:

```

1      m=4 # 第一区间样本数
2      n=6 # 第二区间样本数
3      r1=runif(m,min=0,max=0.5)
4      r2=runif(n,min=0.5,max=1)
5      I=(mean(exp(r1)) + mean(exp(r2)))/2
6      Sigma2=var(exp(r1))/(4*m) + var(exp(r2))/(4*n)

```

6.7 随机数重复使用法

定义 6.9 (随机数重复使用法)

对于同一组随机数, 通过多种估计方法计算目标参数, 利用估计量间的相关性降低方差。例如, 比较两个估计量差异的方差时, 重复使用相同随机数可减少额外变异。

例题 6.9 比较正态分布方差的两个估计量 $\hat{\sigma}_1^2 = \frac{1}{n-1} \sum (X_i - \bar{X})^2$ 和 $\hat{\sigma}_2^2 = \frac{1}{n} \sum (X_i - \bar{X})^2$, R 程序如下:

```

1      set.seed(1)
2      n=100
3      N=1000
4      I11=NULL
5      I21=NULL
6      I22=NULL
7      for(i in 1:N){
8          X=rnorm(n,mean=0,sd=1)
9          Y=rnorm(n,mean=0,sd=1)
10         I11[i]=var(X)
11         I21[i]=n*var(X)/(n-1) # 同一样本
12         I22[i]=n*var(Y)/(n-1) # 不同样本
13     }
14     VDif1=var(I11-I21) # 相同样本方差
15     VDif2=var(I11-I22) # 不同样本方差
16     cat("相同样本",VDif1,"不同样本",VDif2)

```

第六章 练习

1. 设 $X \sim U(0, 1)$, 使用随机投点法和平均值估计法估计 $I = E(X)$, 利用数值分析方法比较两种估计的有效性。
2. 使用随机投点法、对偶变量法和条件期望法估计圆周率 π , 利用数值分析方法比较估计值和估计方差。
3. 随机样本 $X_1, X_2, \dots, X_n$ 来自指数分布 $Exp(1)$, 用平均值估计法和控制变量法估计 $E(X)$, 比较两种方法的估计结果和方差。
4. 使用本章方法估计 $I = \int_{-1}^1 e^x dx$, 在样本量相同的情况下, 比较各估计方法的有效性。
5. 请分别以

$$\begin{aligned}
 f_1(x) &= 1, \quad 0 < x < 1, \\
 f_2(x) &= \frac{e^{-x}}{1 - e^{-1}}, \quad 0 < x < 1, \\
 f_3(x) &= \frac{4}{\pi(1 + x^2)}, \quad 0 < x < 1
 \end{aligned}$$

作为重要函数, 运用重要抽样法估计积分

$$\theta = \int_0^1 \frac{e^{-x}}{1 - e^{-1}} dx,$$

并分析比较相应的方差缩减率。

6. 分别用等比例和最优分层抽样法估计

$$\theta = E(\sqrt{1 - U^2}), \quad U \sim U(0, 1),$$

并与一般样本均值法估计量的有效性进行比较。

7. 用对偶变量法估计

$$\theta = \int_0^1 e^{x^2} dx,$$

并与一般方法比较估计量的方差。

8. 假设 $X_k, k = 1, 2, \dots, 5$ 是均值为 1 独立的指数随机变量, 试用对偶变量法估计

$$\theta = P\left\{\sum_{k=1}^5 kX_k \geq 21.6\right\}.$$

9. 用控制变量法给出 $\theta = E[e^{U+V^2}]$ 的估计和方差, 其中 U, V 独立同分布, 均服从 $U(0, 1)$, 且选择控制变量 $f = (U + V)^2$ 。10. 设 X 和 Y 是相互独立且均值分别为 1 和 2 的指数分布随机变量, 试用条件期望法估计

$$P\{X + Y > 4\}.$$

11. 设 X 和 Y 是相互独立的 $b(n, p)$ 随机变量, 令 $\theta = E[e^{XY}]$ 。

- (a). 给出 θ 的直接估计。
- (b). 用控制变量法估计 θ 。
- (c). 用条件期望法估计 θ 。

12. 设 $\sigma_j, j = 1, 2, \dots, m$ 为 m 个正实数,

$$f(\alpha_1, \alpha_2, \dots, \alpha_m) = \frac{\sigma_1^2}{\alpha_1} + \frac{\sigma_2^2}{\alpha_2} + \dots + \frac{\sigma_m^2}{\alpha_m}, (\alpha_1, \dots, \alpha_m) \in (0, 1)^m,$$

则在 $\alpha_1 + \alpha_2 + \dots + \alpha_m = 1$ 条件下 $f(\alpha_1, \alpha_2, \dots, \alpha_m)$ 的最小值点为

$$\alpha_j = \frac{\sigma_j}{\sum_{k=1}^m \sigma_k}, j = 1, 2, \dots, m,$$

最小值为 $(\sigma_1 + \dots + \sigma_m)^2$ 。

13. 考虑定积分

$$I = \int_{-1}^1 e^x dx = e - e^{-1}.$$

- (a). 用随机模拟方法计算定积分 I , 分别用随机投点法、平均值法、重要抽样法和分层抽样法计算。
- (b). 设估计结果为 $\hat{I}$, 如果需要以 95% 置信度保证计算结果精度在小数点后三位, 则这四种方法分别需要计算多少次被积函数值?
- (c). 用不同的随机数种子重复以上的估计 B 次, 得到 $\hat{I}_j, j = 1, 2, \dots, B$, 由此估计 $\hat{I}$ 的抽样分布方差, 与 (2) 的结果进行验证。
- (d). 称

$$\text{MAE}(\hat{I}) = E|\hat{I} - I|$$

为 $\hat{I}$ 的平均绝对误差。从 (3) 得到的 $\hat{I}_j, j = 1, 2, \dots, B$ 中估计 $\text{MAE}(\hat{I})$ 。比较这四种积分方法的平均绝对误差大小。

14. 设 $h(x) = \frac{e^{-x}}{1+x^2}, x \in (0, 1)$, 用重要抽样法计算积分 $I = \int_0^1 h(x) dx$, 分别采用如下的试抽样密度:

$$f_1(x) = 1, x \in (0, 1),$$

$$f_2(x) = e^{-x}, x \in (0, \infty),$$

$$f_3(x) = \frac{1}{\pi(1+x^2)}, x \in (-\infty, \infty),$$

$$f_4(x) = (1 - e^{-1})^{-1} e^{-x}, x \in (0, 1),$$

$$f_5(x) = \frac{4}{\pi(1+x^2)}, x \in (0, 1).$$

- (a). 作 $h(x)$ 和各试抽样密度的图形, 比较其形状。
- (b). 取样本点个数 $N = 10\,000$, 分别给出对应于不同试抽样密度的估计 $\hat{I}_k, k = 1, 2, 3, 4, 5$, 以及

$\text{Var}(\hat{I}_k)$ 的估计.

- (c). 分析 $\text{Var}(\hat{I}_k)$ 的大小差别的原因.
- (d). 把 $(0, 1)$ 区间均分为 10 段, 在每一段内取 $N = 1\,000$ 个样本点用平均值法计算积分值, 把各段的估计求和得到 I 的估计 $\hat{I}_G$, 估计其方差.
- (e). 用例 3.2.3 的分层抽样方法计算积分的估计 $\hat{I}_T$, 估计 $\text{Var}(\hat{I}_T)$ 并与前面的结果进行比较.
15. 设 $X \sim N(0, 1)$, $h(x) = \exp\left(-\frac{1}{2}(x-3)^2\right) + \exp\left(-\frac{1}{2}(x-6)^2\right)$. 令 $I = Eh(X)$.
- (a). 推导 I 的精确表达式并计算结果.
- (b). 用 $N = 1\,000$ 次函数计算的平均值法估计 I 并估计误差大小.
- (c). 设计适当的重要抽样方法取 $N = 1\,000$ 估计 I 并估计误差大小.
16. 设 $X \sim N(0, 1)$, 则 $\theta = P\{X > 4.5\} = 3.398 \times 10^{-6}$.
- (a). 如果直接生成 N 个 X 的随机数, 用 $X_i > 4.5$ 的比例估计 $P(X > 4.5)$, 平均多少个样本点中才能有一个样本点满足 $X_i > 4.5$?
- (b). 取 V 为指数分布 $\text{Exp}(1)$, 令 $W = V + 4.5$, 用 W 的样本进行重要抽样估计 θ , 取样本点个数 $N = 1\,000$, 求估计值并估计误差大小.
17. 设 $\{U_i, i = 1, 2, \dots\}$ 为独立同 $U(0, 1)$ 分布的随机变量序列. 令

$$K = \min \left\{ k : \sum_{i=1}^k U_i > 1 \right\}.$$

- (a). 证明 $EK = e$.
- (b). 生成 K 的 N 个独立抽样, 用平均值 $\bar{K}$ 估计 e .
- (c). 估计 $\bar{K}$ 的标准差, 给出 e 的近似 95% 置信区间.
18. 设 $\{U_i, i = 1, 2, \dots\}$ 为独立同 $U(0, 1)$ 分布的随机变量序列. 令 M 为序列中第一个比前一个值小的元素的序号, 即

$$M = \min \{m : U_1 \leq U_2 \leq \dots \leq U_{m-1}, U_{m-1} > U_m, m \geq 2\}.$$

- (a). 证明 $P(M > n) = \frac{1}{n!}, n \geq 2$.
- (b). 用概率论中的恒等式 $EM = \sum_{n=0}^{\infty} P(M > n)$ 证明 $EM = e$.
- (c). 生成 M 的 N 个独立抽样, 用平均值 $\bar{M}$ 估计 e .
- (d). 估计 $\bar{M}$ 的标准差, 给出 e 的近似 95% 置信区间.
19. 在例 3.2.5 中, 设 $n = 10$, 已知 (n_j, y_j) 的值为

n_j	20	30	25	30	40	20	50	30	20	20
y_j	6	1	1	0	5	4	1	8	4	7

编写 R 程序估计 $E(\ln K | y_1, y_2, \dots, y_n)$.

20. 用随机模拟法计算二重积分 $\int_0^1 \int_0^1 e^{(x+y)^2} dy dx$, 用对立变量法改善精度.
21. 设 $W \sim \chi^2(n-1)$, 求 $\rho \left[\left(\frac{1}{n-1} W - 1 \right)^2, \left(\frac{1}{n} W - 1 \right)^2 \right]$.
22. 用 R 程序实现例 3.3.8 的模拟. 取 $\mu = 0, \sigma = 1, N = 100\,000, n = 5, 10, 30$, 列出各偏差、均方误差和 $s_1 - s_2$ 的值.
23. 选择适当的编程语言实现例 3.4.2 的算法. 考虑如下的变化情形:
- (a). 银行 8:00 开门, 17:00 关门, 关门后不再允许顾客进入但已进入的顾客会服务完;
- (b). 顾客到来服从非齐次的 Poisson 分布, 其速率函数 $\lambda(t)$ 为阶梯函数;
- (c). 如果顾客到来后发现队太长, 有一定概率离开; 如果顾客等待了太长时间, 有一定概率离开, 这时需要求这些离开顾客的平均人数.
24. 设计模拟如下离散事件的算法. 设某商场每天开放 L_0 时间, 有扒手在该商场出没, 扒手的出现服从强度为 λ_1 的齐次 Poisson 过程, 出现后作案 X 时间后离开, 设 X 服从对数正态分布, $\ln X \sim N(\mu_2, \sigma_2^2)$. 设有一个警察每隔 L_3 时间在商场巡逻 Y 时间, Y 服从 $\text{Exp}(\lambda_2)$ 分布, 只要扒手和警察同时出现在

商城内扒手就会被抓获. 模拟估计一天时间内有扒手被抓获的概率.

25. 设计模拟 $M/M/c$ 随机服务系统的算法. 设服务机构共有 c 个服务窗口, 顾客到来服从齐次 Poisson 过程, 速率为 λ , 顾客排成一队, 一旦某个窗口空闲则队头的顾客接受服务, 每个窗口的服务时间均服从期望为 $1/\mu$ 的指数分布.

- (a). 用 R 程序编程模拟上述随机服务系统;
 (b). 模拟估计顾客在这个服务机构的平均滞留时间 ER_t ;
 (c). 在什么条件下这个服务机构的平均滞留时间能够稳定不变?
 (d). R 程序在处理大量循环方面比较慢, 设法对程序效率进行改善.

26. 3.5 节给出了用模拟方法比较置信区间性能的步骤. 设 $X \sim b(1, p)$, $X_1, X_2, \dots, X_n$ 为样本. 令 $S_0 = \sum_{i=1}^n X_i$, $\hat{p} = S_0/n = \frac{1}{n} \sum_{i=1}^n X_i$. 用模拟方法比较如下五种置信区间:

- (a). 利用正态近似, 当 n 很大时

$$\frac{\hat{p} - p}{\sqrt{\frac{1}{n}\hat{p}(1-\hat{p})}}$$

近似服从 $N(0, 1)$, 于是得置信区间

$$\hat{p} \pm z_{1-\frac{\alpha}{2}} \sqrt{\frac{1}{n}\hat{p}(1-\hat{p})}.$$

- (b). 利用正态近似, 令

$$S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \hat{p})^2 = \frac{n}{n-1} \hat{p}(1-\hat{p}),$$

n 很大时

$$\frac{\hat{p} - p}{\sqrt{\frac{1}{n}S^2}}$$

近似服从 $N(0, 1)$, 于是得置信区间

$$\hat{p} \pm z_{1-\frac{\alpha}{2}} \sqrt{\frac{1}{n}S^2}.$$

- (c). Wilson 置信区间. 利用正态近似, n 很大时

$$\frac{\hat{p} - p}{\sqrt{\frac{1}{n}p(1-p)}}$$

近似服从 $N(0, 1)$, 解关于 p 的不等式

$$\left| \frac{\hat{p} - p}{\sqrt{\frac{1}{n}p(1-p)}} \right| \leq z_{1-\frac{\alpha}{2}},$$

得置信区间 ($\lambda = z_{1-\frac{\alpha}{2}}$)

$$\frac{\hat{p} + \frac{\lambda^2}{2n}}{1 + \frac{\lambda^2}{n}} \pm \frac{\lambda \sqrt{\frac{\lambda^2}{4n} + \hat{p}(1-\hat{p})}}{\sqrt{n} \left(1 + \frac{\lambda^2}{n}\right)}.$$

- (d). Agresti and Coull(1998) 方法. 先计算 Wilson 区间中心 ($\lambda = z_{1-\frac{\alpha}{2}}$)

$$\tilde{p} = \frac{\hat{p} + \frac{\lambda^2}{2n}}{1 + \frac{\lambda^2}{n}},$$

取置信区间为

$$\tilde{p} \pm \lambda \frac{\sqrt{\tilde{p}(1-\tilde{p})}}{\sqrt{n} \sqrt{1 + \frac{\lambda^2}{n}}}.$$

(e). 用二项分布导出 p 的置信区间. 令

$$p_1 = \left\{ 1 + \frac{n - S_0 + 1}{S_0} F_{1-\frac{\alpha}{2}}(2(n - S_0 + 1), 2S_0) \right\}^{-1},$$

$$p_2 = \left\{ 1 + \frac{n - S_0}{S_0 + 1} F_{1-\frac{\alpha}{2}}(2(S_0 + 1), 2(n - S_0)) \right\}^{-1},$$

取置信区间为 $[p_1, p_2]$, 其中 $F_q(n_1, n_2)$ 表示 $F(n_1, n_2)$ 分布的 q 分位数.

对不同的 $n, p, 1 - \alpha$, 比较这五种置信区间的优劣.

27. 不同的检验法有不同的功效, 在难以得到功效函数的显式表达式的时候, 模拟方法可以起到重要补充作用. 对无截距项的回归模型

$$y_k = bz_k + \varepsilon_k, \quad i = 1, 2, \dots, n,$$

$$\varepsilon_1, \varepsilon_2, \dots, \varepsilon_n \text{i.i.d } N(0, \sigma^2)$$

为检验 $H_0: b = 0$, 有如下两种检验方法:

(a). $b = 0$ 时 $y_k = \varepsilon_k$, 于是在 H_0 下

$$t = \frac{\bar{y}}{\sqrt{\frac{1}{n} \frac{1}{n-1} \sum_{i=1}^n (y_i - \bar{y})^2}}$$

服从 $t(n-1)$ 分布. 设 λ 为 $t(n-1)$ 分布的 $1 - \frac{\alpha}{2}$ 分位数, 取否定域为 $\{|t| > \lambda\}$.

(b). 令

$$\hat{b} = \frac{\sum_{i=1}^n x_i y_i}{\sum_{i=1}^n x_i^2}, \quad U = \hat{b}^2 \sum_{i=1}^n x_i^2,$$

$$Q = \sum_{i=1}^n y_i^2 - U, \quad F = \frac{U}{Q/(n-1)},$$

设 λ' 为 $F(1, n-1)$ 的 $1 - \alpha$ 分位数, 取否定域为 $\{F > \lambda'\}$.

对不同的 b, σ^2, n, α 以及不同的 $\{x_i\}$ 模拟比较这两种检验方法的功效.

28. 对例 3.6.7, 证明 $\hat{\phi}_1$ 的均方误差为

$$L_1 = E(\hat{\phi}_1 - \mu^2)^2 = \frac{4\sigma^2\mu^2}{n} + \frac{2n}{n-1} \frac{\sigma^4}{n^2}.$$

29. 考虑如下的非线性回归模型 (logistic 曲线)

$$y = A(1 + e^{-bx}) + \varepsilon, \quad \varepsilon \sim N(0, \sigma^2),$$

其中 $A > 0, b > 0, \sigma^2 > 0$ 是未知参数. 设有独立样本 $(x_i, y_i), i = 1, 2, \dots, n$, 可以用最小二乘法估计 A, b, σ^2 , 估计值记为 $\hat{A}, \hat{b}, \hat{\sigma}^2$.

- (a). 设真实的 $A = 10, b = 1, \sigma = 1$. 编写 R 程序模拟一组样本 (取 $x_i = -10, -9, \dots, 9, 10$), 计算 $\hat{A}, \hat{b}, \hat{\sigma}^2$, 然后用 bootstrap 方法估计 $\hat{A}, \hat{b}, \hat{\sigma}^2$ 的标准误差和偏差.
- (b). 重复生成 N 组模型的样本, 从这 N 组样本中分别得到估计值 $\hat{A}^{(j)}, \hat{b}^{(j)}, (\hat{\sigma}^{(j)})^2, j = 1, 2, \dots, N$, 用得到的这些估计值作为 $\hat{A}, \hat{b}, \hat{\sigma}^2$ 的抽样分布的样本, 估计其标准误差和偏差并与 bootstrap 方法得到的结果进行对比.
30. 设 $\{X_t, t = 0, 1, \dots\}$ 为状态取值于 $S = \{1, 2, \dots, m\}$ 的马氏链, 有平稳分布 $\pi_j, j = 1, 2, \dots, m$, 若 X_0 服从平稳分布, 证明所有 X_t 都服从平稳分布 ($t \geq 0$).
31. 在例 3.7.1 中, 设 $n = 100, a = 10\,000$, 编写 R 程序产生 MCMC 抽样链.
32. 在例 3.7.2 中, 设 $(x_1, x_2, x_3, x_4, x_5) = (82, 72, 45, 34, 17)$, 选取适当的预热期和模拟, 编写 R 程序计算 β 的后验均值估计. 从不同初值出发多做几次考察估计的误差大小.
33. 在例 3.7.3 中, 设 $A = 20, B = 10, d = 1, K = 11$, 选取适当的预热期和步幅 σ , 编写 R 程序产生 MCMC 抽样链.

34. 设向量 $\boxed{x} = (x_1, \dots, x_n)$, 每个 x_i 取值为 +1 或 -1, 记这样的 $\boxed{x}$ 的集合为 $\mathcal{X}$. 设随机向量 $\boxed{X}$ 有如下概率质量函数

$$\pi(\boxed{x}) = P(\boxed{X} = \boxed{x}) = \frac{1}{Z} \exp \left\{ \mu \sum_{i=1}^{n-1} x_i x_{i+1} \right\}$$

其中 μ 已知, Z 为归一化常数. 这样的模型称为一维 Ising 模型. 取 $\mu = 1, n = 50$, 设计 MCMC 算法从 $\pi(\boxed{x})$ 抽样.

35. 证明例 3.7.4 的式 (3.95).
 36. 对例 3.7.5, 取 $n = 20, \alpha = \beta = 0.5$, 生成 (X, Y) 的 Gibbs 抽样链, 比较 Y 的样本的直方图和 $\text{Beta}(\alpha, \beta)$ 分布密度.
 37. 设随机变量 X 和 Y 都取值于区间 $(0, B)$ (B 已知). 设 $Y = y$ 条件下 X 的条件分布密度为

$$f(x|y) \propto e^{-yx}, \quad x \in (0, B),$$

$X = x$ 条件下 Y 的条件分布密度为

$$f(y|x) \propto e^{-xy}, \quad y \in (0, B),$$

编写 R 程序用 Gibbs 抽样方法对 (X, Y) 抽样, 估计 EX 和 $\rho(X, Y)$.

38. 设 $\boxed{X} = (X_1, X_2, \dots, X_n)$ 独立同 $U(0, 1)$ 分布, 对 $0 < d < \frac{1}{n-1}$, 用条件 A 表示这 n 个点两两的距离都超过 d , 可以证明 A 的概率为 $[1 - (n-1)d]^n$. 设 $n = 9, d = 0.1$, 设计 Gibbs 抽样方法生成满足条件 A 的 $\boxed{X}$ 的抽样链.
 39. 在调相信空中, 考虑如下的状态空间模型

$$\begin{aligned} X_t &= \phi_1 X_{t-1} + \eta_t, \quad \eta_t \sim N(0, \sigma_\eta^2), \quad t = 1, 2, \dots, n, \\ y_t &= A \cos(ft + X_t) + \varepsilon_t, \quad \varepsilon_t \sim N(0, \sigma_\varepsilon^2), \quad t = 1, 2, \dots, n, \end{aligned} \quad (*)$$

其中 $\phi_1 = 0.6, \sigma_\eta^2 = 1/6, A = 320, f = 1.072 \times 10^7, \sigma_\varepsilon^2 = 1, \{y_1, \dots, y_n\}$ 为观测值, $\{X_1, \dots, X_n\}$ 为不可观测的随机变量.

- 设 $X_0 = 0, n = 128$, 模拟生成 $(X_t, y_t), t = 1, 2, \dots, n$;
- 根据 §3.8.1 设计 SIS 算法产生关于已知 $y_1, \dots, y_n$ 条件下 $X_1, \dots, X_n$ 的条件分布的适当加权样本, 共生成 $N = 10\,000$ 组, 试抽样采用从 (*) 向前一步的方法;
- 考察以上得到的权重 $\{W_i\}$ 的分布情况;
- 在 SIS 抽样的每一步进行剩余再抽样;
- 根据后验均值方法利用上述改进的抽样估计 $(X_1, \dots, X_n)$;
- 对每个 X_t , 计算上述后验估计的标准误差;
- 独立地重复 $M = 400$ 次估计过程, 从 M 次不同的后验估计计算新的估计标准误差, 与 (6) 得到的结果进行比较.

第七章 重抽样方法

重抽样方法，即基于原始数据生成多个样本信息，之后对多个样本分别采用相同的统计方法（通常而言是参数估计方法），从而可以得到参数估计的分布的相关知识。

书中主要讨论两种抽样方法，即 Bootstrap 法和 Jackknife 法。通过这两种方法得到估计量的偏差、方差等估计。对应课本第六章。大体框架包括：

√ 基于 Bootstrap 法的估计

1. Bootstrap 估计的思想
2. 偏差的 Bootstrap 估计
3. 估计量标准差的 Bootstrap 估计

√ 基于 Jackknife 法的估计

1. 偏差的 Jackknife 估计
2. 估计量标准差的 Jackknife 估计

√ 基于 Bootstrap 法的置信区间估计

其中理论证明与推导不需要掌握，但具体实现法则与主旨思想需要掌握。

我们主要讨论的重点内容是 Bootstrap 法（Jackknife 法指导大概概念方法即可，推导不要求）

7.1 Bootstrap 方法

Bootstrap 估计的思想：自助法，也称 Bootstrap 方法，由 Efron 于 1979 年首次提出，此后发展了大量的关于 Bootstrap 方法的研究。

首先通过一个简单例子给出 Bootstrap 估计的直观理解。

设 $X_1, X_2, \dots, X_n$ 为来自总体分布 $F(x; \theta)$ 的样本，对于感兴趣参数 θ ，通常可采用极大似然估计或者矩估计等估计方法得到 θ 的估计 $\hat{\theta}(X_1, X_2, \dots, X_n)$ 。

很多时候，我们不仅关心 θ 的估计 $\hat{\theta}(X_1, X_2, \dots, X_n)$ 本身，同时也关心估计量的分布以及分布特征，比如 $\hat{\theta}(X_1, X_2, \dots, X_n)$ 的均值 $\mathbb{E}(\hat{\theta})$ 和方差 $\text{Var}(\hat{\theta})$ 。

事实上，一般情况下，很难推导出 $\hat{\theta}(X_1, X_2, \dots, X_n)$ 的分布，进而得到估计量的均值和方差。

 **笔记** 为了得到估计值的方差等特征，如何让估计值“动起来”？

如果 $F(x; \theta)$ 分布形式已知，可以通过蒙特卡洛方法模拟出与 $\hat{\theta}(X_1, X_2, \dots, X_n)$ 同分布的样本，进而根据样本的信息估计 $\hat{\theta}(X_1, X_2, \dots, X_n)$ 的分布以及分布特征。

蒙特卡洛方法近似如下：

1. 从总体分布 $F(x; \theta)$ 中独立产生 n 个数据 $X_{11}, X_{12}, \dots, X_{1n}$ ，得到的 θ 的估计，记为 $\hat{\theta}_1 = \hat{\theta}_1(X_{11}, X_{12}, \dots, X_{1n})$ ；
2. 重复上述步骤 m 次，得到的估计分别记为 $\hat{\theta}_1, \hat{\theta}_2, \dots, \hat{\theta}_m$ 。

基于样本 $\hat{\theta}_1, \hat{\theta}_2, \dots, \hat{\theta}_m$ 推断 $\hat{\theta}(X_1, X_2, \dots, X_n)$ 的分布， $\mathbb{E}(\hat{\theta})$ 和 $\text{Var}(\hat{\theta})$ 可以分别用该样本的均值和方差估计，即

$$\hat{\mathbb{E}}(\hat{\theta}) = m^{-1} \sum_{i=1}^m \hat{\theta}_i, \quad \widehat{\text{Var}}(\hat{\theta}) = m^{-1} \sum_{i=1}^m (\hat{\theta}_i - \hat{\mathbb{E}}(\hat{\theta}))^2.$$

如果分布 $F(x; \theta)$ 未知，唯一的信息只有样本 $X_1, X_2, \dots, X_n$ 。不能利用上述蒙特卡洛方法从总体 $F(x; \theta)$ 中产生数据，进而不能近似 $\hat{\theta}(X_1, X_2, \dots, X_n)$ 的分布及其相关特征。

定义 7.1 (Bootstrap 方法)

Bootstrap 方法就是利用样本分布 $X_1, X_2, \dots, X_n$ 代替总体分布 $F(x; \theta)$ ，从分布 $X_1, X_2, \dots, X_n$ 中有放回的产生数据，进而近似 $\hat{\theta}(X_1, X_2, \dots, X_n)$ 的分布。

具体步骤如下:

1. 从样本 $X_1, X_2, \dots, X_n$ 中有放回的产生数据 $X_{11}^*, X_{12}^*, \dots, X_{1n}^*$, 得到的 θ 的估计, 记为 $\hat{\theta}_1^* = \hat{\theta}_1(X_{11}^*, X_{12}^*, \dots, X_{1n}^*)$;
2. 重复上述步骤 m 次, 相应的估计分别记为 $\hat{\theta}_1^*, \hat{\theta}_2^*, \dots, \hat{\theta}_m^*$ 。

利用 $\hat{\theta}_1^*, \hat{\theta}_2^*, \dots, \hat{\theta}_m^*$ 近似 $\hat{\theta}$ 的分布及其特征。

本质上, 自助法相当于用样本 $X_1, X_2, \dots, X_n$ 的经验分布 F_n 估计总体分布 F , 从经验分布中再抽样来估计总体的特征。



从经验分布再抽样本质上相当于从 $X_1, X_2, \dots, X_n$ 有放回的抽样, 以相同的概率抽取到每个样本。记 X^* 表示分布函数是 F_n 的随机变量, 则 $P(X^* = X_i) = n^{-1}, i = 1, \dots, n$ 。

用 Bootstrap 方法抽取到样本 $X_1^*, X_2^*, \dots, X_n^*$ 的经验分布 F_n^* 是 F_n 的逼近, F_n 是总体分布 F 的逼近。这两种逼近可以表示为 $F_n^* \rightarrow F_n \rightarrow F$ 。

假设我们观察到样本 $\{2, 2, 1, 1, 5, 4, 4, 3, 1, 2\}$, 从中抽取样本点 $1, 2, 3, 4, 5$ 的概率分别为 $0.3, 0.3, 0.1, 0.2, 0.1$ 。

从中随机选择的一个样本 X^* , 其分布函数就是经验分布函数, 即

$$F_{X^*}(x) = F_n(x) = \begin{cases} 0, & x < 1; \\ 0.3, & 1 \leq x < 2; \\ 0.6, & 2 \leq x < 3; \\ 0.7, & 3 \leq x < 4; \\ 0.9, & 4 \leq x < 5; \\ 1, & x \geq 5. \end{cases}$$

需要说明的是: 如果经验分布函数 $F_n(x)$ 没有靠近总体分布函数 $F(x)$, 则重复抽样下的分布也不会靠近 $F(x)$ 。

上例中的样本实际上是从参数为 2 的泊松分布中随机产生, 从样本中大量重复抽样可以很好的估计 $F_n(x)$, 但是不能很好的估计 $F(x)$ 。因为无论重复多少次再抽样, 得到的 Bootstrap 样本都不会包括总体分布的取值 0。

如果暂且不追究样本中的经验分布函数与实际分布函数之前的差别, 通过重抽样, 我们可以使估计值“动起来”, 从而得到以下自助估计。

7.1.1 偏差的自助估计

基于样本数据 $X_1, X_2, \dots, X_n$, 得到感兴趣参数 θ 的估计 $\hat{\theta} = \theta(X_1, X_2, \dots, X_n)$ 。下面分别介绍估计量偏差的 Bootstrap 估计和标准差的 Bootstrap 估计。

首先讨论 $\hat{\theta}$ 的偏差 $\text{Bias}(\hat{\theta}) = \mathbb{E}(\hat{\theta}) - \theta$ 的自助估计 $\widehat{\text{Bias}}(\hat{\theta})$ 。

事实上, 只需要分别估计 $\mathbb{E}(\hat{\theta})$ 和 θ , θ 的估计 $\hat{\theta}$ 基于观察到的样本数据直接得到; 对于 $\mathbb{E}(\hat{\theta})$ 的估计 $\hat{\mathbb{E}}(\hat{\theta})$, 利用自助法获取到的 $\hat{\theta}_1^*, \hat{\theta}_2^*, \dots, \hat{\theta}_m^*$ 的均值来估计, 也就是 $\hat{\mathbb{E}}(\hat{\theta}) = m^{-1} \sum_{i=1}^m \hat{\theta}_i^*$ 。

因此

$$\widehat{\text{Bias}}(\hat{\theta}) = m^{-1} \sum_{i=1}^m \hat{\theta}_i^* - \hat{\theta}.$$

具体步骤为:

1. 从样本 $X_1, X_2, \dots, X_n$ 中有放回的产生数据 $X_{11}^*, X_{12}^*, \dots, X_{1n}^*$, 得到 θ 的估计并记为 $\hat{\theta}_1^* = \hat{\theta}_1(X_{11}^*, X_{12}^*, \dots, X_{1n}^*)$;
2. 重复上述步骤 m 次, 相应的估计分别记为 $\hat{\theta}_1^*, \hat{\theta}_2^*, \dots, \hat{\theta}_m^*$, 以及基于样本 $X_1, X_2, \dots, X_n$ 得到的估计 $\hat{\theta}$;

3. 计算 $\mathbb{E}(\hat{\theta})$ 的自助估计 $\hat{\mathbb{E}}(\hat{\theta}) = m^{-1} \sum_{i=1}^m \hat{\theta}_i^*$, 以及偏差自助估计

$$\widehat{\text{Bias}}(\hat{\theta}) = \hat{\mathbb{E}}(\hat{\theta}) - \hat{\theta} = m^{-1} \sum_{i=1}^m \hat{\theta}_i^* - \hat{\theta}.$$

如果偏差大于零, 意味着 $\hat{\theta}$ 平均来看过高估计了 θ ; 而偏差小于零, 意味着 $\hat{\theta}$ 平均来看过低估计了 θ . 因此, 经偏差修正的参数 θ 的估计量为 $\tilde{\theta} = \hat{\theta} - \widehat{\text{Bias}}(\hat{\theta})$.

例如, 设数据 $X_1, X_2, \dots, X_n$ 来自方差为 σ^2 的分布。则 σ^2 的估计为 $\hat{\sigma}^2 = n^{-1} \sum_{i=1}^n (X_i - \bar{X})^2$ 。 $\hat{\sigma}^2$ 的偏差 $\text{Bias}(\hat{\sigma}^2) = \mathbb{E}(\hat{\sigma}^2) - \sigma^2 = -\sigma^2/n$ 。

可以用 $\hat{\sigma}^2$ 偏差的自助估计

$$\widehat{\text{Bias}}(\hat{\sigma}^2) = m^{-1} \sum_{i=1}^m \hat{\sigma}_i^{*2} - \hat{\sigma}^2$$

来估计偏差的大小 (但并不是无偏估计, 证明过程略)。注意: 偏差的自助估计不一定是偏差本身的无偏估计!

下面给出例子说明估计量偏差的 Bootstrap 估计。

例题 7.1 假设 $X_1, X_2, \dots, X_n$ 是来自 $N(\mu, \sigma^2)$ 的样本, 用 Bootstrap 法估计 σ^2 的估计量 $\hat{\sigma}^2 = n^{-1} \sum_{i=1}^n (X_i - \bar{X})^2$ 的偏差。

```
1  set.seed(1)
2  n=100; mu=0; sigma=2; m=2000;
3  X=rnorm(n,mu,sigma);
4  sigma2hat=mean((X-mean(X))^2) #基于样本信息, sigma^2的估计
5  sigma2Bst=NULL
6  for (i in 1:m){
7    0=sample(seq(1,n),n,replace=T)
8    Bstrap_X=X[0] #有放回地从X中抽取新样本
9    sigma2Bst[i]=mean((Bstrap_X-mean(Bstrap_X))^2)
10   #基于新样本, sigma^2的估计
11 }
12 Bias=mean(sigma2Bst)-sigma2hat #偏差的Bootstrap估计
```

例题 7.2 假设 $(X_1, Y_1), (X_2, Y_2), \dots, (X_n, Y_n)$ 服从二元正态分布, 均值为 (μ_1, μ_2) , 方差为 (σ_1^2, σ_2^2) , 且相关系数为 ρ 。求相关系数 ρ 的估计, 并用 Bootstrap 方法估计其偏差。

```
1  set.seed(1)
2  library(mnormt)
3  n=100
4  mu1=mu2=0
5  sigma1=1;sigma2=2
6  rho=0.6;sigma12=sigma21=rho*sigma1*sigma2
7  mu=c(mu1,mu2)
8  Sigma=matrix(c(sigma1^2,sigma12,sigma21,sigma2^2),2,2)
9  Data=rmnorm(n,mu,Sigma)
10 X=Data[,1];Y=Data[,2]
11
12 #基于样本信息, rho的估计
13 rhohat=sum((X-mean(X))*(Y-mean(Y)))/
14 sqrt(sum((X-mean(X))^2)*sum((Y-mean(Y))^2))
15 m=2000
16 rhoBst=NULL
17 for (i in 1:m){
```

```

18     index=sample(seq(1,n),n,replace=T)
19     Bst_Data=Data[index,] #有放回的从X中抽取新样本
20     X=Bst_Data[,1];Y=Bst_Data[,2]
21     rhoBst[i]=sum((X-mean(X))*(Y-mean(Y)))/
22     sqrt(sum((X-mean(X))^2)*sum((Y-mean(Y))^2))
23     #基于新样本, rho的估计
24 }
25 Bias=mean(rhoBst)-rhohat #偏差的Bootstrap估计

```

例题 7.3 假设 $X_1, X_2, \dots, X_n$ 和 $Y_1, Y_2, \dots, Y_m$ 分别是来自正态分布 $N(\mu_1, \sigma_1^2)$ 和 $N(\mu_2, \sigma_2^2)$ 的两个独立样本, 且 $\sigma_1 = 1, \sigma_2 = 2$ 。给出 $\mu_1 - \mu_2$ 的估计, 并用 Bootstrap 方法估计其偏差。

```

1  set.seed(1)
2  n1=100;n2=200;mu1=0;mu2=0.3;
3  sigma1=1;sigma2=2;
4  X=rnorm(n1,mu1,sigma1); Y=rnorm(n2,mu2,sigma2)
5  diffhat=mean(X)-mean(Y) #基于样本信息, 均值差的估计
6  m=2000; diffBst=NULL;
7  for (i in 1:m){
8      O1=sample(seq(1,n1),n1,replace=T);
9      O2=sample(seq(1,n2),n2,replace=T);
10     Bst_X=X[O1];Bst_Y=Y[O2]; #分别有放回的从X,Y中抽取新样本
11     diffBst[i]=mean(Bst_X)-mean(Bst_Y) #基于新样本, 均值差的估计
12 }
13 Bias=mean(diffBst)-diffhat #偏差的Bootstrap估计

```

7.1.2 估计量标准差的 Bootstrap 估计

关于估计量 $\hat{\theta}$ 的分布, 在前面讲了估计量 $\hat{\theta}$ 抽样分布的 Bootstrap 估计, 则 $\hat{\theta}$ 的标准差 $\widehat{SE}(\hat{\theta})$ 的 Bootstrap 估计, 就是采用 $\hat{\theta}$ 分布 Bootstrap 估计的标准差。

标准差估计具体步骤:

1. 从分布 $X_1, X_2, \dots, X_n$ 中有放回的产生数据 $X_{11}^*, X_{12}^*, \dots, X_{1n}^*$, 得到 θ 的估计, 记为 $\hat{\theta}_1^* = \hat{\theta}_1(X_{11}^*, X_{12}^*, \dots, X_{1n}^*)$;
2. 重复上述步骤 m 次, 相应的估计分别记为 $\hat{\theta}_1^*, \hat{\theta}_2^*, \dots, \hat{\theta}_m^*$;
3. 计算 $\bar{\theta}^* = m^{-1} \sum_{i=1}^m \hat{\theta}_i^*$, $\hat{\theta}$ 标准差的自助估计为

$$\widehat{SE}(\hat{\theta}) = \left\{ \frac{1}{m} \sum_{i=1}^m (\hat{\theta}_i^* - \bar{\theta}^*)^2 \right\}^{1/2}$$

用自助法估计 $\hat{\theta}$ 的方差 $\text{Var}(\hat{\theta})$, 该方差无记为 $\widehat{\text{Var}}(\hat{\theta})$, 也就是说, $\widehat{\text{Var}}(\hat{\theta})$ 为 $\text{Var}(\hat{\theta})$ 的估计值。通常而言在 $\text{Var}(\hat{\theta})$ 不具有具体表达式时候, 采取 $\widehat{\text{Var}}(\hat{\theta})$ 替代。

例题 7.4 假设 $X_1, X_2, \dots, X_n$ 是来自 $N(\mu, \sigma^2)$ 的样本, 用 $\hat{\mu} = n^{-1} \sum_{i=1}^n X_i$ 估计 μ , 并求该估计量方差的 Bootstrap 估计。

```

1  set.seed(1)
2  n=100; mu=0; sigma=2; m=2000
3  X=rnorm(n,mu,sigma);
4  muhat=mean(X) #基于样本信息, mu的估计
5  muBst=NULL
6  for (i in 1:m){
7      index=sample(seq(1,n),n,replace=T)

```

```

8      Bstrap_X=X[O] #有放回地从X中抽取新样本
9      muBst[i]=mean(Bstrap_X) #基于新样本，mu的估计
10  }
11  var_muBst=mean((muBst-mean(muBst))^2) #方差的Bootstrap估计

```

注意：R 函数中 `var()` 的分母为 $n-1$ ，因此没有直接利用

 **练习 7.1 课堂练习** 假设 $(X_1, Y_1), (X_2, Y_2), \dots, (X_n, Y_n)$ 服从二元正态分布，均值为 (μ_1, μ_2) ，方差为 (σ_1^2, σ_2^2) ，且相关系数为 ρ 。求相关系数 ρ 的估计，并用 Bootstrap 方法估计其方差。（与之前代码相似，最后计算方差即可）

例题 7.5 假设 $X_1, X_2, \dots, X_n$ 和 $Y_1, Y_2, \dots, Y_n$ 是来自正态分布 $N(\mu_1, \sigma_1^2)$ 和 $N(\mu_2, \sigma_2^2)$ 的两个独立样本。给出 σ_1^2/σ_2^2 的估计，并用 Bootstrap 方法估计其方差。

```

1  set.seed(1)
2  n1=100;n2=200;
3  mu1=0;mu2=0.2;
4  sigma1=1;sigma2=2;
5  X=rnorm(n1,mu1,sigma1)
6  Y=rnorm(n2,mu2,sigma2)
7  Sx=sum((X-mean(X))^2)/(n1-1);Sy=sum((Y-mean(Y))^2)/(n2-1)
8  ratiohat=Sx/Sy #基于样本信息，方差比值的估计
9  m=2000;
10 ratioBst=NULL;
11 for (i in 1:m)){
12   O1=sample(seq(1,n1),n1,replace=T);
13   O2=sample(seq(1,n2),n2,replace=T);
14   X_Bst=X[O1];Y_Bst=Y[O2]; #分别有放回地从X,Y抽取新样本
15   Sx_Bst=sum((X_Bst-mean(X_Bst))^2)/(n1-1);
16   Sy_Bst=sum((Y_Bst-mean(Y_Bst))^2)/(n2-1);
17   ratioBst[i]=Sx_Bst/Sy_Bst #基于新样本，方差比值的估计
18 }
19 var_ratioBst=mean((ratioBst-mean(ratioBst))^2)
20 #估计量方差的Bootstrap估计

```

7.1.3 基于 Bootstrap 法的置信区间估计

本节介绍几种利用 Bootstrap 法构造感兴趣参数 θ 的渐近置信区间的方法。

主要包括标准正态 Bootstrap 置信区间以及基本的 Bootstrap 置信区间（较多用）。事实上在很多情况下区别不大。（书上的 Bootstrap 的 t 置信区间，以及 Bootstrap 百分位数 (percentile) 置信区间不要求掌握）

标准正态 Bootstrap 置信区间是一种比较简单的方法。假设 $\hat{\theta}$ 是参数 θ 的无偏估计量，估计量的标准差为 $SE(\hat{\theta})$ 。如果

$$Z = \frac{\hat{\theta} - \mathbb{E}\hat{\theta}}{SE(\hat{\theta})} = \frac{\hat{\theta} - \theta}{SE(\hat{\theta})}$$

渐近服从标准正态分布。

θ 渐近的 $100(1-\alpha)\%$ 标准正态 Bootstrap 置信区间为

$$\hat{\theta} \pm z_{\alpha/2} \widehat{SE}_B(\hat{\theta}),$$

这里 $z_{\alpha/2} = \Phi^{-1}(1-\alpha/2)$ ， $\widehat{SE}_B(\hat{\theta})$ 为 $\hat{\theta}$ 标准差的 Bootstrap 估计。标准正态 Bootstrap 置信区间需要渐近正态性条件，以及 $\hat{\theta}$ 为 θ 的无偏估计。

基本的 Bootstrap 置信区间的想法是通过计算估计 $\hat{\theta}$ 的 $\alpha/2$ 和 $1 - \alpha/2$ 的 Bootstrap 百分位数构造，具体表达式为

$$\left[\hat{\theta}_{[m\alpha/2]}^*, \hat{\theta}_{[m(1-\alpha/2)]}^* \right],$$

这里 $\hat{\theta}_{[m\alpha/2]}^*$ 和 $\hat{\theta}_{[m(1-\alpha/2)]}^*$ 是自助法得到估计 $\hat{\theta}_1^*, \hat{\theta}_2^*, \dots, \hat{\theta}_m^*$ 的第 $[m\alpha/2]$ 和 $[m(1-\alpha/2)]$ 个次序统计量的值。

本质上, $\hat{\theta}_1^*, \hat{\theta}_2^*, \dots, \hat{\theta}_m^*$ 可以看作是从 $\hat{\theta}$ 分布中抽取的 Bootstrap 样本, 因此 $P(\hat{\theta}_{[m\alpha/2]}^* < \theta < \hat{\theta}_{[m(1-\alpha/2)]}^*) \approx 1 - \alpha$ 。由于 $\hat{\theta}$ 为 θ 的估计, 所以 $P(\hat{\theta}_{[m\alpha/2]}^* < \theta < \hat{\theta}_{[m(1-\alpha/2)]}^*) \approx 1 - \alpha$ 。

例题 7.6 假设 $X_1, X_2, \dots, X_n$ 是来自 $N(\mu, \sigma^2)$ 的样本, 用 Bootstrap 方法估计参数 μ 的置信区间。

```

1  set.seed(1)
2  alpha=0.05;n=100;mu=0;sigma=1;
3  X=rnorm(n,mu,sigma);
4  muhat=mean(X) #基于样本信息, mu的估计
5  m=K=rep_muBst=500;muBst=t=NULL
6  for (i in 1:m){
7    0=sample(seq(1,n),n,replace=T)
8    Bstrap_X=X[0] #有放回的从X中抽取样本
9    muBst[i]=mean(Bstrap_X) #基于重抽样样本, mu的估计
10   for (k in 1:K){
11     0=sample(seq(1,n),n,replace=T)
12     rep_Bstrap_X=Bstrap_X[0]; #有放回的从重抽样样本中抽取样本
13     rep_muBst[k]=mean(rep_Bstrap_X);
14   }
15   se_rep=sqrt(mean((rep_muBst-mean(rep_muBst))^2));
16   #基于重抽样样本估计的估计量标准差
17   t[i]=(muBst[i]-muhat)/se_rep;
18   #基于第i组重抽样样本和估计的标准差, 构建t统计量
19 }
20 se_muBst=sqrt(mean((muBst-mean(muBst))^2))
21 #构造第一种置信区间和第四种置信区间需要的标准差估计
22 L1=muhat-qnrm(1-alpha/2,0,1)*se_muBst;
23 U1=muhat+qnrm(1-alpha/2,0,1)*se_muBst; #第一种区间
24 smuBst=sort(muBst)
25 L2=smuBst[round(m*alpha/2)];
26 U2=smuBst[round(m*(1-alpha/2))]; #第二种区间
27 #L3=2*muhat-smuBst[round(m*(1-alpha/2))];
28 #U3=2*muhat-smuBst[round(m*alpha/2)]; #第三种区间
29 c(L1,U1);c(L2,U2)

```

7.2 Jackknife 法的估计

在 Bootstrap 方法提出之前, 另外一种有影响力的重抽样方法是由 Quenouille(1949, 1956) 提出的 Jackknife 法。

Jackknife 估计的基本思想是, 对于从样本 $X_1, X_2, \dots, X_n$ 中获得的感兴趣参数 θ 的估计量 $\hat{\theta}(X_1, X_2, \dots, X_n)$, 其分布特征 (如估计量的偏差和方差) 可以用 Jackknife 法得到。(中文翻译为刀切法, 去一法)

对于给定样本 $X_1, X_2, \dots, X_n$, 每次删除其中一个 (或者几个) 样本点, 基于剩下的样本采用相同的估计量公式得到 θ 的估计, 经过逐个删除并分别计算估计之后, 便可以得到一系列估计值, 基于这些估

计值进而估计 $\hat{\theta}$ 的分布特征。

去掉一个数据的 Jackknife 计算 θ 的具体步骤如下：

1. 从观测样本 $X_1, X_2, \dots, X_n$ 中去掉第 i 个数据 X_i 后的剩余样本，定义为第 i 个 Jackknife 样本，记为 $X_{(-i)} = (X_1, \dots, X_{i-1}, X_{i+1}, \dots, X_n)$ ；
2. 基于第 i 个 Jackknife 样本 $X_{(-i)}$, $i = 1, 2, \dots, n$ ，得到相应的估计 $\hat{\theta}_{(-i)} = \hat{\theta}(X_{(-i)})$, $i = 1, \dots, n$ 。
3. 基于第 i 个 Jackknife 样本 $X_{(-i)}$, $i = 1, 2, \dots, n$ ，得到相应的估计 $\hat{\theta}_{(-i)} = \hat{\theta}(X_{(-i)})$, $i = 1, \dots, n$ 。

Jackknife 法就是利用 $\hat{\theta}_{(-i)} = \hat{\theta}(X_{(-i)})$, $i = 1, \dots, n$ 得到估计量 $\hat{\theta}(X_1, X_2, \dots, X_n)$ 的分布特征。

基于 $\hat{\theta}_{(-i)}$, $\hat{\theta}$ 的偏差 $\text{Bias}(\hat{\theta}) = \mathbb{E}(\hat{\theta}) - \theta$ 的 Jackknife 估计定义为（不要求掌握原因与推导）

$$\widetilde{\text{Bias}}(\hat{\theta}) = (n-1) \left(\frac{1}{n} \sum_{i=1}^n \hat{\theta}_{(-i)} - \hat{\theta} \right) = \frac{n-1}{n} \sum_{i=1}^n (\hat{\theta}_{(-i)} - \hat{\theta}). \quad (15)$$

下面给出例子说明估计量偏差的 Jackknife 估计。假设 $X_1, \dots, X_n$ 是来自 $N(\mu, \sigma^2)$ 的样本，用 $\hat{\sigma}^2 = n^{-1} \sum_{i=1}^n (X_i - \bar{X})^2$ 估计 σ^2 ，并用 Jackknife 法估计其偏差。

```

1  set.seed(1)
2  n=100;
3  mu=0; sigma=2;
4  X=rnorm(n,mu,sigma);
5  sigma2hat=sum((X-mean(X))^2)/n #基于原样本, sigma^2的估计
6  sigma2Jack=NULL
7  for (i in 1:n){
8    Jack_X=X[-i] #去掉第i个样本点
9    sigma2Jack[i]=sum((Jack_X-mean(Jack_X))^2)/(n-1)
10   #基于新样本, sigma^2的估计
11 }
12 Bias=(n-1)*mean(sigma2Jack-sigma2hat) #偏差的Jackknife估计

```

例题 7.7 假设 $(X_1, Y_1), (X_2, Y_2), \dots, (X_n, Y_n)$ 服从二元正态分布，均值为 (μ_1, μ_2) ，方差为 (σ_1^2, σ_2^2) ，且相关系数为 ρ 。求相关系数 ρ 的估计，并用 Jackknife 法估计其偏差。

```

1  set.seed(1)
2  library(mnormt)
3  n=100;
4  mu1=mu2=0;
5  sigma1=1;sigma2=2;
6  rho=0.6;sigma12=sigma21=rho*sigma1*sigma2;
7  mu=c(mu1,mu2);
8  Sigma=matrix(c(sigma1^2,sigma12,sigma21,sigma2^2),2,2);
9  Data=rmnorm(n,mu,Sigma);
10 X=Data[,1];Y=Data[,2];
11 rhohat=sum((X-mean(X))*(Y-mean(Y)))/ #基于原样本, rho的估计
12 sqrt(sum((X-mean(X))^2)*sum((Y-mean(Y))^2));
13 rhoJack=NULL;
14 for (i in 1:n){
15   Jack_Data=Data[-i,]; #去掉第i组 (X,Y)
16   X=Jack_Data[,1];Y=Jack_Data[,2];
17   rhoJack[i]=sum((X-mean(X))*(Y-mean(Y)))/
18   sqrt(sum((X-mean(X))^2)*sum((Y-mean(Y))^2));
19   #基于新样本, rho的估计
20 }

```

Bias=(n-1)*mean(rhoJack-rhohat) #偏差的Jackknife估计

对于估计量 $\hat{\theta}$, 其标准差的 Jackknife 估计定义为 (不要求掌握原因与推导)

$$\widehat{SE}_{\text{Jack}}(\hat{\theta}) = \left\{ \frac{n-1}{n} \sum_{i=1}^n (\hat{\theta}_{(-i)} - \bar{\theta}_{(\cdot)})^2 \right\}^{1/2}, \quad (16)$$

这里 $\bar{\theta}_{(\cdot)} = n^{-1} \sum_{i=1}^n \hat{\theta}_{(-i)}$ 。相应地, 可得到方差的 Jackknife 估计。

 **练习 7.2 课堂练习/作业** Interquartile range (IQR), 中文: 四分位距, 是一种衡量变异性的方法, 它通过将数据集划分为四分位数来实现。四分位数将一个按等级排序的数据集划分为四个相等的部分。即 Q1 (第 1 个四分位数)、Q2 (第 2 个四分位数) 和 Q3 (第 3 个四分位数)。

$$\text{IQR} = Q3 - Q1.$$

与方差类似, IQR 衡量分布的“散度”, 分布的 IQR 可以采用样本 IQR 来进行估计。

与方差等不同的是, IQR 估计的估计值的不确定性不太容易量化 (例如, 方差估计的不确定性可以通过构造卡方分布得出置信区间), 因此我们可以考虑使用 bootstrap 方法进行估计。

1. 给定数据为: 1.51 2.68 1.62 3.05 4.50 3.08 4.20 0.19 1.74 0.79 1.68 0.49 3.14 0.74 0.93 2.31 2.70 1.75 2.06 1.54 1.56 1.13 0.43 2.42 4.60 1.01 4.09 5.08 1.46 0.90

使用 Bootstrap 方法, 求 IQR 估计的:

(a). 估计方差

(b). 估计值的 95

相应的, 求 $X_{(n-2)} - X_{(3)}$ 估计的:

(a). 估计方差

(b). 估计值的 95

建议考虑使用 apply() 函数, 如果不熟, 查找相应文档;

2. (2.3. 课本 P102, 习题 6.1 一起做。) 设 $X_1, X_2, \dots, X_n$ 和 $Y_1, Y_2, \dots, Y_m$ 分别是来自总体 $N(\mu_1, \sigma_1^2)$ 和 $N(\mu_2, \sigma_2^2)$ 的两个独立样本, 给出 σ_1^2/σ_2^2 的估计 $\hat{\sigma}_1^2/\hat{\sigma}_2^2$ 。取 $n = 100$, $m = 200$, $\mu_1 = 0$, $\mu_2 = 1$, $\sigma_1 = 1$, $\sigma_2 = 2$, 并用 Bootstrap 方法估计 $\hat{\sigma}_1^2/\hat{\sigma}_2^2$ 的方差和偏差, 给出相应的程序。



笔记 非常重要的考试题!!! 一定要认真做, 考试最后一道压轴题就是这种类型的题目, 题目会强制你写出用 apply() 函数的代码!!! 20 分哦!!!

第七章 练习

1. 设 $X_1, X_2, \dots, X_n$ 和 $Y_1, Y_2, \dots, Y_m$ 分别是来自总体 $N(\mu_1, \sigma_1^2)$ 和 $N(\mu_2, \sigma_2^2)$ 的两个独立样本, 给出 σ_1^2/σ_2^2 的估计 $\hat{\sigma}_1^2/\hat{\sigma}_2^2$ 。取 $n = 100$, $m = 200$, $\mu_1 = 0$, $\mu_2 = 1$, $\sigma_1 = 1$, $\sigma_2 = 2$, 并用 Bootstrap 方法估计 $\hat{\sigma}_1^2/\hat{\sigma}_2^2$ 的方差和偏差, 给出相应的程序。
2. 设 $X_1, X_2, \dots, X_n$ 和 $Y_1, Y_2, \dots, Y_m$ 分别是来自总体 $N(\mu_1, \sigma_1^2)$ 和 $N(\mu_2, \sigma_2^2)$ 的两个独立样本, 给出 σ_1^2/σ_2^2 的估计 $\hat{\sigma}_1^2/\hat{\sigma}_2^2$ 。取 $n = 100$, $m = 200$, $\mu_1 = 0$, $\mu_2 = 1$, $\sigma_1 = 1$, $\sigma_2 = 2$, 并用 Jackknife 方法估计 $\hat{\sigma}_1^2/\hat{\sigma}_2^2$ 的方差和偏差, 给出相应的程序。
3. 设 $X_1, X_2, \dots, X_n$ 是来自总体 $\text{Gamma}(\alpha, \lambda)$ 的独立样本, 给出 α 和 λ 的估计 $\hat{\alpha}$ 和 $\hat{\lambda}$ 。取 $n = 200$, $\alpha = 2$, $\lambda = 1$, 并应用 Bootstrap 方法估计 $\hat{\alpha}$ 和 $\hat{\lambda}$ 的方差和偏差, 给出相应的程序。
4. 设 $X_1, X_2, \dots, X_n$ 是来自总体 $\text{Gamma}(\alpha, \lambda)$ 的独立样本, 给出 α 和 λ 的估计 $\hat{\alpha}$ 和 $\hat{\lambda}$ 。取 $n = 200$, $\alpha = 2$, $\lambda = 1$, 并应用 Jackknife 方法估计 $\hat{\alpha}$ 和 $\hat{\lambda}$ 的方差和偏差, 给出相应的程序。
5. 设 $X_1, X_2, \dots, X_n$ 是来自总体 $N(0, \sigma^2)$ 的独立样本, 用 Bootstrap 方法估计 σ^2 的估计量 $\hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2$ 的偏差, 取 $n = 200$, $\sigma = 2$, 并用 Jackknife 方法估计 Bootstrap 偏差估计量的方差, 给出相应的程序。

第八章 多元分布抽样问题以及 MCMC 方法

内容提要

- 满条件分布 8.2
- Gibbs 抽样 8.3
- 数据增强 8.4

- Metropolis 算法 ??
- Metropolis-Hastings 算法 8.6

8.1 Gibbs 抽样与贝叶斯层次模型：激励示例

8.1.1 贝叶斯层次模型应用背景

贝叶斯层次模型（Bayesian Hierarchical Models, BHM）具有灵活的建模特性，可根据需求设置多层结构以考虑参数的变异性，适用于存在共享参数和组特异性参数的场景。在实际问题中，变点分析（Change Point Analysis）是其重要应用方向，旨在识别序列数据中统计上显著的转折点（如均值、趋势、变异程度的变化），广泛应用于能源消耗、放射性检测、信号处理（如大脑电活动）等领域。

8.1.2 数据来源与问题定义

本示例数据来源于美国国家公路交通安全管理局（National Highway Traffic Safety Administration），通过 R 语言的 ‘rvest’ 包进行网络爬虫获取，包含 91 个等间隔观测值，记录了不同年份每百万人交通事故死亡人数，整体呈下降趋势但存在明显波动。

核心问题为：该序列中是否存在统计上显著的变点？

8.1.3 贝叶斯层次模型构建

假设存在 1 个变点（可通过后续检验验证该假设），构建 Poisson-Gamma-Gamma 模型，包含 5 个真实参数 $(\lambda_1, \lambda_2, \beta_1, \beta_2, k)$ （基于 Gamma 分布的形状-率参数化）：

- 观测模型： $Y_i \sim \text{Pois}(\lambda_1)$ ($i = 1, \dots, k$)； $Y_i \sim \text{Pois}(\lambda_2)$ ($i = k + 1, \dots, n$)
- 先验分布： $\lambda_1 \sim \text{Gamma}(a_1, \beta_1)$ ； $\lambda_2 \sim \text{Gamma}(a_2, \beta_2)$ ； $\beta_1 \sim \text{Gamma}(c_1, d_1)$ ； $\beta_2 \sim \text{Gamma}(c_2, d_2)$

其中，超先验设置为： $a_1 = 10$ ， $a_2 = 2$ （信息先验）； $c_1 = c_2 = d_1 = d_2 = 0.01$ （模糊先验）。替代模型采用逆 Gamma 分布作为超先验，通过经验方法进行模型比较。

8.1.4 后验分布与满条件分布

贝叶斯推断的核心：后验分布与先验分布和似然函数成正比，即

$$\pi(\eta|y) \propto \pi(\eta)\pi(y|\eta) \quad (8.1)$$

当联合后验难以直接抽样时，可通过边际分布或条件分布抽样替代。

本模型的联合后验分布为：

$$\pi(\lambda_1, \lambda_2, \beta_1, \beta_2, k|y) \propto \pi(\beta_1)\pi(\beta_2)\pi(\lambda_1|\beta_1)\pi(\lambda_2|\beta_2)\pi(k) \prod_{i=1}^k \text{Pois}(y_i|\lambda_1) \prod_{i=k+1}^n \text{Pois}(y_i|\lambda_2)$$

五个参数的满条件分布如下：

- $\pi(\lambda_1|\text{Others}) \propto e^{-k\lambda_1 - \beta_1\lambda_1} \lambda_1^{a_1 + \sum_{i=1}^k y_i - 1} \sim \text{Gamma}\left(\sum_{i=1}^k y_i + a_1, k + \beta_1\right)$
- $\pi(\lambda_2|\text{Others}) \propto e^{-(n-k)\lambda_2 - \beta_2\lambda_2} \lambda_2^{a_2 + \sum_{i=k+1}^n y_i - 1} \sim \text{Gamma}\left(\sum_{i=k+1}^n y_i + a_2, (n-k) + \beta_2\right)$

3. $\pi(\beta_1|\text{Others}) \propto \beta_1^{c_1-1} e^{-d_1\beta_1} \beta_1^{a_1} e^{-\beta_1\lambda_1} \sim \text{Gamma}(c_1 + a_1, d_1 + \lambda_1)$
4. $\pi(\beta_2|\text{Others}) \propto \beta_2^{c_2-1} e^{-d_2\beta_2} \beta_2^{a_2} e^{-\beta_2\lambda_2} \sim \text{Gamma}(c_2 + a_2, d_2 + \lambda_2)$
5. $\pi(k|\text{Others}) \propto \exp(k(\lambda_2 - \lambda_1)) \left(\frac{\lambda_1}{\lambda_2}\right)^{\sum_{i=1}^k y_i}$ (离散分布, 通过指定概率抽样)

定义 8.1 (伽马分布 $\text{Ga}(\alpha, \beta)$, $\Gamma(\alpha, \beta)$)

1. 概率密度函数

(a). 若随机变量 $X \sim \Gamma(\alpha, \beta)$, 其概率密度函数为:

$$f(x) = \begin{cases} \frac{\beta^\alpha}{\Gamma(\alpha)} x^{\alpha-1} e^{-\beta x}, & x > 0, \alpha > 0, \beta > 0 \\ 0, & \text{其他} \end{cases}$$

(b). 若先验分布 $\theta \sim \Gamma(\alpha, \beta)$, 其先验密度为:

$$\pi(\theta) = \frac{\beta^\alpha}{\Gamma(\alpha)} \theta^{\alpha-1} e^{-\beta\theta} \propto \theta^{\alpha-1} e^{-\beta\theta}, \quad \theta > 0, \alpha > 0, \beta > 0$$

2. 期望和方差

若 $X \sim \Gamma(\alpha, \beta)$, 则其期望与方差分别为:

$$E(X) = \frac{\alpha}{\beta}, \quad D(X) = \frac{\alpha}{\beta^2}$$

3. 性质

若 $X \sim \Gamma(\alpha, \beta)$, 则 $2\beta X \sim \chi^2(2\alpha)$ (即 $2\beta X$ 服从自由度为 2α 的卡方分布)。



8.1.5 MCMC 结果与变点解释

MCMC 链收敛后, 识别出两个变点: 1937 年和 1950 年, 对应三个时期的强度参数估计如下表所示:

参数	均值	2.5% 分位数	中位数	97.5% 分位数
λ_1	15.81	13.60	15.78	18.15
λ_2	9.25	7.17	9.27	11.12
λ_3	3.29	2.76	3.29	3.84
k_1 (变点 1)	1937.81	1934	1937	1945
k_2 (变点 2)	1949.80	1946	1950	1955

表 8.1: 后验样本统计量

变点解释:

1. 1937 年前后: 大萧条对车辆使用行为产生重大影响, 导致事故死亡率下降;
2. 1950 年前后: 现代安全气囊的发明、限速政策的实施 (部分州设定高速公路限速 55 英里/小时), 显著降低了事故死亡率。

8.2 满条件分布

满条件分布: 上述案例中, 我们理所当然可以把除了某个参数之外的其他参数全部积分掉, 然后使用之前讨论过的方法, 从边际分布抽样后, 再考察条件分布, 然后依次抽样。

然而, 上述案例分析中, 我们仅仅考虑了条件分布。事实上, 进行 (简化的) 后验推断的核心在于求满条件分布。

定义 8.2 (满条件分布)

对于多维随机向量 $\theta = (\theta_1, \theta_2, \dots, \theta_p)$ 的联合密度函数 $\pi(\theta|y)$, 参数 θ_i 的满条件分布是指在给定

其他所有参数 $\theta_{-i} = (\theta_1, \dots, \theta_{i-1}, \theta_{i+1}, \dots, \theta_p)$ 和数据 y 条件下的条件密度函数, 即

$$\pi(\theta_i | \theta_{-i}, y) \propto \pi(\theta_i | y)$$

满条件分布仅保留与 θ_i 相关的项, 积分掉其他所有参数, 无需计算标准化常数。



8.2.1 满条件分布计算示例

设二维随机向量 (x_1, x_2) 的联合密度函数为

$$\pi(x_1, x_2) \propto \exp \left\{ -\frac{1}{2}(x_1 - 1)^2(x_2 - 1)^2 \right\}$$

则满条件分布为:

$$\pi(x_1 | x_2) \propto \exp \left\{ -\frac{1}{2}(x_1 - 1)^2(x_2 - 1)^2 \right\} \sim N(1, (x_2 - 1)^{-2})$$

$$\pi(x_2 | x_1) \propto \exp \left\{ -\frac{1}{2}(x_2 - 1)^2(x_1 - 1)^2 \right\} \sim N(1, (x_1 - 1)^{-2})$$

设 $y_1, \dots, y_n$ 独立同分布, 来自正态分布 $N(\mu, \tau^{-1})$ 。参数 μ, τ^{-1} 的先验分布分别为正态分布 $\mu \sim N(0, 1)$, 伽马分布 $\tau \sim \text{Ga}(2, 1)$, 且 μ 与 τ 独立。计算满条件分布。

记 $y = (y_1, \dots, y_n)$, 则 (y, μ, τ) 的联合密度函数为

$$p(y, \mu, \tau) = (2\pi)^{-\frac{n+1}{2}} \tau^{\frac{n}{2}+1} \exp \left\{ -\frac{\tau}{2} \sum_{i=1}^n (y_i - \mu)^2 - \frac{\mu^2}{2} - \tau \right\}.$$

参数的后验分布为

$$\pi(\mu, \tau | y) = \frac{p(y, \mu, \tau)}{\int p(y, \mu, \tau) d\mu d\tau} \propto p(y, \mu, \tau).$$

满条件分布 $\pi(\mu | \tau, y)$, $\pi(\tau | \mu, y)$ 分别为

$$\begin{aligned} \pi(\mu | \tau, y) &\propto \exp \left\{ -\frac{\tau}{2} \sum_{i=1}^n (y_i - \mu)^2 - \frac{\mu^2}{2} \right\} \\ &\propto \exp \left\{ -\frac{\tau}{2} n\mu^2 - \frac{\mu^2}{2} + \tau\mu \sum_{i=1}^n y_i \right\} \\ &\propto \exp \left\{ -\frac{1}{2}(1 + n\tau) \left(\mu - \frac{\tau \sum_{i=1}^n y_i}{1 + n\tau} \right)^2 \right\}, \end{aligned}$$

$$\begin{aligned} \pi(\tau | \mu, y) &\propto \tau^{\frac{n}{2}+1} \exp \left\{ -\frac{\tau}{2} \sum_{i=1}^n (y_i - \mu)^2 - \tau \right\} \\ &= \tau^{\frac{n}{2}+1} \exp \left\{ -\tau \left(1 + \frac{1}{2} \sum_{i=1}^n (y_i - \mu)^2 \right) \right\}. \end{aligned}$$

通过以上表达, 我们了解到了条件分布的 Kernel(核), 那么由上可得 $\pi(\mu | \tau, y)$ 的分布为 $N\left(\frac{\tau \sum_{i=1}^n y_i}{1 + n\tau}, (1 + n\tau)^{-1}\right)$, $\pi(\tau | \mu, y)$ 服从伽马分布 $\text{Ga}\left(2 + \frac{n}{2}, 1 + \frac{1}{2} \sum_{i=1}^n (y_i - \mu)^2\right)$ 。



笔记 下例中满条件分布并不都能表示为显示形式。

样本 $y_i, i = 1, \dots, n$ 独立且 $y_i \sim b(1, p_i)$, 其中 $p_i = (1 + \exp(-(\alpha + \beta x_i)))^{-1}$ 。参数 α, β 的先验分布分别为 $\alpha \sim N(0, 1)$, $\beta \sim N(0, 1)$, 且 α, β 独立。

记 $y = \{y_1, y_2, \dots, y_n\}$, 则 (y, α, β) 的先验分布为

$$\begin{aligned} \pi(y, \alpha, \beta) &\propto \exp\left(-\frac{1}{2}\beta^2 - \frac{1}{2}\alpha^2\right) \\ &\quad \times \prod_{i=1}^n \{(1 + \exp\{\alpha + \beta x_i\})^{y_i-1} (1 + \exp\{-(\alpha + \beta x_i)\})^{-y_i}\}. \end{aligned}$$

则满条件分布 $\pi(\beta | \alpha, y)$ 和 $\pi(\alpha | \beta, y)$ 分别为:

$$\begin{aligned} \pi(\beta | \alpha, Y) &\propto \exp\left\{-\frac{1}{2}\beta^2\right\} \prod_{i=1}^n \{(1 + \exp\{\alpha + \beta x_i\})^{y_i-1} (1 + \exp\{-(\alpha + \beta x_i)\})^{-y_i}\}, \\ \pi(\alpha | \beta, y) &\propto \exp\left\{-\frac{1}{2}\alpha^2\right\} \prod_{i=1}^n \{(1 + \exp\{\alpha + \beta x_i\})^{y_i-1} (1 + \exp\{-(\alpha + \beta x_i)\})^{-y_i}\}. \end{aligned}$$

而上述满条件分布并不是某个熟悉的分布的核, 因此我们无法直接从该分布中进行抽样, 因此我们就需要一种类似于“提议-拒绝”的方法进行抽样, 即后续所讲的 Metropolis-Hastings 算法。

在讲 Metropolis-Hastings 算法之前, 我们先考虑一下为什么使用满条件分布进行抽样, 等价于之前章节中的方法呢? 我们跳过严格的数学证明, 提供一种直觉性 (intuitive) 的思路。

8.2.2 Gibbs 抽样的直觉解释

Gibbs 抽样将多维联合抽样转化为一维满条件分布抽样, 核心思想如下:

1. 给定参数 μ 的当前值 $\mu^{(t)}$, 从满条件分布 $\pi(\tau | \mu^{(t)}, y)$ 抽样得到 $\tau^{(t)}$, 则 $(\mu^{(t)}, \tau^{(t)})$ 是联合后验的一个样本;
2. 基于 $\tau^{(t)}$, 从 $\pi(\mu | \tau^{(t)}, y)$ 抽样得到 $\mu^{(t+1)}$, 则 $(\mu^{(t+1)}, \tau^{(t)})$ 是联合后验的下一个样本;
3. 重复迭代, 当迭代次数 $T \rightarrow \infty$ 时, 样本序列 $\{(\mu^{(t)}, \tau^{(t)})\}_{t=1}^T$ 依分布收敛到联合后验分布。

定义 8.3 (Gibbs 抽样)

对于参数向量 $\theta = (\theta_1, \theta_2, \dots, \theta_p)$, 其满条件分布 $\pi(\theta_i | \theta_{-i}, y)$ 均易抽样, Gibbs 抽样步骤如下:

1. 初始化参数初始值 $\theta^{(0)} = (\theta_1^{(0)}, \theta_2^{(0)}, \dots, \theta_p^{(0)})$;
2. 对于第 t 次迭代 ($t = 1, 2, \dots, T$):

$$\begin{aligned} \theta_1^{(t)} &\sim \pi(\theta_1 | \theta_2^{(t-1)}, \theta_3^{(t-1)}, \dots, \theta_p^{(t-1)}, y) \\ \theta_2^{(t)} &\sim \pi(\theta_2 | \theta_1^{(t)}, \theta_3^{(t-1)}, \dots, \theta_p^{(t-1)}, y) \\ &\vdots \\ \theta_p^{(t)} &\sim \pi(\theta_p | \theta_1^{(t)}, \theta_2^{(t)}, \dots, \theta_{p-1}^{(t)}, y) \end{aligned}$$

3. 迭代 T 次后, 舍弃前 B 个样本 (燃烧期), 剩余样本 $\{\theta^{(B+1)}, \dots, \theta^{(T)}\}$ 作为联合后验的近似样本。

例题 8.1 独立同分布正态模型 独立同分布正态模型的观测方程为:

$$y_i | \mu, \phi \sim N(\mu, 1/\phi) \quad (8.2)$$

其中 ϕ 为精度参数 (方差的倒数)。

假设先验意义下 μ 与 $\phi = 1/\sigma^2$ 独立, 采用如下先验分布:

$$\mu \sim N(\mu_0, 1/\omega_0) \quad (8.3)$$

$$\phi \sim \text{Gamma}(\nu_0/2, SS_0/2) \quad (8.4)$$

注: 部分研究者将 μ 的先验方差设为 τ_0^2 , 此处 $\omega_0 = 1/\tau_0^2$ 是重参数化, 结果一致。

解 在定义 8.1 的先验下, (μ, ϕ) 的后验分布满足:

$$p(\mu, \phi | Y) \propto L(\mu, \phi | Y) p(\mu, \phi) \quad (8.5)$$

展开后为:

$$\begin{aligned} p(\mu, \phi | y) &\propto \underbrace{\phi^{n/2} \exp\left(-\frac{\phi}{2} \sum_{i=1}^n (y_i - \mu)^2\right)}_{\text{似然}} \\ &\times \underbrace{\omega_0^{1/2} \exp\left(-\frac{\omega_0}{2} (\mu - \mu_0)^2\right)}_{\mu} \underbrace{\phi^{\nu_0/2-1} \exp\left(-\frac{\phi SS_0}{2}\right)}_{\phi} \end{aligned}$$

后验分布可分解为两种条件形式:

1. 情形 I: $p(\mu, \phi | y) = p(\mu | \phi, y) p(\phi | y)$

2. 情形 II: $p(\mu, \phi | y) = p(\mu | y) p(\phi | \mu, y)$

(假设我们不知道使用 Gibbs sampler, 采取严格的条件分布法)

$$p(\phi | y) = \int p(\mu, \phi | Y) d\mu \quad (8.6)$$

该分布无已知形式。



笔记 如何对 μ 进行后验抽样?

后验分布 $p(\phi | \mu, y)$ 的核为:

$$p(\phi | \mu, y) \propto \phi^{(n+\nu_0)/2-1} \exp\left(-\frac{\phi}{2} \left[\sum_{i=1}^n (y_i - \mu)^2 + SS_0\right]\right) \quad (8.7)$$

因此其分布为:

$$\phi | \mu, y \sim \text{Gamma}\left(\frac{n + \nu_0}{2}, \frac{\sum_{i=1}^n (y_i - \mu)^2 + SS_0}{2}\right) \quad (8.8)$$

$$p(\mu | y) = \int p(\mu, \phi | Y) d\phi \quad (8.9)$$

该分布无已知形式。



笔记 如何对 ϕ 进行后验抽样?

1. 假设我们得到一个来自 μ 边际后验分布的值 (记为 $\mu^{(1)}$);
2. 给定 $\mu = \mu^{(1)}$, 可从 $p(\phi | \mu^{(1)}, y)$ 中抽取 ϕ 的值 (记为 $\phi^{(1)}$), 则 $(\mu^{(1)}, \phi^{(1)})$ 是联合分布的一个样本;
3. $\phi^{(1)}$ 可看作来自 ϕ 边际分布的样本, 因此可从 $p(\mu | \phi^{(1)}, y)$ 中抽取新的 μ 值 (记为 $\mu^{(2)}$), 得到联合分布的另一个样本 $(\mu^{(2)}, \phi^{(1)})$;
4. 给定 $\mu^{(2)}$, 从 $\phi | \mu^{(2)}, y$ 中抽取 $\phi^{(2)}$, 依此类推……

这种抽样方法被称为 Gibbs 抽样。



笔记 Gibbs 抽样的实现步骤:

1. 初始化参数初始值 $\theta^{(0)} = (\mu^{(0)}, \phi^{(0)})$;
2. 对 $t = 1, \dots, T$, 从如下满条件分布序列中抽样:

$$\mu^{(t)} \sim p(\mu | \phi^{(t-1)}, y)$$

$$\phi^{(t)} \sim p(\phi | \mu^{(t)}, y)$$

$$\text{令 } \theta^{(t)} = (\mu^{(t)}, \phi^{(t)})$$

3. 序列 $\{\theta^{(t)} : t = 1, \dots, T\}$ 可看作来自 (μ, ϕ) 联合后验分布的相关样本。

性质 Gibbs 抽样是马尔可夫链蒙特卡罗 (MCMC) 算法的一种, 满足:

1. 马尔可夫性: $\phi^{(t)}$ 仅通过 $\phi^{(t-1)}$ 依赖于过去的抽样序列;
2. 收敛性: 当 $t \rightarrow \infty$ 时, $\theta^{(t)} = (\mu^{(t)}, \phi^{(t)})$ 的经验分布收敛于后验分布, 与初始点无关;
3. 遍历性: 当 $T \rightarrow \infty$ 时, 遍历均值收敛于后验均值:

$$\frac{1}{T} \sum_{t=1}^T g(\theta^{(t)}) \rightarrow \mathbb{E}[g(\theta) | y] \quad (8.10)$$

4. 可扩展性: 上述性质可直接推广到 2 个以上参数的情形。

命题 8.1 (多参数 Gibbs 抽样步骤)

设 $\theta = (\theta_1, \dots, \theta_p)'$ 的所有满条件分布均可抽样:

1. 初始化参数初始值 $(\theta_1^{(0)}, \theta_2^{(0)}, \dots, \theta_p^{(0)})$;
2. 对第 $(t+1)$ 次迭代, 依次从满条件分布中抽样:

$$\begin{aligned} \theta_1^{(t+1)} &\sim p(\theta_1 | \theta_2^{(t)}, \theta_3^{(t)}, \theta_4^{(t)}, \dots, \theta_p^{(t)}, y) \\ \theta_2^{(t+1)} &\sim p(\theta_2 | \theta_1^{(t+1)}, \theta_3^{(t)}, \theta_4^{(t)}, \dots, \theta_p^{(t)}, y) \\ \theta_3^{(t+1)} &\sim p(\theta_3 | \theta_1^{(t+1)}, \theta_2^{(t+1)}, \theta_4^{(t)}, \dots, \theta_p^{(t)}, y) \\ &\vdots \\ \theta_p^{(t+1)} &\sim p(\theta_p | \theta_1^{(t+1)}, \theta_2^{(t+1)}, \dots, \theta_{p-1}^{(t+1)}, y) \end{aligned}$$

3. 令 $\theta^{(t+1)} = (\theta_1^{(t+1)}, \dots, \theta_p^{(t+1)})'$ 。

当迭代次数足够大时, 可使用简化版本 (所有参数基于前一步样本值抽样):

1. $\theta_1^{(t+1)} \sim p(\theta_1 | \theta_2^{(t)}, \theta_3^{(t)}, \dots, \theta_p^{(t)}, y)$
2. $\theta_2^{(t+1)} \sim p(\theta_2 | \theta_1^{(t)}, \theta_3^{(t)}, \dots, \theta_p^{(t)}, y)$
3. $\theta_3^{(t+1)} \sim p(\theta_3 | \theta_1^{(t)}, \theta_2^{(t)}, \theta_4^{(t)}, \dots, \theta_p^{(t)}, y)$
4. $\theta_4^{(t+1)}, \dots, \theta_{p-1}^{(t+1)}$ (类似上述步骤)
5. $\theta_p^{(t+1)} \sim p(\theta_p | \theta_2^{(t)}, \theta_3^{(t)}, \dots, \theta_{p-1}^{(t)}, y)$

8.2.3 Gibbs 抽样的详细解释

Gibbs 抽样是由 Geman 等人最初提出来的, 是最简单、应用最广泛的 MCMC 方法. Gibbs 抽样是一种单元素 Metropolis-Hastings 算法的特殊情况, 单元素 Metropolis-Hastings 算法中取 $q_i(x_i \rightarrow x'_i | x_{-i})$ 为 $\pi(x_i | x_{-i})$. 此时, 不难验证

$$\begin{aligned} \alpha_i(x_i \rightarrow x'_i | x_{-i}) &= \min \left(1, \frac{\pi(x'_i) \pi(x_i | x_{-i})}{\pi(x_i) \pi(x'_i | x_{-i})} \right) \\ &= \min \left(1, \frac{\pi(x_{-i}) \pi(x'_i | x_{-i}) \pi(x_i | x_{-i})}{\pi(x_{-i}) \pi(x_i | x_{-i}) \pi(x'_i | x_{-i})} \right) = 1 \end{aligned}$$

这里 $\pi(x_{-i})$ 是 x_{-i} 的密度函数.

下面说明转移核 $\pi(x_i | x_{-i})$ 得到的 Markov 链满足细致平稳条件.

证明 设向量 $X = (X_1, X_2, \dots, X_p)$ 的密度函数为 $\pi(x)$, 固定 $i (i = 1, 2, \dots, p)$, 在给定 $X_{-i} = x_{-i}$ 条件下, 定义随机变量 $X' = (X'_1, X'_2, \dots, X'_p)$, $X'_{-i} = x_{-i}$ 且 X'_i 具有密度函数 $\pi(x'_i | x_{-i})$, 则对任意可测集 B , 有

$$\begin{aligned} P(X' \in B) &= \int_B \pi(x'_{-i}) \pi(x'_i | x'_{-i}) dx' \\ &= \int_B \pi(x') dx' = \pi(B) \end{aligned}$$

因此由转移核 $\pi(x_i | x_{-i})$ 得到的 Markov 链满足细致平稳条件, 根据此核构造的 Markov 链的平稳分布是 $\pi(x)$. 具体的实施步骤如下: 基于初始状态 $x^{(0)} = (x_1^{(0)}, x_2^{(0)}, \dots, x_p^{(0)})$, 假定第 $t-1$ 时刻状态为 $x^{(t-1)} =$

$(x_1^{(t-1)}, x_2^{(t-1)}, \dots, x_p^{(t-1)})$, 则第 t 时刻状态 $x_1^{(t)}, x_2^{(t)}, \dots, x_p^{(t)}$ 构造分别为:

1. 基于条件分布 $\pi(x_1 | x_2^{(t-1)}, \dots, x_p^{(t-1)})$ 产生 $x_1^{(t)}$;
2. 基于条件分布 $\pi(x_i | x_1^{(t)}, \dots, x_{i-1}^{(t)}, x_{i+1}^{(t-1)}, \dots, x_p^{(t-1)})$ 产生 $x_i^{(t)}$;
3. ...
4. 基于条件分布 $\pi(x_p | x_1^{(t)}, \dots, x_{p-1}^{(t)})$ 产生 $x_p^{(t)}$.

由 Gibbs 抽样得到 Markov 链收敛性的判断通常采取两种办法:

1. 第一种方法是从不同的初始状态出发, 同时产生多个 Markov 链, 把每条链的变化画成散点图, 观察链何时与初始状态基本无关, 此时可认为链收敛;
2. 第二种方法是对 Markov 链每隔一段取一个样本, 得到一个样本子列, 计算每段子列的样本均值. 如果均值变化不大, 可以认为 Markov 链收敛.

练习 8.1 对多项分布

$$P(X_1 = m_1, X_2 = m_2, \dots, X_n = m_n) = \frac{N!}{m_1! m_2! \dots m_n!} p_1^{m_1} p_2^{m_2} \dots p_n^{m_n}$$

其中, $N = \sum_{i=1}^n m_i$. 某实验服从上述多项分布, $N = 22, n = 7$, 7 个结果出现的概率分别为

$$p := (p_1, p_2, \dots, p_7) = \left(\frac{\theta}{4}, \frac{1}{8}, \frac{\theta}{4}, \frac{\eta}{4}, \frac{\eta}{4}, \frac{3}{8}, \frac{1}{2}(1 - \theta - \eta) \right)$$

现有观测数据为 $y = (y_1, y_2, y_3, y_4, y_5) = (14, 1, 1, 1, 5)$, 缺失数据为 $z = (z_1, z_2)$, 且

$$(z_1, y_1 - z_1, y_2, y_3, z_2, y_4 - z_2, y_5) \sim M(22; p)$$

其中, M 表示多项分布. 取平坦分布作为 (θ, η) 的先验分布, 即 $\pi(\theta, \eta) \propto 1$.

$$\pi(y, z, \theta, \eta) \propto \left(\frac{\theta}{4} \right)^{z_1+y_2} \left(\frac{1}{8} \right)^{y_1-z_1} \left(\frac{\eta}{4} \right)^{z_2+y_3} \left(\frac{3}{8} \right)^{y_4-z_2} \left(\frac{1-\theta-\eta}{2} \right)^{y_5} \quad (8.11)$$

习题要求:

1. 推导参数 θ, η 的后验分布 $\pi(\theta, \eta | y, z)$;
2. 推导满条件分布 $\pi(\theta | y, z, \eta)$ 、 $\pi(\eta | y, z, \theta)$ 、 $\pi(z_1 | y, \theta, \eta)$ 和 $\pi(z_2 | y, \theta, \eta)$;
3. 基于 Gibbs 抽样方法, 说明如何构造平稳分布为 $\pi(\theta, \eta, z_1, z_2 | y)$ 的 Markov 链, 并简述判断链收敛性的方法.

解

1. 推导参数 θ, η 的后验分布

由贝叶斯公式, 后验分布与联合分布成正比 (积分掉缺失数据 z 后), 且先验分布 $\pi(\theta, \eta) \propto 1$, 因此:

$$\pi(\theta, \eta | y, z) \propto \pi(y, z, \theta, \eta) \propto \theta^{z_1+y_2} \eta^{y_3+z_2} (1 - \theta - \eta)^{y_5}$$

2. 推导满条件分布

(a). 满条件分布 $\pi(\theta | y, z, \eta)$: 固定 η, z, y , 仅保留与 θ 相关项:

$$\begin{aligned} \pi(\theta | y, z, \eta) &\propto \theta^{z_1+y_2} [(1 - \eta) - \theta]^{y_5} \\ &= (1 - \eta)^{z_1+y_2+y_5} \left(\frac{\theta}{1 - \eta} \right)^{z_1+y_2} \left(1 - \frac{\theta}{1 - \eta} \right)^{y_5} \\ &\propto \left(\frac{\theta}{1 - \eta} \right)^{z_1+y_2} \left(1 - \frac{\theta}{1 - \eta} \right)^{y_5} \sim (1 - \eta) \text{Beta}(z_1 + y_2 + 1, y_5 + 1) \end{aligned}$$

(b). 满条件分布 $\pi(\eta | y, z, \theta)$: 固定 θ, z, y , 仅保留与 η 相关项:

$$\pi(\eta | y, z, \theta) \propto \eta^{y_3+z_2} (1 - \theta - \eta)^{y_5} \sim (1 - \theta) \text{Beta}(y_3 + z_2 + 1, y_5 + 1)$$

(c). 满条件分布 $\pi(z_1 | y, \theta, \eta)$: 固定 θ, η, y , 仅保留与 z_1 相关项:

$$\begin{aligned}\pi(z_1 | y, \theta, \eta) &\propto \left(\frac{\theta}{4}\right)^{z_1+y_2} \left(\frac{1}{8}\right)^{y_1-z_1} \\ &\propto \left(\frac{2\theta}{8}\right)^{z_1} \left(\frac{1}{8}\right)^{y_1-z_1} \\ &\propto \left(\frac{2\theta}{2\theta+1}\right)^{z_1} \left(\frac{1}{2\theta+1}\right)^{y_1-z_1} \sim \text{Bino}\left(y_1, \frac{2\theta}{2\theta+1}\right)\end{aligned}$$

(d). 满条件分布 $\pi(z_2 | y, \theta, \eta)$: 固定 θ, η, y , 仅保留与 z_2 相关项:

$$\begin{aligned}\pi(z_2 | y, \theta, \eta) &\propto \left(\frac{\eta}{4}\right)^{z_2+y_3} \left(\frac{3}{8}\right)^{y_4-z_2} \\ &\propto \left(\frac{2\eta}{8}\right)^{z_2} \left(\frac{3}{8}\right)^{y_4-z_2} \\ &\propto \left(\frac{2\eta}{2\eta+3}\right)^{z_2} \left(\frac{3}{2\eta+3}\right)^{y_4-z_2} \sim \text{Bino}\left(y_4, \frac{2\eta}{2\eta+3}\right)\end{aligned}$$

3. Gibbs 抽样构造 Markov 链及收敛性判断

(a). Markov 链构造步骤:

- ① 初始化: 给定 $\theta^{(0)}, \eta^{(0)}, z_1^{(0)}, z_2^{(0)}$ (如取合理初始值);
- ② 迭代抽样 (第 t 步):
 - 从 $\pi(\theta | y, z_1^{(t-1)}, z_2^{(t-1)}, \eta^{(t-1)})$ 抽样得到 $\theta^{(t)}$;
 - 从 $\pi(\eta | y, z_1^{(t-1)}, z_2^{(t-1)}, \theta^{(t)})$ 抽样得到 $\eta^{(t)}$;
 - 从 $\pi(z_1 | y, \theta^{(t)}, \eta^{(t)})$ 抽样得到 $z_1^{(t)}$;
 - 从 $\pi(z_2 | y, \theta^{(t)}, \eta^{(t)})$ 抽样得到 $z_2^{(t)}$;
- ③ 重复迭代 T 次, 得到序列 $\{(\theta^{(t)}, \eta^{(t)}, z_1^{(t)}, z_2^{(t)})\}_{t=1}^T$, 该序列即为平稳分布为 $\pi(\theta, \eta, z_1, z_2 | y)$ 的 Markov 链。

(b). 收敛性判断方法:

- ① 遍历均值法: 每隔固定步长 (如 10 步) 取一个样本, 每若干样本 (如 20 个) 计算一次均值, 若均值趋于稳定, 说明链收敛;
- ② 多初始值法: 从不同初始值出发构造多条链, 绘制链的轨迹图, 若多条链轨迹重合且无明显趋势, 说明链收敛。



笔记 补充: 基于收敛的 Markov 链, 可得到参数的后验特征估计, 例如:

$$E(\eta | y) = 0.123, E(\theta | y) = 0.520, \text{Var}(\eta | y) = 0.0065, \text{Var}(\theta | y) = 0.018.$$

R 代码如下:

```
1 set.seed(1)
2 y = c(14, rep(1, 3), 5) # 数据
3 thinning = 10
4 n_mc = 5000 * thinning # 链长
5 # 各参数初始点
6 theta = rep(NA, n_mc)
7 eta = rep(NA, n_mc)
8 z1 = rep(NA, n_mc)
9 z2 = rep(NA, n_mc)
10 theta[1] = runif(1)
11 eta[1] = runif(1)
12 z1[1] = rbinom(1, y[1], 2 * theta[1] / (2 * theta[1] + 1))
13 z2[1] = rbinom(1, y[4], 2 * eta[1] / (2 * eta[1] + 3))
14
```

```

15   for (in_mc in 2:n_mc) {
16     theta[in_mc] =
17     rbeta(1, z1[in_mc - 1] + y[2] + 1, y[5] + 1) *
18     (1 - eta[in_mc - 1]) # 更新theta
19     eta[in_mc] =
20     rbeta(1, y[3] + z2[in_mc - 1] + 1, y[5] + 1) *
21     (1 - theta[in_mc]) # 更新eta
22     z1[in_mc] = rbinom(1, y[1], 2 * theta[in_mc] /
23     (2 * theta[in_mc] + 1)) # 更新z1
24     z2[in_mc] = rbinom(1, y[4], 2 * eta[in_mc] /
25     (2 * eta[in_mc] + 3)) # 更新z2
26   }
27
28   idx = !as.logical((1:n_mc) %% thinning) # 每10点取子链
29   sample_theta = theta[idx]
30   sample_eta = eta[idx]
31   sample_theta = matrix(sample_theta, nrow = 20)
32   sample_eta = matrix(sample_eta, nrow = 20)
33   means_eta = colMeans(sample_eta)
34   means_theta = colMeans(sample_theta)
35   mean(sample_eta)
36   mean(sample_theta)
37   var(as.vector(sample_eta))
38   var(as.vector(sample_theta))

```

8.3 扩展：数据增强的 Gibbs 抽样

由于 Gibbs 抽样可用于解决高维抽样问题（它将多元联合抽样问题转化为低维抽样问题），在实际研究中，我们可以引入大量辅助变量。

这种方法在统计研究中通常被称为**数据增强**。

结合 Gibbs 抽样与数据增强的一个非常经典的实际例子是**有限混合模型**。

例题 8.2 假设灯泡寿命数据 $y = (y_1, y_2, \dots, y_n)$ 来自两成分指数混合分布：

1. 若灯泡为 A 类（概率 θ ），寿命 $y_i \sim \exp(\lambda_1)$ ；
2. 若灯泡为 B 类（概率 $1 - \theta$ ），寿命 $y_i \sim \exp(\lambda_2)$ 。

然而，当我们收集数据时，无法观测到灯泡的等级，只能观测到寿命数据 $y = (y_1, y_2, \dots, y_n)$ ，我们需要对参数 $(\lambda_1, \lambda_2, \theta)$ 进行推断，其中 θ 是灯泡属于 A 级的概率。

解 直觉思考：这些参数是否可估计？

1. 观测数据： $(y_1, y_2, \dots, y_n)$
2. 两类群体（未知）： 1 类和 2 类

我们引入辅助变量 $Z_i = (Z_{i1}, Z_{i2}) = (1, 0)$ 或 $(0, 1)$ ：

若 $Z_i = (1, 0) \rightarrow 1$ 类

若 $Z_i = (0, 1) \rightarrow 2$ 类

对于观测值 y_i ：

$$P(Z_{i1} = 1) = \theta, \quad P(Z_{i2} = 1) = 1 - \theta$$

若 $Z_{i1} = 1, y_i \sim \exp(\lambda_1)$

若 $Z_{i2} = 1, y_i \sim \exp(\lambda_2)$

(Z_i, y_i) 的联合概率：

$$P(Z_i = (1, 0), y_i) = \theta \lambda_1 e^{-\lambda_1 y_i}, \quad P(Z_i = (0, 1), y_i) = (1 - \theta) \lambda_2 e^{-\lambda_2 y_i}$$

1 类的个体数量为 $\sum_{i=1}^n Z_{i1}$ ，2 类的个体数量为 $\sum_{i=1}^n Z_{i2}$ 。

于是， $P(Y | Z)$ 的形式为：

$$\begin{aligned} & \prod_{i=1}^n \left(\lambda_1 e^{-\lambda_1 y_i} \right)^{Z_{i1}} \left(\lambda_2 e^{-\lambda_2 y_i} \right)^{Z_{i2}} \\ &= \lambda_1^{\sum_{i=1}^n Z_{i1}} e^{-\lambda_1 \sum_{i=1}^n Z_{i1} y_i} \lambda_2^{\sum_{i=1}^n Z_{i2}} e^{-\lambda_2 \sum_{i=1}^n Z_{i2} y_i} \end{aligned}$$

$$P(Z) = \theta^{\sum_{i=1}^n Z_{i1}} (1 - \theta)^{\sum_{i=1}^n Z_{i2}}$$

因此，若 Z 已知，联合似然为：

$$\theta^{\sum_{i=1}^n Z_{i1}} (1 - \theta)^{\sum_{i=1}^n Z_{i2}} \lambda_1^{\sum_{i=1}^n Z_{i1}} e^{-\lambda_1 \sum_{i=1}^n Z_{i1} y_i} \lambda_2^{\sum_{i=1}^n Z_{i2}} e^{-\lambda_2 \sum_{i=1}^n Z_{i2} y_i}$$

考虑先验分布：

$$\pi(\theta) \sim \text{Beta}(a, b) = \frac{\theta^{a-1} (1 - \theta)^{b-1}}{B(a, b)}$$

$$\pi(\lambda_1) \sim \text{Gamma}(\alpha_1, \beta_1) = \frac{\beta_1^{\alpha_1}}{\Gamma(\alpha_1)} \lambda_1^{\alpha_1-1} e^{-\beta_1 \lambda_1}$$

$$\pi(\lambda_2) \sim \text{Gamma}(\alpha_2, \beta_2) = \frac{\beta_2^{\alpha_2}}{\Gamma(\alpha_2)} \lambda_2^{\alpha_2-1} e^{-\beta_2 \lambda_2}$$

于是，联合后验分布为：

$$\begin{aligned} \pi(\theta, \lambda_1, \lambda_2, Z | y) &\propto \theta^{\sum_{i=1}^n Z_{i1} + a - 1} (1 - \theta)^{\sum_{i=1}^n Z_{i2} + b - 1} \\ &\quad \times \lambda_1^{\sum_{i=1}^n Z_{i1} + \alpha_1 - 1} e^{-\lambda_1 (\sum_{i=1}^n y_i Z_{i1} + \beta_1)} \\ &\quad \times \lambda_2^{\sum_{i=1}^n Z_{i2} + \alpha_2 - 1} e^{-\lambda_2 (\sum_{i=1}^n y_i Z_{i2} + \beta_2)} \end{aligned}$$

满条件分布为：

$$\begin{aligned} \pi(\theta | \text{others}) &\sim \text{Beta} \left(\sum_{i=1}^n Z_{i1} + a, \sum_{i=1}^n Z_{i2} + b \right) \\ \pi(\lambda_1 | \text{others}) &\sim \text{Gamma} \left(\sum_{i=1}^n Z_{i1} + \alpha_1, \sum_{i=1}^n y_i Z_{i1} + \beta_1 \right) \\ \pi(\lambda_2 | \text{others}) &\sim \text{Gamma} \left(\sum_{i=1}^n Z_{i2} + \alpha_2, \sum_{i=1}^n y_i Z_{i2} + \beta_2 \right) \end{aligned}$$

但这些满条件分布是在 Z 已知时的分布。实际上 Z 是未知的，因此我们用 Z 的满条件分布来替代它：

$$P(Z_{i1} = 1 | y_i), \quad \text{当 } \theta, \lambda_1, \lambda_2 \text{ 已知时}$$

于是：

$$\begin{aligned}
 P(Z_{i1} = 1 | Y_i = y_i) &= \frac{P(Z_{i1} = 1, Y_i = y_i)}{P(Y_i = y_i)} \\
 &= \frac{P(Z_{i1} = 1)P(Y_i = y_i | Z_{i1} = 1)}{P(Z_{i1} = 1)P(Y_i = y_i | Z_{i1} = 1) + P(Z_{i2} = 1)P(Y_i = y_i | Z_{i2} = 1)} \\
 &= \frac{\theta \lambda_1 e^{-\lambda_1 y_i}}{\theta \lambda_1 e^{-\lambda_1 y_i} + (1 - \theta) \lambda_2 e^{-\lambda_2 y_i}} = p_i
 \end{aligned}$$

在 Gibbs 抽样中， $Z_i \sim \text{Bernoulli}(p_i)$ 。

笔记

1. 辅助变量 Z_i 的满条件分布： $Z_{i1} | \theta, \lambda_1, \lambda_2, y_i \sim \text{Bernoulli}(p_i)$ ，其中

$$p_i = \frac{\theta \lambda_1 e^{-\lambda_1 y_i}}{\theta \lambda_1 e^{-\lambda_1 y_i} + (1 - \theta) \lambda_2 e^{-\lambda_2 y_i}}$$

2. 参数 λ_1 的满条件分布： $\pi(\lambda_1 | Z, \alpha_1, \beta_1) \sim \text{Gamma}(\sum_{i=1}^n Z_{i1} + \alpha_1, \sum_{i=1}^n Z_{i1} y_i + \beta_1)$
3. 参数 λ_2 的满条件分布： $\pi(\lambda_2 | Z, \alpha_2, \beta_2) \sim \text{Gamma}(\sum_{i=1}^n Z_{i2} + \alpha_2, \sum_{i=1}^n Z_{i2} y_i + \beta_2)$
4. 参数 θ 的满条件分布： $\pi(\theta | Z, a, b) \sim \text{Beta}(a + \sum_{i=1}^n Z_{i1}, b + \sum_{i=1}^n Z_{i2})$

定义 8.4 (数据增强)

数据增强是指在抽样过程中引入未观测的辅助变量 Z ，使得扩展后的参数 (θ, Z) 的满条件分布易于抽样，从而简化原参数 θ 的抽样过程，是 Gibbs 抽样在高维问题中的重要应用技巧。



数据增强 Gibbs 抽样步骤：

1. 初始化参数 $(\theta^{(0)}, \lambda_1^{(0)}, \lambda_2^{(0)})$ ；
2. 迭代 T 次：

$$\begin{aligned}
 Z_i^{(t)} &\sim \text{Bernoulli}(p_i^{(t-1)}) \quad (i = 1, \dots, n) \\
 \lambda_1^{(t)} &\sim \text{Gamma}\left(\sum Z_{i1}^{(t)} + \alpha_1, \sum Z_{i1}^{(t)} y_i + \beta_1\right) \\
 \lambda_2^{(t)} &\sim \text{Gamma}\left(\sum Z_{i2}^{(t)} + \alpha_2, \sum Z_{i2}^{(t)} y_i + \beta_2\right) \\
 \theta^{(t)} &\sim \text{Beta}\left(a + \sum Z_{i1}^{(t)}, b + \sum Z_{i2}^{(t)}\right)
 \end{aligned}$$

3. 舍弃燃烧期样本，剩余样本用于推断。

8.4 Metropolis 算法与 Metropolis-Hastings 算法

8.4.1 Metropolis 算法

Metropolis 算法是一种 MCMC 技术，用于从仅已知核（未归一化密度）的目标分布中抽样，适用于 Gibbs 抽样中满条件分布无显式形式的场景。

当满条件分布无明确形式时，Metropolis 算法通过提议-接受机制抽样，核心是构造对称提议分布并计算接受概率。

定义 8.5 (Metropolis 算法)

设目标分布的概率密度为 $p(\theta | Y)$ （仅需已知核），算法步骤为：

1. 初始化：设定初始值 $\theta^{(1)}$ ；
2. 迭代抽样（第 s 步）：
 - (a). 从对称提议分布 $J(\theta | \theta^{(s)})$ （如 $N(\theta^{(s)}, c^2)$ 或 $\text{Unif}(\theta^{(s)} - c, \theta^{(s)} + c)$ ）抽取提议值 θ^* ；

(b). 计算接受概率:

$$\alpha = \min \left\{ 1, \frac{p(\theta^* | Y)}{p(\theta^{(s)} | Y)} \right\} \quad (8.12)$$

若 $p(\theta | Y)$ 为后验分布, 则 $\alpha = \frac{L(\theta^* | Y)\pi(\theta^*)}{L(\theta^{(s)} | Y)\pi(\theta^{(s)})}$;

(c). 从 $\text{Unif}(0, 1)$ 抽取 u , 若 $u \leq \alpha$, 则接受提议值 $\theta^{(s+1)} = \theta^*$; 否则拒绝, $\theta^{(s+1)} = \theta^{(s)}$;

3. 重复迭代直至 MCMC 收敛 (或达到指定迭代次数, 如 $M = 10^5$)。

性质 Metropolis 算法的提议分布 $J(\theta | \theta^{(s)})$ 需满足:

1. 仅依赖当前值 $\theta^{(s)}$, 保证马尔可夫性;
2. 对称性: $J(\theta^* | \theta^{(s)}) = J(\theta^{(s)} | \theta^*)$;
3. 遍历性: 从任意初始值可到达参数空间所有点;
4. 非周期性: 不会周期性返回某一值。

命题 8.2 (Metropolis 算法的调优)

Metropolis 算法的调优目标是选择提议分布, 使接受率约为 35

1. 进行短迭代运行, 记录接受率;
2. 调整提议分布参数 (如正态提议的方差 c^2), 直至接受率接近目标值;
3. 复杂问题可采用自适应 MCMC 算法 (无需手动调优)。

调优的核心权衡:

- 小步长提议: 接受率高, 但链的相关性强, 收敛慢;
- 大步长提议: 接受率低, 链易陷入局部区域。

Metropolis-Hastings 算法是 Metropolis 算法的推广, 允许提议分布非对称, 通过修正接受率保证抽样正确性。

定义 8.6 (Metropolis-Hastings 算法)

设目标分布为 $\pi(\theta | y)$, 算法步骤如下:

1. 初始化参数初始值 $\theta^{(1)}$;
2. 对于第 s 次迭代 ($s = 1, 2, \dots, S$):
 - (a). 从提议分布 $J(\theta | \theta^{(s)})$ (可非对称) 抽样得到提议值 θ^* ;
 - (b). 计算 Metropolis-Hastings 接受率:

$$\alpha = \min \left\{ 1, \frac{\pi(\theta^* | y)J(\theta^{(s)} | \theta^*)}{\pi(\theta^{(s)} | y)J(\theta^* | \theta^{(s)})} \right\}$$

(c). 从 $U(0, 1)$ 抽样得到 u , 若 $u \leq \alpha$, 则 $\theta^{(s+1)} = \theta^*$; 否则 $\theta^{(s+1)} = \theta^{(s)}$;

3. 迭代 S 次后, 舍弃燃烧期样本, 剩余样本作为目标分布的近似样本。

命题 8.3 (Metropolis-Hastings 算法的特殊情况)

1. Metropolis 算法: 当提议分布对称时, $J(\theta^* | \theta^{(s)}) = J(\theta^{(s)} | \theta^*)$, 接受率简化为 $\alpha = \min \left\{ 1, \frac{p(\theta^* | Y)}{p(\theta^{(s)} | Y)} \right\}$;
2. 提议分布等于目标分布: $J(\theta^* | \theta^{(s)}) = p(\theta^* | Y)$, 此时接受率 $\alpha = 1$, 每次提议均被接受;
3. 独立提议: 提议分布与当前值无关 ($J(\theta^* | \theta^{(s)}) = J(\theta^*)$), 接受率为 $\alpha = \min \left\{ 1, \frac{p(\theta^* | Y)J(\theta^{(s)})}{p(\theta^{(s)} | Y)J(\theta^*)} \right\}$ 。

例题 8.3 样本 $y_i, i = 1, \dots, n$ 独立且 $y_i \sim b(1, p_i)$, 其中 $p_i = (1 + \exp(-(\alpha + \beta x_i)))^{-1}$ 。参数 α, β 的先验分布为 $\alpha \sim N(0, 1)$, $\beta \sim N(0, 1)$ 且独立。

后验分布为:

$$\pi(\alpha, \beta | y) \propto \exp\left(-\frac{1}{2}\alpha^2 - \frac{1}{2}\beta^2\right) \prod_{i=1}^n \{(1 + \exp\{\alpha + \beta x_i\})^{y_i-1} (1 + \exp\{-(\alpha + \beta x_i)\})^{-y_i}\}$$

满条件分布:

$$\pi(\beta | \alpha, y) \propto \exp\left\{-\frac{1}{2}\beta^2\right\} \prod_{i=1}^n \{(1 + \exp\{\alpha + \beta x_i\})^{y_i-1} (1 + \exp\{-(\alpha + \beta x_i)\})^{-y_i}\},$$

$$\pi(\alpha | \beta, y) \propto \exp\left\{-\frac{1}{2}\alpha^2\right\} \prod_{i=1}^n \{(1 + \exp\{\alpha + \beta x_i\})^{y_i-1} (1 + \exp\{-(\alpha + \beta x_i)\})^{-y_i}\}.$$

该满条件分布无显式形式, 需通过 Metropolis-Hastings 算法抽样。

```

1  mfun = function(x0, nsample = 2000, c=1){
2    ## 定义对数目标分布
3    log_target = function(x){
4      log(sin(x)^2) + log(cos(2*x)^2) + dnorm(x, log = TRUE)
5    }
6    ## 初始化输出向量
7    sample_mcmc = rep(0, nsample)
8    sample_mcmc[1] = x0
9    counter = 0
10   for(i in 1:nsample){ ## 开始MCMC迭代
11     x_prop = rnorm(1, sample_mcmc[i], c) ## 从提议分布抽样
12     lr = min(0, log_target(x_prop) - log_target(sample_mcmc[i])) ## 计算对数接受率
13     u = runif(1)
14     if (u <= exp(lr)){
15       sample_mcmc[i+1] = x_prop; counter = counter + 1
16     }else{
17       sample_mcmc[i+1] = sample_mcmc[i]
18     }
19   }
20   return(list(sample = sample_mcmc, accept = counter/nsample))
21 }
22 # 运行算法
23 s = mfun(x0 = 0.2, nsample = 10000)$sample

```

 **练习 8.2** 为提升 Metropolis 算法的收敛效率, 建议尝试使用不同的提议分布, 并选择接受率最优的分布。

 **笔记** Metropolis-Hastings 算法被称为“20 世纪最重要的统计算法”之一, 其核心优势是无需目标分布的归一化常数, 仅需已知核即可抽样。

 **笔记** 提议分布 $J(\theta|\theta^{(s)})$ 需满足:

1. 仅依赖当前参数 $\theta^{(s)}$, 保证 Markov 性;
2. 对称性 (Metropolis 算法要求);
3. 遍历性: 从任意初始值可到达参数空间所有点;
4. 非周期性: 不会周期性返回某一值。

 **笔记** 常用对称提议分布:

1. 正态分布: $J(\theta|\theta^{(s)}) = N(\theta^{(s)}, c^2)$ (c 为步长);
2. 均匀分布: $J(\theta|\theta^{(s)}) = \text{Unif}(\theta^{(s)} - c, \theta^{(s)} + c)$ 。

 **笔记** 调优目标: 选择提议分布使接受率约为 35

1. 进行短迭代运行, 记录接受率;

2. 调整提议分布参数（如正态分布的方差 c^2 ），直至接受率接近目标值；
3. 复杂问题可采用自适应 MCMC 算法（无需手动调优）。

8.4.2 课堂练习与思考

1. 尝试使用独立提议分布 $N(0, 2)$ 对目标分布 $\sin(x)^2 \cos(2x)^2 \exp(-x^2/2)$ 进行抽样，对比与对称提议分布的差异；
2. 分析独立提议的 MCMC 与舍选抽样的本质区别：前者通过 Markov 链收敛到目标分布，后者直接接受符合条件的样本，无需迭代。

8.5 结论

本章围绕多元分布抽样问题，系统介绍了 MCMC 方法的核心技术：

1. Gibbs 抽样通过满条件分布抽样简化高维联合分布抽样，适用于满条件分布易处理的场景；
2. 数据增强技术通过引入辅助变量，将复杂分布转化为易于抽样的扩展分布；
3. Metropolis 算法和 Metropolis-Hastings 算法通过提议-接受机制，解决满条件分布无明确形式的抽样问题；
4. 提议分布的调优是 MCMC 算法高效运行的关键，需根据目标分布特性选择合适的提议分布。

MCMC 方法作为贝叶斯推断的核心工具，已广泛应用于统计建模、机器学习、生物信息学等领域，掌握其基本原理和实现方法对解决复杂实际问题具有重要意义。

第八章 练习

1. 基于 Poisson-Gamma-Gamma 模型的变点分析，尝试修改超先验参数（如 $a_1 = 5$, $a_2 = 5$ ），观察 MCMC 链的收敛性和后验估计结果的变化；
2. 针对逻辑回归模型的满条件分布，实现 Metropolis-within-Gibbs 抽样算法，即对易处理的满条件分布采用 Gibbs 抽样，对难处理的满条件分布采用 Metropolis 步骤；
3. 对比不同提议分布（正态分布、均匀分布、Gamma 分布）在 Metropolis-Hastings 算法中的表现，以接受率和链收敛速度为评价指标；
4. 设 $X^{(1)}, X^{(2)}, \dots$ 为一个 Markov 链，转移核为 $P(X^{(t-1)}|X^{(t)}) \sim N(kX^{(t)}, 1)$. 证明当 $0 \leq k < 1$ 时，该 Markov 链收敛，并求其平稳分布。
5. 设 $X_1, X_2, \dots, X_n$ 是来自泊松分布 $\text{Poisson}(\lambda)$ 的一个独立样本， λ 的先验分布为 $\text{Gamma}(2, 1)$ ，求满条件分布 $\pi(\lambda|X_1, X_2, \dots, X_n)$ 。
6. 已知目标分布 $\pi(x)$ 为贝塔分布 $\text{Beta}(6, 2, 1)$ ，取潜在的转移核为均匀分布 $U(0, 1)$ ，利用 Metropolis-Hastings 方法抽取容量为 8 000 的 Markov 链样本并检查其收敛性。若收敛，取收敛的子链计算样本均值，判断其是否接近总体均值。
7. 设 $X_1, X_2, \dots, X_n$ 是来自指数分布 $\text{Exp}(\lambda)$ 的独立样本， λ 的先验分布为 $\text{Gamma}(2, 1)$ ，给定 $n = 100$, $\bar{X} = n^{-1} \sum_{i=1}^n X_i = 1.4$ 。寻找合适的转移核，用 Metropolis-Hastings 方法抽取容量为 8 000 的 Markov 链样本 $\lambda_i (i = 1, 2, \dots, 8\,000)$ ，并检查其收敛性。
8. 设 $X_1, X_2, \dots, X_n$ 是来自总体 $N(\mu, \tau^{-1})$ 的独立样本， μ 的先验分布为 $N(a, b)$, τ 的先验分布为 $\text{Gamma}(c, d)$ ，利用 Gibbs 抽样抽取容量为 8 000 的 Markov 链样本，判断其是否收敛至真实的 μ 和 τ （其中取 $n = 100, \mu = 0, \tau = 1$ ，初始值为 $a_0 = 0, b_0 = 1, c_0 = 2, d_0 = 1$ ）；
9. 设 $\{X_t, t = 0, 1, \dots\}$ 为状态取值于 $S = \{1, 2, \dots, m\}$ 的马氏链，有平稳分布 $\pi_j, j = 1, 2, \dots, m$ ，若 X_0 服从平稳分布，证明所有 X_t 都服从平稳分布 ($t \geq 0$)。

10. 设向量 $x = (x_1, \dots, x_n)$, 每个 x_i 取值为 +1 或 -1, 记这样的 x 的集合为 X 。设随机向量 X 有如下概率质量函数

$$\pi(x) = P(X = x) = \frac{1}{Z} \exp \left\{ \mu \sum_{i=1}^{n-1} x_i x_{i+1} \right\}$$

其中 μ 已知, Z 为归一化常数。这样的模型称为一维 Ising 模型。取 $\mu = 1, n = 50$, 设计 MCMC 算法从 $\pi(x)$ 抽样。

11. 设随机变量 X 和 Y 都取值于 $(0, B)$ 区间 (B 已知)。设 $Y = y$ 条件下 X 的条件分布密度为

$$f(x|y) \propto e^{-yx}, \quad x \in (0, B),$$

$X = x$ 条件下 Y 的条件分布密度为

$$f(y|x) \propto e^{-xy}, \quad y \in (0, B),$$

编写 R 程序用 Gibbs 抽样方法对 (X, Y) 抽样, 估计 EX 和 $\rho(X, Y)$ 。

12. 设 $X = (X_1, X_2, \dots, X_n)$ 独立同 $U(0, 1)$ 分布, 对 $0 < d < \frac{1}{n-1}$, 用条件 A 表示这 n 个点两两的距离都超过 d , 可以证明 A 的概率为 $[1 - (n-1)d]^n$ 。设 $n = 9, d = 0.1$, 设计 Gibbs 抽样方法生成满足条件 A 的 X 的抽样链。

期末复习

考试题型及特点

1. 选择题：5 道，每题 5 分!!!
2. 计算题：数值模拟计算积分或级数，3（或 4）道，每题 5+ 分；
3. 解答题/证明题：如何抽样/采样的过程叙述推导，4 道，每题 10 分；
4. 代码题：与重抽样（Bootstrap 方法）相关，利用 `apply()` 函数去设计算法，并写出代码，与题目 7.2 相似，建议把这题背下来，共 20 分!!!

复习题

1. 用平均值估计法估计 $I = \int_0^1 \frac{\sin x}{x} dx$
2. 用重要抽样法估计 $\mu = \int_0^1 x f(x) dx = \int_0^1 e^x dx$ 的估计值
3. 用蒙特卡洛方法，估计积分：

$$\int_0^1 \frac{e^{-x}}{1+x^2} dx$$

4. 用蒙特卡洛方法，估计级数和：

$$S = \sum_{j=0}^{\infty} \frac{\sin(\sqrt{j})}{\log(j+2)} e^{-6\sqrt{j}} \frac{1}{j!}$$

5. 用蒙特卡洛方法计算积分 $\int_0^{10} \exp(-2|x-5|) dx$ （理论真值约为 1）
6. 对于 $a \geq 0$ ，计算积分：

$$I(a) = \int_a^{\infty} (1+x^2)^{1/2} \cdot \frac{\sin(x)}{x} \cdot \exp(-|x|^{3/2}) dx \quad (8.13)$$

7. 请分别以

$$f_1(x) = 1, \quad 0 < x < 1,$$

$$f_2(x) = \frac{e^{-x}}{1-e^{-1}}, \quad 0 < x < 1,$$

$$f_3(x) = \frac{4}{\pi(1+x^2)}, \quad 0 < x < 1$$

作为重要函数，运用重要抽样法估计积分

$$\theta = \int_0^1 \frac{e^{-x}}{1-e^{-1}} dx,$$

8. 估计

$$\theta = \int_0^1 e^{x^2} dx,$$

9. 考虑定积分

$$I = \int_{-1}^1 e^x dx = e - e^{-1}.$$

10. 设 $h(x) = \frac{e^{-x}}{1+x^2}, x \in (0, 1)$, 用重要抽样法计算积分 $I = \int_0^1 h(x)dx$, 分别采用如下的试抽样密度:

$$f_1(x) = 1, x \in (0, 1),$$

$$f_2(x) = e^{-x}, x \in (0, \infty),$$

$$f_3(x) = \frac{1}{\pi(1+x^2)}, x \in (-\infty, \infty),$$

$$f_4(x) = (1 - e^{-1})^{-1} e^{-x}, x \in (0, 1),$$

$$f_5(x) = \frac{4}{\pi(1+x^2)}, x \in (0, 1).$$

11. 设线性模型 $y = \alpha + \beta x + \epsilon$, 其中 $x \sim N(0, 1)$, $\epsilon \sim N(0, 1)$, $\alpha = 1$, $\beta = 1$. 编写 R 程序生成 300 组样本 (x_i, y_i) , 基于最小二乘法估计 α 和 β (提示: $\hat{\beta} = \frac{\sum (x_i - \bar{x})(y_i - \bar{y})}{\sum (x_i - \bar{x})^2}$, $\hat{\alpha} = \bar{y} - \hat{\beta}\bar{x}$), 并验证估计量的无偏性。
12. Interquartile range (IQR), 中文: 四分位距, 是一种衡量变异性的方法, 它通过将数据集划分为四分位数来实现。四分位数将一个按等级排序的数据集划分为四个相等的部分。即 Q1 (第 1 个四分位数)、Q2 (第 2 个四分位数) 和 Q3 (第 3 个四分位数)。

$$IQR = Q3 - Q1.$$

与方差类似, IQR 衡量分布的“散度”, 分布的 IQR 可以采用样本 IQR 来进行估计。

与方差等不同的是, IQR 估计的估计值的不确定性不太容易量化 (例如, 方差估计的不确定性可以通过构造卡方分布得出置信区间), 因此我们可以考虑使用 bootstrap 方法进行估计。

给定数据为: 1.51 2.68 1.62 3.05 4.50 3.08 4.20 0.19 1.74 0.79 1.68 0.49 3.14 0.74 0.93 2.31 2.70 1.75 2.06 1.54 1.56 1.13 0.43 2.42 4.60 1.01 4.09 5.08 1.46 0.90

使用 Bootstrap 方法, 求 IQR 估计的:

(a). 估计方差

(b). 估计值的 95

相应的, 求 $X_{(n-2)} - X_{(3)}$ 估计的:

(a). 估计方差

(b). 估计值的 95

建议考虑使用 `apply()` 函数, 如果不熟, 查找相应文档;