

非结构化数据分析 2026 年原题回忆

前言

本文档是统计学专业课——非结构化数据分析 2026 年期末考试原题的回忆版（共回忆 100 分真题），旨在帮助各位学弟学妹在大三下（处于保研、考研、出国的关键阶段）减轻压力，取得好成绩。

回忆真题的初衷（**故事的开始**）：统计学，作为开设时间非常很晚的专业，不像经统或金数有非常多的资料和原题流传出来，复习容易陷入迷茫；另外，由于统计学的专业课程都集中在大三，学习压力非常大，如果有原题作为参考，对于复习或者减轻压力，都有不小的帮助。基于此，22 级统计学的 6★学长将一些专业课的原题整理起来，供 23 级的同学复习，并得到了较多好评。在某一天，23 级统计学的 w 学长向 6★学长提出他将回忆和补充专业课真题，希望能帮到各位学弟学妹，并组织多位统计学的同学加入其中。于是，一个属于 UIBE 统计人的热心组织诞生了！若有同学也想加入到帮助学弟学妹的行列中，请联系小红书号：5669549260。

这份回忆版真题主要由 22 级统计学的 6★学长和 23 级统计学的 w 学长回忆完成。两位学长分别单独回忆了一版，6★学长回忆了 88 分完整题目（全部大题和部分客观题），w 学长发动了近 10 位 23 级学长学姐（包括 w 学长、y 学长、z 学长、y 学长、y 学长、j 学长、w 学姐、l 学姐、g 学姐）回忆出全部客观题和大题的提纲，最后由 6★学长综合两版回忆的题目整理排版，将完整的试卷给拼凑了出来，祝愿学弟学妹们考试顺利、成绩优异！另外，w 学长提醒：“此门课程依旧是没有 2020 年试卷流传，而且看似考前划了重点，但学长学姐们考后感觉考试形式相对‘奇哉怪也’，很多题虽然算不上难，但真的‘难评’。”

这份回忆版真题弥足珍贵，凝结了多位学长学姐的心血，请大家不要大肆传播，仅作为期末复习所用，谢谢！

一、选择题（2 分一道，共 20 分）

1. 下列哪种方法适合具有链接预测和拓扑结构的数据建模
A. Word2vec B. 图结构 C. 邻接矩阵 D. 词向量
2. 下列哪种方法无法捕捉长序列的信号
A. LSTM B. Word2vec C. RNN D. Transformer
3. 对神经网络的参数进行迭代估计时，需要用到
A. 偏导数 B. Hessian 矩阵 C. 二阶导 D. 一阶导
4. 某同学在训练神经网络模型时，发现在训练集和测试集上面的评估结果不一致，如何解决这种问题
A. B. C. 数据增强 D.
5. LDA 模型的先验分布是什么
A. 平均分布 B. 多维高斯分布 C. 多点分布 D. 狄利克雷分布
6. 在一个无向图中，有 5 个节点，则这个图最多有多少条边
A. 20 B. 10 C. 5 D. 15
7. 对 12×12 的图像进行卷积，若卷积核为 2×2 ，stride=2，则输出的特征图的维数为
A. 12×12 B. 10×10 C. 6×6 D. 2×2
8. 已知 RNN 的参数量，在此结构上进行优化成 LSTM，则参数量为原来的多少倍
A. 1 B. 2 C. 3 D. 4
9. 某语料库有 M 篇文档，其中文档共有 N 个词语，某个词语有 K 个，这个词语在 T 篇文档里面出现过，则这个词语的 TD-IDF 为
A. B. C. D. 正确的公式
10. 下列关于词袋模型说法正确的是
A. 词袋模型具有马尔可夫性
D. 词袋模型没有考虑词法和语序


二、判断题（1 分一道，共 10 分）

1. LDA 是一种无监督学习方法.
2. RGB 是由红绿蓝三原色组成的.
3. Word2vec 只能用于文章的 embedding.
4. 图像可以转化为结构化数据表示，所以图像是一种结构化数据.

5. 和 RNN 相比，LSTM 在处理长记忆问题上更加具有优势.
6. 在处理图片数据时，解码器将高维图像提取为低维特征，编码器将低维特征还原成原始图像.
7. 网络数据可以用图结构来建模.
8. 稀疏矩阵适合用邻接矩阵的方法进行表示.
9. 在神经网络训练时，使用均方误差和交叉熵误差没有区别.
10. SIFT 算法对原始图像寻找极值点来得到特征点.

三、计算题

1. (15 分) 下面是一个无向图结构，请你求解下列问题



- (1) 请你计算聚类系数和网络密度. (5 分)
- (2) 请你计算节点 B、C、D 的度中心性、介数中心性和接近中心性，并根据计算结果给节点 B、C、D 的重要性排序. (10 分)

2. (20 分) 现对一个图像进行卷积操作，已知一个该图像和卷积核 (3*3) 如下所示

0	0	1	1	1
1	0	0	1	1
0	0	1	1	1
0	1	1	1	1
1	1	1	1	0

0	-0.75	1
-0.75	1	-0.75
1	-0.75	0

- (1) 现对初始图像进行 padding 后，利用该卷积核对图像进行卷积运算，偏倚量为-0.25，最后利用 ReLU 函数作为激活函数，请你计算出卷积后的图像. (5 分)
- (2) 上述的卷积操作有什么作用，提炼了什么特征? (5 分)
- (3) 现在利用梯度下降法对卷积核与偏倚的超参数进行更新，已知偏倚的梯度为-0.2，卷积的梯度见下表所示：

-0.1	-0.3	0.2
------	------	-----

0.2	0.1	-0.1
-0.3	0.2	0.3

请你计算出更新后的卷积核和偏倚. (10 分)

3. (15 分) 请你回答下列问题

D1: “A car is (动名词), another is (动名词)” 共 9 个词

D2: “A dog is (动名词), and a car is (动名词)” 共 10 个词

D3: “Tom is playing basketball, with his friend.”


D4: “Tom is sleeping, and car is next to him”

(1) 请你求出 a, the, with, another, and 的 IDF. (5 分)

(2) 请你计算 4 篇文档每个词的 TF-IDF, 并说明每个文档的关键词. (10 分)

四、问答题

(10 分) 刘老师是某生物科学研究院的研究员, 她最近对稀有鸟类进行追踪调查, 共收集了 50 张三种稀有鸟类的照片。刘老师打算利用卷积网络对这三种稀有鸟类进行识别, 她将 50 张图片按照 4: 1 分成训练集和测试集进行训练, 在两个数据集上面的运行结果如下图所示



(1) 请你说明训练过程出现了什么现象? 有什么方法可以解决? (5 分)

(2) 刘老师决定利用预训练模型和迁移学习的方法改进她的模型, 现在她已经找到已经在 ImageNet 上面的预训练模型。请你说说刘老师利用预训练模型和迁移学习的过程. (5 分)

五、论述题

(10 分) 某电商平台收集了大量用户下单购买数据, 包括用户编号、商品编号、商品名称、商品金额、下单时间。现在该平台想构建一个推荐系统, 定时对用户

推荐三种商品。

(1) 上述数据可以用什么非结构化数据来表示. (5 分)

(2) 请你利用这种非结构化数据建模对用户进行推荐商品 (说明如何对非结构化数据进行处理、建模)